



Софийски университет „Св. Кл. Охридски”

Факултет по математика и информатика

Катедра „Софтуерни технологии”

ДИПЛОМНА РАБОТА

на тема

Разпознаване на семантични роли в новинарски статии

Дипломант: Борислав Мартинов Минчев

Факултетен номер: 5MI3400508

Специалност: Информатика

Магистърска програма: Извличане на информация и откриване на знания

Научен ръководител:

Проф. д-р Иван Койчев, катедра „Софтуерни технологии”,
ФМИ, СУ „Св. Климент Охридски”

Консултант:

докт. Димитър Димитров, катедра „Софтуерни технологии”,
ФМИ, СУ „Св. Климент Охридски”

София, 2026 г.

Анотация

Настоящата дипломна работа представя система за автоматична класификация на наративните роли на именувани обекти в многоезични новинарски текстове. Задачата е формулирана в рамките на SemEval-2025 Task 10, подзадача 1 (Entity Framing), и изисква определяне на основна роля (Protagonist, Antagonist, Innocent) и детайлни роли (22 етикета) за всяко споменаване на обект в дадена новинарска статия.

Предложената йерархична двустепенна система, базирана на XLM-RoBERTa-base, комбинира две последователни етапи на класификация за постигане на йерархични предсказания. Основните приноси включват: (1) осредняване по обхват на обекта за извличане на представяне, специфично за обекта; (2) класификация чрез семантично сходство с опорни вектори; (3) класово балансирана кръстосана ентропия за компенсиране на класовия дисбаланс; (4) меко йерархично обуславяне чрез обучаемата матрица на афинитет; (5) асиметрична загуба (ASL) с регуларизация на кардиналността за многоетикетната класификация; (6) адаптивно праговане.

Системата постига 82,70% F1 за основната роля и 52,62% E2E Fine F1 при 44,54% точно съвпадение (EMR) - подобрение от 14,11 процентни пункта спрямо базовия модел и конкурентен резултат спрямо системи, използващи значително по-големи езикови модели.

Съдържание

Анотация	1
1 Увод	4
1.1 Актуалност на проблема и мотивация	4
1.2 Цел и задачи на дипломната работа	4
1.3 Очаквани приноси	5
1.4 Структура на документа	6
2 Преглед на областта	7
2.1 Основни понятия	7
2.2 Обзор на съществуващи подходи и състезания	8
2.2.1 Йерархична класификация	9
2.2.2 Многоетикетна класификация	10
2.3 Многоезични предварително обучени модели	10
2.4 Функции на загубата за дисбалансиранни данни	11
2.4.1 Фокусирана загуба (Focal Loss)	11
2.4.2 Класово балансирана кръстосана ентропия (Class-Balanced Cross-Entropy)	12
2.4.3 Асиметрична загуба (Asymmetric Loss)	12
3 Описание на задачата и набора от данни	14
3.1 Същност и цели на задачата	14
3.2 Таксономия на ролите	14
3.3 Структура на данните и статистически анализ	15
3.3.1 Статистически анализ на разпределенията	15
3.4 Предобработка и аугментация на данните	21
3.4.1 Параграфна декомпозиция	21
3.4.2 Маркиране на обекта	21
3.4.3 Аугментация на обучителните данни	22
3.4.4 Разделяне на данните	22
3.4.5 Предизвикателства	22

4	Базови модели	24
4.1	Подготовка и предобработка на данните	24
4.1.1	Гранулярност на текста	24
4.1.2	Маркиране на обекта	24
4.1.3	Токенизация и разделяне на данните	25
4.2	Архитектура на модела	25
4.2.1	Предварително обучен модел и класификационна глава	25
4.2.2	Селективно замразяване и функция на загубата	25
4.2.3	Хиперпараметри	26
4.3	Резултати и анализ	26
4.3.1	Обучителен процес	26
4.3.2	Общи резултати	27
4.3.3	Анализ по класове	27
4.3.4	Анализ на грешките	28
4.3.5	Анализ по езици	29
4.3.6	Обобщение	29
4.4	Базов класификатор за фино ниво	29
4.4.1	Архитектура и обучение	30
4.4.2	Резултати	31
4.4.3	Слабости	31
5	Предложена система	33
5.1	Обща архитектура	33
5.2	Представяне на именуваната същност чрез осредняване по обхват (Entity Span Pooling)	34
5.3	Класификация чрез семантично сходство	35
5.3.1	Генериране на опорни представяния	35
5.3.2	Проекция и косинусово подобие	35
5.4	Класово балансирана кръстосана ентропия (CB-CE) за грубо ниво . . .	36
5.5	Класификатор на грубо ниво	36
5.6	Асиметрична загуба за фино ниво	37
5.6.1	Конфигурация на ASL	37
5.6.2	Ентропийна регуларизация (налична, но неактивна в E19) . . .	38
5.7	Меко йерархично обуславяне	38
5.7.1	Йерархичен афинитетен слой	38
5.7.2	Изчисляване на йерархичния приор	39
5.7.3	Комбиниране на логити и приор	39
5.8	Регуларизация на кардиналността	39
5.9	Адаптивно праговане	40

5.9.1	Алгоритъм	40
5.9.2	Обосновка	40
5.10	Класификатор на фино ниво	40
5.10.1	Проекционен MLP	41
5.10.2	Обща загуба	41
5.10.3	Хиперпараметри	42
5.11	Процедура на обучение	42
6	Експерименти и резултати	44
6.1	Експериментална настройка	44
6.1.1	Данни	44
6.1.2	Метрики	44
6.1.3	Хардуер	45
6.2	Резултати на класификатора за грубо ниво	45
6.2.1	Обучителен процес	45
6.2.2	Метрики при валидация	45
6.2.3	Матрица на объркване	46
6.3	Резултати на класификатора за фино ниво	46
6.3.1	Precision, Recall и калибрация на кардиналността	47
6.3.2	F1 по детайлни етикети	47
6.4	Крайна оценка (от край до край)	48
6.5	Сравнение с базовия модел	49
6.6	Сравнение със състезателни системи	49
6.7	Анализ по езици	50
6.8	Аблационно изследване	50
6.8.1	Аблация на класификационната глава	51
6.8.2	Аблация на функцията на загубата за грубо ниво	51
6.8.3	Аблация на функцията на загубата за фино ниво	52
6.8.4	Аблация на регуляризацията на кардиналността	52
6.8.5	Меко срещу твърдо обуславяне	52
6.9	Анализ на грешките	53
7	Заклучение	54
7.1	Обобщение на резултатите	54
7.2	Ограничения	55
7.3	Бъдещи насоки	55
	Използвана литература	57

Глава 1

Увод

1.1 Актуалност на проблема и мотивация

Разпространението на дезинформация и пропаганда в онлайн новинарски медии представлява едно от най-значимите предизвикателства на съвременното информационно общество. Автоматичното разпознаване на начина, по който именуваните обекти (лица, организации, държави) са представени в новинарските текстове — дали като protagonисти, антагонисти или невинни — е от ключово значение за медийния мониторинг, проверката на факти и анализа на наративни манипулации.

В контекста на споделената задача SemEval-2025 Task 10 [1] е предложена формална рамка за многоезична класификация на ролите на именувани обекти в новинарски текстове. Задачата обхваща пет езика (български, английски, хинди, португалски и руски), две тематични области (войната в Украйна и климатичните промени) и три подзадачи. Настоящата работа е посветена на **подзадача 1 (Entity Framing)**, която изисква за всяко споменаване на именуван обект в дадена статия да бъде определена една основна роля (грубо ниво) и една или повече детайлни роли (фино ниво) от предварително дефинирана таксономия с 22 етикета.

Задачата представлява значителен изследователски интерес поради съчетаването на множество предизвикателства: многоезичност (5 езика с различни писмени системи), йерархична структура на етикетите (3 основни и 22 детайлни роли), многоетикетна класификация (всяко споменаване може да има повече от една детайлна роля), изразен класов дисбаланс и силна контекстна зависимост на ролите.

1.2 Цел и задачи на дипломната работа

Целта на дипломната работа е проектирането и реализацията на пълна система за йерархична класификация на ролите на именувани обекти, която преодолява слабостите на базовите модели. Конкретните задачи са:

1. **Установяване на базови нива** за двете нива на класификация (грубо и фино) чрез фино настройване на XLM-RoBERTa-base със стандартни функции на загубата.
2. **Осредняване по обхват на обекта (Entity Span Pooling)** — реализация на механизъм за извличане на представяне, фокусирано върху конкретния обект, чрез специални маркерни токени и осредняване на скрити състояния.
3. **Семантично сходство** — замяна на стандартната линейна класификационна глава с подход, базиран на косинусово подобие спрямо опорни вектори, генерирани от имената на етикетите.
4. **Балансирани функции на загубата** — прилагане на класово балансирана кръстосана ентропия (CB-CE) за грубото ниво и асиметрична загуба (ASL) за многоетикетната класификация на фино ниво.
5. **Меко йерархично обуславяне** — реализация на обучаем механизъм за предаване на информация между нивата на класификация, който позволява несигурността да се разпространи.
6. **Регуларизация и адаптивно праговане** — ограничаване на броя предсказани етикети чрез регуларизация на кардиналността и адаптивна стратегия за праговане.
7. **Аблационен анализ** — систематично изследване на приноса на всеки компонент чрез серия от 20 експеримента.

1.3 Очаквани приноси

Основните приноси на дипломната работа са:

1. **Двустепенна каскадна система** за йерархична класификация с меко обуславяне, която постига конкурентни резултати спрямо системи, базирани на значително по-големи езикови модели.
2. **Систематичен аблационен анализ** на 20 експеримента, изследващ влиянието на класификационната глава, функцията на загубата, йерархичното обуславяне и регуларизацията на кардиналността.
3. **Демонстрация на ефективността на мекото обуславяне** спрямо твърдото маскиране: 44,54% EMR срещу 0,00%.

4. **Конкурентни резултати:** 82,70% претеглен F1 за основната роля и 52,62% E2E Fine F1, сравними с водещата система BERTastic (78,48% асигура за хинди / 51,57% Fine F1) при използване само на XLM-RoBERTa-base (сравнението е ориентирано поради различия в метриките и тестовите множества).

1.4 Структура на документа

Документът е организиран в седем глави. Глава 2 представя преглед на областта: основни понятия, съществуващи подходи, многоезични модели и функции на загубата. Глава 3 описва задачата и набора от данни, включително статистически анализ и предобработка. Глава 4 представя базовите модели за класификация на грубо и фино ниво. Глава 5 описва предложената напреднала система — ядрото на работата. Глава 6 представя експерименталните резултати и аблационния анализ. Глава 7 обобщава приносите, ограниченията и бъдещите насоки.

Глава 2

Преглед на областта

2.1 Основни понятия

Рамкиране на именувани обекти (Entity Framing) е задачата за автоматично определяне на наративната роля, която даден именуван обект изпълнява в текст — например дали дадено лице е представено като герой, злодей или жертва. Тази задача е тясно свързана с анализа на медийни рамки (media framing) и детекцията на пропаганда.

Многоетикетна класификация (Multi-label Classification) е вид класификация, при която всеки пример може едновременно да бъде свързан с няколко етикета от множество от класове. За разлика от многокласовата класификация (multi-class), където точно един етикет се присвоява на всеки пример, при многоетикетната класификация броят на присвоените етикети е променлив. В контекста на нашата задача един обект може да бъде едновременно *Instigator* и *Deceiver*.

Йерархична класификация (Hierarchical Classification) се отнася до задачи, при които етикетите са организирани в дървовидна таксономия. Предсказанията трябва да бъдат съобразени с тази йерархия — например, ако обект е класифициран като *Guardian*, той трябва да принадлежи и към родителската категория *Protagonist*.

Трансферно обучение (Transfer Learning) в обработката на естествен език е парадигма, при която модел първо се предварително обучава върху голям корпус от текст чрез задачи за самонаблюдение (self-supervised learning), а след това се фино настройва (fine-tuning) върху конкретна задача с по-малко данни. Този подход е в основата на съвременните езикови модели като BERT и XLM-RoBERTa.

Представяне на именувана същност чрез специални маркери е техника, при която в текста се вмъкват специални токени [ENTITY] и [/ENTITY] около споменаването на обекта. Моделът може след това да извлече представяне, специфично за обекта, чрез осредняване на скритите състояния между тези маркери (entity span pooling).

2.2 Обзор на съществуващи подходи и състезания

SemEval-2025 Task 10 [1] е споделена задача, организирана в рамките на 19-ия семинар по семантична евалуация (SemEval-2025). Задачата се състои от три подзадачи: (1) Entity Framing — класификация на ролята на именувани обекти; (2) Narrative Classification — присвояване на наративни етикети на ниво документ; (3) Narrative Extraction — генериране на текстово обяснение за доминиращия наратив. В състезанието са се регистрирали 310 екипа, от които 66 са подали официални резултати за всички подзадачи (35 за подзадача 1). Настоящата работа се фокусира изцяло върху подзадача 1.

Това е продължение на серията от споделени задачи за детекция на пропаганда, включително SemEval-2024 Task 4 [2] за многоезично разпознаване на техники за убеждаване в мемове.

Сред системите, постигнали най-добри резултати в подзадача 1 (Entity Framing), се открояват:

- **BERTastic** [3] — съчетава фино настроен XLM-RoBERTa с промптиране на GPT-4o. Постига 78,48% точност за основната роля и 51,57% F1 за детайлните роли. Постига най-висока точност за основната роля за хинди (вторична метрика).
- **DUTIR** [4] — използва рамка, комбинираща многоезичен превод с GLM-4-Plus, QLoRA фино настройване и ансамблова класификация. Постига първо място за английски, португалски и руски.
- **LTG** [5] — прилага евристики за избор на контекст около обекта в комбинация с XLM-RoBERTa. Постига конкурентни резултати спрямо по-големи генеративни модели.
- **GateNLP** [6] — предлага йерархично тристъпково промптиране за наративна класификация. Участва в подзадача 2 (Narrative Classification), постигайки водещи резултати за 3 от 5 езика (английски, руски, португалски).
- **Irapuarani** [7] — сравнява три стратегии, комбиниращи малки и големи езикови модели. Участва в подзадача 2; стратегията с превод на един език показва най-добра обобщаемост.
- **adithjrajeev** [8] — използва последователно обучение с резюмета, центрирани около обекта.

Таблица 2.1: Сравнение на водещи системи в SemEval-2025 Task 10, подзадача 1.

Система	Базов модел	Осн. роля (%)	Fine F1 (%)
BERTastic	XLM-R + GPT-4o	78,48	51,57
DUTIR	GLM-4-Plus + QLoRA	—	—
LTG	XLM-RoBERTa	—	—
Нашият (напреднал)	XLM-RoBERTa-base	82,70	52,62

Забележка: Стойностите на BERTastic (78,48%) представляват асигура за основната роля само за хинди от официалното тестово множество. Нашата стойност (82,70%) е претеглен F1 за 5 езика, оценен на валидационното множество на организаторите. GateNLP и Irapuarani не са включени в таблицата, тъй като участват в подзадача 2 (Narrative Classification).

Забележителна тенденция е, че подходите, базирани на големи езикови модели (LLM), доминират в общото класиране, но фино настроените по-малки модели (напр. XLM-RoBERTa) постигат конкурентни резултати при по-ниски изчислителни разходи.

2.2.1 Йерархична класификация

Йерархичната класификация на текст (Hierarchical Text Classification) е задача, при която етикетите са организирани в дървовидна таксономия с връзки „родител-дете“. За разлика от плоската класификация, при йерархичната предсказанията на различните нива трябва да бъдат *съвместими* — например, ако обект е класифициран с детайлна роля *Guardian*, той трябва да принадлежи и към родителската категория *Protagonist*.

В литературата се разграничават три основни подхода:

- **Плосък подход** (flat) — игнорира йерархията и обучава един класификатор за всички етикети. Прост за реализация, но не гарантира съвместимост между нивата.
- **Локален подход** (local per-level) — обучава отделен класификатор за всяко ниво на йерархията. Предсказанието на горното ниво се предава като вход или ограничение на следващото. Два варианта на предаване са *твърдо маскиране* (hard masking), при което недопустимите етикети се зануляват, и *меко обуславяне* (soft conditioning), при което вероятностите от горното ниво модулират предсказанията на долното.
- **Глобален подход** (global) — единен модел, отчитащ цялата йерархия чрез споделени представяния или рекурсивни механизми.

В настоящата работа се използва локален подход с два етапа: класификация на основната роля (грубо ниво), след което резултатът се предава на класификатора за детайлни роли (фино ниво). Този подход позволява всеки етап да бъде оптимизиран независимо, а йерархичните ограничения да бъдат наложени при прехода между нивата.

2.2.2 Многоетикетна класификация

При многоетикетната класификация (Multi-label Classification) за всеки пример може да бъде присвоено произволно подмножество от множеството от етикети. Това е по-обща задача от многокласовата класификация, при която точно един етикет се присвоява на всеки пример.

Метрики за оценка. Многоетикетната природа на задачата изисква специфични метрики. Основните метрики в SemEval-2025 Task 10 са:

- **Точно съвпадение (Exact Match Ratio, EMR)** — официалната метрика за класиране; измерва дела на примерите, за които предсказаният набор от етикети съвпада *точно* с верния.
- **Micro-F1** — агрегира истински положителните, фалшиво положителните и фалшиво отрицателните над всички етикети и примери.
- **Main Role Accuracy** — точност на класификацията на грубо ниво (3 класа).

Предизвикателство: дисбаланс на етикетите. При 22 възможни етикета и средна кардиналност от 1,1, съотношението положителни/отрицателни за повечето класове е под 1:20. Стандартната бинарна кръстосана ентропия (BCE) води до модел, който минимизира загубата, като предсказва „нищо“ за почти всички етикети. Това мотивира използването на специализирани функции на загубата: *асиметричната загуба* (Asymmetric Loss) намалява приноса на лесните отрицателни примери чрез асиметрично претегляне; *фокусираната загуба* (Focal Loss) адаптивно фокусира обучението върху трудно класифицируемите примери.

2.3 Многоезични предварително обучени модели

Архитектурата Transformer, предложена от Vaswani et al. [9], поставя основата на съвременната обработка на естествен език. Ключовата иновация е механизмът за самовнимание (self-attention), който позволява на модела да улавя зависимости между произволни позиции в поредицата с постоянна сложност.

BERT (Bidirectional Encoder Representations from Transformers) [10] адаптира кодиращата част на Transformer за предварително обучение чрез маскиране на езиков

модел (MLM) и предсказване на следващо изречение (NSP). Двупосочната архитектура позволява на модела да улавя контекст и от двете страни на всеки токен, което води до значителни подобрения в широк кръг задачи.

RoBERTa [11] оптимизира стратегията за предварително обучение на BERT: премахва NSP задачата, увеличава размера на партидата и обема на данните, и въвежда динамично маскиране. Авторите демонстрират, че BERT е бил значително недостатъчно обучен.

XLM-RoBERTa [12] разширява подхода на RoBERTa за 100 езика, като използва 2,5 TB данни от Common Crawl. Моделът постига значителни подобрения спрямо mBERT: +14,6% на XNLI, +13% F1 на MLQA и +2,4% F1 за NER. Той покрива всичките пет езика от задачата (български, английски, хинди, португалски, руски), което го прави естествен избор за нашата многоезична класификация.

В настоящата работа използваме `xlm-roberta-base` (278M параметъра, 12 Transformer слоя, скрита размерност 768).

2.4 Функции на загубата за дисбалансиранни данни

При задачи с изразен класов дисбаланс стандартната кръстосана ентропия третира всички класове равностойно, което води до модел, доминиран от мажоритарния клас. В тази секция разглеждаме три специализирани функции на загубата, използвани в настоящата работа.

2.4.1 Фокусирана загуба (Focal Loss)

Фокусираната загуба (Focal Loss) [13] е предложена от Lin et al. в контекста на детекция на обекти, където дисбалансът между фонови и обектни примери достига 1:1000. Идеята е да се намали приносът на лесно класифицируемите примери чрез модулиращ фактор:

$$\mathcal{L}_{\text{FL}} = -\alpha_t(1 - p_t)^\gamma \log(p_t) \quad (2.1)$$

където p_t е предсказаната вероятност за верния клас, $\gamma \geq 0$ е фокусиращ параметър, а α_t е балансиращо тегло за клас t . При $\gamma = 0$ фокусираната загуба се свежда до стандартна кръстосана ентропия. С нарастване на γ приносът на лесните примери (висок p_t) намалява експоненциално, което фокусира обучението върху трудните примери. В нашите експерименти използваме $\gamma = 2,0$.

2.4.2 Класово балансирана кръстосана ентропия (Class-Balanced Cross-Entropy)

Cui et al. [14] предлагат претегляне на загубата чрез *ефективния брой проби* (effective number of samples). Основната идея е, че при обучение с преизползване на данни (oversampling), маргиналната полза от всеки нов пример намалява. Ефективният брой за клас с n проби се дефинира като:

$$E_n = \frac{1 - \beta^n}{1 - \beta} \quad (2.2)$$

където $\beta \in [0, 1)$ е хиперпараметър. При $\beta \rightarrow 0$ всички класове получават еднакво тегло; при $\beta \rightarrow 1$ теглата са обратно пропорционални на честотата. Теглото за всеки клас i е:

$$w_i = \frac{1 - \beta}{1 - \beta^{n_i}} \quad (2.3)$$

а загубата:

$$\mathcal{L}_{\text{CB-CE}} = -\frac{w_y}{\bar{w}} \sum_{i=1}^C y_i \log(p_i) \quad (2.4)$$

където $\bar{w}$ е средното тегло за нормализация. В нашите експерименти използваме $\beta = 0,9999$.

2.4.3 Асиметрична загуба (Asymmetric Loss)

Ben-Baruch et al. [15] предлагат асиметричната загуба (Asymmetric Loss, ASL), специално проектирана за многоетикетна класификация с изразен дисбаланс. Ключовата идея е да се прилагат *различни* фокусиращи параметри за положителни и отрицателни примери:

$$\mathcal{L}_{\text{ASL}} = \begin{cases} (1 - p)^{\gamma^+} \log(p) & \text{ако } y = 1 \\ p_m^{\gamma^-} \log(1 - p_m) & \text{ако } y = 0 \end{cases} \quad (2.5)$$

където $p_m = \max(p - m, 0)$ е вероятността с приложен марж (margin) m за изместване на вероятността (probability shifting). Параметрите γ^+ и γ^- контролират фокусирането поотделно: типично $\gamma^- > \gamma^+$, което по-агресивно намалява приноса на лесните отрицателни примери.

В нашата система за финия класификатор използваме ASL с параметри $\gamma^+ = 0,0$, $\gamma^- = 2,0$ и марж $m = 0,05$. Изборът на $\gamma^+ = 0$ означава без фокусиране за положителните примери (всеки е информативен), а $\gamma^- = 2$ агресивно намалява приноса на лесните отрицателни. Системата разполага и с разширена версия (ASL-Opt), включваща ентропийна регуларизация ($\lambda_{\text{ent}} = 0,15$) и претегляне на класовете чрез ефек-

тивния брой проби, но при най-добрата конфигурация (E19) се използва основната ASL без тези разширения.

Глава 3

Описание на задачата и набора от данни

3.1 Същност и цели на задачата

Подзадача 1 (Entity Framing) от SemEval-2025 Task 10 се дефинира формално по следния начин: дадена е новинарска статия и списък от споменавания на именувани обекти в нея, всяко определено чрез идентификатор на документа, текстово споменаване и начална/крайна позиция. За всяко споменаване трябва да бъдат определени:

1. **Основна роля** (main role) — точно един от трите етикета: Protagonist, Antagonist, Innocent.
2. **Детайлни роли** (fine-grained roles) — една или повече от 22 етикета, организирани йерархично под трите основни роли.

Задачата е многоезична, като данните обхващат пет езика: български (BG), английски (EN), хинди (HI), португалски (PT) и руски (RU). Тематичните области са две: войната между Русия и Украйна (URW) и климатичните промени (CC).

Официалната метрика за класиране е **точно съвпадение (Exact Match Ratio, EMR)** за детайлните роли, допълнена от micro-F1 и точност на основната роля.

3.2 Таксономия на ролите

Таксономията се състои от три основни роли и 22 детайлни роли, разпределени неравномерно (таблица 3.1). Забелязва се силна асиметрия: категория Antagonist съдържа 12 детайлни роли — два пъти повече от Protagonist и три пъти повече от Innocent. Това отразява по-богатото разнообразие от негативни наративни рамки в новинарските текстове и създава допълнително предизвикателство за класификацията.

Таблица 3.1: Таксономия на ролите: 3 основни и 22 детайлни.

Основна роля	Детайлна роля	Описание (накратко)
Protagonist (6)	Guardian	Защитник, пазител
	Martyr	Мъченик за кауза
	Peacemaker	Миротворец
	Rebel	Бунтовник, борец за промяна
	Underdog	Аутсайдер в неравна борба
	Virtuous	Нравствен, етичен лидер
Antagonist (12)	Instigator	Подбудител на конфликт
	Conspirator	Участник в заговор
	Tyrant	Тиранин, деспот
	Foreign Adversary	Външен противник
	Traitor	Предател
	Spy	Шпионин
	Saboteur	Саботьор
	Corrupt	Корумпиран
	Incompetent	Некомпетентен
	Terrorist	Терорист
	Deceiver	Измамник
	Bigot	Фанатик, нетолерантен
Innocent (4)	Forgotten	Забравен от обществото
	Exploited	Експлоатиран
	Victim	Жертва
	Scapegoat	Изкупителна жертва


3.3 Структура на данните и статистически анализ

Данните са организирани в директории по език. За всеки език са предоставени: обучително множество с анотации (идентификатор, споменаване, позиция, основна роля, детайлни роли), валидационно множество без етикети и директория с оригиналните текстове на статиите. Всяка анотация съдържа идентификатор на документа, текстово споменаване на обект, начална и крайна позиция в текста, основна роля (една от трите) и набор от детайлни роли (подмножество от 22-те). При предобработката около споменаването на обекта се вмъкват маркери [ENTITY] и [/ENTITY].

3.3.1 Статистически анализ на разпределенията


Разпределението на трите основни роли по езици показва ясен дисбаланс: ролята Antagonist доминира във всички езици, следвана от Protagonist, докато Innocent е

най-рядко срещаната категория. Този дисбаланс е по-изразен за хинди и португалски.



Фигура 3.1: Разпределение на основните роли по езици.


Разпределението на броя детайлни етикети, присвоени на всяко споменаване на обект, показва, че повечето обекти имат 1–2 етикета, като средната кардиналност е приблизително 1,1 (по-точно 1,08 в тестовото множество и 1,11 в обучителното). Тази стойност е от значение за проектирането на системата — тя мотивира използването на регуларизация на кардиналността с целева стойност 1,5 (секция 5.8).




Фигура 3.2: Разпределение на броя детайлни етикети на обект.

Матриците на съвместно появяване на детайлните етикети (фигури 3.3–3.5) показват, че съвместно срещаните двойки са предимно в рамките на една и съща основна категория. При Protagonist (фигура 3.3) *Guardian* е най-честата роля (937 примера), като се комбинира най-често с *Virtuous* (116) и *Rebel* (61). При Antagonist (фигура 3.4) доминира *Foreign Adversary* (946), а най-честата двойка е *Instigator* + *Foreign Adversary* (64). При Innocent (фигура 3.5) категорията *Victim* е силно до-


минираща (1080), като често се комбинира с *Exploited* (41). Междукатегорийните комбинации са редки, което подкрепя валидността на йерархичния подход.



Фигура 3.3: Съвместно появяване на детайлните етикети в категория Protagonist.




Фигура 3.4: Съвместно появяване на детайлните етикети в категория Antagonist.




Фигура 3.5: Съвместно появяване на детайлните етикети в категория Innocent.

Анализът на консистентността на ролите за обекти, споменати повече от веднъж, показва, че от 559 обекта с множество споменавания само 22,7% (127 обекта) получават една и съща роля при всяко споменаване. Останалите обекти получават различни роли в различни контексти — например „Русия” се споменава в 315 случая с 30 различни комбинации от роли. Това подчертава силната контекстна зависимост на задачата.




Фигура 3.6: Анализ на консистентността на ролите: (а) разпределение на броя различни набори от роли за обекти с множество споменавания; (б) 15-те най-разнообразни обекти.

Разпределението на дължината на текстовете по езици показва значителна вариация — някои документи са много дълги и надхвърлят максималната дължина от 512 токена, използвана при токенизацията, което налага стратегии за отрязване (truncation).



Фигура 3.7: Разпределение на дължината на текстовете по езици.

Разпределението по тематични области за езиците, за които тази информация е налична, е показано по-долу. Трябва да се отбележи, че идентификаторите на документите за хинди и частично за португалски не съдържат маркери за домейн, поради което тези езици не са включени в диаграмата.



Фигура 3.8: Разпределение по тематични области за езиците с налична информация.

3.4 Предобработка и аугментация на данните

3.4.1 Параграфна декомпозиция

Оригиналните новинарски статии варират значително по дължина — от няколко изречения до над 2000 думи (виж фигура 3.7). Тъй като максималната дължина на входа при токенизация е 512 токена, подаването на цял документ би довело до загуба на контекст след отрязване. Затова текстовете са разделени на абзаци (параграфи), като за всяко споменаване на обект е избран единствено абзацът, в който се намира оригиналният *span*. Този подход:

- ограничава дължината на входа до по-управляеми размери;
- запазва непосредствения контекст около обекта, който е най-информативен за определяне на ролята;
- избягва шум от несвързани абзаци в дълги статии.

След разделяне на абзаци оригиналните позиции на споменаванията (*start/end offsets*) се преизчисляват спрямо началото на съответния абзац.

3.4.2 Маркиране на обекта

В напредналата система (за разлика от базовия модел) токените `[ENTITY]` и `[/ENTITY]` са добавени като *специални токени* в речника на токенизатора. Това означава, че:

- всеки маркер получава собствен идентификатор и не се разделя на подтокени;
- моделът може прецизно да определи границите на обекта;
- добавянето на нови токени изисква разширяване на вградения слой (embedding layer) на модела, което се извършва чрез инициализация от многомерно нормално разпределение, запазващо статистиките на оригиналните вграждания.

3.4.3 Аугментация на обучителните данни

За обогатяване на обучителното множество е приложена стратегия за аугментация, при която за всяко споменаване на обект се генерират допълнителни примери от различни абзаци на същата статия, съдържащи споменавания на същия обект. По този начин моделът получава разнообразни контекстуални представяния за всеки обект, което подобрява обобщаемостта.

3.4.4 Разделяне на данните

Организаторите предоставят обучително и валидационно множество, но не предоставят етикети за тестовото. Затова данните са разделени така:

- **Обучително множество:** 80% от оригиналното обучително множество (4 493 примера след аугментация), получено чрез стратифицирано разделяне, запазващо пропорциите на класовете.
- **Валидационно множество:** останалите 20% (1 124 примера), използвани за мониторинг на обучението и избор на най-добрата контролна точка.
- **Тестово множество:** оригиналното валидационно множество на организаторите (604 примера) — тъй като етикетите му са налични, то служи за крайна оценка.

3.4.5 Предизвикателства

Анализът на данните разкрива няколко ключови предизвикателства:

1. **Класов дисбаланс.** Ролята Antagonist е значително по-застъпена от останалите, а Innocent е много рядка. Това налага използването на балансирани функции на загубата — например Class-Balanced Cross-Entropy.
2. **Разреденост на многоетикетното пространство.** При 22 възможни етикета и средна кардиналност от 1,1, съотношението положителни/отрицателни за повечето класове е под 1:20. Стандартните функции на загубата (BCE) биха довели до модел, който предсказва „нищо“ за повечето етикети.

3. **Многоезичност.** Петте езика имат различни типологични характеристики и писмени системи (латиница, кирилица, деванагари), което изисква многоезичен предварително обучен модел.
4. **Йерархични ограничения.** Детайлните етикети трябва да бъдат съобразени с основната категория. Грешки на грубо ниво неизбежно водят до каскадно разпространение на грешките.
5. **Дълги документи.** Някои статии надхвърлят лимита от 512 токена, като обектът може да е споменат в различни части на текста.
6. **Контекстна зависимост.** Ролята на обекта зависи от контекста, в който е споменат — една и съща личност може да бъде представена като протагонист в една статия и като антагонист в друга.

Глава 4

Базови модели

В тази глава са представени два базови модела — по един за всяко ниво на класификация. Грубият базов модел (секции 4.3 и преди нея) класифицира основните роли (Protagonist, Antagonist, Innocent), а финият (секция 4.4) се справя с много-етикетната задача върху 22 детайлни роли. Целта е да се установят начални нива на производителност за двете нива, спрямо които ще бъдат оценявани по-сложните архитектури в глава 5. Съзнателно са избрани най-простите решения за всеки компонент на системата — стандартна класификационна глава, стандартни функции на загубата и минимална предобработка — за да се изолира приносът на самия предварително обучен модел от приноса на архитектурните надстройки.

4.1 Подготовка и предобработка на данните

4.1.1 Гранулярност на текста

Тъй като максималната дължина на входа при токенизация е 256 токена, подаването на цял документ би довело до загуба на контекст след отрязване. Затова текстовете са разделени на абзаци, като за всяко споменаване на обект е избран единствено абзацът, в който се намира оригиналният span.

4.1.2 Маркиране на обекта

Около споменаването на именувания обект в текста се вмъкват маркери [ENTITY] и [/ENTITY] чрез просто заместване на низ. За разлика от напредналата система (глава 5), тук маркерите се третират като обикновен текст и се разделят на подтокени от стандартния SentencePiece алгоритъм на XLM-RoBERTa. Този избор е съзнателен — целта на базовия модел е да използва минимални модификации.

4.1.3 Токенизация и разделяне на данните

Маркираният текст се токенизира чрез стандартния XLM-RoBERTa токенизатор с максимална дължина от 256 токена, отрязване и допълване до фиксирана дължина. Основните роли се кодират като цели числа: Protagonist – 0, Antagonist – 1, Innocent – 2. Данните са разделени на обучително (4 484 примера, без аугментация), валидационно (1 122 примера) и тестово (604 примера) множество.

4.2 Архитектура на модела

Базовият модел използва стандартната архитектура на AutoModelForSequenceClassification на HuggingFace с линейна класификационна глава върху представянето на [CLS] токена.

4.2.1 Предварително обучен модел и класификационна глава

Използваме `xlm-roberta-base` — многоезичен Transformer модел с 12 слоя, скрита размерност $d = 768$ и общо 278 милиона параметъра. Класификационната глава се състои от два линейни слоя с активационна функция $\tanh$ между тях:

$$\hat{\mathbf{y}} = \mathbf{W}_2 \tanh(\mathbf{W}_1 \mathbf{h}_{[\text{CLS}]} + \mathbf{b}_1) + \mathbf{b}_2 \quad (4.1)$$

където $\mathbf{h}_{[\text{CLS}]} \in \mathbb{R}^{768}$ е скритото състояние на токена [CLS] от последния Transformer слой, $\mathbf{W}_1 \in \mathbb{R}^{768 \times 768}$ и $\mathbf{W}_2 \in \mathbb{R}^{3 \times 768}$ са обучаеми матрици, а $\hat{\mathbf{y}} \in \mathbb{R}^3$ е изходният вектор от логити.

4.2.2 Селективно замразяване и функция на загубата

За да се ограничи пренастройването при малък обем данни, замразяваме всички параметри на модела с изключение на слой 11 (последният Transformer блок, $\approx 7,1\text{M}$ параметъра) и класификационната глава (напълно свързан слой 768×768 + изходна проекция, $\approx 593\text{K}$). Това дава общо 7,68M обучаеми параметъра от 278M (2,76%). Използваме стандартна кръстосана ентропия без претегляне:

$$\mathcal{L}_{\text{CE}} = - \sum_{i=1}^C y_i \log(p_i) \quad (4.2)$$

4.2.3 Хиперпараметри


Таблица 4.1: Хиперпараметри за обучение на базовия класификатор.

Параметър	Стойност
Базов модел	xlm-roberta-base (278М параметъра)
Обучаеми параметри	7,68М (2,76%)
Замразени слоеве	0–10 (11 от 12)
Макс. дължина	256 токена
Брой епохи	5
Размер на партидата	8
Скорост на обучение	2×10^{-5}
Функция на загубата	Кръстосана ентропия
Класификационна глава	Линейна ([CLS] $\rightarrow$ dense $\rightarrow$ output)
Оптимизатор	AdamW

4.3 Резултати и анализ

4.3.1 Обучителен процес

Кривите на обучителната и валидационната загуба показват устойчиво намаление от 1,1 до 0,7 в рамките на 5 епохи. Валидационната загуба конвергира след 3-тата епоха. Разликата между двете криви показва умерено пренастройване, но без значително разминаване.



Фигура 4.1: Криви на обучителната и валидационната загуба на базовия модел.

4.3.2 Общи резултати

Таблица 4.2: Общи резултати на базовия класификатор.


Метрика	Стойност
Точност (Accuracy)	68,87%
Претеглен F1	68,59%

Моделът класифицира правилно 416 от 604 примера.

4.3.3 Анализ по класове

Таблица 4.3: Метрики по класове на базовия модел.

Клас	Бр. примери	Предсказани	Precision	Recall	F1
Protagonist	191	201	0,667	0,702	0,684
Antagonist	266	311	0,659	0,771	0,711
Innocent	147	92	0,837	0,524	0,644




Фигура 4.2: Precision, Recall и F1 по класове за базовия модел.

Наблюдават се три различни профила на грешки: Antagonist показва висок Recall (77,1%) но нисък Precision (65,9%) поради отклонение към мажоритарния клас; Innocent показва обратния модел — висок Precision (83,7%) но нисък Recall (52,4%); Protagonist е балансиран, но с умерена производителност (F1=68,4%).

4.3.4 Анализ на грешките


Матрицата на объркване дава пълна картина на грешките.



Фигура 4.3: Матрица на объркване за базовия класификатор (604 примера).

Общият брой грешки е 188 от 604 примера (31,1%). Двете най-чести грешки са Protagonist→Antagonist и Innocent→Antagonist (по 53 грешки, по 28,2%), следвани от Antagonist→Protagonist (50, 26,6%). Тези грешки показват систематично *отклонение към мажоритарния клас* (majority class bias).

4.3.5 Анализ по езици



Фигура 4.4: Претеглен F1 по езици за базовия модел.

Наблюдават се значителни разлики: португалски постига най-висок резултат (WF1=84,5%), докато руски е най-слаб (WF1=60,4%). Особено показателна е пълната неспособност на модела да разпознава Innocent примери за BG и EN — 100% от тях са погрешно класифицирани.

4.3.6 Обобщение

Базовият модел постига 68,59% претеглен F1. Анализът разкрива три основни слабости, които мотивират напредналата система (глава 5):

1. **Отклонение към мажоритарния клас** — мотивира балансираните функции на загубата.
2. **Неразличаване на Innocent** — мотивира осредняване по обхват (ESP) и по-прецизно представяне на обекта.
3. **Контекстна зависимост по езици** — мотивира стратегии, отчитащи спецификата на домейна.

4.4 Базов класификатор за фино ниво

Като естествено допълнение на грубия базов модел проектираме и втори базов класификатор — за многоетикетната задача на детайлно ниво (22 етикета). Целта е да получим съпоставима отправна точка за фината задача, върху която по-късно да измерим приноса на иновациите в напредналата система.

4.4.1 Архитектура и обучение

Класификаторът използва същия гръбнак (XLM-RoBERTa-base) и същата стратегия на селективно замразяване — 7,69М обучаеми параметъра (2,77%). Промените спрямо грубия базов модел са минимални и са продиктувани изцяло от многоетикетния характер на задачата:

- **Изход:** 22 независими сигмоидни логита (по един за всеки етикет) вместо 3 softmax-логита.
- **Загуба:** бинарна кръстосана ентропия (BCE) с `pos_weight`, изчислен от обучителната честота на всеки етикет и срязан при стойност 10, за да не доминират най-редките класове.
- **Праг и резервен механизъм:** фиксиран праг 0,5 върху сигмоидните вероятности; ако за даден пример нито един етикет не премине прага, се използва `argmax` над логитите (резервен механизъм срещу празни предсказания).

Архитектурно класификаторът наследява стратегията на грубия модел (същото селективно замразяване, същата дължина на входа от 256 токена, `partition` по абзаци, AdamW). За самото обучение обаче използваме малко по-агресивен режим, мотивиран от по-голямата трудност на многоетикетната задача: 10 епохи (вместо 5) и скорост на обучение 3×10^{-5} (вместо 2×10^{-5}). Размерът на партидата остава 8. Селекцията на най-добрия модел се прави по Sample-F1 върху валидационното множество.

Това е *нестрого съответствие* с грубия базов модел — архитектурата е еднаква, режимът на обучение е леко адаптиран, а единствените функционални добавки (`pos_weight`, праг, `argmax fallback`) са допустими за основа и не въвеждат нито една от иновациите на напредналата система (без ASL, без focal loss, без меко обуславяне, без семантично сходство, без адаптивно праговане).

4.4.2 Резултати

Таблица 4.4: Общи резултати на базовия класификатор за фино ниво.

Метрика	Стойност
Sample-F1	38,86%
Micro-F1	35,64%
Macro-F1	22,41%
Точно съвпадение (EMR)	11,75%
Средна предсказана кардиналност	2,70
Средна истинска кардиналност	1,08

Йерархичният анализ показва, че когато грубата роля е предсказана правилно (418 от 604 в тази оценка¹), условният Fine F1 нараства до 48,56% — с близо 9,7 процентни пункта над безусловния Sample-F1. Това количествено потвърждава очаквания каскаден ефект: грешките на първия етап ограничават горната граница на втория.

4.4.3 Слабости

Анализът на per-label F1 и per-language F1 разкрива четири основни слабости:

1. **Колапс на редки етикети.** Седем от 22 етикета имат F1=0 в тестовото множество: *Martyr*, *Traitor*, *Spy*, *Saboteur*, *Bigot*, *Forgotten*, *Scapegoat*. Тези класове имат под 12 примера в теста и pos_weight (срязан при 10) не е достатъчен, за да ги направи научаеми с BCE.
2. **Свърхпредсказване на кардиналност.** Моделът предсказва средно 2,70 етикета на пример, докато истинската стойност е 1,08 — свърхпредсказване от около 2,5×. Фиксиран праг 0,5 без регуларизация не може да компенсира този ефект.
3. **Изразена per-language вариация.** Sample-F1 варира от 0,216 за английски до 0,661 за португалски — разлика от над 44 пункта. Това е значително по-силна вариация от тази при грубия модел.
4. **Каскадни грешки.** Безусловният Sample-F1 (38,86%) изостава с 9,7 пункта зад условния (48,56%), което означава, че значителна част от потенциала на фината класификация се губи поради грешки на грубо ниво.

¹Лекото разминаване с грубия базов класификатор от секция 4.3 (416 от 604) се дължи на отделни прогони на грубия класификатор с независими случайни инициализации.

Тези четири слабости мотивират четири от иновациите на напредналата система (глава 5): класификация чрез семантично сходство срещу колапса на редки етикети; регуларизация на кардиналността срещу свръхпредсказването; адаптивно праговане за по-балансирана селекция; и меко йерархично обуславяне за намаляване на каскадните грешки.

Пълно описание на процеса по проектиране, обосновката на всеки избор и подробни диаграми (per-label F1, per-language F1, разпределение на кардиналността) се намират в преддипломния проект.

Глава 5


Предложена система

В тази глава е описана предложената напреднала система за йерархична класификация на ролите на именувани обекти. Системата е двустепенна каскада — първият етап определя основната роля (3 класа), а вторият — детайлните роли (22 класа) чрез многоетикетна класификация с меко йерархично обуславяне. Всяка от иновациите спрямо базовите модели (глава 4) е мотивирана от конкретна слабост, идентифицирана в анализа на грешките.

5.1 Обща архитектура

Системата се състои от два последователно обучени класификатора, споделящи един и същ предварително обучен модел XLM-RoBERTa-base, но с различни класификационни глави и функции на загубата. Общият поток е:

1. **Вход:** текст с маркиран обект чрез специални токени [ENTITY] / [/ENTITY].
2. **Кодиране:** XLM-RoBERTa преобразува входа в последователност от скрити състояния.
3. **Осредняване по обхват (ESP):** извличане на представяне, специфично за обекта, чрез осредняване на скритите състояния между маркерите.
4. **Етап 1 (грубо ниво):** класификационна глава на базата на семантично сходство с 3 опорни вектора + класово балансирана кръстосана ентропия (CB-CE).
5. **Етап 2 (фино ниво):** проекционен MLP + йерархичен афинитетен слой, обучен с асиметрична загуба (ASL) и регуларизация на кардиналността.
6. **Предсказване:** адаптивно праговане за определяне на крайните етикети.



Фигура 5.1: Обща архитектура на предложената двустепенна система.

5.2 Представяне на именуваната същност чрез осредняване по обхват (Entity Span Pooling)

В базовия модел представянето на обекта се извлича от токена [CLS], който агрегира информация от целия вход, но не кодира експлицитно позицията на обекта. При абзаци с множество споменати лица моделът не може да разграничи кое лице е целевото.

За решаване на този проблем въвеждаме *осредняване по обхват на обекта* (entity span pooling, ESP). Подходът е инспириран от техниките за маркиране на обекти [16] и се състои от две стъпки:

Стъпка 1: Добавяне на специални токени. Токените [ENTITY] и [/ENTITY] се добавят в речника на токенизатора като специални символи. Вграденият слой (embedding layer) на модела се разширява, като новите вграждания се инициализират от многомерно нормално разпределение, запазващо средната стойност и ковариацията на оригиналните вграждания.

Стъпка 2: Осредняване на скритите състояния. След преминаване на текста през Transformer кодиращия блок, се извлича представяне на обекта чрез осредня-

ване на скритите състояния в обхвата между маркерите:

$$\mathbf{e} = \frac{1}{j-i} \sum_{k=i}^{j-1} \mathbf{h}_k \quad (5.1)$$

където $\mathbf{h}_k \in \mathbb{R}^{768}$ е скритото състояние на позиция k , а i и j са позициите на [ENTITY] и [/ENTITY] съответно. Ако маркерите не са намерени или обхватът е невалиден, системата автоматично се връща към представянето на [CLS] токена.

Предимствата на ESP са: (1) представянето е фокусирано именно на целевия обект, а не на целия контекст; (2) осредняването е устойчиво на вариации в дължината на споменаването; (3) специалните токени позволяват на модела да научи контекстуално зависими представяния на границите на обекта.

5.3 Класификация чрез семантично сходство

Вместо стандартна линейна класификационна глава, предлагаме подход, базиран на *семантично сходство* (Semantic Similarity Head). Идеята е концептуално свързана с прототипните мрежи [17]: за всеки клас се генерира опорно представяне (anchor embedding), и класификацията се извършва чрез сравняване на представянето на обекта с опорните вектори.

5.3.1 Генериране на опорни представяния

Опорните вектори се генерират чрез компонента `TaxonomyManager`, който:

1. зарежда имената на етикетите от таксономията (напр. „Protagonist”, „Guardian”, „Victim”);
2. подава всяко име през същия XLM-RoBERTa модел;
3. извлича представянето на [CLS] токена като опорен вектор с размерност $\mathbb{R}^{768}$.

За грубия класификатор се генерират 3 опорни вектора (по един за всяка основна роля), а за финия — 22. Опорните вектори се замразяват по време на обучение и не се актуализират чрез обратно разпространение.

5.3.2 Проекция и косинусово подобие

Представянето на обекта $\mathbf{e} \in \mathbb{R}^{768}$ се преобразува чрез проекционен слой. За грубия класификатор проекцията включва LayerNorm:

$$\mathbf{z} = \text{LayerNorm}(\mathbf{W}_p \mathbf{e} + \mathbf{b}_p) \quad (5.2)$$

където $\mathbf{W}_p \in \mathbb{R}^{768 \times 768}$. За финия класификатор се използва опростена проекция без LayerNorm: $\mathbf{z} = \mathbf{W}_p \mathbf{e} + \mathbf{b}_p$. След нормализация на проектираното представяне и опорните вектори по L_2 нормата, се изчислява косинусово подобие:

$$s_c = T \cdot \cos(\mathbf{z}, \mathbf{a}_c) = T \cdot \frac{\mathbf{z}^\top \mathbf{a}_c}{\|\mathbf{z}\| \cdot \|\mathbf{a}_c\|} \quad (5.3)$$

където $\mathbf{a}_c$ е опорният вектор за клас c , а $T = 15,0$ е температурен параметър [18], който скалира стойностите на подобие в подходящ диапазон за softmax функцията. Без температурно скалиране стойностите на косинусовото подобие (в интервала $[-1, 1]$) биха били твърде малки за ефективно обучение чрез кръстосана ентропия.

Резултатът е вектор от логити $\mathbf{s} \in \mathbb{R}^C$ ($C = 3$ за грубо ниво), който се подава на softmax за получаване на вероятности.

5.4 Класово балансирана кръстосана ентропия (CB-CE) за грубо ниво

Анализът на базовия модел (секция 4.3) показва систематично отклонение към Antagonist (+45 излишни предсказания). За преодоляване на този проблем, в класификатора на грубо ниво заменяме стандартната кръстосана ентропия с класово балансирана кръстосана ентропия (Class-Balanced Cross-Entropy, CB-CE) [14], описана в секция 2.4. Теглата се изчисляват на базата на ефективния брой проби с $\beta = 0,9999$.

Аблационното изследване (секция 6.8.2) демонстрира, че CB-CE води до подобрене от 4,65 процентни пункта в претеглен F1 на грубото ниво спрямо стандартна кръстосана ентропия (82,70% срещу 78,05%) и 3,48 процентни пункта в точно съвпадение (44,54% срещу 41,06%).

5.5 Класификатор на грубо ниво

Пълната архитектура на класификатора за грубо ниво е:

1. **Кодиращ блок:** XLM-RoBERTa-base с 6 размразени Transformer слоя (слоеве 6–11). Слоеве 0–5 са замразени за запазване на общите лингвистични представления.
2. **Entity span pooling:** осредняване на скритите състояния между маркерите (уравнение 5.1).
3. **Класификационна глава:** семантично сходство с 3 опорни вектора и $T = 15,0$ (уравнение 5.3).

4. Функция на загубата: Class-Balanced Cross-Entropy с $\beta = 0,9999$.

Таблица 5.1: Хиперпараметри за обучение на класификатора за грубо ниво.

Параметър	Стойност
Базов модел	xlm-roberta-base (278М параметъра)
Размразени Transformer слоеве	6 (слоеве 6–11 от 12)
Макс. дължина на поредицата	512 токена
Класификационна глава	Семантично сходство
Функция на загубата	CB-CE ($\beta = 0,9999$)
Брой епохи	10
Размер на партидата	9
Скорост на обучение	6×10^{-5}
Разгриване	10% от стъпките
Тегловно затихване	0,0
Отпадане (Dropout)	0,0
Оптимизатор	AdamW [19]

5.6 Асиметрична загуба за фино ниво

За многоетикетната класификация на фино ниво стандартната BCE е неподходяща поради екстремния дисбаланс (средна кардиналност $\sim 1,1$ при 22 етикета, т.е. съотношение $\sim 1:20$ за всеки етикет). Използваме асиметричната загуба (Asymmetric Loss, секция 2.4), допълнена с регуляризиращ механизъм за кардиналността.

5.6.1 Конфигурация на ASL

Параметрите на ASL са: $\gamma^+ = 0,0$ (без фокусиране за положителни примери), $\gamma^- = 2,0$ (агресивно намаляване на лесните отрицателни) и марж за отрязване $m = 0,05$. Изборът на $\gamma^+ = 0$ се обосновава с наблюдението, че положителните примери са малко и всеки от тях е информативен — фокусирането би допълнително намалило и без това малкия им принос.

5.6.2 Ентропийна регуларизация (налична, но неактивна в E19)

Системата разполага с допълнителен ентропиен регуларизиращ член за предотвратяване на прекомерно неуверени предсказания:

$$\mathcal{L}_{\text{ent}} = -\frac{1}{N \cdot L} \sum_{n=1}^N \sum_{l=1}^L [p_{nl} \log p_{nl} + (1 - p_{nl}) \log(1 - p_{nl})] \quad (5.4)$$

където $p_{nl} = \sigma(z_{nl})$ е сигмоидната вероятност за етикет l на пример n . Тази регуларизация наказва неуверени предсказания (вероятности, близки до 0,5), като насърчава модела да прави по-категорични решения за всеки етикет. Теглото е $\lambda_{\text{ent}} = 0,15$. При най-добрата конфигурация (E19) този член не е активиран, но е изследван в аблационния анализ.

5.7 Меко йерархично обуславяне

Ключов компонент на системата е механизмът за предаване на информация от грубото към финото ниво. Разглеждаме два подхода:

Твърдо маскиране (hard masking) занулява логитите на детайлни роли, несъвместими с предсказаната основна роля. Например, ако обект е класифициран като Protagonist, логитите за всички Antagonist и Innocent подроли се установяват на $-\infty$. Проблемът е, че грешка на грубо ниво неизбежно елиминира верния отговор на фино ниво.

Меко обуславяне (soft conditioning) [20] използва вероятностите от грубия класификатор като *мек приор* за финия, позволявайки несигурността да се разпространи. Нашата реализация включва обучаем *йерархичен афинитетен слой*.

5.7.1 Йерархичен афинитетен слой

Слоят параметризира обучаемата матрица $\mathbf{A} \in \mathbb{R}^{3 \times 22}$, инициализирана от таксономията:

$$A_{ij} = \begin{cases} +2,0 & \text{ако детайлна роля } j \text{ принадлежи на основна роля } i \\ -2,0 & \text{в противен случай} \end{cases} \quad (5.5)$$

Тази инициализация кодира структурата на таксономията, но е обучаемата — по време на обучение моделът може да модифицира афинитетите, за да улови по-фини зависимости.

5.7.2 Изчисляване на йерархичния приор

За вероятностен вектор $\mathbf{p}_{\text{coarse}} \in \mathbb{R}^3$ от грубия класификатор, йерархичният приор се изчислява като:

$$\mathbf{h}_{\text{prior}} = \mathbf{p}_{\text{coarse}} \cdot \mathbf{A} \quad (5.6)$$

Резултатът $\mathbf{h}_{\text{prior}} \in \mathbb{R}^{22}$ е вектор от стойности, които представляват степента на съвместимост на всяка детайлна роля с предсказаната основна категория.

5.7.3 Комбиниране на логити и приор

Финалните логити за финия класификатор се получават чрез събиране:

$$\mathbf{z}_{\text{fine}} = f(\mathbf{e}) + \mathbf{h}_{\text{prior}} \quad (5.7)$$

където $f(\mathbf{e})$ е изходът на проекционния MLP (описан в секция 5.10), а $\mathbf{h}_{\text{prior}}$ е йерархичният приор. Адитивното комбиниране позволява на проекционния MLP да надвие приора при достатъчно силни доказателства в данните.

Аблационното изследване (секция 6.8.5) показва, че мекото обуславяне води до значително подобрение спрямо твърдото маскиране: EMR от 44,54% срещу 0,00%.

5.8 Регуларизация на кардиналността

Анализът на данните (фигура 3.2) показва, че средният брой детайлни етикети на обект е приблизително 1,1. В нашите експерименти обаче използваме целева стойност $k = 1,5$ като мек регуляризатор — стойност, поставена малко над емпиричната средна стойност, се оказа полезна емпирично, защото ASL има тенденция да подценява положителните класове, а леко по-висок регуляризационен таргет компенсира това отклонение. За да ориентираме модела към реалистичен брой предсказания, въвеждаме квадратична регуларизация на кардиналността:

$$\mathcal{L}_{\text{card}} = \lambda_{\text{card}} \cdot \frac{1}{N} \sum_{n=1}^N \left(\sum_{l=1}^L \sigma(z_{nl}) - k \right)^2 \quad (5.8)$$

където $\sigma(z_{nl})$ е сигмоидната вероятност за етикет l на пример n , $k = 1,5$ е целевата кардиналност, а $\lambda_{\text{card}} = 0,3$ е теглото на регуларизацията.

Тази регуларизация действа като мек ограничител: тя не забранява повече или по-малко етикети, а наказва отклонения от целевата стойност квадратично. При $\lambda_{\text{card}} = 0$ (без регуларизация) моделът показва тенденция към предсказване на повече етикети, което намалява прецизността (секция 6.8.4).

5.9 Адаптивно праговане

При многоетикетна класификация стандартният подход е да се прилага фиксиран праг τ (напр. $\tau = 0,5$) на сигмоидните вероятности. Ние предлагаме *адаптивна стратегия*, при която ефективният праг зависи от увереността на модела за конкретния пример.

5.9.1 Алгоритъм

За всеки пример с вероятностен вектор $\mathbf{p} = \sigma(\mathbf{z}_{\text{fine}}) \in [0, 1]^{22}$:

1. Определяме максималната вероятност: $p_{\max} = \max_l p_l$.
2. Изчисляваме адаптивен праг: $\tau_{\text{gap}} = r \cdot p_{\max}$, където $r = 0,7$ е коефициент на разлика (gap ratio).
3. Ефективният праг е: $\tau_{\text{eff}} = \max(\tau, \tau_{\text{gap}})$, където $\tau = 0,25$ е минимален абсолютен праг.
4. Избираме етикетите с $p_l \geq \tau_{\text{eff}}$, при ограничения: минимум 1 и максимум 3 етикета.

5.9.2 Обосновка

Адаптивното праговане решава два проблема:

- **При уверен модел** ($p_{\max} = 0,9$): $\tau_{\text{gap}} = 0,7 \cdot 0,9 = 0,63$, $\tau_{\text{eff}} = 0,63$. Само етикети с висока вероятност се приемат, което увеличава прецизността.
- **При неуверен модел** ($p_{\max} = 0,3$): $\tau_{\text{gap}} = 0,7 \cdot 0,3 = 0,21$, $\tau_{\text{eff}} = 0,25$ (долна граница). Поне един етикет е гарантиран чрез ограничението за минимален брой.

Ограничението за максимум 3 етикета е мотивирано от анализа на данните — 99,5% от примерите имат 3 или по-малко детайлни роли.

5.10 Класификатор на фино ниво

Класификаторът за фино ниво обединява всички описани компоненти.

5.10.1 Проекционен MLP

Представянето на обекта от ESP (уравнение 5.1) се преобразува чрез двуслоен MLP:

$$f(\mathbf{e}) = \mathbf{W}_2 \cdot \text{GELU}(\text{LayerNorm}(\mathbf{W}_1 \mathbf{e} + \mathbf{b}_1)) + \mathbf{b}_2 \quad (5.9)$$

където $\mathbf{W}_1 \in \mathbb{R}^{768 \times 768}$, $\mathbf{W}_2 \in \mathbb{R}^{22 \times 768}$, с Dropout (0,1) между GELU и втория линеен слой. Изходът е вектор от 22 логита, по един за всяка детайлна роля.

5.10.2 Обща загуба

Крайната функция на загубата за финия класификатор при конфигурацията E19 е сума от два компонента:

$$\mathcal{L}_{\text{fine}} = \mathcal{L}_{\text{ASL}} + \lambda_{\text{card}} \mathcal{L}_{\text{card}} \quad (5.10)$$

с $\lambda_{\text{card}} = 0,3$.

Системата поддържа и допълнителен ентропиен регуляризиращ член $\lambda_{\text{ent}} \mathcal{L}_{\text{ent}}$ (секция 5.6), който не е активиран при най-добрата конфигурация (E19), но е изследван в аблационния анализ.

5.10.3 Хиперпараметри

Таблица 5.2: Хиперпараметри за обучение на класификатора за фино ниво.

Параметър	Стойност
Базов модел	xlm-roberta-base (278M параметъра)
Размразени Transformer слоеве	6 (слоеве 6–11 от 12)
Макс. дължина на поредицата	512 токена
Проекционен MLP	$768 \rightarrow 768 \rightarrow 22$ (с LayerNorm, GELU, Dropout 0,1)
Йерархично обуславяне	Меко (обучаема матрица 3×22)
Брой епохи	10
Размер на партидата	6
Скорост на обучение	8×10^{-5}
Разгриване	50 стъпки
Оптимизатор	AdamW [19]
Загуба	ASL ($\gamma^+ = 0,0$, $\gamma^- = 2,0$, $m = 0,05$)
Ентропийна регуларизация	не (налична, но неактивна в E19)
Регуларизация на кардиналност	$\lambda_{\text{card}} = 0,3$, цел $k = 1,5$
Адаптивно праговане	$\tau = 0,25$, $r = 0,7$, мин. 1, макс. 3

5.11 Процедура на обучение

Обучението на двата класификатора се извършва *последователно* (каскадно), а не съвместно:

- Обучение на грубия класификатор.** Моделът се обучава за 10 епохи върху обучителното множество. Най-добрата контролна точка се избира по претеглен F1 на валидационното множество.
- Генериране на предсказания за грубо ниво.** Най-добрият грубо-нивен модел се използва за генериране на предсказания (и вероятности) за обучителното, валидационното и тестовото множество.
- Обучение на финия класификатор.** Моделът получава като допълнителен вход вероятностния вектор от грубия класификатор ($\mathbf{p}_{\text{coarse}} \in \mathbb{R}^3$). По време на обучение се използват предсказаните вероятности (а не верните етикети), за да симулират реалния шум при извеждане.

4. **Извеждане (inference).** За всеки тестов пример: грубият класификатор дава $\mathbf{p}_{\text{coarse}}$, която се подава на финия класификатор чрез мекото обуславяне, и адаптивното праговане определя крайните етикети.

Обучението на всеки класификатор отнема приблизително 15–20 минути на NVIDIA GPU. Общото системно решение изисква ~ 45 минути за пълен цикъл (обучение + извеждане).

Глава 6

Експерименти и резултати

В тази глава представяме експерименталната оценка на предложената система. Провеждаме 20 експеримента за систематично изследване на всеки компонент чрез аблационен анализ.

6.1 Експериментална настройка

6.1.1 Данни

Разпределението на данните е: обучително множество — 4 493 примера (след аугментация), валидационно — 1 124 примера, тестово — 604 примера. Тестовото множество е оригиналното валидационно множество на организаторите на SemEval-2025 Task 10 (секция 3.4).

6.1.2 Метрики

Използваме четири основни метрики за оценка:

- **Coarse Test F1** — претеглен F1 на класификатора за грубо ниво (3 класа).
- **Fine Test μ F1** — Micro-F1 на класификатора за фино ниво при подадени *верни* основни етикети (оценка с перфектен вход).
- **E2E Fine F1** — Sample-F1 за детайлните роли в крайната система (от край до край), при подадени предсказани основни етикети.
- **Точно съвпадение (Exact Match Ratio, EMR)** — процент на примери, за които предсказаният набор от етикети съвпада *точно* с верния. Това е официалната метрика за класиране в SemEval.

6.1.3 Хардуер


Обучението е проведено на NVIDIA GPU с CUDA. Използвана е рамката HuggingFace Transformers [21] v4.x с PyTorch. Общото време за обучение на двата класификатора е приблизително 45 минути.

6.2 Резултати на класификатора за грубо ниво

Класификаторът за грубо ниво (секция 5.5) постига **82,70% претеглен F1** на тестовото множество — подобрение от 14,11 процентни пункта спрямо базовия модел (68,59%).

6.2.1 Обучителен процес


Кривите на загубата при обучение показват, че загубата на грубия класификатор намалява от 0,96 до 0,78, а тази на финия — от 0,14 до 0,01.



Фигура 6.1: Криви на загубата при обучение на грубия и финия класификатор.

6.2.2 Метрики при валидация


Еволюцията на метриките по епохи показва, че грубият класификатор конвергира около 8-мата епоха (Ассигасу и F1 $\sim 0,82$), а финият показва стабилно Micro-F1 $> 0,93$ от първата епоха.



Фигура 6.2: Метрики при валидация по епохи за двата класификатора.

6.2.3 Матрица на объркване

Спрямо базовия модел, системата значително подобрява разпознаването на Innocent (76,2% Recall срещу 52,4%) и намалява фалшивите Antagonist предсказания.




Фигура 6.3: Матрица на объркване за напредналия класификатор за грубо ниво (604 примера).

6.3 Резултати на класификатора за фино ниво

При подадени *верни* основни етикети (оценка с перфектен вход), финият класификатор постига **94,18% Micro-F1** и **70,19% Macro-F1** на тестовото множество.

6.3.1 Precision, Recall и калибрация на кардиналността


Средният брой предсказани етикети по епохи конвергира от 1,0 към 1,5, което съвпада с целевата кардиналност.



Фигура 6.4: Precision, Recall, F1 и среден брой предсказания по епохи за финия класификатор.

6.3.2 F1 по детайлни етикети

Наблюдава се съществена вариация в E2E F1 по детайлни етикети — етикетите с повече примери (Victim: 0,82, Peacemaker: 0,68, Foreign Adversary: 0,59) се класифицират значително по-добре от редките (Traitor: 0,00, Forgotten: 0,00, Saboteur: 0,09).



Фигура 6.5: E2E F1 по детайлни етикети (тестово множество).

6.4 Крайна оценка (от край до край)

Крайната оценка комбинира предсказанията на двата класификатора.

Таблица 6.1: Крайни резултати на предложената система (E19).

Метрика	Стойност
Coarse Test WF1	82,70%
Fine Test μ F1 (перф. вход)	94,18%
E2E Fine F1	52,62%
Точно съвпадение (EMR)	44,54%
Средно предсказани етикети/пример	1,17
Средно верни етикети/пример	1,08

6.5 Сравнение с базовия модел

Стойностите на базовия модел в таблица 6.2 идват от два независими класификатора — грубия (секция 4.3) и фино-ориентирания (секция 4.4). Сравнението показва, че всяка ключова метрика се подобрява значително от предложената система.

Таблица 6.2: Сравнение: базов модел (глава 4) срещу предложена система (E19).

Метрика	Базов модел	Предложена система
Coarse WF1	68,59%	82,70%
Осредняване по обхват (ESP)	Не (CLS)	Да
Класификационна глава	Линейна	Семантично сходство
Функция на загубата (грубо)	CE	CB-CE
Функция на загубата (фино)	BCE + pos_weight	ASL
Йерархично обуславяне	Не	Меко
Фин класификатор	Да (независим)	Да (каскаден)
Fine Sample-F1 (E2E)	38,86%	52,62%
Exact Match (EMR)	11,75%	44,54%
Размразени слоеве	1	6
Макс. дължина	256	512

6.6 Сравнение със състезателни системи

Таблица 6.3: Сравнение с водещи системи от SemEval-2025 Task 10.


Система	Базов модел	Осн. роля (%)	Fine F1 (%)
BERTastic [3]	XLM-R + GPT-4o	78,48	51,57
DUTIR [4]	GLM-4-Plus + QLoRA	—	—
LTG [5]	XLM-RoBERTa	—	—
Предложена система (E19)	XLM-RoBERTa-base	82,70	52,62

Забележка: Стойностите на BERTastic представляват асигура за хинди от официалното тестово множество. Нашата система е оценена с претеглен F1 за 5 езика на валидационното множество. Директното сравнение е ориентировъчно поради различията в метриките и данните.

Нашата система, базирана изцяло на XLM-RoBERTa-base (278M параметъра), постига конкурентни резултати спрямо BERTastic, който използва допълнително

промптиране на GPT-4o. Това демонстрира, че внимателно проектирана архитектура с балансирани загуби и йерархично обуславяне може да конкурира значително по-големи модели.

6.7 Анализ по езици



Фигура 6.6: Претеглен F1 по езици за напредналия класификатор за грубо ниво.

Подобрението спрямо базовия модел е видимо за всички езици. По-конкретно, точността за Innocent е значително подобрена — от $F1=0,000$ за BG и EN в базовия модел до стойности над 0,7 в напредналата система, благодарение на CB-CE и ESP.

6.8 Аблационно изследване

Проведени са 20 експеримента за систематично изследване на приноса на всеки компонент. По-долу представяме основните аблационни резултати.

6.8.1 Аблация на класификационната глава

Таблица 6.4: Аблация на типа класификационна глава.

Грубо ниво	Фино ниво	Coarse F1 (%)	E2E Fine F1 (%)	EMR (%)
Semantic	Semantic	79,61	50,66	37,09
MLP	Semantic	80,74	32,34	29,30
Semantic	MLP	79,12	49,90	38,74
MLP	MLP	80,74	35,29	31,29

Резултатите разкриват важна асиметрия: MLP главата постига по-висок Coarse F1 (80,74% срещу 79,61%), но семантичната глава води до значително по-висок E2E Fine F1 (50,66% срещу 32,34%). Причината е, че семантичната глава генерира по-калибрирани вероятности, които се предават по-ефективно на финия класификатор чрез мекото обуславяне.

6.8.2 Аблация на функцията на загубата за грубо ниво

Таблица 6.5: Аблация на функцията на загубата за грубо ниво.

Загуба	Coarse F1 (%)	E2E Fine F1 (%)	EMR (%)
Focal Loss	79,61	50,66	37,09
Cross-Entropy	78,05	50,29	41,06
Weighted CE	81,19	50,44	41,06
CB-CE	82,70	52,62	44,54

CB-CE дава най-добри резултати по всички три метрики. Подобрението спрямо стандартна CE е 4,65 пункта в Coarse F1 и 3,48 пункта в EMR. Фокусираната загуба, макар и широко използвана за дисбалансиранни данни, отстъпва на CB-CE, вероятно защото фокусиращият параметър γ е по-труден за настройка при многокласова класификация с 3 класа.

6.8.3 Аблация на функцията на загубата за фино ниво

Таблица 6.6: Аблация на функцията на загубата за фино ниво.

Загуба	Параметри	Fine μ F1 (%)	E2E F1 (%)	EMR (%)
Focal	$\gamma = 2,0$	95,12	28,56	22,19
ASL	$\gamma^- = 2,0, \gamma^+ = 1,0$	93,78	51,63	42,38
ASL	$\gamma^- = 2,0, \gamma^+ = 0,0$	92,50	50,66	37,09
ASL	$\gamma^- = 4,0, \gamma^+ = 1,0$	92,46	32,36	25,99

Показателно е, че фокусираната загуба постига най-висок Fine μ F1 (95,12%) при оценка с перфектен вход, но най-нисък E2E F1 (28,56%). Това показва, че високата точност при подадени верни етикети не гарантира добра крайна производителност — моделът с фокусирана загуба предсказва твърде много етикети, което намалява прецизността. ASL с умерени параметри показва най-добрия баланс.

6.8.4 Аблация на регуляризацията на кардиналността

Таблица 6.7: Аблация на регуляризацията на кардиналността.

λ_{card}	Fine μ F1 (%)	E2E F1 (%)	EMR (%)
0,0 (без)	94,92	25,97	22,35
0,3	92,50	50,66	37,09
0,5	92,69	53,33	40,73

Без регуляризация ($\lambda_{\text{card}} = 0$) моделът предсказва значително повече етикети от реалното, което води до значително по-нисък E2E F1 (25,97%). Регуляризацията с $\lambda_{\text{card}} = 0,3$ удвоява E2E F1, а $\lambda_{\text{card}} = 0,5$ дава най-висок E2E F1, но по-нисък EMR. Стойността $\lambda_{\text{card}} = 0,3$ е избрана като компромис.

6.8.5 Меко срещу твърдо обуславяне

Таблица 6.8: Меко срещу твърдо йерархично обуславяне.

Обуславяне	Fine μ F1 (%)	E2E F1 (%)	EMR (%)
Меко (E19)	94,18	52,62	44,54
Твърдо (E20)	67,86	31,13	0,00

Твърдото маскиране води до незадоволителни резултати: $EMR = 0,00\%$, което означава, че *ниито един* пример не получава точно правилния набор от етикети. Причината е, че при 17,3% грешки на грубо ниво, твърдото маскиране неминуемо елиминира верните детайлни етикети за всяка грешка. Мекото обуславяне позволява на финия класификатор да компенсира частично грешките от грубо ниво.

6.9 Анализ на грешките

За по-задълбочено разбиране на грешките, класифицираме тестовите примери в четири категории:

1. **coarse_wrong** (17,3%) — основната роля е грешна. Това автоматично влияе и на детайлните роли, особено при твърдо маскиране.
2. **fine_missing** ($\sim 20\%$) — основната роля е вярна, но един или повече верни детайлни етикети са пропуснати.
3. **fine_extra** ($\sim 10\%$) — основната роля е вярна, но са добавени излишни детайлни етикети.
4. **perfect** (44,54%) — предсказаният набор от етикети съвпада точно с верния (EMR).

Основният източник на грешки е каскадното разпространение от грубо към фино ниво. При 82,70% точност на грубо ниво, 17,3% от примерите тръгват с грешен контекст. Мекото обуславяне смекчава този ефект, но не може напълно да го елиминира — подобрението на грубия класификатор остава най-важният фактор за крайната производителност.

Глава 7

Заклучение

7.1 Обобщение на резултатите

В настоящата дипломна работа беше разработена и оценена пълна система за йерархична класификация на ролите на именувани обекти в многоезични новинарски текстове. Системата е двустепенна каскада, базирана на XLM-RoBERTa-base, и включва:

- **Осредняване по обхват на обекта (Entity Span Pooling)** за извличане на представяне, фокусирано върху конкретния обект.
- **Класификация чрез семантично сходство** с опорни вектори, генерирани от имената на етикетите.
- **Класово балансирана кръстосана ентропия (CB-CE)** за компенсиране на класовия дисбаланс на грубо ниво.
- **Асиметрична загуба (ASL)** с регуларизация на кардиналността за многоетикетната класификация на фино ниво.
- **Меко йерархично обуславяне** чрез обучаемата матрица на афинитет (3×22).
- **Регуларизация на кардиналността** с целева стойност 1,5.
- **Адаптивно праговане** с динамичен ефективен праг.

Системата постига **82,70% претеглен F1** за основната роля (подобрене от 14,11 п.п. спрямо базовия модел) и **52,62% E2E Fine F1** при **44,54% точно съвпадение (EMR)**. Спрямо базовия класификатор за фино ниво (38,86% Sample-F1, 11,75% EMR) подобрието е още по-изразено: +13,76 процентни пункта в Sample-F1 и +32,79 процентни пункта в EMR (E2E Fine F1 на напредналата система е изчислен със същата формула като Sample-F1, така че двете стойности са пряко съпоставими).

Тези резултати са конкурентни спрямо водещата система BERTastic (78,48% accuracy за хинди / 51,57% Fine F1), която използва допълнително промптиране на GPT-4o, при отчитане на различията в метриките и тестовите множества.

Аблационният анализ (20 експеримента) демонстрира приноса на всеки компонент и разкрива два ключови извода: (1) мекото обуславяне е критично (44,54% EMR срещу 0,00% при твърдо маскиране); (2) регуляризацията на кардиналността удвоява E2E F1 (50,66% срещу 25,97% без нея).

7.2 Ограничения

Предложената система има следните ограничения:

1. **Последователно обучение.** Двата класификатора се обучават каскадно, а не съвместно. Грешките от грубия класификатор не могат да бъдат коригирани чрез обратна връзка от финия.
2. **Фиксирани параметри на праговане.** Стойностите $\tau = 0,25$, $r = 0,7$ са фиксирани и не се оптимизират за конкретния модел или език.
3. **Единичен модел.** Не е приложен ансамблов подход, който би могъл да подобри устойчивостта на предсказанията.
4. **Разлика между перфектен вход и крайна оценка.** Финият класификатор постига 94,18% μ F1 при подадени верни основни етикети, но само 52,62% E2E Fine F1 — разлика от 41,56 п.п., което показва, че грешките от грубо ниво остават основен ограничаващ фактор.

7.3 Бъдещи насоки

Идентифицираме няколко перспективни направления за бъдещо развитие:

1. **Съвместно обучение** на двата класификатора с обща функция на загубата, което би позволило обратна връзка от финото към грубото ниво.
2. **По-големи модели.** Използване на XLM-RoBERTa-large (550M параметъра) или многоезични варианти на по-нови модели, което би подобрило както грубото, така и финото ниво.
3. **Подходи с големи езикови модели (LLM).** Промптиране или фино настройване на големи генеративни модели (напр. Llama, Mistral) за генериране на обяснения заедно с етикетите, което би могло да подобри интерпретируемостта.

4. **Разширена аугментация.** Използване на обратен превод (back-translation) или парафразиране за обогатяване на обучителното множество, особено за езици с малко данни (български, руски).
5. **Оптимизация на праговане.** Автоматично настройване на параметрите на адаптивното праговане чрез Байесова оптимизация или обучение на допълнителен класификатор за определяне на оптималния праг.

Използвана литература

- [1] Jakub Piskorski, Tarek Mahmoud, Nikolaos Nikolaidis, Ricardo Campos, Alípio Mário Jorge, Dimitar Dimitrov, Purificação Silvano, Roman Yangarber, Shivam Sharma, Tanmoy Chakraborty, Nuno Guimaraes, Elisa Sartori, Nicolas Stefanovitch, Zhuohan Xie, Preslav Nakov и Giovanni Da San Martino. ?SemEval 2025 Task 10: Multilingual Characterization and Extraction of Narratives from Online News? B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, с. 2610—2643. URL: <https://aclanthology.org/2025.semeval-1.331/>.
- [2] Dimitar Dimitrov, Firoj Alam, Maram Hasanain, Abul Hasnat, Fabrizio Silvestri, Preslav Nakov и Giovanni Da San Martino. ?SemEval-2024 Task 4: Multilingual Detection of Persuasion Techniques in Memes? B: *Proceedings of the 18th International Workshop on Semantic Evaluation (SemEval-2024)*. Mexico City, Mexico: Association for Computational Linguistics, 2024.
- [3] Tarek Mahmoud, Zhuohan Xie и Preslav Nakov. ?BERTastic at SemEval-2025 Task 10: State-of-the-Art Accuracy in Coarse-Grained Entity Framing for Hindi News? B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, с. 386—396. URL: <https://aclanthology.org/2025.semeval-1.55/>.
- [4] Tengxiao Lv, Juntao Li, Chao Liu, Yiyang Kang, Ling Luo, Yuanyuan Sun и Hongfei Lin. ?DUTIR at SemEval-2025 Task 10: A Large Language Model-based Approach for Entity Framing in Online News? B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, с. 174—179. URL: <https://aclanthology.org/2025.semeval-1.25/>.
- [5] Egil Rønningstad и Gaurav Negi. ?LTG at SemEval-2025 Task 10: Optimizing Context for Classification of Narrative Roles? B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025. URL: <https://aclanthology.org/2025.semeval-1.61/>.

- [6] Iknoor Singh, Carolina Scarton и Kalina Bontcheva. ?GateNLP at SemEval-2025 Task 10: Hierarchical Three-Step Prompting for Multilingual Narrative Classification? B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025. URL: <https://aclanthology.org/2025.semeval-1.21/>.
- [7] Gabriel Assis, Lívia de Azevedo, João Vitor de Moraes, Laura Alvarenga и Aline Paes. ?Irapuarani at SemEval-2025 Task 10: Evaluating Strategies Combining Small and Large Language Models for Multilingual Narrative Detection? B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, c. 38—48. URL: <https://aclanthology.org/2025.semeval-1.7/>.
- [8] Adith Rajeev и Radhika Mamidi. ?adithrajeev at SemEval-2025 Task 10: Sequential Learning for Role Classification Using Entity-Centric News Summaries? B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, c. 241—246. URL: <https://aclanthology.org/2025.semeval-1.36/>.
- [9] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser и Illia Polosukhin. ?Attention Is All You Need? B: *Advances in Neural Information Processing Systems 30 (NeurIPS)*. 2017.
- [10] Jacob Devlin, Ming-Wei Chang, Kenton Lee и Kristina Toutanova. ?BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding? B: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Minneapolis, Minnesota: Association for Computational Linguistics, 2019, c. 4171—4186.
- [11] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer и Veselin Stoyanov. ?RoBERTa: A Robustly Optimized BERT Pretraining Approach? B: *arXiv preprint arXiv:1907.11692* (2019).
- [12] Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco Guzmán, Edouard Grave, Myle Ott, Luke Zettlemoyer и Veselin Stoyanov. ?Unsupervised Cross-lingual Representation Learning at Scale? B: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*. Association for Computational Linguistics, 2020, c. 8440—8451.
- [13] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He и Piotr Dollár. ?Focal Loss for Dense Object Detection? B: *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*. 2017, c. 2980—2988.

- [14] Yin Cui, Menglin Jia, Tsung-Yi Lin, Yang Song и Serge Belongie. ?Class-Balanced Loss Based on Effective Number of Samples? B: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2019, c. 9268—9277.
- [15] Emanuel Ben-Baruch, Tal Ridnik, Nadav Zamir, Asaf Noy, Itamar Friedman, Matan Protter и Lihi Zelnik-Manor. ?Asymmetric Loss For Multi-Label Classification? B: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, c. 82—91.
- [16] Livio Baldini Soares, Nicholas FitzGerald, Jeffrey Ling и Tom Kwiatkowski. ?Matching the Blanks: Distributional Similarity Matters for Zero-Shot Entity Linking? B: *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL)*. Florence, Italy: Association for Computational Linguistics, 2019, c. 2896—2905.
- [17] Jake Snell, Kevin Swersky и Richard S. Zemel. ?Prototypical Networks for Few-Shot Learning? B: *Advances in Neural Information Processing Systems 30 (NeurIPS)*. 2017, c. 4077—4087.
- [18] Chuan Guo, Geoff Pleiss, Yu Sun и Kilian Q. Weinberger. ?On Calibration of Modern Neural Networks? B: *Proceedings of the 34th International Conference on Machine Learning (ICML)*. 2017, c. 1321—1330.
- [19] Ilya Loshchilov и Frank Hutter. ?Decoupled Weight Decay Regularization? B: *International Conference on Learning Representations (ICLR)*. 2019.
- [20] Jónatas Wehrmann, Ricardo Cerri и Rodrigo Barros. ?Hierarchical Multi-Label Classification Networks? B: *Proceedings of the 35th International Conference on Machine Learning (ICML)*. 2018, c. 5225—5234.
- [21] Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, Joe Davison, Sam Shleifer, Patrick von Platen, Clara Ma, Yacine Jernite, Julien Plu, Canwen Xu, Teven Le Scao, Sylvain Gugger, Mariama Drame, Quentin Lhoest и Alexander M. Rush. ?Transformers: State-of-the-Art Natural Language Processing? B: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations (EMNLP)*. Online: Association for Computational Linguistics, 2020, c. 38—45.