

Софийски университет „Св. Кл. Охридски”

Факултет по математика и информатика

Катедра „Софтуерни технологии”

ДИПЛОМНА РАБОТА

на тема

Разпознаване на семантични роли в новинарски статии

Дипломант: **Борислав Мартинов Минчев**

Факултетен номер: **5MI3400508**

Специалност: **Информатика**

Магистърска програма: **Извличане на информация и откриване на знания**

Научен ръководител:

Проф. д-р Иван Койчев, катедра „Софтуерни технологии”,
ФМИ, СУ „Св. Климент Охридски”

Консултант:

д-р. Димитър Димитров, катедра „Софтуерни технологии”,
ФМИ, СУ „Св. Климент Охридски”

София, 2026 г.

Съдържание

1 Увод **4**
1.1 Актуалност на проблема и мотивация 4
1.2 Цел и задачи на дипломната работа 4
1.3 Основни приноси 5
1.4 Структура на дипломната работа 6

2 Обзор на съществуващи подходи **7**
2.1 Основни понятия 7
2.2 Подходи за разпознаване на семантични роли 8
2.3 Техники за йерархична и многоетикетна класификация 9
2.3.1 Йерархична класификация 9
2.3.2 Многоетикетна класификация 9
2.4 Многоезични предварително обучени модели 10
2.5 Функции на загубата за дисбалансирани данни 11
2.5.1 Фокална загуба (Focal Loss) 11
2.5.2 Класово балансирана кръстосана ентропия (Class-Balanced Cross-Entropy) 11
2.5.3 Асиметрична загуба (Asymmetric Loss) 12

3 Описание на задачата и налични набори от данни **13**
3.1 Същност и цели на задачата 13
3.2 Таксономия на ролите 13
3.3 Структура на данните и статистически анализ 14
3.4 Предварителна обработка на данните 16
3.4.1 Корекция на границите на обекта 16
3.4.2 Разделяне на параграфи 16
3.4.3 Маркиране на обекта 17
3.4.4 Разделяне на данните 17
3.4.5 Предизвикателства 17

4 Обучение на базови модели **19**
4.1 Подготовка на данните . . . 19
4.1.1 Обхват на входния текст . . . 19
4.1.2 Маркиране на обекта . . . 19
4.1.3 Токенизация и разделяне на данните . . . 20
4.2 Базов класификатор за грубо ниво . . . 20
4.3 Резултати на базовия класификатор за грубо ниво . . . 21
4.4 Базов класификатор за фино ниво . . . 21

5 Предложен двустепенен подход **23**
5.1 Обща архитектура . . . 23
5.2 Представяне на именуваната същност чрез осредняване по обхват (Entity Span Pooling) . . . 24
5.3 Класификация чрез семантично сходство . . . 25
5.3.1 Генериране на опорни представяния . . . 25
5.3.2 Проекция и косинусово подобие . . . 26
5.4 Класово балансирана кръстосана ентропия (CB-CE) за грубо ниво . . . 26
5.5 Класификатор на грубо ниво . . . 27
5.6 Асиметрична загуба за фино ниво . . . 28
5.6.1 Конфигурация на ASL . . . 28
5.6.2 Ентропийна регуларизация . . . 29
5.7 Меко йерархично обуславяне . . . 29
5.7.1 Йерархичен афинитетен слой . . . 29
5.7.2 Изчисляване на предварителните тегла . . . 30
5.7.3 Комбиниране на логити с предварителните тегла . . . 30
5.8 Регуларизация на кардиналността . . . 30
5.9 Относителен праг . . . 31
5.9.1 Алгоритъм . . . 31
5.9.2 Обосновка . . . 31
5.10 Класификатор на фино ниво . . . 32
5.10.1 Проекционен MLP . . . 32
5.10.2 Обща загуба . . . 32
5.10.3 Хиперпараметри . . . 33
5.11 Каскадна процедура на обучение . . . 33

6 Експерименти **35**
6.1 Постановка на експериментите . . . 35
6.1.1 Данни . . . 35
6.1.2 Метрики . . . 35
6.1.3 Хардуер . . . 36

6.2 Обучителни криви и валидация . . . 36
6.2.1 Криви на загубата . . . 36
6.2.2 Метрики при валидация . . . 37
6.3 Резултати на класификатора за грубо ниво . . . 37
6.4 Резултати на класификатора за фино ниво . . . 38
6.4.1 Precision, Recall и калибрация на кардиналността . . . 38
6.4.2 F1 по детайлни етикети . . . 39
6.5 Крайна оценка (от край до край) . . . 40
6.6 Сравнение с базовия модел . . . 41
6.7 Сравнение със състезателни системи . . . 42
6.8 Анализ по езици . . . 42
6.9 Изследване на приноса на компонентите . . . 43
6.9.1 Принос на класификационната глава . . . 44
6.9.2 Принос на функцията на загубата за грубо ниво . . . 44
6.9.3 Принос на функцията на загубата за фино ниво . . . 45
6.9.4 Принос на регуларизацията на кардиналността . . . 45
6.9.5 Меко срещу твърдо обуславяне . . . 45
6.10 Анализ на грешките . . . 46

7 Разработка на прототип на интерактивно приложение 47
7.1 Описание на приложението . . . 47
7.1.1 Основен поток . . . 47
7.1.2 Управление на кеша . . . 49
7.2 Анализ на приноса на думите . . . 49
7.2.1 Обзор на методите за атрибуция . . . 49
7.2.2 Оклузия на ниво дума . . . 51
7.2.3 Оклузия на ниво фраза . . . 51
7.2.4 Градиент × Вграждане (Gradient × Embedding) . . . 52
7.2.5 Нормализация и визуализация . . . 52
7.3 Примерни резултати . . . 53

8 Заключение 56
8.1 Обобщение на резултатите . . . 56
8.2 Ограничения . . . 57
8.3 Идеи за бъдещо развитие . . . 57

Използвана литература 59

Глава 1

Увод

1.1 Актуалност на проблема и мотивация

Дезинформацията и пропагандата в онлайн медиите създават нужда от инструменти, които автоматично анализират как се представят отделните участници в новинарските текстове. Когато модел може да разпознае дали едно лице, организация или държава е представено като протагонист, антагонист или невинна страна, това отваря пътя към по-надежден медиен мониторинг, проверка на факти и анализ на наративни манипулации.

Споделената задача SemEval-2025 Task 10 [1] предлага формална рамка за многоезична класификация на ролите на именуваните обекти. Тя обхваща пет езика (български, английски, хинди, португалски и руски), две тематични области (войната в Украйна и климатичните промени) и три подзадачи. Тази работа разглежда **подзадача 1 (Entity Framing)**: за всяко споменаване на обект в статия трябва да бъде назначена една основна роля (грубо ниво) и една или повече детайлни роли (фино ниво) от таксономия с 22 предварително дефинирани етикета.

Задачата е интересна, защото съчетава няколко трудности едновременно: многоезичност (5 езика с различни писмени системи), йерархична структура на етикетите (3 основни и 22 детайлни роли), многоетикетна класификация (всяко споменаване може да има повече от една детайлна роля), силен класов дисбаланс и силна контекстна зависимост на ролите.

1.2 Цел и задачи на дипломната работа

Целта на дипломната работа е да се разработи и оцени прототип на система за присвояване на роли (герой, злодей, жертва) на именувани единици в новинарски статии чрез прилагане на големи езикови модели. Задачите, произтичащи от целта, са:

1. Обзор на съществуващите подходи за разпознаване на семантични роли и мултиезиково извличане на информация.

2. Предварителна обработка на предоставените данни и създаване на обучаващи множества.

3. Изграждане и обучение на модел за присвояване на роли в новини.

4. Планиране и провеждане на експерименти за оценка и сравняване на разработените модели за присвояване на роли в новини.

5. Разработка на прототип на система за присвояване на роли в новини.

1.3 Основни приноси

Основните приноси на дипломната работа са:

1. **Анализ на данните** от SemEval-2025 Task 10, който откроява основните предизвикателства на задачата: класов дисбаланс, ниска кардиналност на детайлните роли, йерархична структура на етикетите и силна контекстна зависимост на ролите.

2. **Двустепенна каскадна система** за йерархична класификация с меко обуславяне, чиито компоненти - осредняване по обхват на обекта, класификация чрез семантично сходство, специализирани функции на загубата и регуларизация на кардиналността - са мотивирани от конкретните слабости на базовия модел.

3. **Систематично изследване на приноса на компонентите**, което проследява ролята на класификационната глава, функцията на загубата, йерархичното обуславяне и регуларизацията на кардиналността, и демонстрира ефективността на мекото обуславяне спрямо твърдото маскиране: 44,54% EMR срещу 0,00%.

4. **Конкурентни резултати на тестовото множество**: 81,68% претеглен F1 за основната роля, 50,67% E2E Fine F1 и 44,54% точно съвпадение (EMR), постигнати с базовия XLM-RoBERTa-base (278M параметъра). За сравнение, водещите системи в SemEval-2025 Task 10 отчитат средно 0,475 EMR (DUTIR) и 0,421 EMR (PATeam) на скритото състезателно тестово множество, използвайки многократно по-големи декодерни модели. Сравнението е ориентировъчно, защото множествата са различни.

5. **Интерактивно приложение** за демонстрация на системата с модул за анализ на приноса на думите, което прави решенията на модела интерпретируеми чрез три метода за атрибуция.

1.4 Структура на дипломната работа

Документът е организиран в осем глави. Глава 2 прави обзор на съществуващите подходи: основни понятия, подходи за разпознаване на семантични роли, многоезични модели и функции на загубата. Глава 3 описва задачата и наличните набори от данни, включително статистически анализ и предварителна обработка. Глава 4 обучава базовите модели за грубата и фината класификация. Глава 5 описва предложения двустепенен подход - ядрото на работата. Глава 6 обсъжда експерименталните резултати и приноса на отделните компоненти. Глава 7 описва разработения прототип на интерактивно приложение за демонстрация и анализа на приноса на думите, включително сравнение на три метода за атрибуция. Глава 8 обобщава приносите, ограниченията и идеите за бъдещо развитие.

Глава 2

Обзор на съществуващи подходи

2.1 Основни понятия

Рамкиране на именувани обекти (Entity Framing) е задачата да се определи автоматично каква наративна роля играе даден именуван обект в текста - например дали дадено лице е представено като герой, злодей или жертва. Тази задача е тясно свързана с анализа на медийни рамки (media framing) и детекцията на пропаганда.

Многоетикетна класификация (Multi-label Classification) е вид класификация, при която всеки пример може да получи няколко етикета едновременно. За разлика от многокласовата класификация (multi-class), при която всеки пример получава точно един етикет, тук броят на етикетите е променлив. При нашата задача един обект може да бъде едновременно например *Instigator* и *Deceiver*.

Йерархична класификация (Hierarchical Classification) обхваща задачи, при които етикетите са организирани в дървовидна таксономия. Предсказанията трябва да са съвместими с йерархията - например, ако обект е класифициран като *Guardian*, той трябва да принадлежи и към родителската категория *Protagonist*.

Трансферно обучение (Transfer Learning) е парадигма в обработката на естествен език, при която моделът първо се предварително обучава върху голям корпус от текст чрез самонаблюдавано обучение (self-supervised learning), а след това се фино настройва (fine-tuning) върху конкретна задача с по-малко данни. На този подход се основават съвременните езикови модели като BERT и XLM-RoBERTa.

Представяне на обект чрез специални маркери е техника, при която около споменаването на обекта в текста се вмъкват специални токени `[ENTITY]` и `[/ENTITY]`. Моделът извлича представяне на конкретния обект чрез осредняване на скритите състояния между двата маркера (entity span pooling).

2.2 Подходи за разпознаване на семантични роли

SemEval-2025 Task 10 [1] е споделена задача от 19-ото издание на SemEval. Тя включва три подзадачи: (1) Entity Framing - класификация на ролята на именувани обекти; (2) Narrative Classification - присвояване на наративни етикети на ниво документ; (3) Narrative Extraction - генериране на текстово обяснение за доминиращия наратив. В състезанието са регистрирани над 300 екипа; 66 от тях подават официални резултати за всички подзадачи (35 за подзадача 1). Тази работа разглежда само подзадача 1.

Задачата продължава поредицата от споделени задачи за детекция на пропаганда, сред които SemEval-2024 Task 4 [2] за многоезично разпознаване на техники за убеждаване в мемета.

Разработките, предложени за решаването на тази задача, включват:

- **BERTastic** [3] - съчетава фино настроен XLM-RoBERTa с промптиране на GPT-4o. Класира се седми по средно EMR за петте езика (0,386), но постига първо място за хинди по вторичната метрика accuracy за основната роля.
- **DUTIR** [4] - комбинира многоезичен превод с GLM-4-Plus, QLoRA фино настройване и ансамблова класификация. Печели първо място общо в подзадача 1 (средно 0,475 EMR), а също и за английски, португалски и руски.
- **LTG** [5] - комбинира XLM-RoBERTa с евристики за избор на контекст около обекта. Постига конкурентни резултати с по-големи генеративни модели.
- **adithjrajeev** [6] - използва тристъпков pipeline: генериране на резюме, центрирано около обекта, последвано от BERT-базиран класификатор за ролята на обекта.

Таблица 2.1: Класиране на водещите системи в SemEval-2025 Task 10, подзадача 1, по средно EMR на скритото състезателно тестово множество [1].

Система	**Базови модели**	**Avg EMR**
DUTIR	GLM-4-Plus, Qwen2.5, Llama 3.1	0,475
QUST	DeBERTa, Phi-4, Qwen2.5	0,431
PATeam	Qwen2.5-72B, Phi-4	0,421
DEMON	BERT, Llama 3	0,414
TartanTritons	RoBERTa, Qwen2.5, Llama 3.1	0,404
BERTastic	XLM-RoBERTa, GPT-4o	0,386
LTG	XLM-RoBERTa, Llama 3, Bernice	0,354

Забележка: Класирането използва официалната метрика EMR (Exact Match Ratio), осреднена за петте езика на задачата.

Подходите, базирани на големи декодерни модели, доминират в общото класиране, но фино настроените по-малки енкодерни модели (напр. XLM-RoBERTa в BERTastic и LTG) постигат конкурентни резултати при многократно по-ниски изчислителни разходи.

2.3 Техники за йерархична и многоетикетна класификация

2.3.1 Йерархична класификация

Йерархичната класификация на текст (Hierarchical Text Classification) е задача, при която етикетите са организирани в дървовидна таксономия с връзки „родител-дете". За разлика от плоската класификация, при йерархичната предсказанията на различните нива трябва да са *съвместими* - например, ако обект е класифициран с детайлна роля *Guardian*, той трябва да принадлежи и към родителската категория *Protagonist*.

В литературата се разграничават три основни подхода:

- **Плосък подход** (flat) - игнорира йерархията и обучава един класификатор за всички етикети. Прост за реализация, но не гарантира съвместимост между нивата.
- **Локален подход** (local per-level) - обучава отделен класификатор за всяко ниво на йерархията. Предсказанието на горното ниво се предава като вход или ограничение на следващото. Срещат се два варианта: *твърдо маскиране* (hard masking), което занулява недопустимите етикети, и *меко обуславяне* (soft conditioning), при което вероятностите от горното ниво модулират предсказанията на долното.
- **Глобален подход** (global) - един модел, който отчита цялата йерархия чрез споделени представяния или рекурсивни механизми.

В тази работа използваме локален подход с два етапа: класификация на основната роля (грубо ниво), след което резултатът се предава на класификатора за детайлни роли (фино ниво). Така всеки етап може да бъде оптимизиран независимо, а йерархичните ограничения се налагат при прехода между нивата.

2.3.2 Многоетикетна класификация

Многоетикетната класификация изисква специфични метрики и функции на загубата. Основните метрики в SemEval-2025 Task 10 са:

- **Точно съвпадение (Exact Match Ratio, EMR)** - официалната метрика за класиране; измерва броя на примерите, за които предсказаният набор от етикети съвпада *точно* с верния.
- **Micro-F1** - агрегира истински положителните, фалшиво положителните и фалшиво отрицателните над всички етикети и примери.
- **Main Role Accuracy** - точност на класификацията на грубо ниво (3 класа).

Предизвикателство: дисбаланс на етикетите. При 22 възможни етикета и средна кардиналност от 1,1, съотношението положителни/отрицателни за повечето класове е под 1:20. Със стандартна бинарна кръстосана ентропия (BCE) моделът най-лесно минимизира загубата, като предсказва „нищо" за почти всички етикети. Това налага специализирани функции на загубата: *асиметричната загуба* (Asymmetric Loss) намалява приноса на лесните отрицателни примери чрез асиметрично претегляне; *фокалната загуба* (Focal Loss) фокусира обучението върху трудните за класификация примери.

2.4 Многоезични предварително обучени модели

Transformer архитектурата [7], е в основата на съвременните езикови модели. Ключовата иновация е механизмът за самовнимание (self-attention), чрез който моделът улавя зависимости между произволни позиции в поредицата в една стъпка.

BERT (Bidirectional Encoder Representations from Transformers) [8] адаптира кодиращата част на Transformer за предварително обучение чрез маскирано езиково моделиране (MLM) и предсказване на следващо изречение (NSP). Двупосочната архитектура улавя контекст и от двете страни на всеки токен, което води до значителни подобрения за много задачи.

RoBERTa [9] оптимизира стратегията за предварително обучение на BERT: премахва NSP задачата, увеличава размера на партидата и обема на данните и въвежда динамично маскиране. Авторите показват, че BERT е недообучен спрямо потенциала си.

XLM-RoBERTa [10] разширява подхода на RoBERTa за 100 езика, като използва 2,5 TB данни от Common Crawl. Моделът постига значителни подобрения спрямо mBERT: +14,6% на XNLI, +13% F1 на MLQA и +2,4% F1 за NER. Той покрива всичките пет езика от задачата (български, английски, хинди, португалски, руски), което го прави естествен избор за нашата многоезична класификация.

В тази работа използваме `xlm-roberta-base` (278M параметъра, 12 Transformer слоя, скрита размерност 768).

2.5 Функции на загубата за дисбалансирани данни

При задачи с изразен класов дисбаланс стандартната кръстосана ентропия третира всички класове равностойно и обучението се доминира от мажоритарния клас. По-долу разглеждаме три специализирани функции на загубата, които използваме в експериментите.

2.5.1 Фокална загуба (Focal Loss)

Фокалната загуба (Focal Loss) [11] е предложена от Lin et al. за задачата по детекция на обекти, където дисбалансът между фонови и обектни примери достига 1:1000. Идеята е да се намали приносът на лесно класифицируемите примери чрез модулиращ фактор:

$$\mathcal{L}_{\mathrm{FL}} = -\alpha_t (1 - p_t)^{\gamma} \log(p_t) \tag{2.1}$$

където p_t е предсказаната вероятност за верния клас, $\gamma \geq 0$ е фокален параметър, а α_t е балансиращо тегло за клас t. При $\gamma = 0$ фокалната загуба се свежда до стандартна кръстосана ентропия. С нарастване на γ приносът на лесните примери (висок p_t) намалява експоненциално, което фокусира обучението върху трудните примери.

2.5.2 Класово балансирана кръстосана ентропия (Class-Balanced Cross-Entropy)

Cui et al. [12] предлагат претегляне на загубата чрез *ефективния брой проби* (effective number of samples). Основната идея е, че при преизползване на данни (oversampling) приносът на всеки нов пример постепенно намалява. Ефективният брой за клас с n проби се дефинира като:

$$E_n = \frac{1 - \beta^n}{1 - \beta} \tag{2.2}$$

където $\beta \in [0, 1)$ е хиперпараметър. При $\beta \to 0$ всички класове получават еднакво тегло; при $\beta \to 1$ теглата са обратно пропорционални на честотата. Теглото за всеки клас i е:

$$w_i = \frac{1 - \beta}{1 - \beta^{n_i}} \tag{2.3}$$

а загубата:

$$\mathcal{L}_{\text{CB-CE}} = -\frac{w_y}{\bar{w}} \sum_{i=1}^{C} y_i \log(p_i) \tag{2.4}$$

където $\bar{w}$ е средното тегло за нормализация. В нашите експерименти използваме $\beta = 0{,}9999$.

2.5.3 Асиметрична загуба (Asymmetric Loss)

Ben-Baruch et al. [13] предлагат асиметричната загуба (Asymmetric Loss, ASL), специално проектирана за многоетикетна класификация с изразен дисбаланс. Ключовата идея е да се прилагат *различни* степени на фокусиране за положителни и отрицателни примери:

$$\mathcal{L}_{\text{ASL}} = \begin{cases} (1-p)^{\gamma^+} \log(p) & \text{ако } y = 1 \\ p_m^{\gamma^-} \log(1-p_m) & \text{ако } y = 0 \end{cases} \tag{2.5}$$

където $p_m = \max(p - m, 0)$ е изместената вероятност с марж (margin) m - похватът probability shifting. Параметрите γ^+ и γ^- контролират фокусирането поотделно: типично $\gamma^- > \gamma^+$, което по-агресивно намалява приноса на лесните отрицателни примери.

В нашата система за финия класификатор използваме ASL с параметри $\gamma^+ = 0{,}0$, $\gamma^- = 2{,}0$ и марж $m = 0{,}05$. Изборът на $\gamma^+ = 0$ означава без фокусиране за положителните примери (всеки е информативен), а $\gamma^- = 2$ агресивно намалява приноса на лесните отрицателни. Системата разполага и с разширена версия (ASL-Opt) - тя добавя ентропийна регуларизация ($\lambda_{\text{ent}} = 0{,}15$) и претегляне на класовете чрез ефективния брой проби.

Глава 3

Описание на задачата и налични набори от данни

3.1 Същност и цели на задачата

Подзадача 1 (Entity Framing) от SemEval-2025 Task 10 е формулирана така: дадени са новинарска статия и списък от споменавания на именувани обекти в нея, всяко от които се описва с идентификатор на документа, текстово споменаване и начална/крайна позиция. За всяко споменаване трябва да бъдат определени:

1. **Основна роля** (main role) - точно един от трите етикета: Protagonist, Antagonist, Innocent.

2. **Детайлни роли** (fine-grained roles) - една или повече от 22 етикета, организирани йерархично под трите основни роли.

Задачата е многоезична, като данните обхващат пет езика: български (BG), английски (EN), хинди (HI), португалски (PT) и руски (RU). Тематичните области са две: войната между Русия и Украйна (URW) и климатичните промени (CC).

Официалната метрика за класиране е **точно съвпадение (Exact Match Ratio, EMR)** за детайлните роли, допълнена от micro-F1 и точност на основната роля.

3.2 Таксономия на ролите

Таксономията се състои от три основни роли и 22 детайлни роли, разпределени неравномерно (Таблица 3.1). Разпределението е силно асиметрично: Antagonist съдържа 12 детайлни роли - два пъти повече от Protagonist и три пъти повече от Innocent. Това отразява по-голямото разнообразие на негативни наративни рамки в новинарските текстове и прави класификацията по-трудна.

Таблица 3.1: Таксономия на ролите: 3 основни и 22 детайлни.

Основна роля	**Детайлна роля**	**Описание (накратко)**
Protagonist	Guardian	Защитник, пазител
	Martyr	Мъченик за кауза
	Peacemaker	Миротворец
	Rebel	Бунтовник, борец за промяна
	Underdog	Аутсайдер в неравна борба
	Virtuous	Нравствен, етичен лидер
Antagonist	Instigator	Подбудител на конфликт
	Conspirator	Участник в заговор
	Tyrant	Тиранин, деспот
	Foreign Adversary	Външен противник
	Traitor	Предател
	Spy	Шпионин
	Saboteur	Саботьор
	Corrupt	Корумпиран
	Incompetent	Некомпетентен
	Terrorist	Терорист
	Deceiver	Измамник
	Bigot	Фанатик, нетолерантен
Innocent	Forgotten	Забравен от обществото
	Exploited	Експлоатиран
	Victim	Жертва
	Scapegoat	Изкупителна жертва

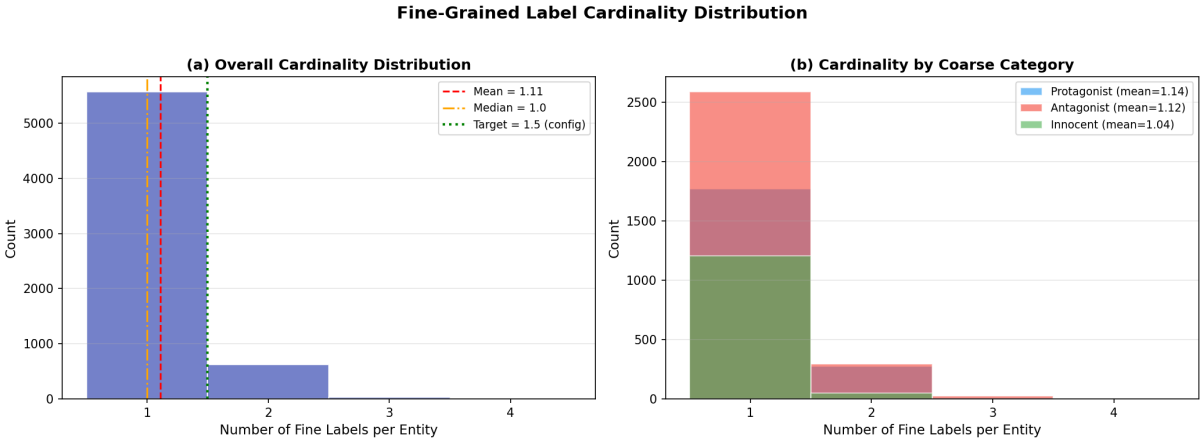
3.3 Структура на данните и статистически анализ

Данните са организирани в директории по език. За всеки език са предоставени обучително множество с анотации, валидационно множество без етикети и директория с оригиналните текстове. Всяка анотация съдържа идентификатор на документа, текстово споменаване, начална и крайна позиция, основна роля (една от трите) и набор от детайлни роли (подмножество от 22-те).

Разпределението на трите основни роли е силно небалансирано. Antagonist доминира във всички езици, Protagonist го следва, а Innocent остава най-рядката категория - факт, който по-нататък определя избора на функциите на загубата.

Повечето обекти носят само един-два детайлни етикета. Средната кардиналност е около 1,1 (1,08 в тестовото и 1,11 в обучителното множество), което е доста ниско и по-късно обосновава регуларизацията на кардиналността с целева стойност 1,5

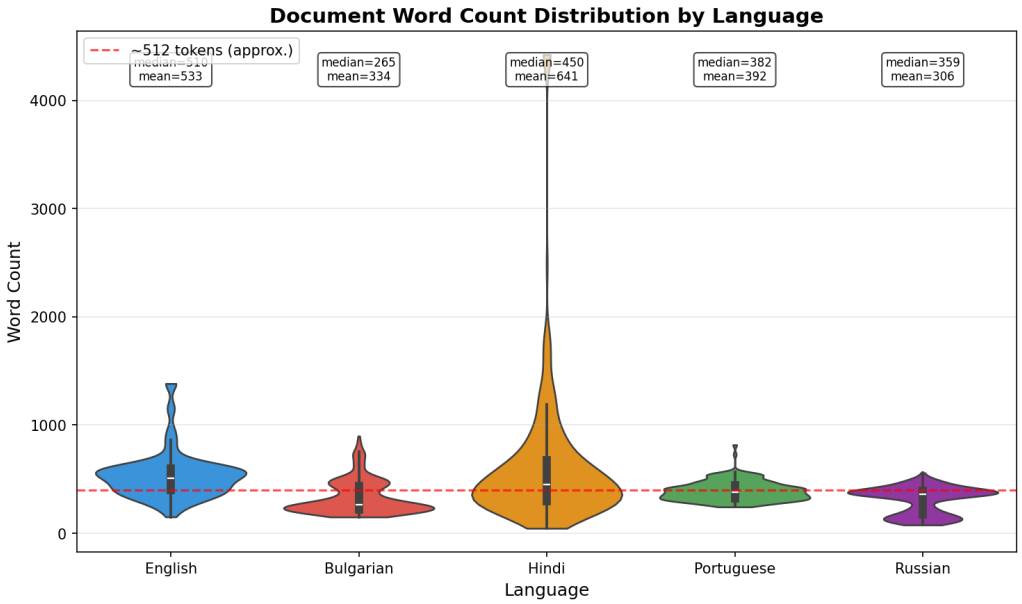
(Секция 5.8).



Фигура 3.1: Разпределение на броя детайлни етикети на обект.

Когато два детайлни етикета се срещат заедно, те винаги принадлежат на една и съща основна категория. Това не е изненадващо - всяко споменаване има точно една основна роля - но е добра проверка, че каскадният двустепенен подход е съвместим с данните. Във всяка от трите категории се откроява по една доминираща роля (*Guardian*, *Foreign Adversary* и *Victim*), с което дисбалансът на фино ниво става още по-изразен.

Дължината на текстовете също се различава чувствително между езиците (Фигура 3.2); част от документите надхвърлят лимита от 512 токена при токенизацията и изискват отрязване.



Фигура 3.2: Разпределение на дължината на текстовете по езици.

Задачата е и силно контекстно зависима: един и същ обект често получава раз-

лични роли в различни статии, така че проста справочна таблица обект → роля не върши работа. Останалите аспекти на анализа - матриците на съвместно появяване, разнообразието на ролите на ниво обект и разпределението по тематични области - бяха разгледани по-подробно в преддипломния проект.

3.4 Предварителна обработка на данните

3.4.1 Корекция на границите на обекта

Всяко споменаване идва с начална и крайна позиция, които би трябвало да ограждат точно обекта в текста. На практика при част от примерите това не е така - откъсът, който позициите посочват, не съвпада със записаното споменаване. Причината са дребни технически разминавания при подготовката на данните: различно кодиране на символите, нормализирани интервали и най-вече различните знаци за край на ред между оригиналните документи и анотациите.

На пръв поглед това е незначителен детайл, но за нашата система е от съществено значение. Точно между тези граници по-късно вмъкваме маркерите `[ENTITY]`/`[/ENTITY]`, а осредняването по обхват (Секция 5.2) изгражда представянето на обекта именно от този участък. Ако позициите са изместени само с няколко символа, маркерите ограждат грешни думи и моделът всъщност описва нещо различно от целевия обект. Затова при зареждането сверяваме дали позициите наистина сочат към споменаването и когато не съвпадат, ги възстановяваме - търсим споменаването около първоначалните позиции и постепенно разширяваме обхвата, докато го намерим.

3.4.2 Разделяне на параграфи

Оригиналните новинарски статии варират значително по дължина - от няколко изречения до над 2000 думи (виж Фигура 3.2). Тъй като максималната дължина на входа при токенизация е 512 токена, подаването на цял документ би довело до загуба на контекст след отрязване. Затова разделяме текстовете на абзаци и за всяко споменаване запазваме само абзаца, в който то се среща. Така входът остава в разумни граници, запазваме непосредствения контекст около обекта - който носи най-много информация за ролята му - и същевременно отрязваме шума от несвързани абзаци в дългите статии. След разделянето позициите на всяко споменаване (start/end offsets) се преизчисляват спрямо началото на съответния абзац.

3.4.3 Маркиране на обекта

В предложената система, за разлика от базовия модел, токените `[ENTITY]` и `[/ENTITY]` се добавят като *специални токени* в речника на токенизатора. Това им дава собствен идентификатор, така че не се разбиват на подтокени и моделът разпознава границите на обекта еднозначно. Разширяването на речника налага и разширяване на вградения слой (embedding layer); новите вектори се инициализират от нормално разпределение със същите средна стойност и стандартно отклонение като оригиналните вграждания, за да не нарушат разпределението на вече наученото.

3.4.4 Разделяне на данните

Организаторите предоставят обучително и валидационно множество, но не предоставят етикети за тестовото. Затова данните са разделени така:

- **Обучително множество:** 80% от оригиналното обучително множество (4 493 примера след параграфна декомпозиция).
- **Валидационно множество:** останалите 20% (1 124 примера), използвани за мониторинг на обучението и избор на най-добрата контролна точка.
- **Тестово множество:** оригиналното валидационно множество на организаторите (604 примера) - тъй като етикетите му са налични, то служи за крайна оценка.

Поради тази причина използваме тези множества едновременно за избор на конфигурация (Глава 6) и за крайна оценка. Затова докладваните резултати може да са леко оптимистично отклонени спрямо напълно скрито тестово множество.

3.4.5 Предизвикателства

Множеството поставя няколко ключови предизвикателства:

1. **Класов дисбаланс.** Ролята Antagonist е значително по-застъпена от останалите, а Innocent е много рядка. Това налага функции на загубата, които компенсират дисбаланса - в нашата система Class-Balanced Cross-Entropy за грубата класификация и Asymmetric Loss за финия многоетикетен случай.
2. **Разреденост на многоетикетното пространство.** При 22 възможни етикета и средна кардиналност от 1,1, съотношението положителни/отрицателни за повечето класове е под 1:20. Със стандартни функции на загубата (BCE) моделът най-лесно минимизира загубата, като предсказва „нищо” за повечето етикети.

3. **Многоезичност.** Петте езика имат различни типологични характеристики и писмени системи (латиница, кирилица, деванагари), което изисква многоезичен предварително обучен модел.

4. **Йерархични ограничения.** Детайлните етикети трябва да бъдат съобразени с основната категория. Грешки на грубо ниво неизбежно водят до каскадно разпространение на грешките.

5. **Контекстна зависимост.** Ролята на обекта зависи от контекста, в който е споменат - една и съща личност може да бъде представена като протагонист в една статия и като антагонист в друга.

Глава 4

Обучение на базови модели

В тази глава представяме два базови модела - по един за всяко ниво на класификация. Грубият базов модел (описан в секции до 4.3) класифицира основните роли (Protagonist, Antagonist, Innocent), а финият (Секция 4.4) предсказва детайлните 22 роли в многоетикетна постановка. Целта е да установим начални резултати за двете нива, които служат за сравнение с по-сложните архитектури в Глава 5. Съзнателно избираме най-простите решения за всеки компонент - стандартна класификационна глава, стандартни функции на загубата и минимална предварителна обработка - за да изолираме приноса на самия предварително обучен модел от този на архитектурните надстройки.

4.1 Подготовка на данните

4.1.1 Обхват на входния текст

Тъй като максималната дължина на входа при токенизация е 256 токена, подаването на цял документ би довело до загуба на контекст след отрязване. Затова разделяме текстовете на абзаци и за всяко споменаване избираме само абзаца, който съдържа оригиналното споменаване.

4.1.2 Маркиране на обекта

Около споменаването на обекта се вмъкват маркери `[ENTITY]` и `[/ENTITY]` чрез проста замяна в текста. За разлика от напредналата система (Глава 5), тук маркерите се третират като обикновен текст и се разделят на подтокени от стандартния SentencePiece алгоритъм на XLM-RoBERTa - това е съзнателен избор за минимални модификации в базовия модел.

4.1.3 Токенизация и разделяне на данните

Маркираният текст се токенизира чрез стандартния XLM-RoBERTa токенизатор с максимална дължина от 256 токена, с отрязване на по-дългите и допълване на по-късите последователности. Основните роли се кодират като цели числа: Protagonist – 0, Antagonist – 1, Innocent – 2. Разделянето на данните следва схемата от Секция 3.4: обучително (4 493 примера), валидационно (1 124 примера) и тестово (604 примера) множество.

4.2 Базов класификатор за грубо ниво

Базовият модел стъпва върху стандартната архитектура XLMRobertaForSequenceClassificatio от HuggingFace transformers, с двуслойна класификационна глава над представянето на `[CLS]` токена. Гръбнакът е `xlm-roberta-base` - многоезичен Transformer с 12 слоя, скрита размерност $d = 768$ и 278 милиона параметъра. Класификационната глава е:

$$\hat{\mathbf{y}} = \mathbf{W}_2 \tanh(\mathbf{W}_1 \mathbf{h}_{\texttt{[CLS]}} + \mathbf{b}_1) + \mathbf{b}_2 \tag{4.1}$$

където $\mathbf{h}_{\texttt{[CLS]}} \in \mathbb{R}^{768}$ е скритото състояние на `[CLS]` токена от последния слой, а $\hat{\mathbf{y}} \in \mathbb{R}^3$ е векторът от логити. За да ограничим пренастройването при толкова малко данни, замразяваме всичко освен последния Transformer блок и класификационната глава, с което обучаеми остават 7,68M от 278M параметъра (2,76%). Загубата е обикновена кръстосана ентропия без претегляне. Пълната конфигурация е събрана в Таблица 4.1.

Таблица 4.1: Хиперпараметри за обучение на базовия класификатор.

Параметър	**Стойност**
Базов модел	`xlm-roberta-base` (278M параметъра)
Обучаеми параметри	7,68M (2,76%)
Замразени слоеве	0–10 (11 от 12)
Макс. дължина	256 токена
Брой епохи	5
Размер на партидата	8
Скорост на обучение	2×10^{-5}
Затихване на теглата (weight decay)	0,01
Функция на загубата	Кръстосана ентропия
Класификационна глава	`[CLS]` $\rightarrow$ dense $\rightarrow$ tanh $\rightarrow$ out_proj
Оптимизатор	AdamW

4.3 Резултати на базовия класификатор за грубо ниво

Базовият модел достига 67,72% точност и 67,33% претеглен F1, като познава вярно 409 от 604 примера.

Таблица 4.2: Общи резултати на базовия класификатор.

Метрика	**Стойност**
Точност (Accuracy)	67,72%
Претеглен F1	67,33%

Общата цифра крие две неща. Най-очевидното е отклонението към мажоритарния клас: моделът залага твърде охотно на доминиращия Antagonist, а най-рядкият Innocent почти не бива предсказван (Recall едва 48,3%), като примерите му се разсейват към другите две категории. Това само по себе си мотивира балансираните функции на загубата. По-малко очевидно, но не по-маловажно, е *откъде* всъщност моделът черпи сигнал. Анализът на приноса на думите (преддипломния проект) показва, че при грешките най-тежат общи контекстни думи, а не тези около самия обект - пряко следствие от `[CLS]` представянето, което смесва целия вход, вместо да се фокусира върху конкретната същност. Именно това наблюдение по-нататък ни насочва към осредняването по обхват (ESP, Секция 5.2).

По-подробната картина - метриките по класове и по езици, матрицата на объркване, обучителните криви и визуализациите на приноса на думите - е оставена за преддипломния проект.

4.4 Базов класификатор за фино ниво

Вторият базов модел покрива многоетикетната задача с 22 детайлни роли. Той стъпва на същия гръбнак (XLM-RoBERTa-base) и на същото селективно замразяване (7,69M обучаеми параметъра, 2,77%), но тук е важно едно уточнение: двата базови класификатора живеят отделно. Финият не вижда предсказанието на грубия - обучава се и се оценява сам за себе си, а на изхода двете предсказания просто се събират. Това го отличава от напредналата система, където финият етап е меко обусловен от грубите вероятности (Секция 5.7).

Останалите разлики спрямо грубия модел идват направо от многоетикетната постановка. Вместо три softmax-логита тук имаме 22 независими сигмоида, а загубата е бинарна кръстосана ентропия с pos_weight, изчислен от обучителната честота на всеки етикет и ограничен на 10. За самото предсказване слагаме фиксиран праг

0,5 върху сигмоидните вероятности; ако нито един етикет не го премине, връщаме argmax над логитите, за да не остане примерът без предсказание. Поради по-голямата сложност обучаваме за 10 епохи при скорост 3×10^{-5}, като размерът на партидата остава 8. Нито една от тези добавки не въвежда механизъм от напредналата система - те само правят базовия модел работоспособен за многоетикетния случай.

Таблица 4.3: Общи резултати на базовия класификатор за фино ниво.

Метрика	**Стойност**
Sample-F1	38,86%
Micro-F1	35,64%
Macro-F1	22,41%
Точно съвпадение (EMR)	11,75%
Средна предсказана кардиналност	2,70
Средна истинска кардиналност	1,08

Когато грубата роля е предсказана правилно, условният Fine F1 нараства до 48,77% - 9,9 процентни пункта над безусловния Sample-F1. Това потвърждава очакванията каскаден ефект: грешките на първия етап ограничават горната граница на втория.

Разбивката по етикети и по езици изкарва наяве няколко отделни проблема. Най-тежкият е пълният колапс на редките роли: седем от 22-та етикета остават с F1=0 на теста (*Martyr*, *Traitor*, *Spy*, *Saboteur*, *Bigot*, *Forgotten*, *Scapegoat*). Всички те имат под 12 примера и pos_weight просто не стига, за да ги измъкне BCE. Отделно от това моделът предсказва твърде много етикети - средно 2,70 на пример при истинска стойност 1,08, тоест около 2,5× в повече, което фиксираният праг не е в състояние да овладее. Част от грешките пък изобщо не произлизат от финия модел, а са наследени от грешно предсказана груба роля.

Точно тези проблеми очертават пътя към напредналата система (Глава 5): класификация по семантично сходство срещу колапса на редките роли, регуларизация на кардиналността и относителен праг срещу свръхпредсказването, меко йерархично обуславяне срещу каскадните грешки. Как точно е проектиран всеки от тези избори, заедно с подробните диаграми по етикети, по езици и по кардиналност, е разгледано в преддипломния проект.

Глава 5

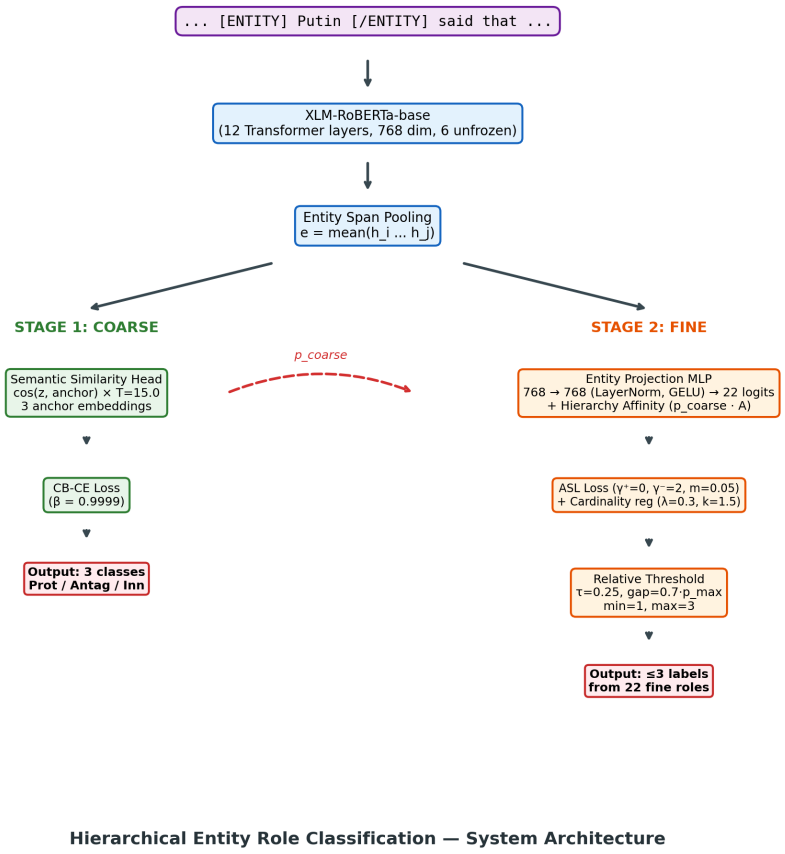
Предложен двустепенен подход

В тази глава описваме предложената напреднала система за йерархична класификация на ролите на именувани обекти. Системата е двустепенна - първият етап определя основната роля (3 класа), а вторият - детайлните роли (22 класа) чрез многоетикетна класификация с меко йерархично обуславяне. Всяка от иновациите спрямо базовите модели (Глава 4) е мотивирана от конкретна слабост, идентифицирана в анализа на грешките.

5.1 Обща архитектура

Системата се състои от два последователно обучени класификатора, базирани на един и същ предварително обучен модел XLM-RoBERTa-base, но с различни класификационни глави и функции на загубата. Общият поток е:

1. **Вход:** текст с маркиран обект чрез специални токени `[ENTITY]`/`[/ENTITY]`.
2. **Кодиране:** XLM-RoBERTa преобразува входа в последователност от скрити състояния.
3. **Осредняване по обхват (ESP):** извличане на представяне, специфично за обекта, чрез осредняване на скритите състояния между маркерите.
4. **Етап 1 (грубо ниво):** класификационна глава, базирана на семантично сходство с 3 опорни вектора + класово балансирана кръстосана ентропия (CB-CE).
5. **Етап 2 (фино ниво):** проекционен MLP + йерархичен афинитетен слой за меко обуславяне с грубите вероятности, обучен с асиметрична загуба (ASL) и регуларизация на кардиналността.
6. **Предсказване:** относителен праг за определяне на крайните етикети.



Фигура 5.1: Обща архитектура на предложената двустепенна система.

5.2 Представяне на именуваната същност чрез осредняване по обхват (Entity Span Pooling)

В базовия модел представянето на обекта се извлича от токена `[CLS]`, който агрегира информация от целия вход, но не кодира експлицитно позицията на обекта. При абзаци с множество споменати лица моделът не може да разграничи кое лице е целевото.

За решаване на този проблем въвеждаме *осредняване по обхват на обекта* (entity span pooling, ESP). Подходът е базиран на техниките за маркиране на обекти [14] и се състои от две стъпки:

Стъпка 1: Добавяне на специални токени. Токените `[ENTITY]` и `[/ENTITY]` се добавят в речника на токенизатора като специални символи. Вграденият слой (embedding layer) на модела се разширява, като новите вграждания се инициализират стандартно (с нормално разпределение, както е по подразбиране в библиотеката `transformers`).

Стъпка 2: Осредняване на скритите състояния. След като текстът премине

през Transformer-енкодера, представянето на обекта се извлича чрез осредняване на скритите състояния в обхвата между маркерите:

$$\mathbf{e} = \frac{1}{j-i} \sum_{k=i}^{j-1} \mathbf{h}_k \tag{5.1}$$

където $\mathbf{h}_k \in \mathbb{R}^{768}$ е скритото състояние на позиция k, а i и j са позициите на `[ENTITY]` и `[/ENTITY]` съответно. Ако маркерите не са намерени или обхватът е невалиден, се използва представянето на `[CLS]` токена като резервен вариант.

Предимствата на ESP са: (1) представянето е фокусирано именно на целевия обект, а не на целия контекст; (2) осредняването е устойчиво на вариации в дължината на споменаването; (3) специалните токени дават възможност на модела да изгради контекстуално зависими представяния на границите на обекта.

5.3 Класификация чрез семантично сходство

За класификатора на грубо ниво заменяме стандартната линейна глава с подход, базиран на *семантично сходство* (Semantic Similarity Head). Идеята е близка до прототипните мрежи [15]: за всеки клас се изгражда опорно представяне (anchor embedding) от името на ролята, а класификацията се свежда до сравнение между представянето на обекта и опорните вектори. Така главата получава лингвистичен сигнал от самите имена на ролите („Protagonist „Antagonist „Innocent"), което е особено ценно при малко данни и силен класов дисбаланс. Този подход се прилага само на грубо ниво. Финият класификатор използва различна архитектура - MLP с меко йерархично обуславяне (§5.7, §5.10).

5.3.1 Генериране на опорни представяния

Опорните вектори се генерират по следната процедура:

1. зарежда се името на всеки етикет от таксономията (напр. „Protagonist", „Guardian", „Victim");
2. името се подава през XLM-RoBERTa-base (същия енкодер, използван за входния текст);
3. представянето на `[CLS]` токена се извлича като опорен вектор с размерност $\mathbb{R}^{768}$.

За грубия класификатор се генерират 3 опорни вектора (по един за всяка основна роля). Векторите се изчисляват веднъж и след това се замразяват: те служат като

фиксирани референтни точки в пространството на представянията, така че по време на обучението се настройват само енкодерът и проекцията, а не самите цели на класификацията.

5.3.2 Проекция и косинусово подобие

Представянето на обекта $\mathbf{e} \in \mathbb{R}^{768}$ се преобразува чрез проекционен слой с LayerNorm:

$$\mathbf{z} = \mathrm{LayerNorm}\big(\mathbf{W}_p\mathbf{e} + \mathbf{b}_p\big) \tag{5.2}$$

където $\mathbf{W}_p \in \mathbb{R}^{768\times768}$. След нормализация на проектираното представяне и опорните вектори по L_2 нормата се изчислява косинусово подобие:

$$s_c = T \cdot \cos(\mathbf{z}, \mathbf{a}_c) = T \cdot \frac{\mathbf{z}^\top \mathbf{a}_c}{\|\mathbf{z}\| \cdot \|\mathbf{a}_c\|} \tag{5.3}$$

където $\mathbf{a}_c$ е опорният вектор за клас c, а $T = 15{,}0$ е температурен параметър [16], който скалира стойностите на подобието в подходящ диапазон за softmax функцията. Без температурно скалиране стойностите на косинусовото подобие (в интервала $[-1, 1]$) биха били твърде малки за ефективно обучение чрез кръстосана ентропия.

Резултатът е вектор от 3 логита $\mathbf{s} \in \mathbb{R}^3$, който се подава на softmax за получаване на вероятности.

5.4 Класово балансирана кръстосана ентропия (CB-CE) за грубо ниво

Анализът на базовия модел (Секция 4.3) показа систематично отклонение към Antagonist (+43 излишни предсказания). За справяне с този проблем в класификатора на грубо ниво заменяме стандартната кръстосана ентропия с класово балансирана кръстосана ентропия (Class-Balanced Cross-Entropy, CB-CE) [12], описана в Секция 2.5. Теглата се изчисляват чрез ефективния брой проби (Уравнение 2.3) с $\beta = 0{,}9999$. Броят n_c за всеки клас идва от тренировъчното множество (Antagonist: 2120, Protagonist: 1521, Innocent: 852).

CB-CE представлява обобщение на стандартното претегляне: при $\beta \to 0$ теглата се изравняват (без претегляне), а при $\beta \to 1$ клонят към обратната честота $w_c \propto 1/n_c$. Хиперпараметърът β позволява плавно интерполиране между двата случая, което е особено полезно при умерен дисбаланс - какъвто е нашият (съотношение $\sim$2,5:1 между най-големия и най-малкия клас). Изборът $\beta = 0{,}9999$ е препоръчван от Cui et al. при дисбалансирани данни със стотици проби на клас. Тази стойност е достатъчно близо до 1, за да е почти еквивалентна на чисто обратно-честотно

претегляне, но избягва числената нестабилност на $\beta = 1$, която би довела до изродени тегла при много редки или липсващи класове. В нашия случай $E_n \approx n_c$ и теглата w_c се различават с под 4% от чисто обратно-честотните, но леко смекченото претегляне намалява риска от свръхкомпенсация в полза на миноритарния клас Innocent.

Изследването на приноса на компонентите (Секция 6.9.2) показва, че CB-CE води до подобрение от 3,63 процентни пункта в претеглен F1 на грубото ниво спрямо стандартна кръстосана ентропия (81,68% срещу 78,05%) и 3,48 процентни пункта в точно съвпадение (44,54% срещу 41,06%). Спрямо чисто обратно-честотното претегляне (Weighted CE) подобрението е по-малко (0,49 пункта в Coarse F1), което съответства на теоретичното очакване, че при умерен дисбаланс двата подхода дават близки резултати.

5.5 Класификатор на грубо ниво

Пълната архитектура е:

1. **Кодиращ блок:** XLM-RoBERTa-base с 6 размразени Transformer слоя (слоеве 6–11). Слоеве 0–5 са замразени за запазване на общите лингвистични представяния.

2. **Entity span pooling:** осредняване на скритите състояния между маркерите (Уравнение 5.1).

3. **Класификационна глава:** семантично сходство с 3 опорни вектора и $T = 15{,}0$ (Уравнение 5.3).

4. **Функция на загубата:** Class-Balanced Cross-Entropy с $\beta = 0{,}9999$.

Таблица 5.1: Хиперпараметри за обучение на класификатора за грубо ниво.

Параметър	**Стойност**
Базов модел	`xlm-roberta-base` (278M параметъра)
Размразени Transformer слоеве	6 (слоеве 6–11 от 12)
Макс. дължина на поредицата	512 токена
Класификационна глава	Семантично сходство
Функция на загубата	CB-CE ($\beta = 0{,}9999$)
Брой епохи	10
Размер на партидата	9
Скорост на обучение	6×10^{-5}
Разгряване	10% от стъпките
Тегловно затихване	0,0
Отпадане (Dropout)	0,0
Оптимизатор	AdamW [17]

Размразяването на 6 от 12-те Transformer слоя е компромис между изразителна сила и риска от overfitting при сравнително малкия корпус. Скоростта на обучение, размерът на партидата и липсата на регуляризация (weight decay и dropout = 0) са установени емпирично, тъй като по-агресивни стойности водеха до по-нестабилно обучение.

5.6 Асиметрична загуба за фино ниво

За многоетикетната класификация на фино ниво стандартната BCE е неподходяща поради екстремния дисбаланс (средна кардиналност ∼1,1 при 22 етикета, т.е. съотношение ∼1:20 за всеки етикет). При такъв дисбаланс отрицателните примери доминират градиента и моделът се научава да предсказва „всичко нула без реално да разграничава класовете. Използваме асиметрична загуба (Asymmetric Loss, Секция 2.5), допълнена с регуляризация на кардиналността.

5.6.1 Конфигурация на ASL

Параметрите на ASL са: $\gamma^+ = 0{,}0$ (без фокусиране за положителни примери), $\gamma^- = 2{,}0$ (агресивно намаляване на лесните отрицателни) и марж за отместване на вероятностите $m = 0{,}05$. Изборът на $\gamma^+ = 0$ се обосновава с наблюдението, че положителните примери са малко и всеки от тях е информативен - фокусирането би допълнително намалило и без това малкия им принос. Стандартната препоръка на Ben-Baruch et al. е $\gamma^- = 4$, но при нашия силно дисбалансиран корпус тази стойност

доведе до по-ниски резултати (всички вероятности клонят към нула), затова приехме $\gamma^- = 2$ - компромис, при който отрицателните остават подтиснати, но позитивните не се изпускат напълно. Маржът $m = 0{,}05$ съответства на стандартната стойност от paper-a - отрицателни примери с предсказана вероятност под 5% се игнорират изцяло.

5.6.2 Ентропийна регуларизация

Имплементирана е допълнителна ентропийна регуляризация, която предотвратява прекомерно неуверени предсказания:

$$\mathcal{L}_{\text{ent}} = -\frac{1}{N \cdot L} \sum_{n=1}^{N} \sum_{l=1}^{L} \left[p_{nl} \log p_{nl} + (1 - p_{nl}) \log(1 - p_{nl}) \right] \tag{5.4}$$

където $p_{nl} = \sigma(z_{nl})$ е сигмоидната вероятност за етикет l на пример n. Тази регуларизация наказва неуверени предсказания (вероятности, близки до 0,5), като насърчава модела да прави по-категорични решения за всеки етикет. Теглото е $\lambda_{\text{ent}} = 0{,}15$. При най-добрата конфигурация този член не е активиран, но е изследван при анализа на приноса на компонентите.

5.7 Меко йерархично обуславяне

Между грубия и финия класификатор трябва да тече информация - предсказването на детайлната роля зависи от това към коя основна роля принадлежи обектът. Разглеждаме два подхода:

Твърдо маскиране (hard masking) занулява логитите на детайлни роли, несъвместими с предсказаната основна роля. Например, ако обект е класифициран като Protagonist, логитите за всички Antagonist и Innocent подроли стават $-\infty$. Така грешка на грубо ниво неизбежно елиминира верния отговор на фино ниво.

Меко обуславяне (soft conditioning) [18] използва вероятностите от грубия класификатор като *меки предварителни тегла* за финия, така че несигурността от грубото ниво се разпространява надолу. Реализираме това чрез обучаем *йерархичен афинитетен слой*.

5.7.1 Йерархичен афинитетен слой

Слоят съдържа обучаема матрица $\mathbf{A} \in \mathbb{R}^{3 \times 22}$, инициализирана от таксономията:

$$A_{ij} = \begin{cases} +2{,}0 & \text{ако детайлна роля } j \text{ принадлежи на основна роля } i \\ -2{,}0 & \text{в противен случай} \end{cases} \tag{5.5}$$

Тази инициализация кодира структурата на таксономията: при инициализация слоят наподобява твърдото маскиране (валидни роли получават голям положителен принос, невалидни - голям отрицателен). Слоят обаче е обучаем, така че по време на обучение моделът може да отслаби строгата йерархия там, където данните го налагат - например, ако определена детайлна роля се среща и в контекст на повече от една основна роля.

5.7.2 Изчисляване на предварителните тегла

За вектор от вероятности $\mathbf{p}_{\text{coarse}} \in \mathbb{R}^3$ от грубия класификатор, йерархичните предварителни тегла се изчисляват като:

$$\mathbf{h}_{\text{prior}} = \mathbf{p}_{\text{coarse}} \cdot \mathbf{A} \tag{5.6}$$

Резултатът $\mathbf{h}_{\text{prior}} \in \mathbb{R}^{22}$ съдържа стойности, отразяващи степента на съвместимост на всяка детайлна роля с предсказаната основна категория.

5.7.3 Комбиниране на логити с предварителните тегла

Финалните логити за финия класификатор се получават чрез събиране:

$$\mathbf{z}_{\text{fine}} = f(\mathbf{e}) + \mathbf{h}_{\text{prior}} \tag{5.7}$$

където $f(\mathbf{e})$ е изходът на проекционния MLP (описан в Секция 5.10), а $\mathbf{h}_{\text{prior}}$ са йерархичните предварителни тегла. Адитивното комбиниране позволява на проекционния MLP да надделее над тях при достатъчно силни доказателства в данните.

Изследването на приноса на компонентите (Секция 6.9.5) показва, че мекото обуславяне води до значително подобрение спрямо твърдото маскиране: EMR от 44,54% срещу 0,00%.

5.8 Регуларизация на кардиналността

Анализът на данните (Фигура 3.1) показва, че средният брой детайлни етикети на обект е приблизително 1,1. За да ориентираме модела към реалистичен брой предсказания, въвеждаме квадратичен регуляризатор на кардиналността с целева стойност $k = 1{,}5$. Тази стойност е избрана малко над емпиричната средна, защото ASL има тенденция да подценява положителните класове - леко по-висока цел компенсира това отклонение.

$$\mathcal{L}_{\text{card}} = \lambda_{\text{card}} \cdot \frac{1}{N} \sum_{n=1}^{N} \left(\sum_{l=1}^{L} \sigma(z_{nl}) - k \right)^2 \tag{5.8}$$

където $\sigma(z_{nl})$ е сигмоидната вероятност за етикет l на пример n, $k = 1{,}5$ е целевата кардиналност, а $\lambda_{\text{card}} = 0{,}3$ е теглото на регуларизацията.

Тази регуларизация действа като мек ограничител: тя не забранява повече или по-малко етикети, а наказва отклонения от целевата стойност квадратично. При $\lambda_{\text{card}} = 0$ (без регуларизация) моделът има тенденция да предсказва повече етикети, което намалява прецизността (Секция 6.9.4).

5.9 Относителен праг

При многоетикетна класификация стандартният подход е да се прилага фиксиран праг τ (напр. $\tau = 0{,}5$) на сигмоидните вероятности. Ние предлагаме *относителен праг*, чиято стойност се изчислява за всеки пример спрямо най-високата вероятност в неговия изход.

5.9.1 Алгоритъм

За всеки пример с вектор от вероятности $\mathbf{p} = \sigma(\mathbf{z}_{\text{fine}}) \in [0, 1]^{22}$:

1. Определяме максималната вероятност: $p_{\max} = \max_l p_l$.
2. Изчисляваме адаптивен праг: $\tau_{\text{gap}} = r \cdot p_{\max}$, където $r = 0{,}7$ е коефициент на разлика (gap ratio).
3. Ефективният праг е: $\tau_{\text{eff}} = \max(\tau, \tau_{\text{gap}})$, където $\tau = 0{,}25$ е минимален абсолютен праг.
4. Избираме етикетите с $p_l \geq \tau_{\text{eff}}$, с ограничения за минимум 1 и максимум 3 етикета.

5.9.2 Обосновка

Относителният праг решава два проблема:

- **При уверен модел** ($p_{\max} = 0{,}9$): $\tau_{\text{gap}} = 0{,}7 \cdot 0{,}9 = 0{,}63$, $\tau_{\text{eff}} = 0{,}63$. Само етикети с висока вероятност се приемат, което увеличава прецизността.
- **При неуверен модел** ($p_{\max} = 0{,}3$): $\tau_{\text{gap}} = 0{,}7 \cdot 0{,}3 = 0{,}21$, $\tau_{\text{eff}} = 0{,}25$ (долна граница). Минималното ограничение гарантира поне един етикет.

Ограничението за максимум 3 етикета е мотивирано от анализа на данните - 99,98% от примерите имат 3 или по-малко детайлни роли.

5.10 Класификатор на фино ниво

Класификаторът за фино ниво обединява всички описани компоненти: ESP, проекционен MLP, меки йерархични предварителни тегла, асиметрична загуба и регуляризация на кардиналността. Тук описваме как те се свързват в един обучаем модул.

5.10.1 Проекционен MLP

Представянето на обекта от ESP (Уравнение 5.1) се преобразува чрез двуслоен MLP. За разлика от грубия класификатор (§5.3), където проекцията е едностепенна и логитите се изчисляват чрез косинусово сходство с опорни вектори, тук финият класификатор директно изчислява 22 логита през нелинейна трансформация. Двуслойната структура (с GELU и LayerNorm) дава достатъчна изразителна мощност за фината 22-класова задача:

$$f(\mathbf{e}) = \mathbf{W}_2 \cdot \mathrm{GELU}\big(\mathrm{LayerNorm}(\mathbf{W}_1\mathbf{e} + \mathbf{b}_1)\big) + \mathbf{b}_2 \tag{5.9}$$

където $\mathbf{W}_1 \in \mathbb{R}^{768\times768}$, $\mathbf{W}_2 \in \mathbb{R}^{22\times768}$, с Dropout (0,1) между GELU и втория линеен слой. Изходът е вектор от 22 логита, по един за всяка детайлна роля.

5.10.2 Обща загуба

Крайната функция на загубата за финия класификатор при най-добре представилата се конфигурация е сума от два компонента:

$$\mathcal{L}_{\text{fine}} = \mathcal{L}_{\text{ASL}} + \lambda_{\text{card}}\mathcal{L}_{\text{card}} \tag{5.10}$$

с $\lambda_{\text{card}} = 0{,}3$.

Имплементиран е и допълнителен член за ентропийна регуляризация $\lambda_{\text{ent}}\mathcal{L}_{\text{ent}}$ (Секция 5.6), който не е активиран при най-добрата конфигурация, но е изследван при анализа на приноса на компонентите.

5.10.3 Хиперпараметри

Таблица 5.2: Хиперпараметри за обучение на класификатора за фино ниво.

Параметър	**Стойност**
Базов модел	`xlm-roberta-base` (278M параметъра)
Размразени Transformer слоеве	6 (слоеве 6–11 от 12)
Макс. дължина на поредицата	512 токена
Проекционен MLP	$768 \to 768 \to 22$ (с LayerNorm, GELU, Dropout 0,1)
Йерархично обуславяне	Меко (обучаема матрица 3×22)
Брой епохи	10
Размер на партидата	6
Скорост на обучение	8×10^{-5}
Разгряване	50 стъпки
Оптимизатор	AdamW [17]
Загуба	ASL ($\gamma^+ = 0{,}0$, $\gamma^- = 2{,}0$, $m = 0{,}05$)
Ентропийна регуларизация	не (налична, но неактивна в финалната конфигурация)
Регуларизация на кардиналност	$\lambda_{\text{card}} = 0{,}3$, цел $k = 1{,}5$
Относителен праг	$\tau = 0{,}25$, $r = 0{,}7$, мин. 1, макс. 3

5.11 Каскадна процедура на обучение

Обучението на двата класификатора се извършва *последователно* (каскадно), а не съвместно (емпиричните обучителни криви и валидационните метрики са представени в Секция 6.2):

1. **Обучение на грубия класификатор.** Моделът се обучава за 10 епохи върху обучителното множество. След обучението избираме най-добрия модел по претеглен F1 на валидационното множество.

2. **Генериране на предсказания за грубо ниво.** Най-добрият модел генерира предсказания (и вероятности) за обучителното, валидационното и тестовото множество.

3. **Обучение на финия класификатор.** Моделът получава като допълнителен вход вектор от вероятности от грубия класификатор ($\mathbf{p}_{\text{coarse}} \in \mathbb{R}^3$). По време на обучение се използват предсказаните вероятности (а не верните етикети), за да отразят шума, който очакваме при извеждане.

4. **Извеждане (inference).** За всеки тестов пример: грубият класификатор дава $\mathbf{p}_{\text{coarse}}$, която се подава на финия класификатор чрез мекото обуславяне, и относителният праг определя крайните етикети.

Използваният хардуер и времената за обучение на двата класификатора са представени в Секция 6.1.3 (глава *Експерименти и резултати*).

Глава 6

Експерименти

В тази глава представяме експерименталната оценка на предложената система. Изследването на приноса на компонентите обхваща 16 експеримента, всеки от които изолира приноса на отделен компонент.

6.1 Постановка на експериментите

6.1.1 Данни

Разпределението на данните е: обучително множество - 4 493 примера (след параграфна декомпозиция), валидационно - 1 124 примера, тестово - 604 примера. Като тестово множество използваме публичното валидационно множество на SemEval-2025 Task 10 от 10 януари 2025 (Секция 3.4); разпределението по езици и роли е представено там.

6.1.2 Метрики

Използваме четири основни метрики за оценка:

- **Претеглен F1 (грубо ниво)** - претеглен F1 на класификатора за грубо ниво (3 класа).
- **Micro-F1 (фино, изолиран)** - Micro-F1 на класификатора за фино ниво при подадени верни основни етикети. Измерва качеството на финия модел изолирано от грешките на грубия.
- **Sample-F1 (фино, end-to-end)** - Sample-F1 за детайлните роли в крайната система (от край до край), при подадени *предсказани* основни етикети. Sample-F1 се изчислява, като F1 се пресмята поотделно за всеки пример (върху множеството от негови етикети) и резултатите се осредняват; това е стандартната метрика за многоетикетна класификация по подзадача 1.

- **Точно съвпадение (Exact Match Ratio, EMR)** - процент на примери, за които предсказаният набор от етикети съвпада *точно* с верния набор. Това е официалната метрика за класиране в подзадача 1 на SemEval-2025.

6.1.3 Хардуер

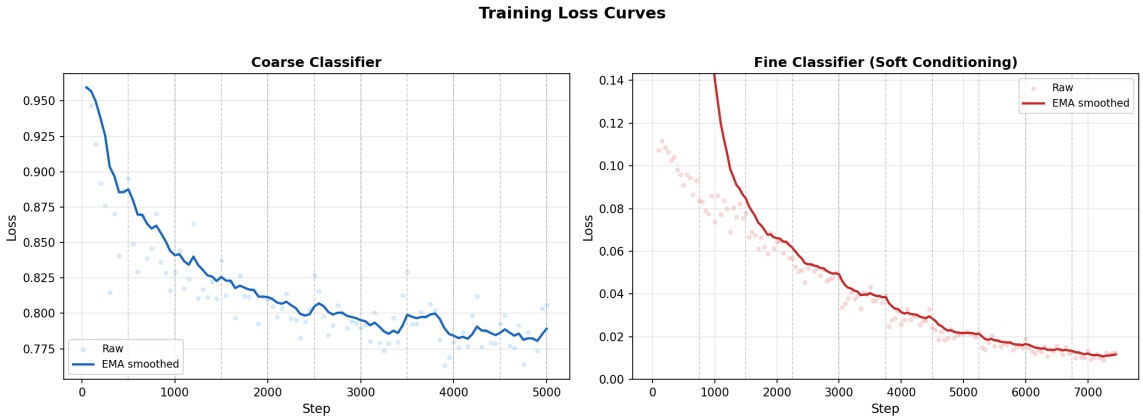
Обучението е проведено на видеокарта NVIDIA GeForce RTX 2060 с 6 GB VRAM с CUDA. Използвана е рамката HuggingFace Transformers [19] v4.x с PyTorch. Обучението на грубия класификатор отнема приблизително 60–90 минути, а на финия - около 120 минути, което дава общо време за обучение на двата класификатора от порядъка на 180–210 минути.

6.2 Обучителни криви и валидация

В тази секция представяме обучителните криви и валидационните метрики за двата класификатора - грубия и финия, обучени по каскадната процедура от Секция 5.11. И двата модела са обучавани с базов модел XLM-RoBERTa-base и същата основа от 6 размразени Transformer слоя (Секции 5.5 и 5.10).

6.2.1 Криви на загубата

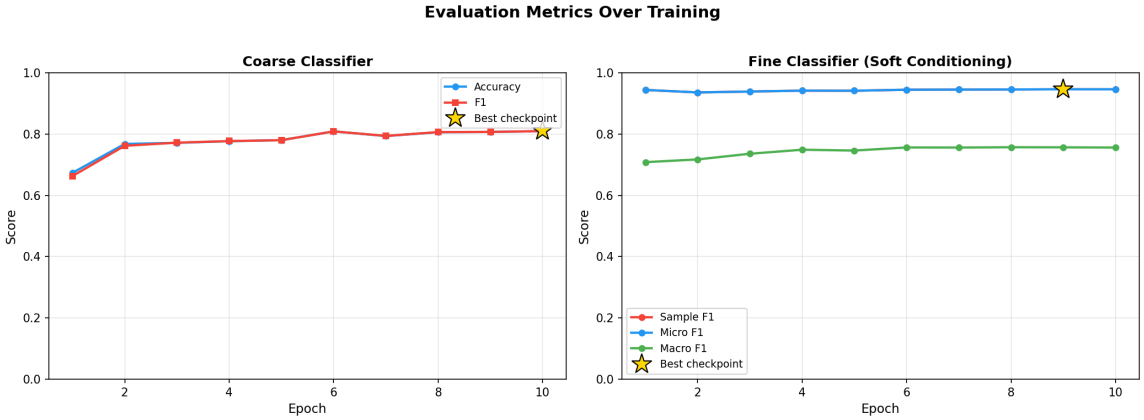
Кривите на загубата при обучение (изгладени с EMA) показват траекторията на загубата по време на обучението. Грубият класификатор намалява от ∼0,96 до ∼0,78 за 5 000 стъпки и стабилизира своята стойност в последните епохи; финият спада от ∼0,14 до ∼0,01 за 7 300 стъпки, без признаци на повторно нарастване, което изключва прекомерно напасване.



Фигура 6.1: Криви на загубата при обучение на грубия и финия класификатор.

6.2.2 Метрики при валидация

Еволюцията на метриките по епохи показва, че грубият класификатор достига най-добра валидация на 10-та епоха (Accuracy и F1 ∼0,81). Финият показва стабилно Micro-F1 ∼0,94 от първата епоха, докато Macro-F1 се подобрява от ∼0,71 до ∼0,76 - индикация, че регуляризацията на кардиналността постепенно подобрява предсказването на редките класове.

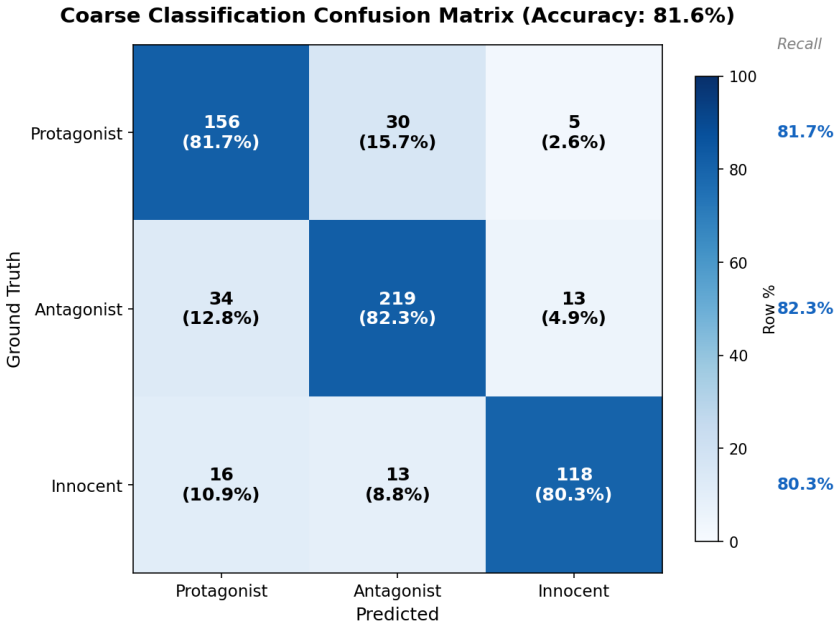


Фигура 6.2: Метрики при валидация по епохи за двата класификатора.

6.3 Резултати на класификатора за грубо ниво

Класификаторът за грубо ниво (Секция 5.5) постига **81,68% претеглен F1** на тестовото множество - подобрение от 14,35 процентни пункта спрямо базовия модел (67,33%).

Класификаторът постига балансиран recall и за трите класа: Protagonist 81,7%, Antagonist 82,3%, Innocent 80,3% - спрямо базовия модел, който не разпознава Innocent (48,3% recall). Основното остатъчно объркване е между Protagonist и Antagonist (30+34=64 примера от тестовото множество).



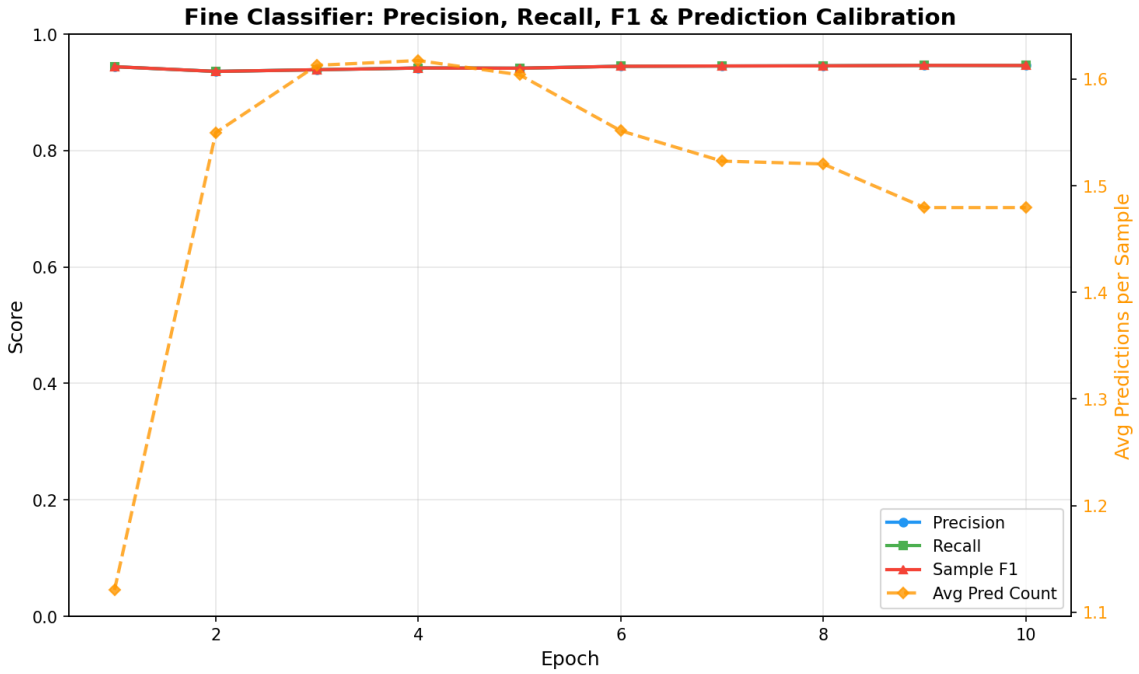
Фигура 6.3: Матрица на объркване за класификатора за грубо ниво на предложената система (604 примера).

6.4 Резултати на класификатора за фино ниво

При подадени *верни* основни етикети (изолирана оценка), финият класификатор постига **93,87% Micro-F1** и **72,28% Macro-F1** на тестовото множество.

6.4.1 Precision, Recall и калибрация на кардиналността

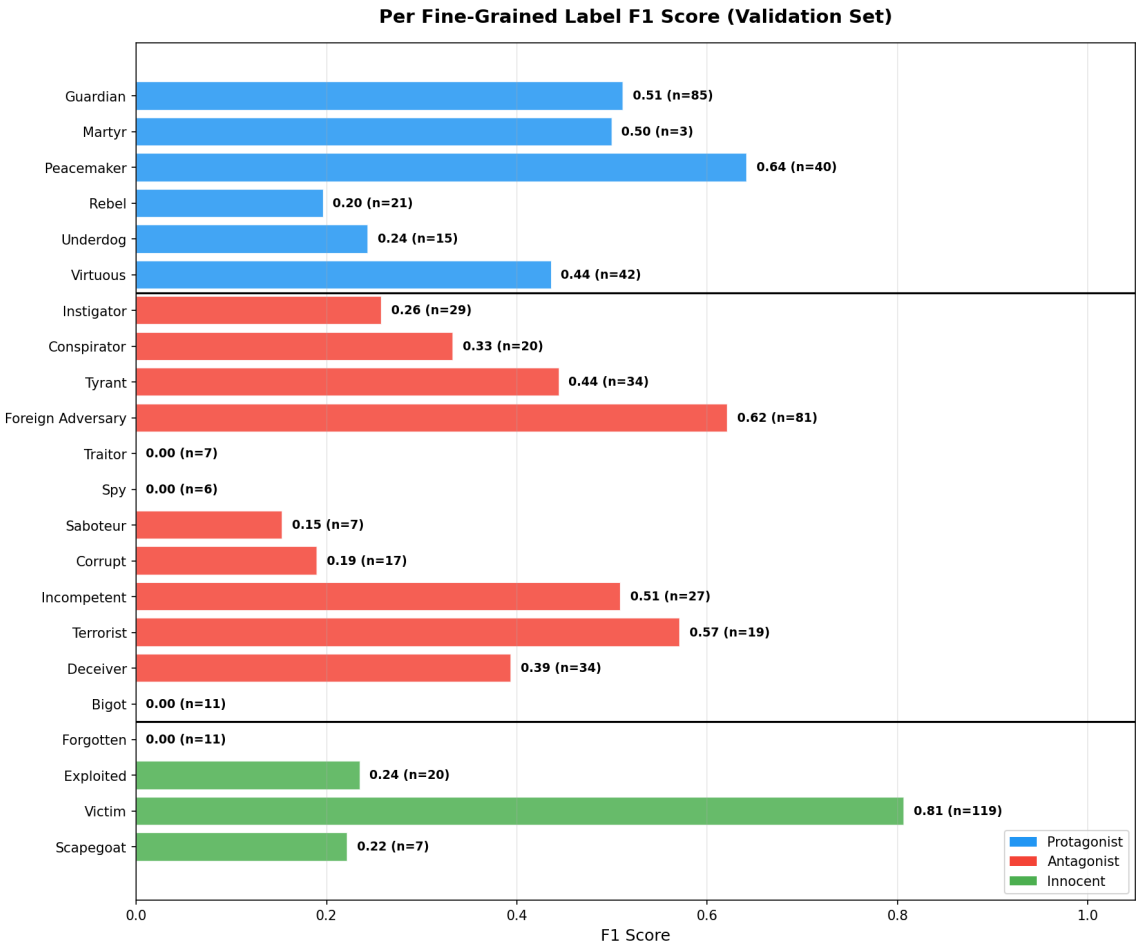
Средният брой предсказани етикети по епохи започва от ∼1,12, достига пик ∼1,62 на 4-та епоха и се стабилизира около 1,48 към края на обучението - близо до целевата кардиналност 1,5. Precision, Recall и Sample-F1 се припокриват около 0,94, което показва добре балансиран модел без систематично свръх- или подпредсказване. Това потвърждава ефективността на регуляризацията на кардиналността с тегло $\lambda_{\text{card}} = 0{,}3$.



Фигура 6.4: Precision, Recall, F1 и среден брой предсказания по епохи за финия класификатор.

6.4.2 F1 по детайлни етикети

Наблюдава се съществена вариация в E2E F1 по детайлни етикети, силно корелираща с броя примери в обучителното множество. Честите етикети постигат добри резултати (Victim: 0,81 при $n = 119$; Foreign Adversary: 0,62 при $n = 81$; Peacemaker: 0,64 при $n = 40$), докато пет редки етикета имат F1=0,00 (Traitor, Spy, Bigot, Forgotten - всеки с $n \leq 11$ в тестовото множество, или 0,15 за Saboteur с $n = 7$).



Фигура 6.5: E2E F1 по детайлни етикети (тестово множество).

6.5 Крайна оценка (от край до край)

Крайната оценка (end-to-end) комбинира предсказанията на двата класификатора в каскада: грубият модел първо предсказва основната роля, след което финият модел предсказва детайлните роли само в съответната подгрупа. За разлика от изолираните оценки в Секции 6.3 и 6.4, тук грешките на грубия се пренасят директно в крайния резултат.

Таблица 6.1: Крайни резултати на предложената система на тестовото множество (604 примера).

Метрика	**Стойност**
Претеглен F1 (грубо ниво)	81,68%
Micro-F1 (фино, изолиран)	93,87%
Sample-F1 (фино, end-to-end)	50,67%
Точно съвпадение (EMR)	44,54%
Средно предсказани етикети/пример	1,15
Средно верни етикети/пример	1,08

Голямата разлика между изолирания Micro-F1 (93,87%) и end-to-end Sample-F1 (50,67%) показва, че грешките на грубия класификатор са основното ограничение на крайната система - когато грубият сгреши, финият работи в грешен клон от йерархията и не може да възстанови верните фини роли. EMR от 44,54% означава, че близо половината примери получават перфектно множество от етикети - силен резултат за многоетикетна класификация с 22 възможни фини роли.

6.6 Сравнение с базовия модел

Стойностите на базовия модел в Таблица 6.2 идват от два отделни класификатора - грубия (Секция 4.3) и финия (Секция 4.4). Предложената система превъзхожда базовия модел по всички ключови метрики - +14,4 процентни пункта по Coarse F1, +11,8 пункта по Fine Sample-F1 и +32,8 пункта по EMR.

Таблица 6.2: Сравнение: базов модел (Глава 4) срещу предложена система.

Метрика	**Базов модел**	**Предложена система**
Претеглен F1 (грубо ниво)	67,33%	**81,68%**
Осредняване по обхват (ESP)	Не (CLS)	Да
Класификационна глава	Линейна	Семантично сходство
Функция на загубата (грубо)	CE	CB-CE
Функция на загубата (фино)	BCE + pos_weight	ASL
Йерархично обуславяне	Не	Меко
Връзка груб → фин	Не (независими модели)	Да (каскада)
Sample-F1 (фино, end-to-end)	38,86%	**50,67%**
Точно съвпадение (EMR)	11,75%	**44,54%**
Размразени слоеве	1	6
Максимална дължина	256	512

Подобренията се натрупват от множество независими промени. Най-съществените са: преходът от BCE+pos_weight към ASL с регуляризация на кардиналността за финия класификатор, въвеждането на CB-CE за грубия и размразяването на 6 вместо 1 Transformer слоя. Изолираните приноси на всеки компонент са изследвани в Секция 6.9. Част от подобрението идва и от увеличената входна дължина (256→512), което не е архитектурна промяна и в бъдеща работа би могло да се изследва отделно.

6.7 Сравнение със състезателни системи

Предложената система постига **44,54% EMR** на тестовото множество (публичното dev множество на SemEval-2025 от 10 януари 2025). Таблица 6.3 съпоставя този резултат с водещите системи в подзадача 1, чиито стойности са на скритото състезателно тестово множество.

Таблица 6.3: Резултати на предложената система спрямо водещите системи от SemEval-2025 Task 10.

Система	**Базови модели**	**Параметри**	**Avg EMR**
DUTIR [4]	GLM-4-Plus, Qwen2.5, Llama 3.1	десетки B	0,475
PATeam	Qwen2.5-72B, Phi-4	72B / 14B	0,421
BERTastic [3]	XLM-R + GPT-4o (API)	278M + API	0,386
LTG [5]	XLM-RoBERTa	278M	0,354
Предложена система	XLM-RoBERTa-base	**278M**	**0,4454**

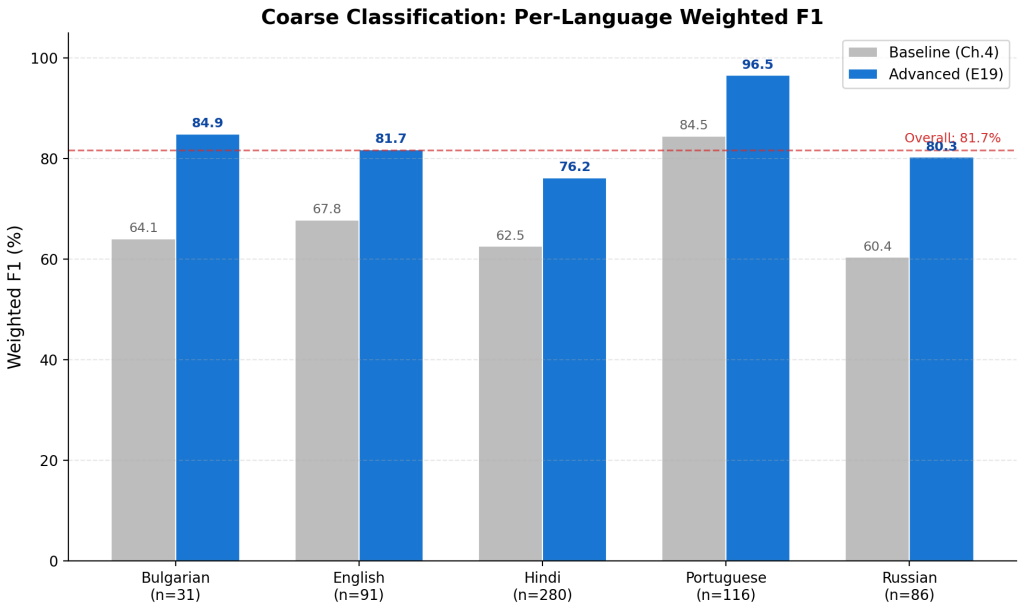
Забележка: Стойностите на състезателните системи са от официалното класиране в [1] на скритото тестово множество. Предложената система е оценена на публичното dev множество от 10 януари 2025. Сравнението е ориентировъчно поради различните множества, но показва къде се намира предложената система в общата картина.

С 278M параметъра и без външно API, предложената система е 30-250 пъти помалка от водещите. Тези системи използват или големи декодерни модели (десетки милиарди параметри), или платено API (GPT-4o). EMR от 44,54% поставя предложената система в обхвата между BERTastic (38,6%) и PATeam (42,1%) - в съседство със системи, които ползват външни API или модели с над 70 милиарда параметри.

6.8 Анализ по езици

Корпусът на SemEval-2025 покрива пет езика - български (BG), английски (EN), хинди (HI), португалски (PT) и руски (RU). Фигура 6.6 сравнява претегления F1 на грубия класификатор по език за базовия модел и предложената система. Подобрение

е видно за всички езици, като най-голям ръст се наблюдава за BG (+20,8 пп) и RU (+19,9 пп).



Фигура 6.6: Претеглен F1 на грубия класификатор по езици - сравнение на базовия модел и предложената система.

Най-голямото подобрение е по разпознаването на Innocent - в базовия модел F1=0,000 за BG и EN (моделът колапсира към мажоритарните класове), докато в предложената система F1 се повишава до 0,29 (BG), 0,67 (EN), 0,79 (HI), 0,97 (PT), 0,63 (RU). Това е заслуга на CB-CE и кардиналностната регуляризация. Все пак BG (n=31) остава най-трудният език - вероятно поради ниската поддръжка в обучителното множество.

6.9 Изследване на приноса на компонентите

Изследването на приноса на компонентите обхваща 16 експеримента по пет основни оси: класификационна глава, загуба за грубо ниво, загуба за фино ниво, регуляризация на кардиналността и тип йерархично обуславяне.

6.9.1 Принос на класификационната глава

Таблица 6.4: Принос на типа класификационна глава.

Грубо ниво	**Фино ниво**	**Coarse F1 (%)**	**E2E Fine F1 (%)**	**EMR (%)**
Semantic	Semantic	79,61	**50,66**	37,09
MLP	Semantic	80,74	32,34	29,30
Semantic	MLP	79,12	49,90	**38,74**
MLP	MLP	80,74	35,29	31,29

Резултатите разкриват асиметрия: MLP главата постига по-висок Coarse F1 (80,74% срещу 79,61%) на изолирана оценка, но семантичната глава води до 18 процентни пункта по-висок E2E Fine F1 (50,66% срещу 32,34%). Едно обяснение е, че опорните вектори на семантичната глава ограничават възможните логити в по-добре отделими посоки, което води до по-калибрирани вероятности при подаване към финия класификатор.

6.9.2 Принос на функцията на загубата за грубо ниво

Таблица 6.5: Принос на функцията на загубата за грубо ниво.

Загуба	**Coarse F1 (%)**	**E2E Fine F1 (%)**	**EMR (%)**
Focal Loss	79,61	50,66	37,09
Cross-Entropy	78,05	50,29	41,06
Weighted CE	81,19	50,44	41,06
CB-CE	**81,68**	**50,67**	**44,54**

CB-CE дава най-добри резултати по всички три метрики. Подобрението спрямо стандартна CE е 3,63 пункта в Coarse F1 и 3,48 пункта в EMR. Фокалната загуба, въпреки доминантната си позиция за дисбалансирани данни, тук отстъпва на CB-CE - при само 3 класа фокусирането върху „трудни примери"не носи същата полза, както при многокласови дисбаланси с десетки класове.

6.9.3 Принос на функцията на загубата за фино ниво

Таблица 6.6: Принос на функцията на загубата за фино ниво.

Загуба	**Параметри**	**Fine μF1 (%)**	**E2E F1 (%)**	**EMR (%)**
Focal	$\gamma = 2{,}0$	95,12	28,56	22,19
ASL	$\gamma^- = 2{,}0$, $\gamma^+ = 1{,}0$	93,78	**51,63**	**42,38**
ASL	$\gamma^- = 2{,}0$, $\gamma^+ = 0{,}0$	92,50	50,66	37,09
ASL	$\gamma^- = 4{,}0$, $\gamma^+ = 1{,}0$	92,46	32,36	25,99

Показателно е, че фокалната загуба постига най-висок Fine μF1 (95,12%) при изолирана оценка, но най-нисък E2E F1 (28,56%). ASL с умерени параметри показва най-добрия баланс. Резултатите тук са с фиксирана груба загуба (Focal)

6.9.4 Принос на регуларизацията на кардиналността

Таблица 6.7: Принос на регуларизацията на кардиналността.

λ_{card}	**Fine μF1 (%)**	**E2E F1 (%)**	**EMR (%)**
0,0 (без)	94,92	25,97	22,35
0,3	92,50	50,66	37,09
0,5	92,69	**53,33**	40,73

Без регуларизация ($\lambda_{\text{card}} = 0$) моделът предсказва повече етикети от реалното, което води до драстичен спад на E2E F1 (25,97%). Регуларизацията с $\lambda_{\text{card}} = 0{,}3$ почти удвоява E2E F1, а $\lambda_{\text{card}} = 0{,}5$ дава най-висок E2E F1, но по-нисък EMR. Стойността $\lambda_{\text{card}} = 0{,}3$ е избрана като компромис.

6.9.5 Меко срещу твърдо обуславяне

Таблица 6.8: Меко срещу твърдо йерархично обуславяне.

Обуславяне	**Fine μF1 (%)**	**E2E F1 (%)**	**EMR (%)**
Меко	93,87	**50,67**	**44,54**
Твърдо	67,86	31,13	0,00

Мекото обуславяне значително превъзхожда твърдото маскиране по всички метрики: EMR = 44,54% срещу 0,00% и Fine μF1 = 93,87% срещу 67,86% дори при изолирана оценка. Важно е да се отбележи, че двата подхода се различават не само по маскирането: мекото обуславяне включва и регуляризация на кардиналността, която твърдият вариант няма. Затова разликата отразява предимството на мекия подход в неговата цялост. Мекото обуславяне запазва градиентите към всички класове и позволява на финия класификатор да компенсира частично грешките от грубо ниво.

6.10 Анализ на грешките

За по-задълбочено разбиране на грешките, класифицираме тестовите примери в четири категории:

1. **coarse_wrong** (18,4%) - основната роля е грешна. Това автоматично влияе и на детайлните роли, особено при твърдо маскиране.

2. **fine_missing** (∼35%) - основната роля е вярна, но един или повече верни детайлни етикети са пропуснати.

3. **fine_extra** (∼37%) - основната роля е вярна, но са добавени излишни детайлни етикети.

4. **perfect** (44,54%) - предсказаният набор от етикети съвпада точно с верния (EMR).

Забележка: категориите **fine_missing** и **fine_extra** не са взаимно изключващи се - един пример може едновременно да има пропуснати и излишни етикети, в който случай се брои и в двете.

Основният източник на грешки е каскадното разпространение от грубо към фино ниво. При 81,68% F1 на грубо ниво, 18,4% от примерите тръгват с грешен контекст. Мекото обуславяне смекчава този ефект, но не може напълно да го елиминира - подобрението на грубия класификатор остава най-важният фактор за крайната производителност.

Глава 7

Разработка на прототип на интерактивно приложение

В тази глава описваме разработеното интерактивно приложение за демонстрация на системата и реализирания модул за анализ на приноса на думите и фразите. Двата компонента са изградени върху вече обучената система (Глава 5) и не изискват повторно обучение или промяна на архитектурата.

7.1 Описание на приложението

Приложението представлява уеб-базиран инструмент за демонстрация на обучената система, който позволява класификация на произволен новинарски текст на всеки от петте езика на задачата без нужда от команден ред или познания по програмиране. То има две основни предназначения: да направи системата достъпна за директно изпробване от потребител и да служи като средство за качествен анализ, чрез което да се проследи как моделът достига до конкретно решение. От тях произтичат и функционалностите: въвеждане и класификация на текст с визуализация на предсказаните основни и детайлни роли, предзаредени примери на различни езици, анализ на приноса на отделните думи и фрази към решението (Секция 7.2), както и кеширане на резултатите за плавно интерактивно изследване.

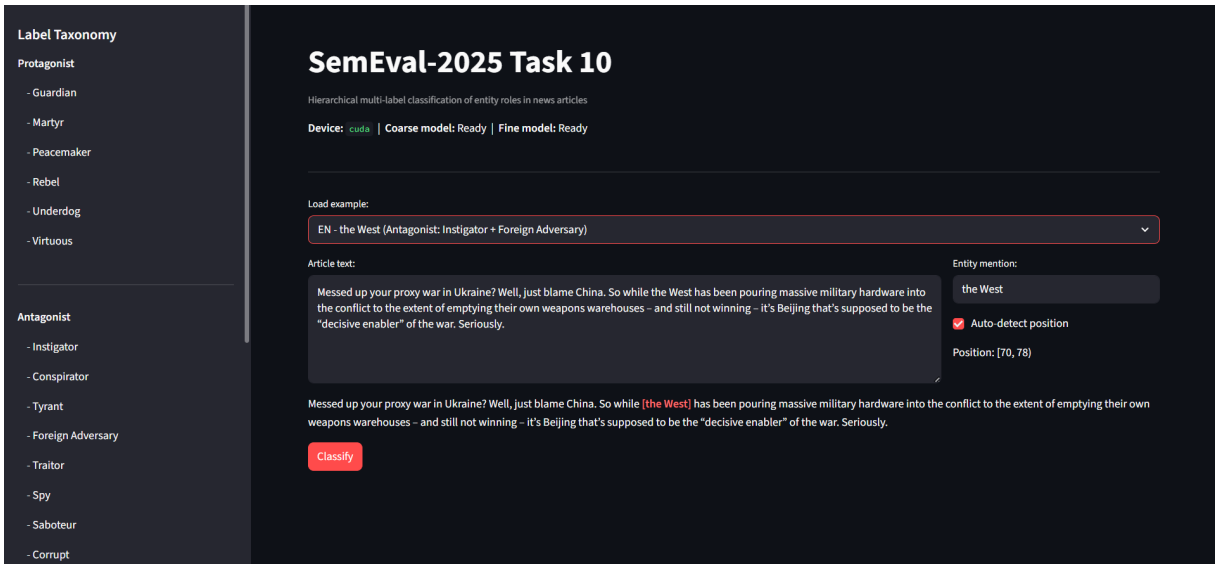
Приложението е реализирано с библиотеката Streamlit 1.56 върху PyTorch 2.9 и HuggingFace Transformers 4.57.

7.1.1 Основен поток

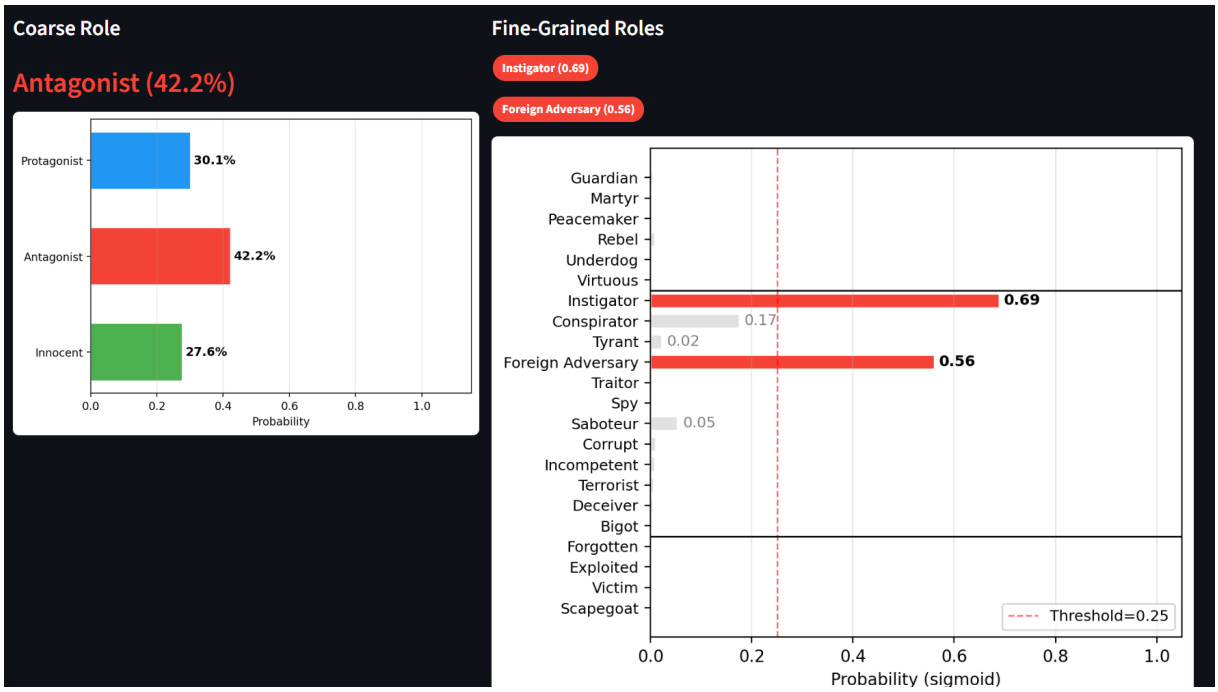
Потребителят въвежда новинарски текст, споменаване на обекта и началната му позиция в текста (или активира опцията за автоматично намиране на позицията). Системата изпълнява пълната каскадна обработка от Глава 5: маркиране на обекта с токените `[ENTITY]`/`[/ENTITY]`, токенизация, преминаване през грубия класифика-

тор, след което финия. Резултатите се визуализират като два панела - вероятностна диаграма за трите основни роли и вероятностна диаграма за 22-те детайлни роли, групирани по основна категория.

Предложени са шест случайно избрани примера, които покриват три езика (английски, български и хинди) и разнообразни комбинации от роли - включително случаи с повече от една предсказана детайлна роля. Страничният панел показва пълната таксономия (Таблица 3.1) за справка.



Фигура 7.1: Интерфейсът на приложението при въвеждане на текст. Потребителят избира предзареден пример или въвежда произволен текст, а споменаването на обекта се маркира автоматично (в оранжево).



Фигура 7.2: Резултати от класификацията за обекта “the West” (EN). Вляво - вероятностите за трите основни роли (предсказана: Antagonist, 42.2%); вдясно - вероятностите за 22-те детайлни роли, с подчертани предсказани роли Instigator (0.69) и Foreign Adversary (0.56).

7.1.2 Управление на кеша

Предсказанията и резултатите от анализа на приноса (Секция 7.2) се съхраняват в `st.session_state`. Ключът за кеширане включва хеш на маркирания текст, задачата (грубо/фино), целевия клас и метода. Благодарение на това превключването между разделите или промяната на параметъра top-K не предизвиква повторно изчисление. Кешът се изчиства при всяко ново натискане на бутона *Classify*.

7.2 Анализ на приноса на думите

Класификационната система взема решения въз основа на контекста около обекта, но самото решение е непрозрачно - не е ясно кои думи или фрази са го обусловили. Модулът за анализ на приноса отговаря на този въпрос: за всяко предсказание визуализира кои части от текста са допринесли най-много за избраната роля и в каква посока.

7.2.1 Обзор на методите за атрибуция

При класификационни модели, базирани на Transformer архитектура, въпросът “коя дума е накарала модела да предскаже тази роля?” е нетривиален - информаци-

ята се разпространява нелинейно из всички слоя на самовнимание. В литературата са предложени четири основни класа методи за отговор на този въпрос.

Методи на пертурбация. Заменят части от входа и измерват промяната в изхода. Ключово предимство на тези подходи е че работят независимо от конкретния модел - не изискват достъп до градиентите или вътрешната структура на модела, само до изхода му. LIME [20] обучава локален линеен апроксимиращ модел около всяко предсказание; SHAP [21] изчислява Shapley стойности - теоретично обосновано разпределение на приноса между признаците, произлизащо от теорията на кооперативните игри. За невронни мрежи SHAP се прилага като KernelSHAP, чийто брой изчислителни проходи нараства линейно с броя токени и типично достига хиляди за стандартен абзац.

Методи, базирани на градиенти. Изчисляват чувствителността на изхода спрямо входните вграждания чрез обратно разпространение на грешката. Методът Gradient (или Saliency) [22] взема директно абсолютната стойност на градиента; Gradient $\times$ Input умножава градиента по самото вграждане; Integrated Gradients [23] интегрира градиентите по права линия от неутрална базова линия до входа в $m \geq 50$ стъпки, с което изпълнява теоретично желани аксиоми за атрибуция (чувствителност и инвариантност към имплементацията); SmoothGrad [24] усреднява градиенти при добавен шум, за да намали визуалния шум. Тези методи изискват само един (или m) проход (forward/backward pass) и са бързи, но дават линейна апроксимация.

Методи на базата на вниманието. Използват attention scores от Transformer слоевете. Достъпни без допълнителни изчисления, но надеждността им като обяснение е оспорена: Jain и Wallace [25] показват, че вниманието може да се пренареди, без да се промени предсказанието, откъдето следва, че то не е обяснение само по себе си. По-надеждни варианти са Attention Rollout [26], който проследява информационния поток между слоевете чрез матрично произведение на attention матриците, и Attention $\times$ Gradient, който комбинира attention тегла с градиенти.

Разпространение на релевантността (LRP и ALTI). Layer-wise Relevance Propagation (LRP) разпространява "доказателства за предсказанието" назад от изхода до входа по специфични правила за всеки тип слой [27]. ALTI (Aggregating Layerwise Token Importance) [28] е специализиран за Transformer модели вариант, който агрегира значимостта на токените слой по слой, като отчита и остатъчните връзки. Тези методи дават по-пълна картина на информационния поток, но изискват промени в реализацията на модела.

Integrated Gradients и SHAP са широко приети като теоретично строги методи за атрибуция. Integrated Gradients изисква интерполация на вграждането между базова линия и входа в $m \geq 50$ стъпки [23]; SHAP изисква стотици изчислителни проходи за надеждни Shapley стойности [21]. LRP и ALTI пък изискват директен достъп до вътрешните активации и промени в архитектурата. При нашите ограничения (виде-

окарта NVIDIA GeForce RTX 2060 с 6 GB VRAM, изчислително време от порядъка на секунди, без промяна на вече обучения модел) тези подходи надвишават практическите изисквания. Избираме по-бързи варианти със сходна обяснителна стойност: оклузия на ниво дума, оклузия на ниво фраза и Градиент × Вграждане.

7.2.2 Оклузия на ниво дума

Методът е предложен за NLP от Li et al. [29] и следва директна идея: за всяка валидна позиция w в контекста заменяме съответния токен с `<mask>` и измерваме промяната в непреобразувания логит за целевия клас:

$$s_w = \ell(x) - \ell(x \setminus w) \tag{7.1}$$

Положителна стойност означава, че думата подкрепя предсказаната роля; отрицателна - че ѝ противодейства. За ефективност всички валидни позиции се обработват в един пакет с размер 32. От анализа се изключват служебните позиции (CLS, SEP, PAD), маркерите `[ENTITY]` / `[/ENTITY]` и токените в обхвата на обекта, тъй като entity span pooling (Уравнение 5.1) разчита на маркерите за локализиране на $\mathbf{e}$ и маскирането им би разрушило механизма.

И за грубото, и за финото ниво работим със суров логит, а не с вероятност. Причината е, че вероятностите въвеждат насищане: при уверени предсказания стойността на sigmoid или softmax е близо до 0 или 1 и маскирането измества изхода с незначими делти, докато логитът е неограничен и остава чувствителен независимо от увереността на модела. При финото ниво има и допълнителна полза - логитът е $z = f(\mathbf{e}) + \mathbf{h}_{\text{prior}}$ (Уравнение 5.7), а тъй като $\mathbf{h}_{\text{prior}}$ е константен при фиксиран $\mathbf{p}_{\text{coarse}}$, той се съкращава в делтата $\Delta z = z_{\text{orig}} - z_{\text{masked}}$ и така измерваме само приноса на контекстните думи към $f(\mathbf{e})$.

7.2.3 Оклузия на ниво фраза

Разширяваме стандартната оклузия от ниво токен до ниво фраза: вместо един токен, маскира се цяла фраза от k последователни думи. Това дава по-силен и по-чист сигнал - при силно контекстуализирани токени индивидуалните делти са малки, но ефектът им се сумира при фразово маскиране. Фразите не пресичат границите на изреченията, като разделянето се извършва чрез NLTK `sent_tokenize`, а размерът k се избира автоматично (от 1 до 4 думи) така, че общият брой фрази да не надхвърля максимум 10.

Разделянето с фиксирана дължина е съзнателно опростен подход. Синтактичният анализ би дал лингвистично по-обосновани граници, но надеждни парсъри за всичките пет езика на задачата не са налични, а дори за английски те връщат мес-

тоимения и функционални думи, които внасят шум. Разработването на по-прецизен многоезичен метод остава насока за бъдещо развитие.

7.2.4 Градиент × Вграждане (Gradient × Embedding)

Методът е адаптация на Gradient × Input [22] за текстови модели: вместо скаларни входни стойности, градиентът се умножава по вградените векторни представяния на токените. За всеки токен t с вградено представяне $\mathbf{e}_t \in \mathbb{R}^D$ изчисляваме точковото произведение между градиента на логита и самото представяне:

$$s_t = \nabla_{\mathbf{e}_t} \ell \cdot \mathbf{e}_t = \sum_{d=1}^{D} \frac{\partial \ell}{\partial e_{t,d}} \cdot e_{t,d} \tag{7.2}$$

Приносът на едно измерение d е голям само ако токенът е голям в това измерение u логитът е чувствителен точно там. Чрез умножението двете условия трябва да са изпълнени едновременно - едно само по себе си не е достатъчно. При изпълнение се регистрира hook върху вградения слой `word_embeddings`, който запазва изходния тензор на вграждането и позволява изчисляване на градиента му чрез `retain_grad()`. След един обратен проход стойността за всеки токен t се изчислява директно като `(emb.grad * emb).sum(dim=-1)`, идентично с Уравнение 7.2. Ако hook-ът не улови градиента, методът връща `None` и потребителският интерфейс автоматично превключва на оклузия на ниво дума.

Ограничения. Методът е линейна апроксимация и не отчита нелинейни взаимодействия между токени. Засегнат е и от пристрастие към нормата на вграждането: по-редките думи в речника на XLM-RoBERTa обикновено имат по-голяма L_2-норма, което може да изкриви абсолютната им стойност независимо от семантичния им принос. Методът е подходящ като допълнителна бърза индикация, а не като основен аналитичен инструмент.

7.2.5 Нормализация и визуализация

И трите метода изразяват резултатите като дял от общото влияние (%):

$$\text{share}_w = \frac{s_w}{\sum_i |s_i|} \times 100\% \tag{7.3}$$

Положителна стойност (зелено) означава, че думата подкрепя предсказаната роля; отрицателна (червено) - че ѝ противодейства.

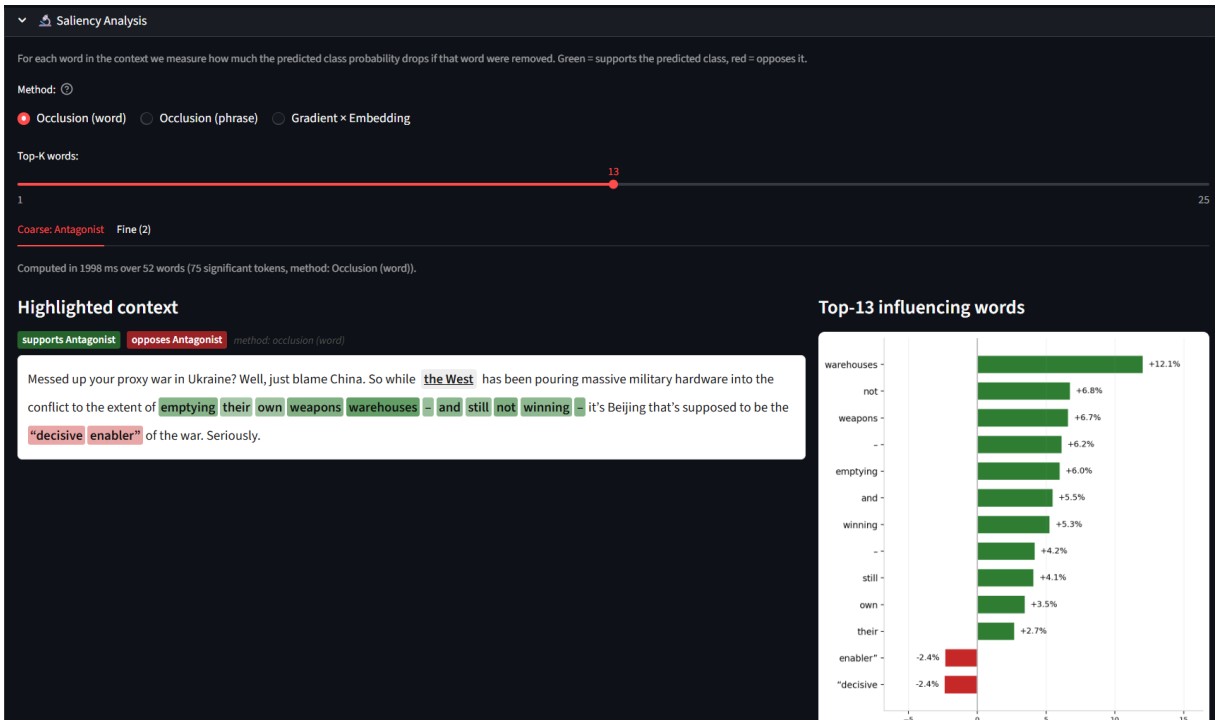
Резултатът се представя в два синхронизирани формата. При първия думите или фразите от топ-K получават зелен или червен фон с интензивност, пропорционална на $|\text{share}_w|$, обектът се обозначава отделно с неутрален фон, а думите извън топ-K

остават без цвят. Вторият формат е хоризонтална лента-диаграма на същия топ-K запис, наредена по $|\text{share}_w|$; при фразовата оклузия последователни думи с еднаква делта стойност се обединяват в единен запис, а дългите фразови етикети се разбиват на редове. Параметърът top-K контролира и двата формата едновременно, а отделните раздели за грубото и финото ниво позволяват сравнение на кои части от текста обуславят двете нива на класификация.

7.3 Примерни резултати

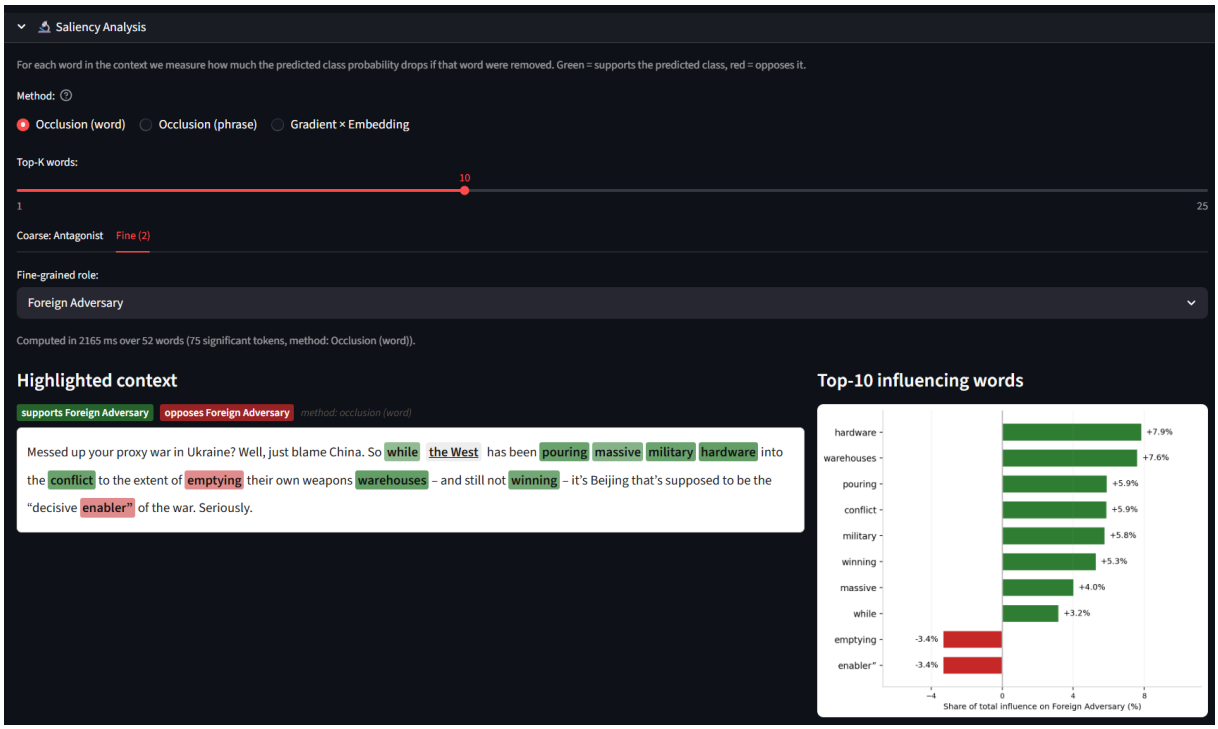
За илюстрация използваме готовия пример “the West” (EN) с предсказани роли Antagonist на грубо ниво и Instigator + Foreign Adversary на фино ниво. Примерът е подходящ за демонстрация, защото текстът съдържа изрична военна лексика, чийто принос моделът трябва да разграничи по нива.

Word Occlusion (грубо ниво). За ролята Antagonist думите “warehouses”, “weapons”, “emptying” и “winning” получават най-висок положителен принос (+12.1%, +6.7%, +6.0%, +5.3%) - военна лексика, свързана с изчерпване на ресурси и агресия, директно подкрепя тази роля. Думите “decisive” и “enabler” имат отрицателен принос (-2.4% всяка) - в контекста на изречението те описват обвинение към трета страна (China), а не директна агресия, и моделът ги оценява като неподкрепящ сигнал за тази роля.



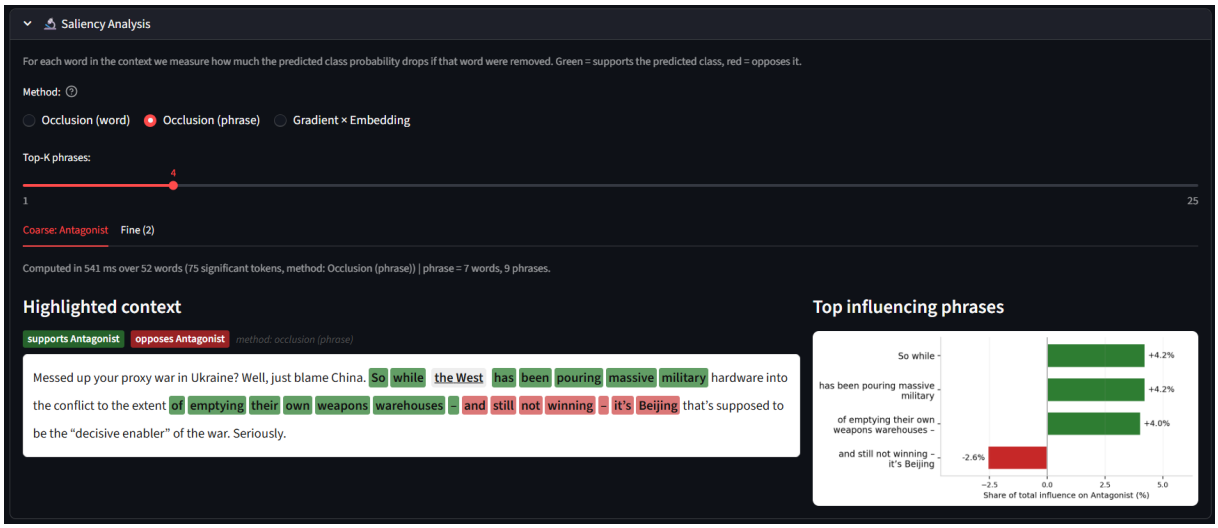
Фигура 7.3: Word Occlusion за ролята Antagonist (грубо ниво). Думи, свързани с военна тематика и изчерпване на ресурси, получават най-висок положителен принос.

Word Occlusion (фино ниво). При превключване към фино ниво за ролята Foreign Adversary разпределението на приноса се измества: водещи стават “hardware” (+7.9%), “pouring” (+5.9%), “conflict” (+5.9%) и “military” (+5.8%). Antagonist се активира от общия военен контекст, докато Foreign Adversary реагира по-специфично на думи, свързани с военна намеса и конфликт.



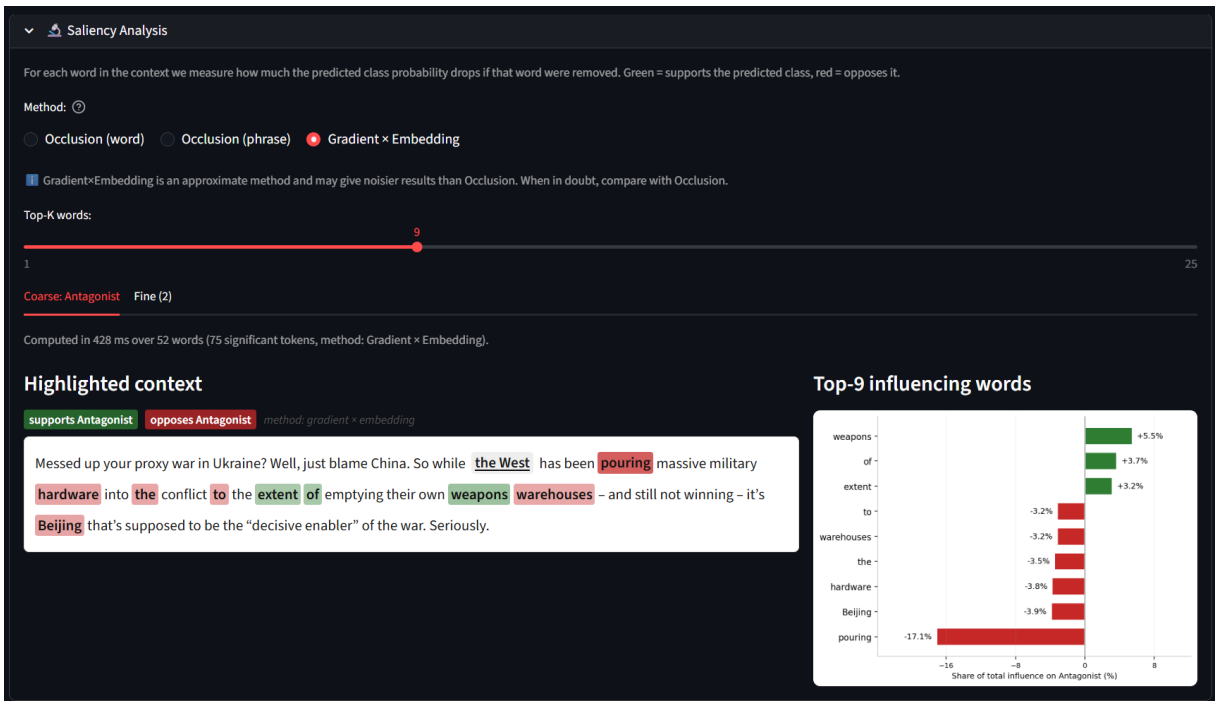
Фигура 7.4: Word Occlusion за ролята Foreign Adversary (фино ниво). Разпределението на приноса се измества към думи, свързани с военна намеса и конфликт, в сравнение с грубото ниво.

Phrase Occlusion. При оклузията по фрази, моделът идентифицира три свързани фрази с висок принос: “So while” (+4.2%), “has been pouring massive military” (+4.2%) и “of emptying their own weapons warehouses” (+4.0%), докато “and still not winning - it’s Beijing” (-2.6%) противодейства. Фразовата оклузия потвърждава наблюденията от оклузията на ниво дума и показва, че военната лексика действа съгласувано като смислова група, а не изолирано.



Фигура 7.5: Phrase Occlusion за ролята Antagonist. Фразата "has been pouring massive military" е идентифицирана като водещ положителен принос.

Gradient × Вграждане. Методът дава по-различна картина: "pouring" (-17.1%) получава силно отрицателна стойност, докато при оклузията е положително. Това е пряка илюстрация на ограничението, описано в Секция 7.2.4 - линейната апроксимация и пристрастието към нормата на вграждането могат да дадат различен знак от пертурбационните методи. Резултатите от двата класа методи следва да се разглеждат съвместно за по-надеждна интерпретация.



Фигура 7.6: Gradient × Вграждане за ролята Antagonist. Резултатите се различават от оклузионните методи, което илюстрира линейната апроксимация на метода.

Глава 8

Заключение

8.1 Обобщение на резултатите

В настоящата работа разработихме и оценихме система за йерархична класификация на ролите на именувани обекти в многоезични новинарски текстове. Системата е двустепенна каскада, базирана на XLM-RoBERTa-base, и включва:

- **Осредняване по обхват на обекта (Entity Span Pooling)** за извличане на представяне, фокусирано върху конкретния обект.
- **Класификация чрез семантично сходство** с опорни вектори, генерирани от имената на етикетите.
- **Класово балансирана кръстосана ентропия (CB-CE)** за компенсиране на класовия дисбаланс на грубо ниво.
- **Асиметрична загуба (ASL) с регуляризация на кардиналността** (целева стойност 1,5) за многоетикетната класификация на фино ниво.
- **Меко йерархично обуславяне** чрез обучаема матрица на афинитет (3×22).
- **Относителен праг** с адаптивен ефективен праг за всеки пример.
- **Интерактивно приложение за демонстрация** (Глава 7), реализирано с Streamlit, което позволява класификация на произволен текст на петте езика на задачата.
- **Модул за анализ на приноса на думите** (Глава 7), предлагащ три метода за атрибуция - оклузия на ниво дума, оклузия на ниво фраза и Градиент × Вграждане - без повторно обучение или промяна на архитектурата.

Системата постига **81,68% претеглен F1** за основната роля (подобрение от 14,35 п.п. спрямо базовия модел) и **50,67% Sample-F1 (фино, end-to-end)** при **44,54% точно съвпадение (EMR)**. Спрямо базовия класификатор за фино ниво (38,86% Sample-F1, 11,75% EMR) подобрението е още по-изразено: +11,81 процентни пункта в Sample-F1 и +32,79 процентни пункта в EMR. За сравнение, водещите системи в SemEval-2025 Task 10 отчитат средно 0,475 EMR (DUTIR) и 0,421 EMR (PATeam) на скритото състезателно тестово множество, докато предложената система постига 0,4454 EMR на публичното dev множество. Сравнението е ориентировъчно поради различните множества, но показва, че малък енкодерен модел (278M параметъра) може да постигне резултати в обхвата на многократно по-големи декодерни системи.

Изследването на приноса на компонентите (16 експеримента) показва приноса на всеки компонент и разкрива два ключови извода: (1) мекото обуславяне, съчетано с регуляризация на кардиналността, значително превъзхожда твърдото маскиране (44,54% EMR срещу 0,00%); (2) регуларизацията на кардиналността почти удвоява E2E F1 (50,66% срещу 25,97% без нея).

8.2 Ограничения

Предложената система има следните ограничения:

1. **Последователно обучение.** Двата класификатора се обучават каскадно, а не съвместно. Грешките от грубия класификатор не могат да бъдат коригирани чрез обратна връзка от финия.

2. **Фиксирани параметри на праговане.** Стойностите $\tau = 0{,}25$, $r = 0{,}7$ са фиксирани и не се оптимизират за конкретния модел или език.

3. **Единичен модел.** Не е приложен ансамблов подход, който би могъл да подобри устойчивостта на предсказанията.

4. **Разлика между перфектен вход и крайна оценка.** Финият класификатор постига 93,87% μF1 при изолирана оценка, но само 50,67% Sample-F1 (фино, end-to-end) - разлика от 43,20 п.п., което показва, че грешките от грубо ниво остават основен ограничаващ фактор.

8.3 Идеи за бъдещо развитие

Идентифицираме няколко перспективни направления за бъдещо развитие:

1. **Съвместно обучение** на двата класификатора с обща функция на загубата, което би позволило обратна връзка от финото към грубото ниво.

2. **По-големи модели.** Използване на XLM-RoBERTa-large (550M параметъра) или многоезични варианти на по-нови модели, което би подобрило както грубото, така и финото ниво.

3. **Подходи с големи езикови модели (LLM).** Работа с промптове или фино настройване на големи генеративни модели (например Llama, Mistral) за директно генериране на ролеви етикети - може да се изследва дали по-голям параметричен капацитет компенсира комплекта от ръчно проектирани компоненти (CB-CE, ASL, кардиналностна регуляризация).

4. **Разширена аугментация.** Използване на обратен превод (back-translation) или парафразиране за обогатяване на обучителното множество, особено за езици с малко данни (български, руски).

5. **Оптимизация на прага.** Автоматично настройване на параметрите на относителния праг чрез Байесова оптимизация или обучение на допълнителен класификатор за определяне на оптималния праг.

6. **Разширяване на анализа на приноса на думите.** Замяна на оклузионния метод с Integrated Gradients [23], което би дало теоретично по-обосновани атрибуции при сходно изчислително натоварване. Интересно направление е и сравнителен анализ между трите реализирани метода по корелация на атрибуциите за едни и същи примери.

Използвана литература

[1] Jakub Piskorski, Tarek Mahmoud, Nikolaos Nikolaidis, Ricardo Campos, Alípio Mário Jorge, Dimitar Dimitrov, Purificação Silvano, Roman Yangarber, Shivam Sharma, Tanmoy Chakraborty, Nuno Guimaraes, Elisa Sartori, Nicolas Stefanovitch, Zhuohan Xie, Preslav Nakov и Giovanni Da San Martino. "SemEval 2025 Task 10: Multilingual Characterization and Extraction of Narratives from Online News". В: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, с. 2610—2643. URL: https://aclanthology.org/2025.semeval-1.331/.

[2] Dimitar Dimitrov, Firoj Alam, Maram Hasanain, Abul Hasnat, Fabrizio Silvestri, Preslav Nakov и Giovanni Da San Martino. "SemEval-2024 Task 4: Multilingual Detection of Persuasion Techniques in Memes". В: *Proceedings of the 18th International Workshop on Semantic Evaluation (SemEval-2024)*. Mexico City, Mexico: Association for Computational Linguistics, 2024.

[3] Tarek Mahmoud, Zhuohan Xie и Preslav Nakov. "BERTastic at SemEval-2025 Task 10: State-of-the-Art Accuracy in Coarse-Grained Entity Framing for Hindi News". В: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, с. 386—396. URL: https://aclanthology.org/2025.semeval-1.55/.

[4] Tengxiao Lv, Juntao Li, Chao Liu, Yiyang Kang, Ling Luo, Yuanyuan Sun и Hongfei Lin. "DUTIR at SemEval-2025 Task 10: A Large Language Model-based Approach for Entity Framing in Online News". В: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, с. 174—179. URL: https://aclanthology.org/2025.semeval-1.25/.

[5] Egil Rønningstad и Gaurav Negi. "LTG at SemEval-2025 Task 10: Optimizing Context for Classification of Narrative Roles". В: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025. URL: https://aclanthology.org/2025.semeval-1.61/.

[6] Adith Rajeev и Radhika Mamidi. "adithjrajeev at SemEval-2025 Task 10: Sequential Learning for Role Classification Using Entity-Centric News Summaries". В: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, с. 241—246. URL: https://aclanthology.org/2025.semeval-1.36/.

[7] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser и Illia Polosukhin. "Attention Is All You Need". В: *Advances in Neural Information Processing Systems 30 (NeurIPS)*. 2017.

[8] Jacob Devlin, Ming-Wei Chang, Kenton Lee и Kristina Toutanova. "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding". В: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Minneapolis, Minnesota: Association for Computational Linguistics, 2019, с. 4171—4186.

[9] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer и Veselin Stoyanov. "RoBERTa: A Robustly Optimized BERT Pretraining Approach". В: *arXiv preprint arXiv:1907.11692* (2019).

[10] Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco Guzmán, Edouard Grave, Myle Ott, Luke Zettlemoyer и Veselin Stoyanov. "Unsupervised Cross-lingual Representation Learning at Scale". В: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*. Association for Computational Linguistics, 2020, с. 8440—8451.

[11] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He и Piotr Dollár. "Focal Loss for Dense Object Detection". В: *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*. 2017, с. 2980—2988.

[12] Yin Cui, Menglin Jia, Tsung-Yi Lin, Yang Song и Serge Belongie. "Class-Balanced Loss Based on Effective Number of Samples". В: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2019, с. 9268—9277.

[13] Emanuel Ben-Baruch, Tal Ridnik, Nadav Zamir, Asaf Noy, Itamar Friedman, Matan Protter и Lihi Zelnik-Manor. "Asymmetric Loss For Multi-Label Classification". В: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, с. 82—91.

[14] Livio Baldini Soares, Nicholas FitzGerald, Jeffrey Ling и Tom Kwiatkowski. "Matching the Blanks: Distributional Similarity Matters for Zero-Shot Entity Linking". B: *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL)*. Florence, Italy: Association for Computational Linguistics, 2019, с. 2896—2905.

[15] Jake Snell, Kevin Swersky и Richard S. Zemel. "Prototypical Networks for Few-Shot Learning". B: *Advances in Neural Information Processing Systems 30 (NeurIPS)*. 2017, с. 4077—4087.

[16] Chuan Guo, Geoff Pleiss, Yu Sun и Kilian Q. Weinberger. "On Calibration of Modern Neural Networks". B: *Proceedings of the 34th International Conference on Machine Learning (ICML)*. 2017, с. 1321—1330.

[17] Ilya Loshchilov и Frank Hutter. "Decoupled Weight Decay Regularization". B: *International Conference on Learning Representations (ICLR)*. 2019.

[18] Jônatas Wehrmann, Ricardo Cerri и Rodrigo Barros. "Hierarchical Multi-Label Classification Networks". B: *Proceedings of the 35th International Conference on Machine Learning (ICML)*. 2018, с. 5225—5234.

[19] Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, Joe Davison, Sam Shleifer, Patrick von Platen, Clara Ma, Yacine Jernite, Julien Plu, Canwen Xu, Teven Le Scao, Sylvain Gugger, Mariama Drame, Quentin Lhoest и Alexander M. Rush. "Transformers: State-of-the-Art Natural Language Processing". B: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations (EMNLP)*. Online: Association for Computational Linguistics, 2020, с. 38—45.

[20] Marco Tulio Ribeiro, Sameer Singh и Carlos Guestrin. ""Why Should I Trust You?": Explaining the Predictions of Any Classifier". B: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, с. 1135—1144.

[21] Scott M. Lundberg и Su-In Lee. "A Unified Approach to Interpreting Model Predictions". B: *Advances in Neural Information Processing Systems 30 (NeurIPS)*. 2017.

[22] Karen Simonyan, Andrea Vedaldi и Andrew Zisserman. "Deep Inside Convolutional Networks: Visualising Image Classification Models and Saliency Maps". B: *International Conference on Learning Representations (ICLR), Workshop Track*. 2014.

[23] Mukund Sundararajan, Ankur Taly и Qiqi Yan. "Axiomatic Attribution for Deep Networks". B: *Proceedings of the 34th International Conference on Machine Learning (ICML)*. 2017, с. 3319—3328.

[24] Daniel Smilkov, Nikhil Thorat, Been Kim, Fernanda Viégas и Martin Wattenberg. "SmoothGrad: removing noise by adding noise". В: *ICML Workshop on Visualization for Deep Learning*. 2017.

[25] Sarthak Jain и Byron C. Wallace. "Attention is not Explanation". В: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. 2019, с. 3543—3556.

[26] Samira Abnar и Willem Zuidema. "Quantifying Attention Flow in Transformers". В: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*. Association for Computational Linguistics, 2020, с. 4190—4197.

[27] Sebastian Bach, Alexander Binder, Grégoire Montavon, Frederick Klauschen, Klaus-Robert Müller и Wojciech Samek. "On Pixel-Wise Explanations for Non-Linear Classifier Decisions by Layer-Wise Relevance Propagation". В: *PLOS ONE*. Т. 10. 7. 2015.

[28] Javier Ferrando, Gerard I. Gállego и Marta R. Costa-jussà. "Towards Opening the Black Box of Neural Machine Translation: Source and Target Interpretations of the Transformer". В: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2022, с. 8756—8769.

[29] Jiwei Li, Xinlei Chen, Eduard Hovy и Dan Jurafsky. "Visualizing and Understanding Neural Models in NLP". В: *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Association for Computational Linguistics, 2016, с. 681—691.