



Софийски университет „Св. Кл. Охридски”

Факултет по математика и информатика

Катедра „Софтуерни технологии”

ДИПЛОМНА РАБОТА

на тема

Разпознаване на семантични роли в новинарски статии

Дипломант: Борислав Мартинов Минчев

Факултетен номер: 5MI3400508

Специалност: Информатика

Магистърска програма: Извличане на информация и откриване на знания

Научен ръководител:

Проф. д-р Иван Койчев, катедра „Софтуерни технологии”,
ФМИ, СУ „Св. Климент Охридски”

Консултант:

д-р. Димитър Димитров, катедра „Софтуерни технологии”,
ФМИ, СУ „Св. Климент Охридски”

София, 2026 г.

Анотация

В настоящата дипломна работа е описана система, която автоматично разпознава наративната роля на именуваните обекти в многоезични новинарски статии. Задачата идва от SemEval-2025 Task 10, подзадача 1 (Entity Framing): за всяко споменаване на обект в статия системата трябва да определи една основна роля (Protagonist, Antagonist или Innocent) и една или повече детайлни роли от таксономия с 22 етикетата.

Предложената система е двустепенна и се основава на XLM-RoBERTa-base: първият етап предсказва основната роля, а вторият - детайлните, обусловени от изхода на първия. Системата съчетава шест компонента: (1) осредняване по обхват на обекта за получаване на представяне, фокусирано върху него (entity span pooling); (2) класификация чрез семантично сходство с опорни вектори; (3) класово балансирана кръстосана ентропия за грубото ниво; (4) меко йерархично обуславяне чрез обучаемата матрица на афинитет; (5) асиметрична загуба (ASL) с регуларизация на кардиналността за финото ниво; (6) относителен праг.

Системата постига 81,68% претеглен F1 за основната роля и 50,67% E2E Fine F1 за детайлните, при 44,54% точно съвпадение (EMR). И трите метрики са значително над разработения от нас базовия модел (съответно +14,35, +11,81 и +32,79 процентни пункта). Резултатите са получени с XLM-RoBERTa-base (278М параметъра), докато водещите системи в SemEval-2025 Task 10 използват многократно по-големи декодери като Qwen2.5-72B, Phi-4 и GLM-4-Plus с QLoRA фино настройване.

Съдържание

Анотация	1
1 Увод	5
1.1 Актуалност на проблема и мотивация	5
1.2 Цел и задачи на дипломната работа	5
1.3 Основни приноси	6
1.4 Структура на документа	6
2 Преглед на областта	8
2.1 Основни понятия	8
2.2 Обзор на съществуващи подходи и състезания	9
2.2.1 Йерархична класификация	10
2.2.2 Многоетикетна класификация	10
2.3 Многоезични предварително обучени модели	11
2.4 Функции на загубата за дисбалансиранни данни	11
2.4.1 Фокална загуба (Focal Loss)	12
2.4.2 Класово балансирана кръстосана ентропия (Class-Balanced Cross-Entropy)	12
2.4.3 Асиметрична загуба (Asymmetric Loss)	13
3 Описание на задачата и набора от данни	14
3.1 Същност и цели на задачата	14
3.2 Таксономия на ролите	14
3.3 Структура на данните и статистически анализ	15
3.4 Предварителна обработка на данните	21
3.4.1 Параграфна декомпозиция	21
3.4.2 Маркиране на обекта	21
3.4.3 Разделяне на данните	21
3.4.4 Предизвикателства	22

4	Базови модели	23
4.1	Подготовка на данните	23
4.1.1	Гранулярност на текста	23
4.1.2	Маркиране на обекта	23
4.1.3	Токенизация и разделяне на данните	24
4.2	Архитектура на модела	24
4.2.1	Предварително обучен модел и класификационна глава	24
4.2.2	Селективно замразяване и функция на загубата	24
4.2.3	Хиперпараметри	25
4.3	Резултати и анализ	25
4.3.1	Обучителен процес	25
4.3.2	Общи резултати	26
4.3.3	Анализ по класове	26
4.3.4	Анализ на грешките	27
4.3.5	Анализ по езици	28
4.3.6	Обобщение	28
4.4	Базов класификатор за фино ниво	28
4.4.1	Архитектура и обучение	29
4.4.2	Резултати	30
4.4.3	Слабости	30
4.5	Качествен анализ на приноса на думите	31
5	Предложена система	33
5.1	Обща архитектура	33
5.2	Представяне на именуваната същност чрез осредняване по обхват (Entity Span Pooling)	34
5.3	Класификация чрез семантично сходство	35
5.3.1	Генериране на опорни представяния	35
5.3.2	Проекция и косинусово подобие	36
5.4	Класово балансирана кръстосана ентропия (CB-CE) за грубо ниво	36
5.5	Класификатор на грубо ниво	37
5.6	Асиметрична загуба за фино ниво	38
5.6.1	Конфигурация на ASL	38
5.6.2	Ентропийна регуларизация	39
5.7	Меко йерархично обуславяне	39
5.7.1	Йерархичен афинитетен слой	39
5.7.2	Изчисляване на предварителните тегла	40
5.7.3	Комбиниране на логити с предварителните тегла	40
5.8	Регуларизация на кардиналността	40

5.9	Относителен праг	41
5.9.1	Алгоритъм	41
5.9.2	Обосновка	41
5.10	Класификатор на фино ниво	42
5.10.1	Проекционен MLP	42
5.10.2	Обща загуба	42
5.10.3	Хиперпараметри	43
5.11	Каскадна процедура на обучение	43
6	Експерименти и резултати	45
6.1	Експериментална настройка	45
6.1.1	Данни	45
6.1.2	Метрики	45
6.1.3	Хардуер	46
6.2	Обучителни криви и валидация	46
6.2.1	Криви на загубата	46
6.2.2	Метрики при валидация	47
6.3	Резултати на класификатора за грубо ниво	47
6.3.1	Матрица на объркване	47
6.4	Резултати на класификатора за фино ниво	48
6.4.1	Precision, Recall и калибрация на кардиналността	48
6.4.2	F1 по детайлни етикети	49
6.5	Крайна оценка (от край до край)	50
6.6	Сравнение с базовия модел	51
6.7	Сравнение със състезателни системи	52
6.8	Анализ по езици	52
6.9	Аблационно изследване	53
6.9.1	Аблация на класификационната глава	54
6.9.2	Аблация на функцията на загубата за грубо ниво	54
6.9.3	Аблация на функцията на загубата за фино ниво	55
6.9.4	Аблация на регуляризацията на кардиналността	55
6.9.5	Меко срещу твърдо обуславяне	55
6.10	Анализ на грешките	56
7	Разработка на интерактивно приложение и анализ на приноса на думите	57
7.1	Описание на приложението	57
7.1.1	Основен поток	57
7.1.2	Управление на кеша	59
7.2	Анализ на приноса на думите	59

7.2.1	Обзор на методите за атрибуция	59
7.2.2	Оклузия на ниво дума	61
7.2.3	Оклузия на ниво фраза	61
7.2.4	Градиент $\times$ Вграждане (Gradient $\times$ Embedding)	62
7.2.5	Нормализация и визуализация	62
7.3	Примерни резултати	63
8	Заклучение	67
8.1	Обобщение на резултатите	67
8.2	Ограничения	68
8.3	Бъдещи насоки	68
	Използвана литература	70

Глава 1

Увод

1.1 Актуалност на проблема и мотивация

Дезинформацията и пропагандата в онлайн медиите създават нужда от инструменти, които автоматично анализират как се представят отделните участници в новинарските текстове. Когато модел може да разпознае дали едно лице, организация или държава е представено като протагонист, антагонист или невинна страна, това отваря пътя към по-надежден медиен мониторинг, проверка на факти и анализ на наративни манипулации.

Споделената задача SemEval-2025 Task 10 [1] предлага формална рамка за многоезична класификация на ролите на именуваните обекти. Тя обхваща пет езика (български, английски, хинди, португалски и руски), две тематични области (войната в Украйна и климатичните промени) и три подзадачи. Тази работа разглежда **подзадача 1 (Entity Framing)**: за всяко споменаване на обект в статия трябва да бъде назначена една основна роля (грубо ниво) и една или повече детайлни роли (фино ниво) от таксономия с 22 предварително дефинирани етикета.

Задачата е интересна, защото съчетава няколко трудности едновременно: многоезичност (5 езика с различни писмени системи), йерархична структура на етикетите (3 основни и 22 детайлни роли), многоетикетна класификация (всяко споменаване може да има повече от една детайлна роля), силен класов дисбаланс и силна контекстна зависимост на ролите.

1.2 Цел и задачи на дипломната работа

Целта на дипломната работа е да се разработи и оцени прототип на система за присвояване на роли (герой, злодей, жертва) на именувани единици в новинарски статии чрез прилагане на големи езикови модели. Задачите, произтичащи от целта, са:

1. Обзор на съществуващите подходи за разпознаване на семантични роли и мултиезиково извличане на информация.
2. Предварителна обработка на предоставените данни и създаване на обучаващи множества.
3. Изграждане и обучение на модел за присвояване на роли в новини.
4. Планиране и провеждане на експерименти за оценка и сравняване на разработените модели за присвояване на роли в новини.
5. Разработка на прототип на система за присвояване на роли в новини.

1.3 Основни приноси

Основните приноси на дипломната работа са:

1. **Двустепенна каскадна система** за йерархична класификация с меко обуславяне, която постига конкурентни резултати дори в сравнение със системи, които използват значително по-големи езикови модели.
2. **Систематичен аблационен анализ**, който проследява ролята на класификационната глава, функцията на загубата, йерархичното обуславяне и регуляризацията на кардиналността.
3. **Демонстрация на ефективността на мекото обуславяне** спрямо твърдото маскиране: 44,54% EMR срещу 0,00%.
4. **Конкурентни резултати на тестовото множество**: 81,68% претеглен F1 за основната роля, 50,67% E2E Fine F1 и 44,54% точно съвпадение (EMR), постигнати с базовия XLM-RoBERTa-base (278M параметъра). За сравнение, водещите системи в SemEval-2025 Task 10 отчитат средно 0,475 EMR (DUTIR) и 0,421 EMR (PATeam) на скритото състезателно тестово множество, използвайки многократно по-големи декодерни модели. Сравнението е ориентировъчно, защото множествата са различни.

1.4 Структура на документа

Документът е организиран в осем глави. Глава 2 прави преглед на областта: основни понятия, съществуващи подходи, многоезични модели и функции на загубата. Глава 3 описва задачата и набора от данни, включително статистически анализ и предварителна обработка. Глава 4 въвежда базовите модели за грубата и фината

класификация. Глава 5 описва предложената напреднала система - ядрото на работата. Глава 6 обсъжда експерименталните резултати и аблационния анализ. Глава 7 описва разработеното интерактивно приложение за демонстрация и анализа на приноса на думите, включително сравнение на три метода за атрибуция. Глава 8 обобщава приносите, ограниченията и бъдещите насоки.

Глава 2

Преглед на областта

2.1 Основни понятия

Рамкиране на именувани обекти (Entity Framing) е задачата да се определи автоматично каква наративна роля играе даден именуван обект в текста - например дали дадено лице е представено като герой, злодей или жертва. Тази задача е тясно свързана с анализа на медийни рамки (media framing) и детекцията на пропаганда.

Многоетикетна класификация (Multi-label Classification) е вид класификация, при която всеки пример може да получи няколко етикета едновременно. За разлика от многокласовата класификация (multi-class), при която всеки пример получава точно един етикет, тук броят на етикетите е променлив. При нашата задача един обект може да бъде едновременно например *Instigator* и *Deceiver*.

Йерархична класификация (Hierarchical Classification) обхваща задачи, при които етикетите са организирани в дървовидна таксономия. Предсказанията трябва да са съвместими с йерархията - например, ако обект е класифициран като *Guardian*, той трябва да принадлежи и към родителската категория *Protagonist*.

Трансферно обучение (Transfer Learning) е парадигма в обработката на естествен език, при която моделът първо се предварително обучава върху голям корпус от текст чрез самонаблюдавано обучение (self-supervised learning), а след това се фина настройва (fine-tuning) върху конкретна задача с по-малко данни. На този подход се основават съвременните езикови модели като BERT и XLM-RoBERTa.

Представяне на обект чрез специални маркери е техника, при която около споменаването на обекта в текста се вмъкват специални токени [ENTITY] и [/ENTITY]. Моделът извлича представяне на конкретния обект чрез осредняване на скритите състояния между двата маркера (entity span pooling).

2.2 Обзор на съществуващи подходи и състезания

SemEval-2025 Task 10 [1] е споделена задача на 19-ия семинар по семантична евалуация. Тя включва три подзадачи: (1) Entity Framing - класификация на ролята на именувани обекти; (2) Narrative Classification - присвояване на наративни етикети на ниво документ; (3) Narrative Extraction - генериране на текстово обяснение за доминиращия наратив. В състезанието са регистрирани над 300 екипа; 66 от тях подават официални резултати за всички подзадачи (35 за подзадача 1). Тази работа разглежда само подзадача 1.

Задачата продължава поредицата от споделени задачи за детекция на пропаганда, сред които SemEval-2024 Task 4 [2] за многоезично разпознаване на техники за убеждаване в мемове.

Системите, които ще обсъдим в този обзор, включват:

- **BERTastic** [3] - съчетава фино настроен XLM-RoBERTa с промптиране на GPT-4o. Класира се седми по средно EMR за петте езика (0,386), но постига първо място за хинди по вторичната метрика асигасу за основната роля.
- **DUTIR** [4] - комбинира многоезичен превод с GLM-4-Plus, QLoRA фино настройване и ансамблова класификация. Печели първо място общо в подзадача 1 (средно 0,475 EMR), а също и за английски, португалски и руски.
- **LTG** [5] - комбинира XLM-RoBERTa с евристики за избор на контекст около обекта. Постига конкурентни резултати с по-големи генеративни модели.
- **adithjrajeev** [6] - използва тристъпков pipeline: генериране на резюме, центрирано около обекта, последвано от BERT-базиран класификатор за ролята на обекта.

Таблица 2.1: Класиране на водещите системи в SemEval-2025 Task 10, подзадача 1, по средно EMR на скритото състезателно тестово множество [1].

Система	Базови модели	Avg EMR
DUTIR	GLM-4-Plus, Qwen2.5, Llama 3.1 + QLoRA	0,475
QUST	-	0,431
PATeam	Qwen2.5-72B, Phi-4	0,421
DEMON	-	0,414
TartanTritons	-	0,404
BERTastic	XLM-RoBERTa + GPT-4o	0,386
LTG	XLM-RoBERTa	-

Забележка: Класирането използва официалната метрика EMR (Exact Match Ratio), осреднена за петте езика на задачата.

Подходите, базирани на големи декодерни модели, доминират в общото класиране, но фино настроените по-малки енкoderни модели (напр. XLM-RoBERTa в BERTastic и LTG) постигат конкурентни резултати при многократно по-ниски изчислителни разходи.

2.2.1 Йерархична класификация

Йерархичната класификация на текст (Hierarchical Text Classification) е задача, при която етикетите са организирани в дървовидна таксономия с връзки „родител-дете“. За разлика от плоската класификация, при йерархичната предсказанията на различните нива трябва да са *съвместими* - например, ако обект е класифициран с детайлна роля *Guardian*, той трябва да принадлежи и към родителската категория *Protagonist*.

В литературата се разграничават три основни подхода:

- **Плосък подход** (flat) - игнорира йерархията и обучава един класификатор за всички етикети. Прост за реализация, но не гарантира съвместимост между нивата.
- **Локален подход** (local per-level) - обучава отделен класификатор за всяко ниво на йерархията. Предсказанието на горното ниво се предава като вход или ограничение на следващото. Срещат се два варианта: *твърдо маскиране* (hard masking), което занулява недопустимите етикети, и *меко обуславяне* (soft conditioning), при което вероятностите от горното ниво модулират предсказанията на долното.
- **Глобален подход** (global) - един модел, който отчита цялата йерархия чрез споделени представяния или рекурсивни механизми.

В тази работа използваме локален подход с два етапа: класификация на основната роля (грубо ниво), след което резултатът се предава на класификатора за детайлни роли (фино ниво). Така всеки етап може да бъде оптимизиран независимо, а йерархичните ограничения се налагат при прехода между нивата.

2.2.2 Многоетикетна класификация

Многоетикетната класификация изисква специфични метрики и функции на загубата.

Метрики за оценка. Основните метрики в SemEval-2025 Task 10 са:

- **Точно съвпадение (Exact Match Ratio, EMR)** - официалната метрика за класиране; измерва броя на примерите, за които предсказаният набор от етикети съвпада *точно* с верния.

- **Micro-F1** - агрегира истински положителните, фалшиво положителните и фалшиво отрицателните над всички етикети и примери.
- **Main Role Accuracy** - точност на класификацията на грубо ниво (3 класа).

Предизвикателство: дисбаланс на етикетите. При 22 възможни етикета и средна кардиналност от 1,1, съотношението положителни/отрицателни за повечето класове е под 1:20. Със стандартна бинарна кръстосана ентропия (BCE) моделът най-лесно минимизира загубата, като предсказва „нищо“ за почти всички етикети. Това налага специализирани функции на загубата: *асиметричната загуба* (Asymmetric Loss) намалява приноса на лесните отрицателни примери чрез асиметрично претегляне; *фокалната загуба* (Focal Loss) фокусира обучението върху трудните за класификация примери.

2.3 Многоезични предварително обучени модели

Transformer архитектурата [7], е в основата на съвременните езикови модели. Ключовата иновация е механизмът за самовнимание (self-attention), чрез който моделът улавя зависимости между произволни позиции в поредицата в една стъпка.

BERT (Bidirectional Encoder Representations from Transformers) [8] адаптира кодиращата част на Transformer за предварително обучение чрез маскирано езиково моделиране (MLM) и предсказване на следващо изречение (NSP). Двупосочната архитектура улавя контекст и от двете страни на всеки токен, което води до значителни подобрения за много задачи.

RoBERTa [9] оптимизира стратегията за предварително обучение на BERT: премахва NSP задачата, увеличава размера на партидата и обема на данните и въвежда динамично маскиране. Авторите показват, че BERT е недообучен спрямо потенциала си.

XLNet-RoBERTa [10] разширява подхода на RoBERTa за 100 езика, като използва 2,5 TB данни от Common Crawl. Моделът постига значителни подобрения спрямо mBERT: +14,6% на XNLI, +13% F1 на MLQA и +2,4% F1 за NER. Той покрива всичките пет езика от задачата (български, английски, хинди, португалски, руски), което го прави естествен избор за нашата многоезична класификация.

В тази работа използваме `xlm-roberta-base` (278M параметъра, 12 Transformer слоя, скрита размерност 768).

2.4 Функции на загубата за дисбалансиранни данни

При задачи с изразен класов дисбаланс стандартната кръстосана ентропия третира всички класове равностойно и обучението се доминира от мажоритарния клас.

По-долу разглеждаме три специализирани функции на загубата, които използваме в експериментите.

2.4.1 Фокална загуба (Focal Loss)

Фокалната загуба (Focal Loss) [11] е предложена от Lin et al. за задачата по детекция на обекти, където дисбалансът между фонови и обектни примери достига 1:1000. Идеята е да се намали приносът на лесно класифицируемите примери чрез модулиращ фактор:

$$\mathcal{L}_{\text{FL}} = -\alpha_t(1 - p_t)^\gamma \log(p_t) \quad (2.1)$$

където p_t е предсказаната вероятност за верния клас, $\gamma \geq 0$ е фокален параметър, а α_t е балансиращо тегло за клас t . При $\gamma = 0$ фокалната загуба се свежда до стандартна кръстосана ентропия. С нарастване на γ приносът на лесните примери (висок p_t) намалява експоненциално, което фокусира обучението върху трудните примери. В нашите експерименти използваме $\gamma = 2,0$.

2.4.2 Класово балансирана кръстосана ентропия (Class-Balanced Cross-Entropy)

Cui et al. [12] предлагат претегляне на загубата чрез *ефективния брой проби* (effective number of samples). Основната идея е, че при преизползване на данни (oversampling) приносът на всеки нов пример постепенно намалява. Ефективният брой за клас с n проби се дефинира като:

$$E_n = \frac{1 - \beta^n}{1 - \beta} \quad (2.2)$$

където $\beta \in [0, 1)$ е хиперпараметър. При $\beta \rightarrow 0$ всички класове получават еднакво тегло; при $\beta \rightarrow 1$ теглата са обратно пропорционални на честотата. Теглото за всеки клас i е:

$$w_i = \frac{1 - \beta}{1 - \beta^{n_i}} \quad (2.3)$$

а загубата:

$$\mathcal{L}_{\text{CB-CE}} = -\frac{w_y}{\bar{w}} \sum_{i=1}^C y_i \log(p_i) \quad (2.4)$$

където $\bar{w}$ е средното тегло за нормализация. В нашите експерименти използваме $\beta = 0,9999$.

2.4.3 Асиметрична загуба (Asymmetric Loss)

Ben-Baruch et al. [13] предлагат асиметричната загуба (Asymmetric Loss, ASL), специално проектирана за многоетикетна класификация с изразен дисбаланс. Ключовата идея е да се прилагат *различни* степени на фокусиране за положителни и отрицателни примери:

$$\mathcal{L}_{\text{ASL}} = \begin{cases} (1-p)^{\gamma^+} \log(p) & \text{ако } y = 1 \\ p_m^{\gamma^-} \log(1-p_m) & \text{ако } y = 0 \end{cases} \quad (2.5)$$

където $p_m = \max(p - m, 0)$ е изместената вероятност с марж (margin) m - похватът probability shifting. Параметрите γ^+ и γ^- контролират фокусирането поотделно: типично $\gamma^- > \gamma^+$, което по-агресивно намалява приноса на лесните отрицателни примери.

В нашата система за финия класификатор използваме ASL с параметри $\gamma^+ = 0,0$, $\gamma^- = 2,0$ и марж $m = 0,05$. Изборът на $\gamma^+ = 0$ означава без фокусиране за положителните примери (всеки е информативен), а $\gamma^- = 2$ агресивно намалява приноса на лесните отрицателни. Системата разполага и с разширена версия (ASL-Opt) - тя добавя ентропийна регуларизация ($\lambda_{\text{ent}} = 0,15$) и претегляне на класовете чрез ефективния брой проби. При най-добрата конфигурация (E19) се използва основната ASL без тези разширения.

Глава 3

Описание на задачата и набора от данни

3.1 Същност и цели на задачата

Подзадача 1 (Entity Framing) от SemEval-2025 Task 10 е формулирана така: дадени са новинарска статия и списък от споменавания на именувани обекти в нея, всяко от които се описва с идентификатор на документа, текстово споменаване и начална/крайна позиция. За всяко споменаване трябва да бъдат определени:

1. **Основна роля** (main role) - точно един от трите етикета: Protagonist, Antagonist, Innocent.
2. **Детайлни роли** (fine-grained roles) - една или повече от 22 етикета, организирани йерархично под трите основни роли.

Задачата е многоезична, като данните обхващат пет езика: български (BG), английски (EN), хинди (HI), португалски (PT) и руски (RU). Тематичните области са две: войната между Русия и Украйна (URW) и климатичните промени (CC).

Официалната метрика за класиране е **точно съвпадение (Exact Match Ratio, EMR)** за детайлните роли, допълнена от micro-F1 и точност на основната роля.

3.2 Таксономия на ролите

Таксономията се състои от три основни роли и 22 детайлни роли, разпределени неравномерно (Таблица 3.1). Разпределението е силно асиметрично: Antagonist съдържа 12 детайлни роли - два пъти повече от Protagonist и три пъти повече от Innocent. Това отразява по-голямото разнообразие на негативни наративни рамки в новинарските текстове и прави класификацията по-трудна.


Таблица 3.1: Таксономия на ролите: 3 основни и 22 детайлни.

Основна роля	Детайлна роля	Описание (накратко)
Protagonist (6)	Guardian	Защитник, пазител
	Martyr	Мъченик за кауза
	Peacemaker	Миротворец
	Rebel	Бунтовник, борец за промяна
	Underdog	Аутсайдер в неравна борба
	Virtuous	Нравствен, етичен лидер
Antagonist (12)	Instigator	Подбудител на конфликт
	Conspirator	Участник в заговор
	Tyrant	Тиранин, деспот
	Foreign Adversary	Външен противник
	Traitor	Предател
	Spy	Шпионин
	Saboteur	Саботьор
	Corrupt	Корумпиран
	Incompetent	Некомпетентен
	Terrorist	Терорист
	Deceiver	Измамник
	Bigot	Фанатик, нетолерантен
Innocent (4)	Forgotten	Забравен от обществото
	Exploited	Експлоатиран
	Victim	Жертва
	Scapegoat	Изкупителна жертва

3.3 Структура на данните и статистически анализ


Данните са организирани в директории по език. За всеки език са предоставени обучително множество с анотации, валидационно множество без етикети и директория с оригиналните текстове. Всяка анотация съдържа идентификатор на документа, текстово споменаване, начална и крайна позиция, основна роля (една от трите) и набор от детайлни роли (подмножество от 22-те). При предварителната обработка около споменаването се вмъкват маркери [ENTITY] и [/ENTITY].

Разпределението на трите основни роли по езици показва ясен дисбаланс: Antagonist доминира във всички езици, на второ място е Protagonist, а Innocent е най-рядко срещаната категория.



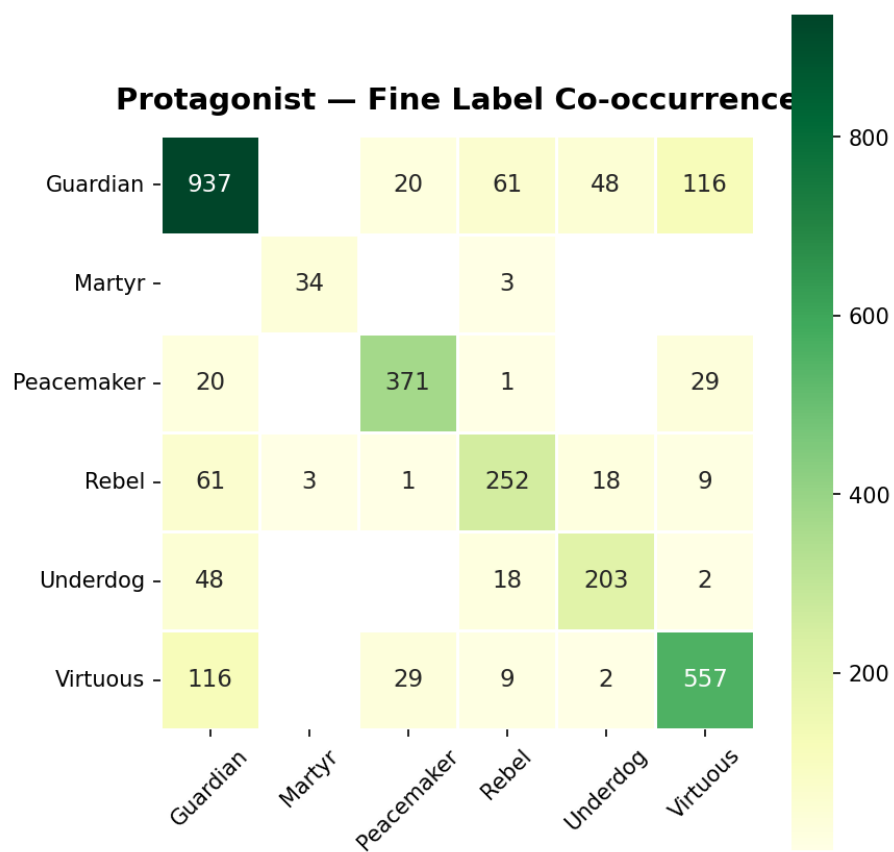
Фигура 3.1: Разпределение на основните роли по езици.

Повечето обекти имат 1–2 детайлни етикета, със средна кардиналност приблизително 1,1 (по-точно 1,08 в тестовото множество и 1,11 в обучителното). Тази ниска стойност мотивира включването на регуларизация на кардиналността с целева стойност 1,5 (Секция 5.8).

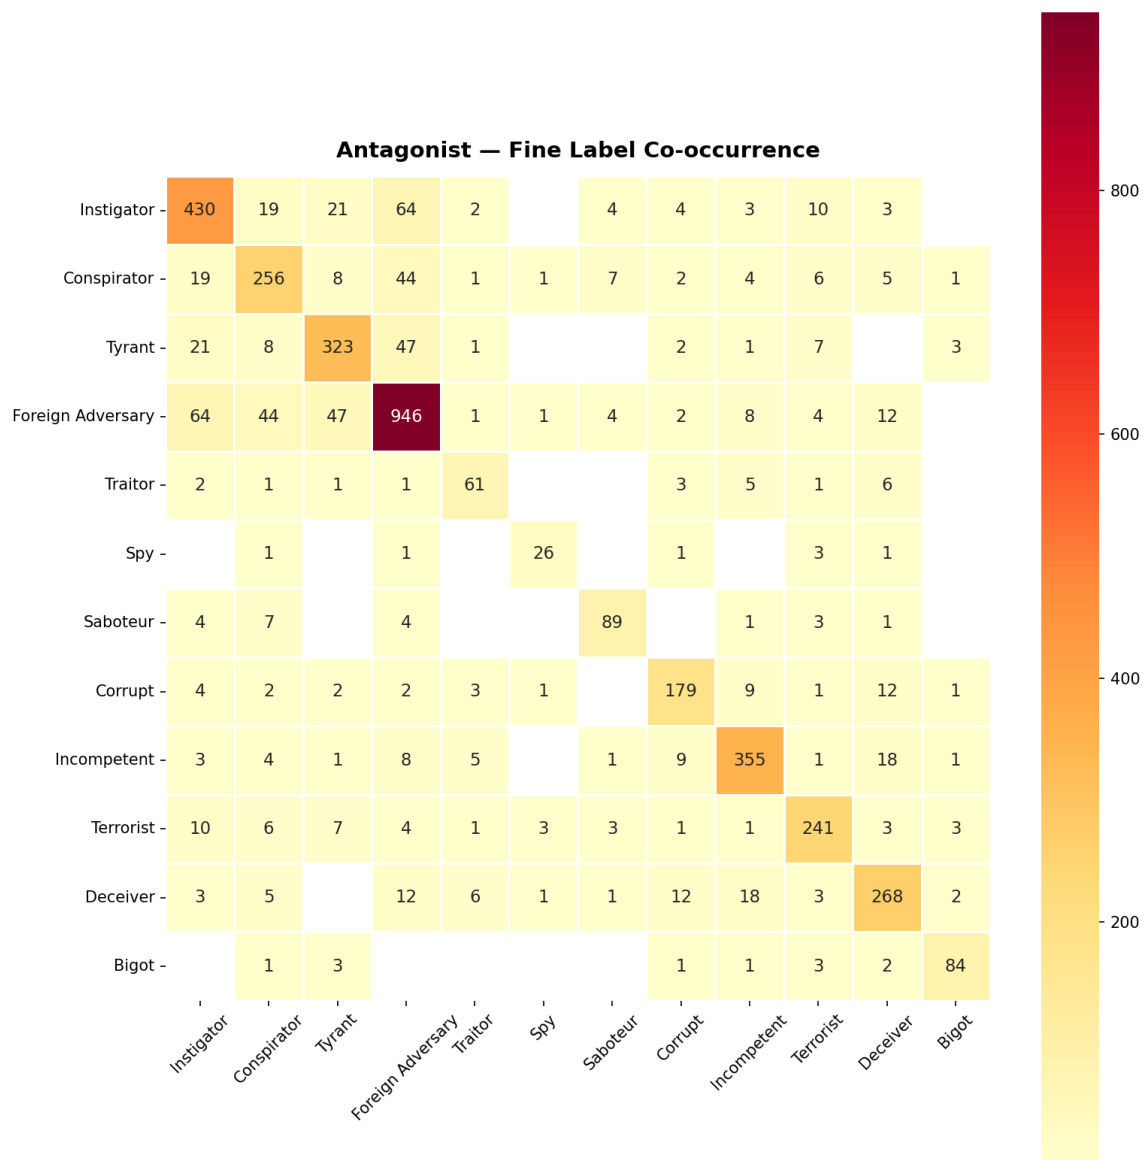


Фигура 3.2: Разпределение на броя детайлни етикети на обект.


Матриците на съвместно появяване на детайлните етикети (Фигури 3.3–3.5) показват, че двойките, които се появяват заедно, винаги са в рамките на една и съща основна категория - това следва от структурата на задачата, в която всяко споменаване има точно една основна роля. При Protagonist (Фигура 3.3) *Guardian* е най-честата роля (937 примера), като се комбинира най-често с *Virtuous* (116) и *Rebel* (61). При Antagonist (Фигура 3.4) доминира *Foreign Adversary* (946), а най-честата двойка е *Instigator* + *Foreign Adversary* (64). При Innocent (Фигура 3.5) категорията *Victim* е силно доминираща (1080), като често се комбинира с *Exploited* (41).



Фигура 3.3: Съвместно появяване на детайлните етикети в категория Protagonist.




Фигура 3.4: Съвместно появяване на детайлните етикети в категория Antagonist.




Фигура 3.5: Съвместно появяване на детайлните етикети в категория Innocent.

От 559 обекта с множество споменавания само 22,7% (127) получават една и съща роля при всяко споменаване. Останалите получават различни роли в различни контексти - например „Русия” се среща в 315 случая с 30 различни комбинации от роли. Това подчертава силната контекстна зависимост на задачата.




Фигура 3.6: Анализ на консистентността на ролите: (а) разпределение на броя различни набори от роли за обекти с множество споменавания; (б) 15-те най-разнообразни обекти.

Дължината на текстовете варира значително между езиците. Някои документи надхвърлят максималната дължина от 512 токена, използвана при токенизацията, и налагат стратегии за отрязване (truncation).



Фигура 3.7: Разпределение на дължината на текстовете по езици.

По-долу е показано разпределението по тематични области за езиците, за които тази информация е налична. Идентификаторите на документите за хинди и частично за португалски не съдържат маркери за домейн, затова тези езици не са включени в диаграмата.



Фигура 3.8: Разпределение по тематични области за езиците с налична информация.

3.4 Предварителна обработка на данните

3.4.1 Параграфна декомпозиция

Оригиналните новинарски статии варират значително по дължина - от няколко изречения до над 2000 думи (виж Фигура 3.7). Тъй като максималната дължина на входа при токенизация е 512 токена, подаването на цял документ би довело до загуба на контекст след отрязване. Затова разделяме текстовете на абзаци и за всяко споменаване избираме само абзаца, който съдържа оригиналното споменаване. Този подход:

- ограничава дължината на входа до по-управляеми размери;
- запазва непосредствения контекст около обекта, който е най-информативен за определяне на ролята;
- избягва шум от несвързани абзаци в дълги статии.

След разделяне на абзаци оригиналните позиции на споменаванията (start/end offsets) се преизчисляват спрямо началото на съответния абзац.

3.4.2 Маркиране на обекта

В предложената система (за разлика от базовия модел) токените [ENTITY] и [/ENTITY] са добавени като *специални токени* в речника на токенизатора. Това означава, че:

- всеки маркер получава собствен идентификатор и не се разделя на подтокени;
- моделът може прецизно да определи границите на обекта;
- добавянето на нови токени налага разширяване на вградения слой (embedding layer); новите вектори се инициализират от нормално разпределение със същите средна стойност и стандартно отклонение като оригиналните вграждания.

3.4.3 Разделяне на данните

Организаторите предоставят обучително и валидационно множество, но не предоставят етикети за тестовото. Затова данните са разделени така:

- **Обучително множество:** 80% от оригиналното обучително множество (4 493 примера след параграфна декомпозиция).
- **Валидационно множество:** останалите 20% (1 124 примера), използвани за мониторинг на обучението и избор на най-добрата контролна точка.

- **Тестово множество:** оригиналното валидационно множество на организаторите (604 примера) - тъй като етикетите му са налични, то служи за крайна оценка.

3.4.4 Предизвикателства

Множеството поставя няколко ключови предизвикателства:

1. **Класов дисбаланс.** Ролята Antagonist е значително по-застъпена от останалите, а Innocent е много рядка. Това налага функции на загубата, които компенсират дисбаланса - в нашата система Class-Balanced Cross-Entropy за грубата класификация и Asymmetric Loss за финия многоетикетен случай.
2. **Разреденост на многоетикетното пространство.** При 22 възможни етикета и средна кардиналност от 1,1, съотношението положителни/отрицателни за повечето класове е под 1:20. Със стандартни функции на загубата (BCE) моделът най-лесно минимизира загубата, като предсказва „нищо” за повечето етикети.
3. **Многоезичност.** Петте езика имат различни типологични характеристики и писмени системи (латиница, кирилица, деванагари), което изисква многоезичен предварително обучен модел.
4. **Йерархични ограничения.** Детайлните етикети трябва да бъдат съобразени с основната категория. Грешки на грубо ниво неизбежно водят до каскадно разпространение на грешките.
5. **Контекстна зависимост.** Ролята на обекта зависи от контекста, в който е споменат - една и съща личност може да бъде представена като протагонист в една статия и като антагонист в друга.

Глава 4

Базови модели

В тази глава представяме два базови модела - по един за всяко ниво на класификация. Грубият базов модел (описан в секции до 4.3) класифицира основните роли (Protagonist, Antagonist, Innocent), а финият (Секция 4.4) предсказва детайлните 22 роли в многоетикетна постановка. Целта е да установим начални резултати за двете нива, които служат за сравнение с по-сложните архитектури в Глава 5. Съзнателно избираме най-простите решения за всеки компонент - стандартна класификационна глава, стандартни функции на загубата и минимална предварителна обработка - за да изолираме приноса на самия предварително обучен модел от този на архитектурните надстройки.

4.1 Подготовка на данните

4.1.1 Гранулярност на текста

Тъй като максималната дължина на входа при токенизация е 256 токена, подаването на цял документ би довело до загуба на контекст след отрязване. Затова разделяме текстовете на абзаци и за всяко споменаване избираме само абзаца, който съдържа оригиналното споменаване.

4.1.2 Маркиране на обекта

Около споменаването на обекта се вмъкват маркери [ENTITY] и [/ENTITY] чрез проста замяна в текста. За разлика от напредналата система (Глава 5), тук маркерите се третират като обикновен текст и се разделят на подтокени от стандартния SentencePiece алгоритъм на XLM-RoBERTa - това е съзнателен избор за минимални модификации в базовия модел.

4.1.3 Токенизация и разделяне на данните

Маркираният текст се токенизира чрез стандартния XLM-RoBERTa токенизатор с максимална дължина от 256 токена, с отрязване на по-дългите и допълване на по-късите последователности. Основните роли се кодират като цели числа: Protagonist – 0, Antagonist – 1, Innocent – 2. Разделяме данните стратифицирано по основната роля на обучително (4 484 примера), валидационно (1 122 примера) и тестово (604 примера) множество.

4.2 Архитектура на модела

Базовият модел използва стандартната архитектура XLMRobertaForSequenceClassification от HuggingFace transformers с двуслойна класификационна глава върху представянето на [CLS] токена.

4.2.1 Предварително обучен модел и класификационна глава

Използваме xlm-roberta-base - многоезичен Transformer модел с 12 слоя, скрита размерност $d = 768$ и общо 278 милиона параметъра. Класификационната глава се състои от два линейни слоя с активационна функция $\tanh$ между тях:

$$\hat{y} = \mathbf{W}_2 \tanh(\mathbf{W}_1 \mathbf{h}_{[\text{CLS}]} + \mathbf{b}_1) + \mathbf{b}_2 \quad (4.1)$$

където $\mathbf{h}_{[\text{CLS}]} \in \mathbb{R}^{768}$ е скритото състояние на токена [CLS] от последния Transformer слой, $\mathbf{W}_1 \in \mathbb{R}^{768 \times 768}$ и $\mathbf{W}_2 \in \mathbb{R}^{3 \times 768}$ са обучаеми матрици, а $\hat{y} \in \mathbb{R}^3$ е изходният вектор от логити. Преди и между двата линейни слоя се прилага dropout (с вероятност 0,1) за регуляризация.

4.2.2 Селективно замразяване и функция на загубата

За да се ограничи пренастройването при ограничени данни, замразяваме всички параметри на модела с изключение на слой 11 (последният Transformer блок, $\approx 7,1\text{M}$ параметъра) и класификационната глава (линеен слой 768×768 + изходна проекция, $\approx 593\text{K}$). Това дава общо 7,68M обучаеми параметъра от 278M (2,76%). Използваме стандартна кръстосана ентропия без претегляне:

$$\mathcal{L}_{\text{CE}} = - \sum_{i=1}^C y_i \log(p_i) \quad (4.2)$$

4.2.3 Хиперпараметри


Таблица 4.1: Хиперпараметри за обучение на базовия класификатор.

Параметър	Стойност
Базов модел	xlm-roberta-base (278М параметъра)
Обучаеми параметри	7,68М (2,76%)
Замразени слоеве	0–10 (11 от 12)
Макс. дължина	256 токена
Брой епохи	5
Размер на партидата	8
Скорост на обучение	2×10^{-5}
Затихване на теглата (weight decay)	0,01
Функция на загубата	Кръстосана ентропия
Класификационна глава	[CLS] $\rightarrow$ dense $\rightarrow$ tanh $\rightarrow$ out_proj
Оптимизатор	AdamW

4.3 Резултати и анализ

4.3.1 Обучителен процес

Обучителната и валидационната загуба намаляват плавно от 1,1 до 0,7 за 5 епохи, като валидационната конвергира след 3-тата. Разликата между двете криви говори за умерено пренастройване.



Фигура 4.1: Криви на обучителната и валидационната загуба на базовия модел.

4.3.2 Общи резултати

Таблица 4.2: Общи резултати на базовия класификатор.


Метрика	Стойност
Точност (Accuracy)	67,72%
Претеглен F1	67,33%

Моделът класифицира правилно 409 от 604 примера.

4.3.3 Анализ по класове

Таблица 4.3: Метрики по класове на базовия модел.


Клас	Бр. примери	Предсказани	Precision	Recall	F1
Protagonist	191	213	0,643	0,717	0,678
Antagonist	266	309	0,650	0,756	0,699
Innocent	147	82	0,866	0,483	0,620



Фигура 4.2: Precision, Recall и F1 по класове за базовия модел.

Виждаме три различни профила на грешки. Antagonist получава висок Recall (75,6%) и нисък Precision (65,0%), защото моделът прекалено често предсказва точно него (мажоритарния клас). Innocent показва обратния модел: висок Precision (86,6%) и нисък Recall (48,3%) - моделът рядко го предсказва, но когато го направи, обикновено е верен. Protagonist е балансиран, с умерен F1=67,8%.


4.3.4 Анализ на грешките



Фигура 4.3: Матрица на объркване за базовия класификатор (604 примера).

Общият брой грешки е 195 от 604 примера (32,3%). Най-честите грешки са Innocent→Antagonist и Antagonist→Protagonist (по 57, по 29,2%), следвани от Protagonist→Antagonist (51, 26,2%). Съществено е, че Innocent почти никога не се предсказва - примерите му се разпределят към двата мажоритарни класа, което е проява на *отклонение към мажоритарния клас* (majority class bias).

4.3.5 Анализ по езици



Фигура 4.4: Претеглен F1 по езици за базовия модел.

Резултатите варират значително между езиците: португалски е най-висок (WF1=82,0%), а руски е най-слаб (WF1=60,4%). Моделът не разпознава нито един Innocent пример за BG (0/3) и EN (0/9) - 100% от тях са грешни.

4.3.6 Обобщение

Базовият модел постига 67,33% претеглен F1. В анализа се очертават две основни слабости, които мотивират напредналата система (Глава 5):

1. **Отклонение към мажоритарния клас** - мотивира балансираните функции на загубата.
2. **Слабо представяне чрез [CLS] токен** - проявява се най-силно при Innocent (Recall 48,3%). Мотивира преминаване към представяне чрез осредняване по обхват (ESP), което извлича информация директно от обхвата на обекта.

4.4 Базов класификатор за фино ниво

Освен грубия базов модел проектираме и втори базов класификатор - за много-етикетната задача с 22 детайлни роли. Целта е да получим съпоставима отправна точка, спрямо която да измерим приноса на иновациите в напредналата система.

4.4.1 Архитектура и обучение

Класификаторът използва същия гръбнак (XLM-RoBERTa-base) и същата стратегия на селективно замразяване - 7,69М обучаеми параметъра (2,77%). Промените спрямо грубия базов модел са минимални и произтичат изцяло от многоетикетния характер на задачата:

- **Изход:** 22 независими сигмоидни логита (по един за всеки етикет) вместо 3 softmax-логита.
- **Загуба:** бинарна кръстосана ентропия (BCE) с `pos_weight` (изчислен от обучителната честота на всеки етикет, ограничен на 10) - сар-ът предотвратява свръхпредсказването, което се появява при високи `pos_weight` стойности за най-редките класове.
- **Праг и резервен механизъм:** фиксиран праг 0,5 върху сигмоидните вероятности; ако за даден пример нито един етикет не премине прага, се използва `argmax` над логитите (резервен механизъм срещу празни предсказания).

Архитектурно класификаторът наследява стратегията на грубия модел (същото селективно замразяване, същата дължина на входа от 256 токена, параграфна декомпозиция, AdamW). За самото обучение обаче увеличаваме епохите и скоростта на обучение поради по-голямата сложност на многоетикетната задача: 10 епохи (вместо 5) и скорост на обучение 3×10^{-5} (вместо 2×10^{-5}). Размерът на партидата остава 8. Избираме най-добрия модел по Sample-F1 върху валидационното множество.

Базовият модел за фино ниво следва грубия с леки адаптации: архитектурата е еднаква, режимът на обучение е малко по-силен. Единствените функционални добавки (`pos_weight`, праг, `argmax fallback`) са в съответствие с философията на базовия модел и не въвеждат нито една от иновациите на напредналата система: ASL, focal loss, меко обуславяне, семантично сходство, относителен праг.

4.4.2 Резултати

Таблица 4.4: Общи резултати на базовия класификатор за фино ниво.

Метрика	Стойност
Sample-F1	38,86%
Micro-F1	35,64%
Macro-F1	22,41%
Точно съвпадение (EMR)	11,75%
Средна предсказана кардиналност	2,70
Средна истинска кардиналност	1,08

Когато грубата роля е предсказана правилно (410 от 604 в този експеримент¹), условният Fine F1 нараства до 48,77% - 9,9 процентни пункта над безусловния Sample-F1. Това потвърждава очаквания каскаден ефект: грешките на първия етап ограничават горната граница на втория.

4.4.3 Слабости

В анализа на per-label F1 и per-language F1 се очертават три основни слабости:

1. **Колапс на редки етикети.** Седем от 22 етикета имат F1=0 в тестовото множество: *Martyr*, *Traitor*, *Spy*, *Saboteur*, *Bigot*, *Forgotten*, *Scapegoat*. Тези класове имат под 12 примера в теста и pos_weight (ограничен на 10) не е достатъчен, за да ги научи моделът с BCE.
2. **Свърхпредсказване на кардиналност.** Моделът предсказва средно 2,70 етикета на пример, докато истинската стойност е 1,08 - свърхпредсказване от около 2,5×. Фиксиран праг 0,5 без регуларизация не може да компенсира този ефект.
3. **Каскадни грешки.** Както показва §4.4, значителна част от грешките на финия модел идват от грешки на грубия класификатор.

Тези три слабости мотивират четири от иновациите на напредналата система (Глава 5): класификация чрез семантично сходство срещу колапса на редки етикети; регуларизация на кардиналността и относителен праг срещу свърхпредсказването; меко йерархично обуславяне за намаляване на каскадните грешки.


Пълно описание на процеса по проектиране, обосновката на всеки избор и подробни диаграми (per-label F1, per-language F1, разпределение на кардиналността) се намират в преддипломния проект.

¹Лекото разминаване с грубия базов класификатор от Секция 4.3 (409 от 604) се дължи на отделни обучения на грубия класификатор с независими случайни инициализации.

4.5 Качествен анализ на приноса на думите


За да разберем не само *колко* грешни базовият модел, но и *защо*, прилагаме анализ на приноса на думите чрез оклузия (методът е описан подробно в Глава 7). За всеки токен от контекста измерваме промяната в логита на предсказания клас при неговото маскиране: положителна стойност означава, че думата подкрепя предсказанието, отрицателна - че му противодейства. Разглеждаме три тестови примера, по един за всяка основна роля.

Пример 1 (истинско: Antagonist)




Фигура 4.5: Принос на думите за пример с истинска роля Antagonist. Базовият модел греша, като предсказва Protagonist с ниска увереност (41%); представянето чрез [CLS] не успява да фокусира решението върху обекта.

Пример 2 (истинско: Innocent)



Фигура 4.6: Принос на думите за пример с истинска роля Innocent (правилно класифициран). Водещ принос имат думите около описанието на пострадалата страна.


Пример 3 (истинско: Protagonist)



Фигура 4.7: Принос на думите за пример с истинска поля Protagonist (правилно класифициран с висока увереност, 82%).

Анализът потвърждава двете основни слабости от Секция 4.3. При грешно класифицирания пример (Фигура 4.5) най-висок принос получават общи контекстни думи, а не тези, които характеризират ролята на конкретния обект - пряко следствие от представянето чрез [CLS] токена, което агрегира целия вход, без да локализира обекта. Това наблюдение мотивира въвеждането на осредняване по обхват на обекта (ESP) в предложената система (Секция 5.2).

За пълнота сравняваме двата класа методи за анализ на приноса - оклузия и Градиент $\times$ Вграждане (Фигура 4.8). За първия пример двата метода се разминават съществено: само една от петте най-важни думи съвпада, а знакът на приноса често е противоположен (например думата "pounded" е с положителен принос при оклузията, но силно отрицателен при градиентния метод). Това потвърждава наблюдението от Глава 7, че градиентният метод е линейна апроксимация и е препоръчителен само като допълнителна бърза индикация, докато оклузията остава основният метод.



Фигура 4.8: Сравнение на оклузия и Градиент $\times$ Вграждане за първия пример. Разсейващата диаграма (вдясно) показва, че двата метода често дават различен знак на приноса за една и съща дума.

Глава 5

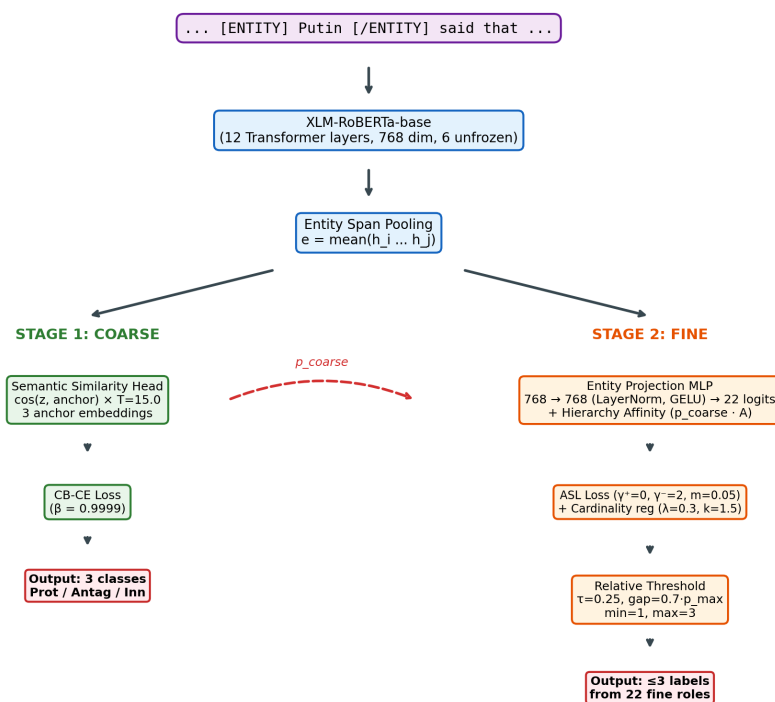
Предложена система

В тази глава описваме предложената напреднала система за йерархична класификация на ролите на именувани обекти. Системата е двустепенна - първият етап определя основната роля (3 класа), а вторият - детайлните роли (22 класа) чрез многоетикетна класификация с меко йерархично обуславяне. Всяка от иновациите спрямо базовите модели (Глава 4) е мотивирана от конкретна слабост, идентифицирана в анализа на грешките.

5.1 Обща архитектура

Системата се състои от два последователно обучени класификатора, базирани на един и същ предварително обучен модел XLM-RoBERTa-base, но с различни класификационни глави и функции на загубата. Общият поток е:

1. **Вход:** текст с маркиран обект чрез специални токени [ENTITY] / [/ENTITY].
2. **Кодиране:** XLM-RoBERTa преобразува входа в последователност от скрити състояния.
3. **Осредняване по обхват (ESP):** извличане на представяне, специфично за обекта, чрез осредняване на скритите състояния между маркерите.
4. **Етап 1 (грубо ниво):** класификационна глава, базирана на семантично сходство с 3 опорни вектора + класово балансирана кръстосана ентропия (CB-CE).
5. **Етап 2 (фино ниво):** проекционен MLP + йерархичен афинитетен слой за меко обуславяне с грубите вероятности, обучен с асиметрична загуба (ASL) и регуларизация на кардиналността.
6. **Предсказване:** относителен праг за определяне на крайните етикети.



Hierarchical Entity Role Classification — System Architecture

Фигура 5.1: Обща архитектура на предложената двустепенна система.

5.2 Представяне на именуваната същност чрез осредняване по обхват (Entity Span Pooling)

В базовия модел представянето на обекта се извлича от токена [CLS], който агрегира информация от целия вход, но не кодира експлицитно позицията на обекта. При абзаци с множество споменати лица моделът не може да разграничи кое лице е целевото.

За решаване на този проблем въвеждаме *осредняване по обхват на обекта* (entity span pooling, ESP). Подходът е базиран на техниките за маркиране на обекти [14] и се състои от две стъпки:

Стъпка 1: Добавяне на специални токени. Токените [ENTITY] и [/ENTITY] се добавят в речника на токенизатора като специални символи. Вграденият слой (embedding layer) на модела се разширява, като новите вграждания се инициализират стандартно (с нормално разпределение, както е по подразбиране в библиотеката transformers).

Стъпка 2: Осредняване на скритите състояния. След като текстът премине

през Transformer-енкодера, представянето на обекта се извлича чрез осредняване на скритите състояния в обхвата между маркерите:

$$\mathbf{e} = \frac{1}{j-i} \sum_{k=i}^{j-1} \mathbf{h}_k \quad (5.1)$$

където $\mathbf{h}_k \in \mathbb{R}^{768}$ е скритото състояние на позиция k , а i и j са позициите на [ENTITY] и [/ENTITY] съответно. Ако маркерите не са намерени или обхватът е невалиден, се използва представянето на [CLS] токена като резервен вариант.

Предимствата на ESP са: (1) представянето е фокусирано именно на целевия обект, а не на целия контекст; (2) осредняването е устойчиво на вариации в дължината на споменаването; (3) специалните токени дават възможност на модела да изгради контекстуално зависими представяния на границите на обекта.

5.3 Класификация чрез семантично сходство

За класификатора на грубо ниво заменяме стандартната линейна глава с подход, базиран на *семантично сходство* (Semantic Similarity Head). Идеята е близка до прототипните мрежи [15]: за всеки клас се изгражда опорно представяне (anchor embedding) от името на ролята, а класификацията се свежда до сравнение между представянето на обекта и опорните вектори. Така главата получава лингвистичен сигнал от самите имена на ролите („Protagonist”, „Antagonist”, „Innocent”), което е особено ценно при малко данни и силен класов дисбаланс. Този подход се прилага само на грубо ниво. Финият класификатор използва различна архитектура - MLP с меко йерархично обуславяне (§5.7, §5.10).

5.3.1 Генериране на опорни представяния

Опорните вектори се генерират по следната процедура:

1. зарежда се името на всеки етикет от таксономията (напр. „Protagonist”, „Guardian”, „Victim”);
2. името се подава през XLM-RoBERTa-base (същия енкодер, използван за входния текст);
3. представянето на [CLS] токена се извлича като опорен вектор с размерност $\mathbb{R}^{768}$.

За грубия класификатор се генерират 3 опорни вектора (по един за всяка основна роля). Векторите се изчисляват веднъж и след това се замразяват: те служат като

фиксираните референтни точки в пространството на представянията, така че по време на обучението се настройват само енкодерът и проекцията, а не самите цели на класификацията.

5.3.2 Проекция и косинусово подобие

Представянето на обекта $\mathbf{e} \in \mathbb{R}^{768}$ се преобразува чрез проекционен слой с LayerNorm:

$$\mathbf{z} = \text{LayerNorm}(\mathbf{W}_p \mathbf{e} + \mathbf{b}_p) \quad (5.2)$$

където $\mathbf{W}_p \in \mathbb{R}^{768 \times 768}$. След нормализация на проектираното представяне и опорните вектори по L_2 нормата се изчислява косинусово подобие:

$$s_c = T \cdot \cos(\mathbf{z}, \mathbf{a}_c) = T \cdot \frac{\mathbf{z}^\top \mathbf{a}_c}{\|\mathbf{z}\| \cdot \|\mathbf{a}_c\|} \quad (5.3)$$

където $\mathbf{a}_c$ е опорният вектор за клас c , а $T = 15,0$ е температурен параметър [16], който скалира стойностите на подобие в подходящ диапазон за softmax функцията. Без температурно скалиране стойностите на косинусовото подобие (в интервала $[-1, 1]$) биха били твърде малки за ефективно обучение чрез кръстосана ентропия.

Резултатът е вектор от 3 логита $\mathbf{s} \in \mathbb{R}^3$, който се подава на softmax за получаване на вероятности.

5.4 Класово балансирана кръстосана ентропия (СВ-СЕ) за грубо ниво

Анализът на базовия модел (Секция 4.3) показва систематично отклонение към Antagonist (+43 излишни предсказания). За справяне с този проблем в класификатора на грубо ниво заменяме стандартната кръстосана ентропия с класово балансирана кръстосана ентропия (Class-Balanced Cross-Entropy, СВ-СЕ) [12], описана в Секция 2.4. Теглата се изчисляват чрез ефективния брой проби (Уравнение 2.3) с $\beta = 0,9999$. Броят n_c за всеки клас идва от тренировъчното множество (Antagonist: 2120, Protagonist: 1521, Innocent: 852).

СВ-СЕ представлява обобщение на стандартното претегляне: при $\beta \rightarrow 0$ теглата се изравняват (без претегляне), а при $\beta \rightarrow 1$ клонят към обратната честота $w_c \propto 1/n_c$. Хиперпараметърът β позволява плавно интерполиране между двата случая, което е особено полезно при умерен дисбаланс - какъвто е нашият (съотношение $\sim 2,5:1$ между най-големия и най-малкия клас). Изборът $\beta = 0,9999$ е препоръчван от Cui et al. при дисбалансираните данни със стотици проби на клас. Тази стойност е достатъчно близо до 1, за да е почти еквивалентна на чисто обратно-честотно

претегляне, но избягва числената нестабилност на $\beta = 1$, която би довела до изродени тегла при много редки или липсващи класове. В нашия случай $E_n \approx n_c$ и теглата w_c се различават с под 4% от чисто обратно-честотните, но леко смекченото претегляне намалява риска от свръхкомпенсация в полза на миноритарния клас Innocent.

Аблационното изследване (Секция 6.9.2) показва, че СВ-СЕ води до подобрение от 3,63 процентни пункта в претеглен F1 на грубото ниво спрямо стандартна кръс-тосана ентропия (81,68% срещу 78,05%) и 3,48 процентни пункта в точно съвпадение (44,54% срещу 41,06%). Спрямо чисто обратно-честотното претегляне (Weighted CE) подобрението е по-малко (0,49 пункта в Coarse F1), което съответства на теоретичното очакване, че при умерен дисбаланс двата подхода дават близки резултати.

5.5 Класификатор на грубо ниво

Пълната архитектура е:

1. **Кодиращ блок:** XLM-RoBERTa-base с 6 размразени Transformer слоя (слоеве 6–11). Слоеве 0–5 са замразени за запазване на общите лингвистични представления.
2. **Entity span pooling:** осредняване на скритите състояния между маркерите (Уравнение 5.1).
3. **Класификационна глава:** семантично сходство с 3 опорни вектора и $T = 15,0$ (Уравнение 5.3).
4. **Функция на загубата:** Class-Balanced Cross-Entropy с $\beta = 0,9999$.

Таблица 5.1: Хиперпараметри за обучение на класификатора за грубо ниво.

Параметър	Стойност
Базов модел	xlm-roberta-base (278М параметъра)
Размразени Transformer слоеве	6 (слоеве 6–11 от 12)
Макс. дължина на поредицата	512 токена
Класификационна глава	Семантично сходство
Функция на загубата	СВ-СЕ ($\beta = 0,9999$)
Брой епохи	10
Размер на партидата	9
Скорост на обучение	6×10^{-5}
Разгриване	10% от стъпките
Тегловно затихване	0,0
Отпадане (Dropout)	0,0
Оптимизатор	AdamW [17]

Размразяването на 6 от 12-те Transformer слоя е компромис между изразителна сила и риска от overfitting при сравнително малкия корпус. Скоростта на обучение, размерът на партидата и липсата на регуляризация (weight decay и dropout = 0) са установени емпирично, тъй като по-агресивни стойности водеха до по-нестабилно обучение.

5.6 Асиметрична загуба за фино ниво

За многоетикетната класификация на фино ниво стандартната BCE е неподходяща поради екстремния дисбаланс (средна кардиналност $\sim 1,1$ при 22 етикета, т.е. съотношение $\sim 1:20$ за всеки етикет). При такъв дисбаланс отрицателните примери доминират градиента и моделът се научава да предсказва „всичко нула без реално да разграничава класовете. Използваме асиметрична загуба (Asymmetric Loss, Секция 2.4), допълнена с регуляризация на кардиналността.

5.6.1 Конфигурация на ASL

Параметрите на ASL са: $\gamma^+ = 0,0$ (без фокусиране за положителни примери), $\gamma^- = 2,0$ (агресивно намаляване на лесните отрицателни) и марж за отместване на вероятностите $m = 0,05$. Изборът на $\gamma^+ = 0$ се обосновава с наблюдението, че положителните примери са малко и всеки от тях е информативен - фокусирането би допълнително намалило и без това малкия им принос. Стандартната препоръка на Ben-Baruch et al. е $\gamma^- = 4$, но при нашия силно дисбалансиран корпус тази стойност

доведе до по-ниски резултати (всички вероятности клонят към нула), затова приехме $\gamma^- = 2$ - компромис, при който отрицателните остават подтиснати, но позитивните не се изпускат напълно. Маржът $m = 0,05$ съответства на стандартната стойност от rareg-a - отрицателни примери с предсказана вероятност под 5% се игнорират изцяло.

5.6.2 Ентропийна регуларизация

Имплементирана е допълнителна ентропийна регуларизация, която предотвратява прекомерно неуверени предсказания:

$$\mathcal{L}_{\text{ent}} = -\frac{1}{N \cdot L} \sum_{n=1}^N \sum_{l=1}^L [p_{nl} \log p_{nl} + (1 - p_{nl}) \log(1 - p_{nl})] \quad (5.4)$$

където $p_{nl} = \sigma(z_{nl})$ е сигмоидната вероятност за етикет l на пример n . Тази регуларизация наказва неуверени предсказания (вероятности, близки до 0,5), като насърчава модела да прави по-категорични решения за всеки етикет. Теглото е $\lambda_{\text{ent}} = 0,15$. При най-добрата конфигурация (E19) този член не е активиран, но е изследван в аблационния анализ.

5.7 Меко йерархично обуславяне

Между грубия и финия класификатор трябва да тече информация - предсказването на детайлната роля зависи от това към коя основна роля принадлежи обектът. Разглеждаме два подхода:

Твърдо маскиране (hard masking) занулява логитите на детайлни роли, не съвместими с предсказаната основна роля. Например, ако обект е класифициран като Protagonist, логитите за всички Antagonist и Innocent подроли стават $-\infty$. Така грешка на грубо ниво неизбежно елиминира верния отговор на фино ниво.

Меко обуславяне (soft conditioning) [18] използва вероятностите от грубия класификатор като *меки предварителни тегла* за финия, така че несигурността от грубото ниво се разпространява надолу. Реализираме това чрез обучаем *йерархичен афинитетен слой*.

5.7.1 Йерархичен афинитетен слой

Слоят съдържа обучаемата матрица $\mathbf{A} \in \mathbb{R}^{3 \times 22}$, инициализирана от таксономията:

$$A_{ij} = \begin{cases} +2,0 & \text{ако детайлна роля } j \text{ принадлежи на основна роля } i \\ -2,0 & \text{в противен случай} \end{cases} \quad (5.5)$$

Тази инициализация кодира структурата на таксономията: при инициализация слоят наподобява твърдото маскиране (валидни роли получават голям положителен принос, невалидни - голям отрицателен). Слойът обаче е обучаем, така че по време на обучение моделът може да отслаби строгата йерархия там, където данните го налагат - например, ако определена детайлна роля се среща и в контекст на повече от една основна роля.

5.7.2 Изчисляване на предварителните тегла

За вектор от вероятности $\mathbf{p}_{\text{coarse}} \in \mathbb{R}^3$ от грубия класификатор, йерархичните предварителни тегла се изчисляват като:

$$\mathbf{h}_{\text{prior}} = \mathbf{p}_{\text{coarse}} \cdot \mathbf{A} \quad (5.6)$$

Резултатът $\mathbf{h}_{\text{prior}} \in \mathbb{R}^{22}$ съдържа стойности, отразяващи степента на съвместимост на всяка детайлна роля с предсказаната основна категория.

5.7.3 Комбиниране на логити с предварителните тегла

Финалните логити за финия класификатор се получават чрез събиране:

$$\mathbf{z}_{\text{fine}} = f(\mathbf{e}) + \mathbf{h}_{\text{prior}} \quad (5.7)$$

където $f(\mathbf{e})$ е изходът на проекционния MLP (описан в Секция 5.10), а $\mathbf{h}_{\text{prior}}$ са йерархичните предварителни тегла. Адитивното комбиниране позволява на проекционния MLP да надделее над тях при достатъчно силни доказателства в данните.

Аблационното изследване (Секция 6.9.5) показва, че мекото обуславяне води до значително подобрение спрямо твърдото маскиране: EMR от 44,54% срещу 0,00%.

5.8 Регуляризация на кардиналността

Анализът на данните (Фигура 3.2) показва, че средният брой детайлни етикети на обект е приблизително 1,1. За да ориентираме модела към реалистичен брой предсказания, въвеждаме квадратичен регуляризатор на кардиналността с целева стойност $k = 1,5$. Тази стойност е избрана малко над емпиричната средна, защото ASL има тенденция да подценява положителните класове - леко по-висока цел компенсира това отклонение.

$$\mathcal{L}_{\text{card}} = \lambda_{\text{card}} \cdot \frac{1}{N} \sum_{n=1}^N \left(\sum_{l=1}^L \sigma(z_{nl}) - k \right)^2 \quad (5.8)$$

където $\sigma(z_{nl})$ е сигмоидната вероятност за етикет l на пример n , $k = 1,5$ е целевата кардиналност, а $\lambda_{\text{card}} = 0,3$ е теглото на регуляризацията.

Тази регуляризация действа като мек ограничител: тя не забранява повече или по-малко етикети, а наказва отклонения от целевата стойност квадратично. При $\lambda_{\text{card}} = 0$ (без регуляризация) моделът има тенденция да предсказва повече етикети, което намалява прецизността (Секция 6.9.4).

5.9 Относителен праг

При многоетикетна класификация стандартният подход е да се прилага фиксиран праг τ (напр. $\tau = 0,5$) на сигмоидните вероятности. Ние предлагаме *относителен праг*, чиято стойност се изчислява за всеки пример спрямо най-високата вероятност в неговия изход.

5.9.1 Алгоритъм

За всеки пример с вектор от вероятности $\mathbf{p} = \sigma(\mathbf{z}_{\text{fine}}) \in [0, 1]^{22}$:

1. Определяме максималната вероятност: $p_{\text{max}} = \max_l p_l$.
2. Изчисляваме адаптивен праг: $\tau_{\text{gap}} = r \cdot p_{\text{max}}$, където $r = 0,7$ е коефициент на разлика (gap ratio).
3. Ефективният праг е: $\tau_{\text{eff}} = \max(\tau, \tau_{\text{gap}})$, където $\tau = 0,25$ е минимален абсолютен праг.
4. Избираме етикетите с $p_l \geq \tau_{\text{eff}}$, с ограничения за минимум 1 и максимум 3 етикета.

5.9.2 Обосновка

Относителният праг решава два проблема:

- **При уверен модел** ($p_{\text{max}} = 0,9$): $\tau_{\text{gap}} = 0,7 \cdot 0,9 = 0,63$, $\tau_{\text{eff}} = 0,63$. Само етикети с висока вероятност се приемат, което увеличава прецизността.
- **При неуверен модел** ($p_{\text{max}} = 0,3$): $\tau_{\text{gap}} = 0,7 \cdot 0,3 = 0,21$, $\tau_{\text{eff}} = 0,25$ (долна граница). Минималното ограничение гарантира поне един етикет.

Ограничението за максимум 3 етикета е мотивирано от анализа на данните - 99,98% от примерите имат 3 или по-малко детайлни роли.

5.10 Класификатор на фино ниво

Класификаторът за фино ниво обединява всички описани компоненти: ESP, проекционен MLP, меки йерархични предварителни тегла, асиметрична загуба и регуляризация на кардиналността. Тук описваме как те се свързват в един обучаем модул.

5.10.1 Проекционен MLP

Представянето на обекта от ESP (Уравнение 5.1) се преобразува чрез двуслоен MLP. За разлика от грубия класификатор (§5.3), където проекцията е едностепенна и логитите се изчисляват чрез косинусово сходство с опорни вектори, тук финият класификатор директно изчислява 22 логита през нелинейна трансформация. Двуслойната структура (с GELU и LayerNorm) дава достатъчна изразителна мощност за фината 22-класова задача:

$$f(\mathbf{e}) = \mathbf{W}_2 \cdot \text{GELU}(\text{LayerNorm}(\mathbf{W}_1 \mathbf{e} + \mathbf{b}_1)) + \mathbf{b}_2 \quad (5.9)$$

където $\mathbf{W}_1 \in \mathbb{R}^{768 \times 768}$, $\mathbf{W}_2 \in \mathbb{R}^{22 \times 768}$, с Dropout (0,1) между GELU и втория линейен слой. Изходът е вектор от 22 логита, по един за всяка детайлна роля.

5.10.2 Обща загуба

Крайната функция на загубата за финия класификатор при конфигурацията E19 е сума от два компонента:

$$\mathcal{L}_{\text{fine}} = \mathcal{L}_{\text{ASL}} + \lambda_{\text{card}} \mathcal{L}_{\text{card}} \quad (5.10)$$

с $\lambda_{\text{card}} = 0,3$.

Имплементиран е и допълнителен член за ентропийна регуляризация $\lambda_{\text{ent}} \mathcal{L}_{\text{ent}}$ (Секция 5.6), който не е активиран при най-добрата конфигурация (E19), но е изследван в аблационния анализ.

5.10.3 Хиперпараметри

Таблица 5.2: Хиперпараметри за обучение на класификатора за фино ниво.

Параметър	Стойност
Базов модел	xlm-roberta-base (278M параметъра)
Размразени Transformer слоеве	6 (слоеве 6–11 от 12)
Макс. дължина на поредицата	512 токена
Проекционен MLP	$768 \rightarrow 768 \rightarrow 22$ (с LayerNorm, GELU, Dropout 0,1)
Йерархично обуславяне	Меко (обучаема матрица 3×22)
Брой епохи	10
Размер на партидата	6
Скорост на обучение	8×10^{-5}
Разгриване	50 стъпки
Оптимизатор	AdamW [17]
Загуба	ASL ($\gamma^+ = 0,0$, $\gamma^- = 2,0$, $m = 0,05$)
Ентропийна регуларизация	не (налична, но неактивна в E19)
Регуларизация на кардиналност	$\lambda_{\text{card}} = 0,3$, цел $k = 1,5$
Относителен праг	$\tau = 0,25$, $r = 0,7$, мин. 1, макс. 3

5.11 Каскадна процедура на обучение

Обучението на двата класификатора се извършва *последователно* (каскадно), а не съвместно (емпиричните обучителни криви и валидационните метрики са представени в Секция 6.2):

1. **Обучение на грубия класификатор.** Моделът се обучава за 10 епохи върху обучителното множество. След обучението избираме най-добрия модел по претеглен F1 на валидационното множество.
2. **Генериране на предсказания за грубо ниво.** Най-добрият модел генерира предсказания (и вероятности) за обучителното, валидационното и тестовото множество.
3. **Обучение на финия класификатор.** Моделът получава като допълнителен вход вектор от вероятности от грубия класификатор ($\mathbf{p}_{\text{coarse}} \in \mathbb{R}^3$). По време на обучение се използват предсказаните вероятности (а не верните етикети), за да отразят шума, който очакваме при извеждане.

4. **Извеждане (inference).** За всеки тестов пример: грубият класификатор дава $\mathbf{p}_{\text{coarse}}$, която се подава на финия класификатор чрез мекото обуславяне, и относителният праг определя крайните етикети.

Използваният хардуер и времената за обучение на двата класификатора са представени в Секция 6.1.3 (глава *Експерименти и резултати*).

Глава 6

Експерименти и резултати

В тази глава представяме експерименталната оценка на предложената система. Аблационният анализ обхваща 20 експеримента, всеки от които изолира приноса на отделен компонент.

6.1 Експериментална настройка

6.1.1 Данни

Разпределението на данните е: обучително множество - 4 493 примера (след параграфна декомпозиция), валидационно - 1 124 примера, тестово - 604 примера. Като тестово множество използваме публичното валидационно множество на SemEval-2025 Task 10 от 10 януари 2025 (Секция 3.4); разпределението по езици и роли е представено там.

6.1.2 Метрики

Използваме четири основни метрики за оценка:

- **Претеглен F1 (грубо ниво)** - претеглен F1 на класификатора за грубо ниво (3 класа).
- **Micro-F1 (фино, изолиран)** - Micro-F1 на класификатора за фино ниво при подадени верни основни етикети. Измерва качеството на финия модел изолирано от грешките на грубия.
- **Sample-F1 (фино, end-to-end)** - Sample-F1 за детайлните роли в крайната система (от край до край), при подадени *предсказани* основни етикети. Sample-F1 се изчислява, като F1 се пресмята поотделно за всеки пример (върху множеството от негови етикети) и резултатите се осредняват; това е стандартната метрика за многоетикетна класификация по подзадача 1.

- **Точно съвпадение (Exact Match Ratio, EMR)** - процент на примери, за които предсказаният набор от етикети съвпада *точно* с верния набор. Това е официалната метрика за класиране в подзадача 1 на SemEval-2025.

6.1.3 Хардуер


Обучението е проведено на видеокарта NVIDIA GeForce RTX 2060 с 6 GB VRAM с CUDA. Използвана е рамката HuggingFace Transformers [19] v4.x с PyTorch. Обучението на грубия класификатор отнема приблизително 60–90 минути, а на финия - около 120 минути, което дава общо време за обучение на двата класификатора от порядъка на 180–210 минути.

6.2 Обучителни криви и валидация

В тази секция представяме обучителните криви и валидационните метрики за двата класификатора - грубия и финия, обучени по каскадната процедура от Секция 5.11. И двата модела са обучавани с базов модел XLM-RoBERTa-base и същата основа от 6 размразени Transformer слоя (Секции 5.5 и 5.10).

6.2.1 Криви на загубата


Кривите на загубата при обучение (изгладени с ЕМА) показват траекторията на загубата по време на обучението. Грубият класификатор намалява от $\sim 0,96$ до $\sim 0,78$ за 5 000 стъпки и стабилизира своята стойност в последните епохи; финият спада от $\sim 0,14$ до $\sim 0,01$ за 7 300 стъпки, без признаци на повторно нарастване, което изключва прекомерно напасване.



Фигура 6.1: Криви на загубата при обучение на грубия и финия класификатор.

6.2.2 Метрики при валидация

Еволюцията на метриките по епохи показва, че грубият класификатор достига най-добра валидация на 10-та епоха (Асигура и F1 $\sim 0,81$). Финият показва стабилно Micro-F1 $\sim 0,94$ от първата епоха, докато Macro-F1 се подобрява от $\sim 0,71$ до $\sim 0,76$ - индикация, че регуляризацията на кардиналността постепенно подобрява предсказването на редките класове.




Фигура 6.2: Метрики при валидация по епохи за двата класификатора.

6.3 Резултати на класификатора за грубо ниво

Класификаторът за грубо ниво (Секция 5.5) постига **81,68% претеглен F1** на тестовото множество - подобрене от 14,35 процентни пункта спрямо базовия модел (67,33%).

6.3.1 Матрица на объркване

Класификаторът постига балансиран recall и за трите класа: Protagonist 81,7%, Antagonist 82,3%, Innocent 80,3% - спрямо базовия модел, който не разпознава Innocent (48,3% recall). Основното остатъчно объркване е между Protagonist и Antagonist (30+34=64 примера от тестовото множество).




Фигура 6.3: Матрица на объркване за класификатора за грубо ниво на предложената система (604 примера).

6.4 Резултати на класификатора за фино ниво

При подадени *верни* основни етикети (изолирана оценка), финият класификатор постига **93,87% Micro-F1** и **72,28% Macro-F1** на тестовото множество.

6.4.1 Precision, Recall и калибрация на кардиналността


Средният брой предсказани етикети по епохи започва от $\sim 1,12$, достига пик $\sim 1,62$ на 4-та епоха и се стабилизира около 1,48 към края на обучението - близо до целевата кардиналност 1,5. Precision, Recall и Sample-F1 се припокриват около 0,94, което показва добре балансиран модел без систематично свръх- или подпредсказване. Това потвърждава ефективността на регуляризацията на кардиналността с тегло $\lambda_{\text{card}} = 0,3$ (Секция ??).



Фигура 6.4: Precision, Recall, F1 и среден брой предсказания по епохи за финия класификатор.

6.4.2 F1 по детайлни етикети

Наблюдава се съществена вариация в E2E F1 по детайлни етикети, силно корелираща с броя примери в обучителното множество. Честите етикети постигат добри резултати (Victim: 0,81 при $n = 119$; Foreign Adversary: 0,62 при $n = 81$; Peacemaker: 0,64 при $n = 40$), докато пет редки етикета имат F1=0,00 (Traitor, Spy, Bigot, Forgotten - всеки с $n \leq 11$ в тестовото множество, или 0,15 за Saboteur с $n = 7$).



Фигура 6.5: E2E F1 по детайлни етикети (тестово множество).

6.5 Крайна оценка (от край до край)

Крайната оценка (end-to-end) комбинира предсказанията на двата класификатора в каскада: грубият модел първо предсказва основната роля, след което финият модел предсказва детайлните роли само в съответната подгрупа. За разлика от изолираните оценки в Секции 6.3 и 6.4, тук грешките на грубия се пренасят директно в крайния резултат.

Таблица 6.1: Крайни резултати на предложената система (E19) на тестовото множество (604 примера).

Метрика	Стойност
Претеглен F1 (грубо ниво)	81,68%
Micro-F1 (фино, изолиран)	93,87%
Sample-F1 (фино, end-to-end)	50,67%
Точно съвпадение (EMR)	44,54%
Средно предсказани етикети/пример	1,15
Средно верни етикети/пример	1,08

Голямата разлика между изолирания Micro-F1 (93,87%) и end-to-end Sample-F1 (50,67%) показва, че грешките на грубия класификатор са основното ограничение на крайната система - когато грубият сгреша, финият работи в грешен клон от йерархията и не може да възстанови верните фини роли. EMR от 44,54% означава, че близо половината примери получават перфектно множество от етикети - силен резултат за многоетикетна класификация с 22 възможни фини роли.

6.6 Сравнение с базовия модел

Стойностите на базовия модел в Таблица 6.2 идват от два отделни класификатора - грубия (Секция 4.3) и финия (Секция 4.4). Предложената система превъзхожда базовия модел по всички ключови метрики - +14,4 процентни пункта по Coarse F1, +11,8 пункта по Fine Sample-F1 и +32,8 пункта по EMR.

Таблица 6.2: Сравнение: базов модел (Глава 4) срещу предложена система (E19).

Метрика	Базов модел	Предложена система
Претеглен F1 (грубо ниво)	67,33%	81,68%
Осредняване по обхват (ESP)	Не (CLS)	Да
Класификационна глава	Линейна	Семантично сходство
Функция на загубата (грубо)	CE	CB-CE
Функция на загубата (фино)	BCE + pos_weight	ASL
Йерархично обуславяне	Не	Меко
Връзка груб $\rightarrow$ фин	Не (независими модели)	Да (каскада)
Sample-F1 (фино, end-to-end)	38,86%	50,67%
Точно съвпадение (EMR)	11,75%	44,54%
Размразени слоеве	1	6
Максимална дължина	256	512

Подобренията се натрупват от множество независими промени. Най-съществените са: преходът от BCE+pos_weight към ASL с регуляризация на кардиналността за финалния класификатор, въвеждането на СВ-СЕ за грубия и размразяването на 6 вместо 1 Transformer слой. Изолираните приноси на всеки компонент са изследвани в аблационното изследване (Секция 6.9). Част от подобрението идва и от увеличената входна дължина (256→512), което не е архитектурна промяна и в бъдеща работа би могло да се изследва отделно.

6.7 Сравнение със състезателни системи

Предложената система постига **44,54% EMR** на тестовото множество (публичното dev множество на SemEval-2025 от 10 януари 2025). Таблица 6.3 съпоставя този резултат с водещите системи в подзадача 1, чиито стойности са на скритото състезателно тестово множество.

Таблица 6.3: Резултати на предложената система спрямо водещите системи от SemEval-2025 Task 10.

Система	Базови модели	Параметри	Avg EMR
DUTIR [4]	GLM-4-Plus, Qwen2.5, Llama 3.1	десетки B	0,475
PATeam	Qwen2.5-72B, Phi-4	72B / 14B	0,421
BERTastic [3]	XLM-R + GPT-4o (API)	278M + API	0,386
LTG [5]	XLM-RoBERTa	278M	-
Предложена система (E19)	XLM-RoBERTa-base	278M	0,4454


Забележка: Стойностите на състезателните системи са от официалното класиране в [1] на скритото тестово множество. Предложената система е оценена на публичното dev множество от 10 януари 2025. Сравнението е ориентировъчно поради различните множества, но показва къде се намира предложената система в общата картина.

С 278M параметъра и без външно API, предложената система е 30-250 пъти по-малка от водещите. Тези системи използват или големи декодерни модели (десетки милиарди параметри), или платено API (GPT-4o). EMR от 44,54% поставя предложената система в обхвата между BERTastic (38,6%) и PATeam (42,1%) - в съседство със системи, които ползват външни API или модели с над 70 милиарда параметри.

6.8 Анализ по езици

Корпусът на SemEval-2025 покрива пет езика - български (BG), английски (EN), хинди (HI), португалски (PT) и руски (RU). Фигура 6.6 сравнява претегления F1 на грубия класификатор по език за базовия модел и предложената система. Подобрение

е видно за всички езици, като най-голям ръст се наблюдава за BG (+20,8 пп) и RU (+19,9 пп).



Фигура 6.6: Претеглен F1 на грубия класификатор по езици - сравнение на базовия модел и предложената система.

Най-голямото подобрение е по разпознаването на Innocent - в базовия модел $F1=0,000$ за BG и EN (моделът колапсира към мажоритарните класове), докато в предложената система F1 се повишава до 0,29 (BG), 0,67 (EN), 0,79 (HI), 0,97 (PT), 0,63 (RU). Това е заслуга на СВ-СЕ и кардиналностната регуляризация. Все пак BG ($n=31$) остава най-трудният език - вероятно поради ниската поддръжка в обучителното множество.

6.9 Аблационно изследване

Аблационното изследване обхваща 20 експеримента по пет основни оси: класификационна глава, загуба за грубо ниво, загуба за фино ниво, регуляризация на кардиналността и тип йерархично обуславяне.

6.9.1 Аблация на класификационната глава

Таблица 6.4: Аблация на типа класификационна глава.

Грубо ниво	Фино ниво	Coarse F1 (%)	E2E Fine F1 (%)	EMR (%)
Semantic	Semantic	79,61	50,66	37,09
MLP	Semantic	80,74	32,34	29,30
Semantic	MLP	79,12	49,90	38,74
MLP	MLP	80,74	35,29	31,29

Резултатите разкриват асиметрия: MLP главата постига по-висок Coarse F1 (80,74% срещу 79,61%) на изолирана оценка, но семантичната глава води до 18 процентни пункта по-висок E2E Fine F1 (50,66% срещу 32,34%). Едно обяснение е, че опорните вектори на семантичната глава ограничават възможните логити в по-добре отделими посоки, което води до по-калибрирани вероятности при подаване към финия класификатор.

6.9.2 Аблация на функцията на загубата за грубо ниво

Таблица 6.5: Аблация на функцията на загубата за грубо ниво.

Загуба	Coarse F1 (%)	E2E Fine F1 (%)	EMR (%)
Focal Loss	79,61	50,66	37,09
Cross-Entropy	78,05	50,29	41,06
Weighted CE	81,19	50,44	41,06
CB-CE	81,68	50,67	44,54

CB-CE дава най-добри резултати по всички три метрики. Подобрението спрямо стандартна CE е 3,63 пункта в Coarse F1 и 3,48 пункта в EMR. Фокалната загуба, въпреки доминантната си позиция за дисбалансиранни данни, тук отстъпва на CB-CE - при само 3 класа фокусирането върху „трудни примери“ не носи същата полза, както при многокласови дисбаланси с десетки класове.

6.9.3 Аблация на функцията на загубата за фино ниво

Таблица 6.6: Аблация на функцията на загубата за фино ниво.

Загуба	Параметри	Fine μ F1 (%)	E2E F1 (%)	EMR (%)
Focal	$\gamma = 2,0$	95,12	28,56	22,19
ASL	$\gamma^- = 2,0, \gamma^+ = 1,0$	93,78	51,63	42,38
ASL	$\gamma^- = 2,0, \gamma^+ = 0,0$	92,50	50,66	37,09
ASL	$\gamma^- = 4,0, \gamma^+ = 1,0$	92,46	32,36	25,99

Показателно е, че фокалната загуба постига най-висок Fine μ F1 (95,12%) при изолирана оценка, но най-нисък E2E F1 (28,56%). ASL с умерени параметри показва най-добрия баланс. Резултатите тук са с фиксирана груба загуба (Focal); финалната конфигурация (CB-CE + ASL $\gamma^- = 2, \gamma^+ = 0$) е E19 в §6.5 с EMR = 44,54%.

6.9.4 Аблация на регуляризацията на кардиналността

Таблица 6.7: Аблация на регуляризацията на кардиналността.

λ_{card}	Fine μ F1 (%)	E2E F1 (%)	EMR (%)
0,0 (без)	94,92	25,97	22,35
0,3	92,50	50,66	37,09
0,5	92,69	53,33	40,73

Без регуляризация ($\lambda_{\text{card}} = 0$) моделът предсказва повече етикети от реалното, което води до драстичен спад на E2E F1 (25,97%). Регуляризацията с $\lambda_{\text{card}} = 0,3$ почти удвоява E2E F1, а $\lambda_{\text{card}} = 0,5$ дава най-висок E2E F1, но по-нисък EMR. Стойността $\lambda_{\text{card}} = 0,3$ е избрана като компромис.

6.9.5 Меко срещу твърдо обуславяне

Таблица 6.8: Меко срещу твърдо йерархично обуславяне.

Обуславяне	Fine μ F1 (%)	E2E F1 (%)	EMR (%)
Меко (E19)	93,87	50,67	44,54
Твърдо (E20)	67,86	31,13	0,00

Твърдото маскиране води до незадоволителни резултати: $EMR = 0,00\%$, и $Fine \mu F1$ спада драстично от $93,87\%$ до $67,86\%$ дори при изолирана оценка. Това показва, че твърдото елиминироване на невъзможни класове прекъсва обучителния сигнал и пречи на финия класификатор да научи добри представяния. Мекото обуславяне запазва градиентите към всички класове и позволява на финия класификатор да компенсира частично грешките от грубо ниво.

6.10 Анализ на грешките

За по-задълбочено разбиране на грешките, класифицираме тестовите примери в четири категории:

1. **coarse_wrong** ($18,4\%$) - основната роля е грешна. Това автоматично влияе и на детайлните роли, особено при твърдо маскиране.
2. **fine_missing** ($\sim 35\%$) - основната роля е вярна, но един или повече верни детайлни етикети са пропуснати.
3. **fine_extra** ($\sim 37\%$) - основната роля е вярна, но са добавени излишни детайлни етикети.
4. **perfect** ($44,54\%$) - предсказаният набор от етикети съвпада точно с верния (EMR).

Забележка: категориите **fine_missing** и **fine_extra** не са взаимно изключващи се - един пример може едновременно да има пропуснати и излишни етикети, в който случай се брои и в двете.

Основният източник на грешки е каскадното разпространение от грубо към фино ниво. При $81,68\%$ F1 на грубо ниво, $18,4\%$ от примерите тръгват с грешен контекст. Мекото обуславяне смекчава този ефект, но не може напълно да го елиминира - подобрението на грубия класификатор остава най-важният фактор за крайната производителност.

Глава 7

Разработка на интерактивно приложение и анализ на приноса на думите

В тази глава описваме разработеното интерактивно приложение за демонстрация на системата и реализирания модул за анализ на приноса на думите и фразите. Двата компонента са изградени върху вече обучената система (Глава 5) и не изискват повторно обучение или промяна на архитектурата.

7.1 Описание на приложението

Приложението представлява уеб-базиран инструмент за демонстрация на обучената система, който позволява класификация на произволен новинарски текст на всеки от петте езика на задачата без нужда от команден ред или познания по програмиране. То има две основни предназначения: да направи системата достъпна за директно изпробване от потребител и да служи като средство за качествен анализ, чрез което да се проследи как моделът достига до конкретно решение. От тях произтичат и функционалностите: въвеждане и класификация на текст с визуализация на предсказаните основни и детайлни роли, предзаредени примери на различни езици, анализ на приноса на отделните думи и фрази към решението (Секция 7.2), както и кеширане на резултатите за плавно интерактивно изследване.

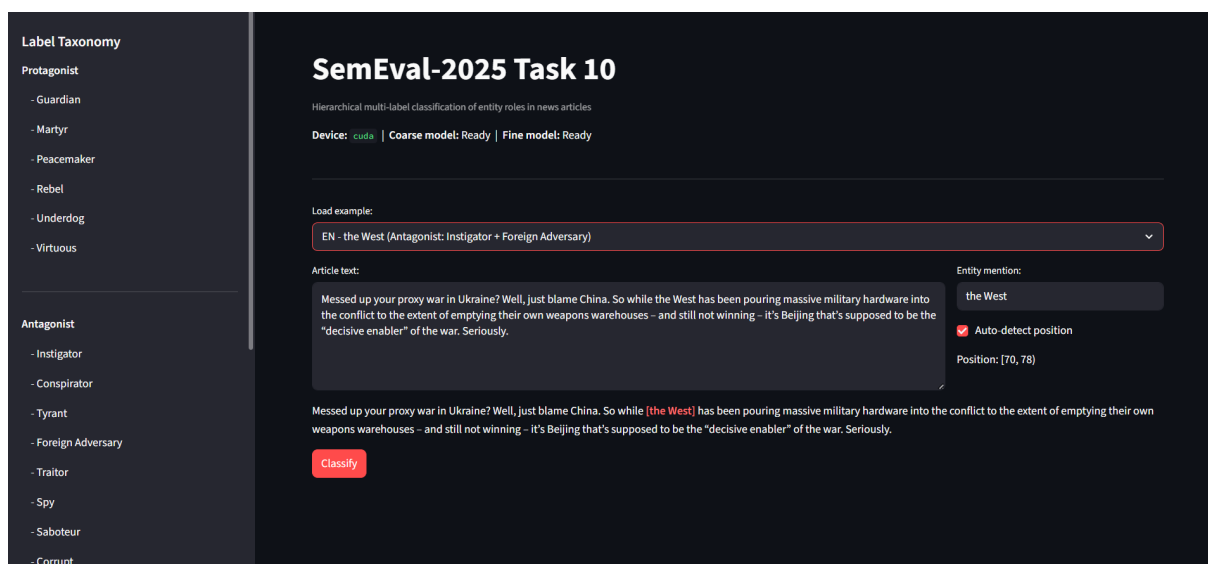
Приложението е реализирано с библиотеката Streamlit 1.56 върху PyTorch 2.9 и HuggingFace Transformers 4.57.

7.1.1 Основен поток

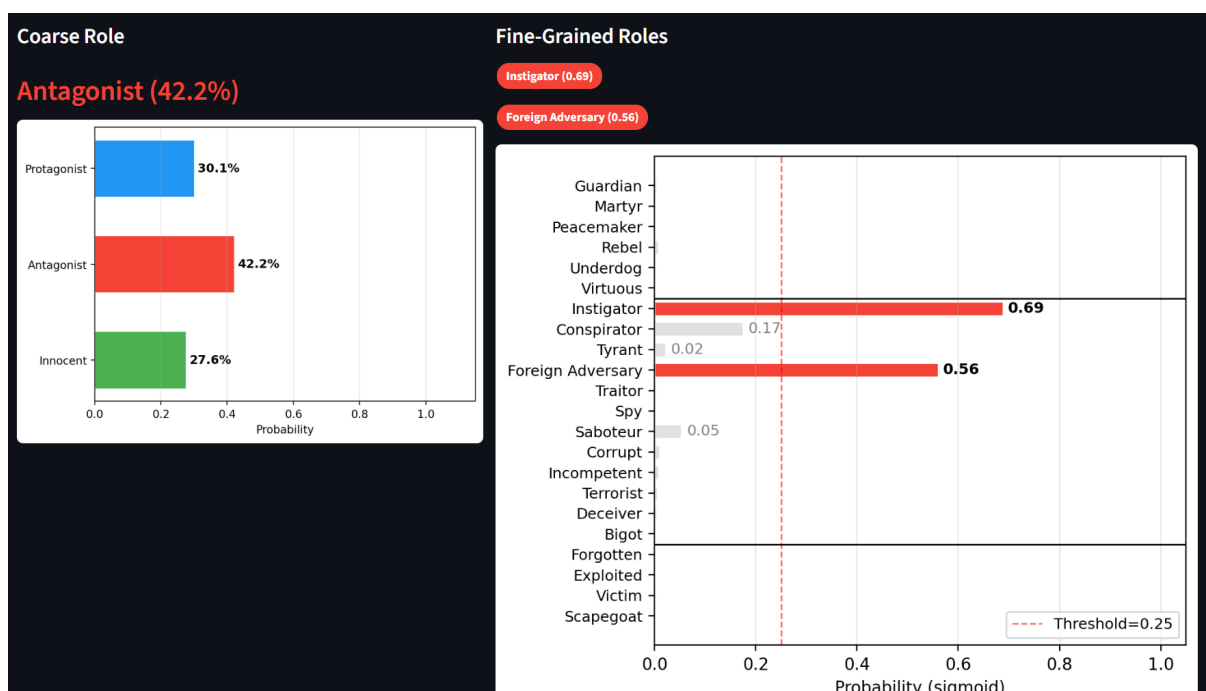
Потребителят въвежда новинарски текст, споменаване на обекта и началната му позиция в текста (или активира опцията за автоматично намиране на позицията). Системата изпълнява пълната каскадна обработка от Глава 5: маркиране на обекта с токените [ENTITY]/[/ENTITY], токенизация, преминаване през грубия класифика-

тор, след което финия. Резултатите се визуализират като два панела - вероятностна диаграма за трите основни роли и вероятностна диаграма за 22-те детайлни роли, групирани по основна категория.

Предложени са шест случайно избрани примера, които покриват три езика (английски, български и хинди) и разнообразни комбинации от роли - включително случаи с повече от една предсказана детайлна роля. Страничният панел показва пълната таксономия (Таблица 3.1) за справка.



Фигура 7.1: Интерфейсът на приложението при въвеждане на текст. Потребителят избира предзареден пример или въвежда произволен текст, а споменаването на обекта се маркира автоматично (в оранжево).



Фигура 7.2: Резултати от класификацията за обекта “the West” (EN). Вляво - вероятностите за трите основни роли (предсказана: Antagonist, 42.2%); вдясно - вероятностите за 22-те детайлни роли, с подчертани предсказани роли Instigator (0.69) и Foreign Adversary (0.56).

7.1.2 Управление на кеша

Предсказанията и резултатите от анализа на приноса (Секция 7.2) се съхраняват в `st.session_state`. Ключът за кеширане включва хеш на маркирания текст, задачата (грубо/фино), целевия клас и метода. Благодарение на това превключването между разделите или промяната на параметъра *top-K* не предизвиква повторно изчисление. Кешът се изчиства при всяко ново натискане на бутона *Classify*.

7.2 Анализ на приноса на думите

Класификационната система взема решения въз основа на контекста около обекта, но самото решение е непрозрачно - не е ясно кои думи или фрази са го обусловили. Модулът за анализ на приноса отговаря на този въпрос: за всяко предсказание визуализира кои части от текста са допринесли най-много за избраната роля и в каква посока.

7.2.1 Обзор на методите за атрибуция

При класификационни модели, базирани на Transformer архитектура, въпросът “коя дума е накарала модела да предскаже тази роля?” е нетривиален - информации-

ята се разпространява нелинейно из всички слоя на самовнимание. В литературата са предложени четири основни класа методи за отговор на този въпрос.

Методи на пертурбация. Заменят части от входа и измерват промяната в изхода. Ключово предимство на тези подходи е че работят независимо от конкретния модел - не изискват достъп до градиентите или вътрешната структура на модела, само до изхода му. LIME [20] обучава локален линеен апроксимиращ модел около всяко предсказание; SHAP [21] изчислява Shapley стойности - теоретично обосновано разпределение на приноса между признаците, произлизащо от теорията на кооперативните игри. За невронни мрежи SHAP се прилага като KernelSHAP, чийто брой изчислителни проходи нараства линейно с броя токени и типично достига хиляди за стандартен абзац.

Методи, базирани на градиенти. Изчисляват чувствителността на изхода спрямо входните вграждания чрез обратно разпространение на грешката. Методът Gradient (или Saliency) [22] взема директно абсолютната стойност на градиента; Gradient $\times$ Input умножава градиента по самото вграждане; Integrated Gradients [23] интегрира градиентите по права линия от неутрална базова линия до входа в $m \geq 50$ стъпки, с което изпълнява теоретично желани аксиоми за атрибуция (чувствителност и инвариантност към имплементацията); SmoothGrad [24] усреднява градиенти при добавен шум, за да намали визуалния шум. Тези методи изискват само един (или m) проход (forward/backward pass) и са бързи, но дават линейна апроксимация.

Методи на базата на вниманието. Използват attention scores от Transformer слоевете. Достъпни без допълнителни изчисления, но надеждността им като обяснение е оспорена: Jain и Wallace [25] показват, че вниманието може да се пренареди, без да се промени предсказанието, откъдето следва, че то не е обяснение само по себе си. По-надеждни варианти са Attention Rollout [26], който проследява информационния поток между слоевете чрез матрично произведение на attention матриците, и Attention $\times$ Gradient, който комбинира attention терга с градиенти.

Разпространение на релевантността (LRP и ALTI). Layer-wise Relevance Propagation (LRP) разпространява “доказателства за предсказанието” назад от изхода до входа по специфични правила за всеки тип слой [27]. ALTI (Aggregating Layerwise Token Importance) [28] е специализиран за Transformer модели вариант, който агрегира значимостта на токените слой по слой, като отчита и остатъчните връзки. Тези методи дават по-пълна картина на информационния поток, но изискват промени в реализацията на модела.

Integrated Gradients и SHAP са широко приети като теоретично строги методи за атрибуция. Integrated Gradients изисква интерполация на вграждането между базова линия и входа в $m \geq 50$ стъпки [23]; SHAP изисква стотици изчислителни проходи за надеждни Shapley стойности [21]. LRP и ALTI пък изискват директен достъп до вътрешните активации и промени в архитектурата. При нашите ограничения (виде-

окарта NVIDIA GeForce RTX 2060 с 6 GB VRAM, изчислително време от порядъка на секунди, без промяна на вече обученния модел) тези подходи надвишават практически изисквания. Избираме по-бързи варианти със сходна обяснителна стойност: оклузия на ниво дума, оклузия на ниво фраза и Градиент $\times$ Вграждане.

7.2.2 Оклузия на ниво дума

Принцип. Методът е предложен за NLP от Li et al. [29] и следва директна идея: за всяка валидна позиция w в контекста заменяме съответния токен с `<mask>` и измерваме промяната в непреобразувания логит за целевия клас:

$$s_w = \ell(x) - \ell(x \setminus w) \quad (7.1)$$

Положителна стойност означава, че думата подкрепя предсказаната роля; отрицателна - че ѝ противодейства.

Пакетна обработка. Всички валидни позиции се обработват в един пакет с размер 32. Тези позиции се изключват от анализа: CLS, SEP, PAD, маркерите [ENTITY]/[/ENTITY] и токените в обхвата на обекта. Entity span pooling (Уравнение 5.1) разчита на маркерите за локализиране на **e**, и маскирането им би разрушило механизма.

Защо непреобразуван логит. И за грубото, и за финото ниво се използва суров логит, а не вероятност. Вероятностите въвеждат насищане (saturation): при уверени предсказания стойността на sigmoid/softmax е близо до 0 или 1, и маскирането измества изхода с незначими делти. Логитът е неограничен и остава чувствителен независимо от увереността на модела. Допълнително, при финото ниво логитът е $z = f(\mathbf{e}) + \mathbf{h}_{\text{prior}}$ (Уравнение 5.7): тъй като $\mathbf{h}_{\text{prior}}$ е константен при фиксиран $\mathbf{p}_{\text{coarse}}$, той се съкращава в делтата $\Delta z = z_{\text{orig}} - z_{\text{masked}}$ и измерваме само приноса на контекстните думи към $f(\mathbf{e})$.

7.2.3 Оклузия на ниво фраза

Принцип. Разширяваме стандартната оклузия от ниво токен до ниво фраза: вместо един токен, маскира се цяла фраза от k последователни думи. Дава по-силен и по-чист сигнал - при силно контекстуализирани токени индивидуалните делти са малки, но ефектът им се сумира при фразово маскиране.

Ограничения на фразите. Фразите не пресичат границите на изреченията - разделянето се извършва чрез NLTK `sent_tokenize`. Размерът k се избира автоматично (от 1 до 4 думи) така, че общият брой фрази да не надхвърля максимум 10.

Забележка за избора на подход. Разделянето с фиксирана дължина е опрос-

тен подход - синтактичният анализ би дал лингвистично по-обосновани граници, но надеждни парсъри за всичките пет езика на задачата не са налични, а дори за английски те връщат местоимения и функционални думи, които внасят шум. Разработването на по-прецизен многоезичен метод остава насока за бъдещо развитие.

7.2.4 Градиент $\times$ Вграждане (Gradient $\times$ Embedding)

Принцип. Методът е адаптация на Gradient $\times$ Input [22] за текстови модели: вместо скаларни входни стойности, градиентът се умножава по вградените векторни представления на токени. За всеки токен t с вградено представяне $\mathbf{e}_t \in \mathbb{R}^D$ изчисляваме точковото произведение между градиента на логита и самото представяне:

$$s_t = \nabla_{\mathbf{e}_t} \ell \cdot \mathbf{e}_t = \sum_{d=1}^D \frac{\partial \ell}{\partial e_{t,d}} \cdot e_{t,d} \quad (7.2)$$

Приносът на едно измерение d е голям само ако токенът е голям в това измерение и логитът е чувствителен точно там. Чрез умножението двете условия трябва да са изпълнени едновременно - едно само по себе си не е достатъчно.

Имплементация. При изпълнение се регистрира hook върху вградения слой `word_embeddings`, който запазва изходния тензор на вграждането и позволява изчисляване на градиента му чрез `retain_grad()`. След един обратен проход стойността за всеки токен t се изчислява директно като `(emb.grad * emb).sum(dim=-1)`, идентично с Уравнение 7.2. Ако hook-ът не улови градиента, методът връща `None` и потребителският интерфейс автоматично превключва на оклузия на ниво дума.

Ограничения. Методът е линейна апроксимация и не отчита нелинейни взаимодействия между токени. Засегнат е и от пристрастие към нормата на вграждането: по-редките думи в речника на XLM-RoBERTa обикновено имат по-голяма L_2 -норма, което може да изкриви абсолютната им стойност независимо от семантичния им принос. Методът е подходящ като допълнителна бърза индикация, а не като основен аналитичен инструмент.

7.2.5 Нормализация и визуализация

Дял на влиянието. И трите метода изразяват резултатите като дял от общото влияние (%):

$$\text{share}_w = \frac{s_w}{\sum_i |s_i|} \times 100\% \quad (7.3)$$

Положителна стойност (зелено) означава, че думата подкрепя предсказаната роля; отрицателна (червено) - че ѝ противодейства.

Оцветен текст. Думите/фразите от топ- K получават зелен или червен фон с

интензивност, пропорционална на $|\text{share}_w|$. Обектът е представен като отделно визуално обозначение с неутрален фон. Думите извън топ- K се показват без цветен фон.

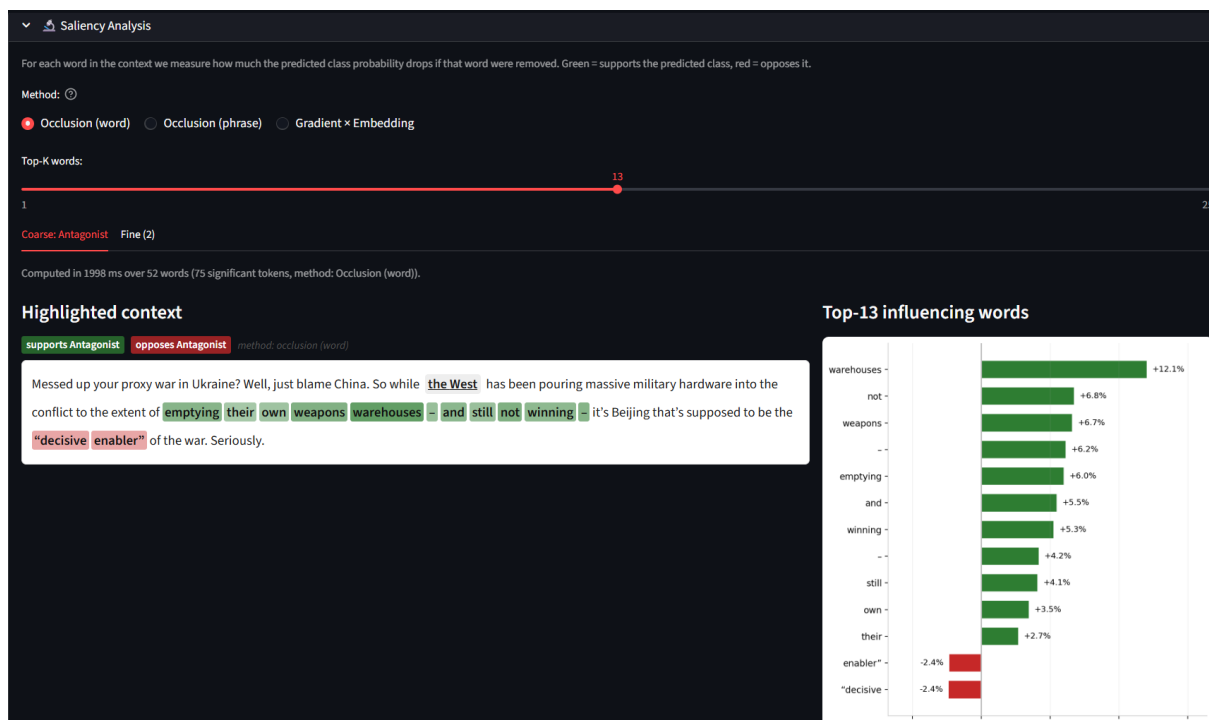
Диаграма. Хоризонтална лента-диаграма на топ- K записа, наредени по $|\text{share}_w|$. При фразовата оклузия последователни думи с еднаква делта стойност (принадлежащи на един блок) се обединяват в единен запис. Дългите фразови етикети се разбиват на редове.

И двата формата на визуализация (оцветен текст и диаграма) са синхронизирани - параметърът топ- K контролира и двата. Отделни раздели за грубото и финото ниво позволяват сравнение на кои части от текста обуславят двете нива на класификация.

7.3 Примерни резултати

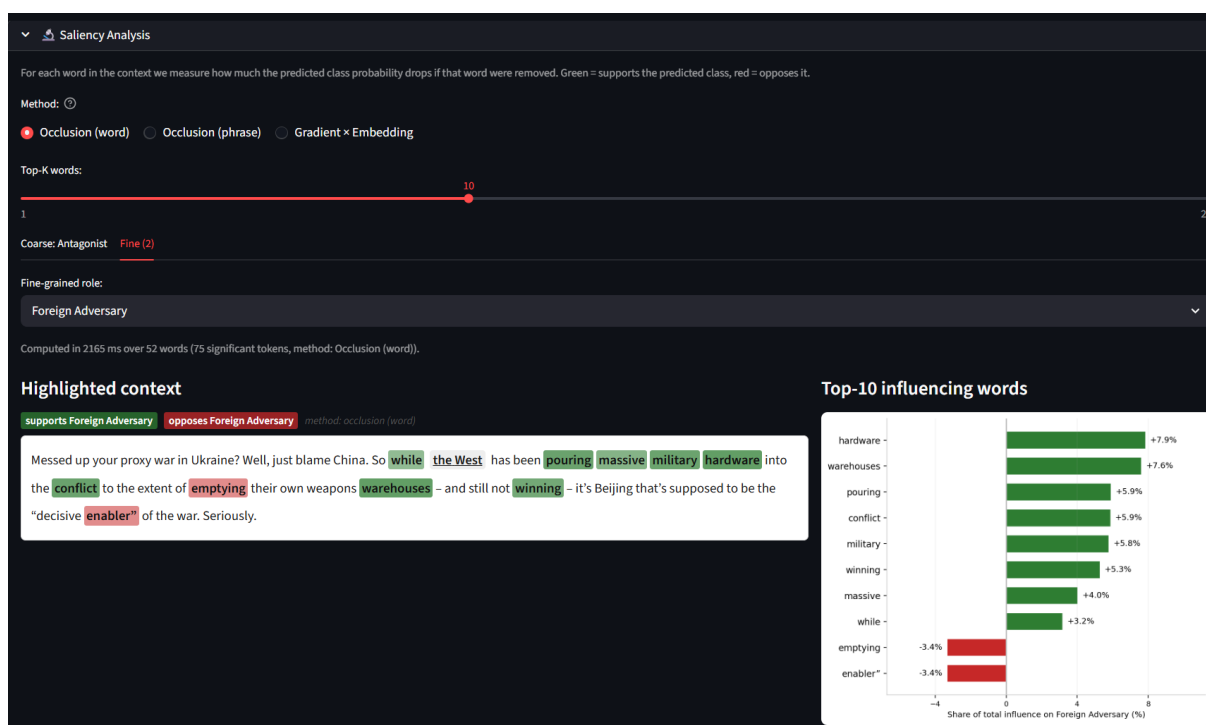
За илюстрация използваме готовия пример “the West” (EN) с предсказани роли Antagonist на грубо ниво и Instigator + Foreign Adversary на фино ниво. Примерът е подходящ за демонстрация, защото текстът съдържа изрична военна лексика, чийто принос моделът трябва да разграничи по нива.

Word Occlusion (грубо ниво). За ролята Antagonist думите “warehouses”, “weapons”, “emptying” и “winning” получават най-висок положителен принос (+12.1%, +6.7%, +6.0%, +5.3%) - военна лексика, свързана с изчерпване на ресурси и агресия, директно подкрепя тази роля. Думите “decisive” и “enabler” имат отрицателен принос (-2.4% всяка) - в контекста на изречението те описват обвинение към трета страна (China), а не директна агресия, и моделът ги оценява като неподкрепящ сигнал за тази роля.



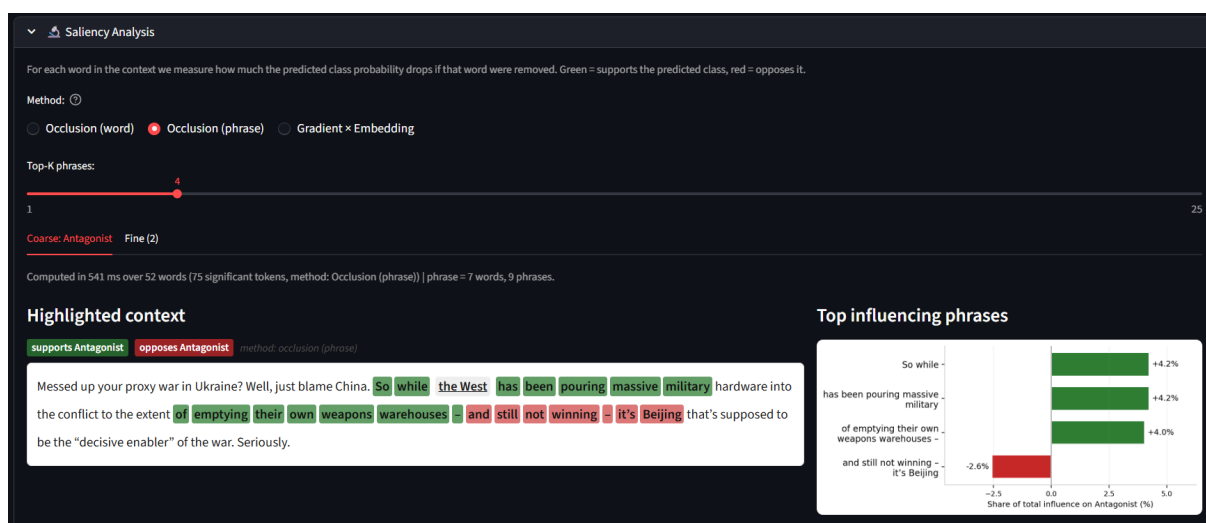
Фигура 7.3: Word Occlusion за ролята Antagonist (грубо ниво). Думи, свързани с военна тематика и изчерпване на ресурси, получават най-висок положителен принос.

Word Occlusion (фино ниво). При превключване към фино ниво за ролята Foreign Adversary разпределението на приноса се измества: водещи стават “hardware” (+7.9%), “pouring” (+5.9%), “conflict” (+5.9%) и “military” (+5.8%). Antagonist се активира от общия военен контекст, докато Foreign Adversary реагира по-специфично на думи, свързани с военна намеса и конфликт.



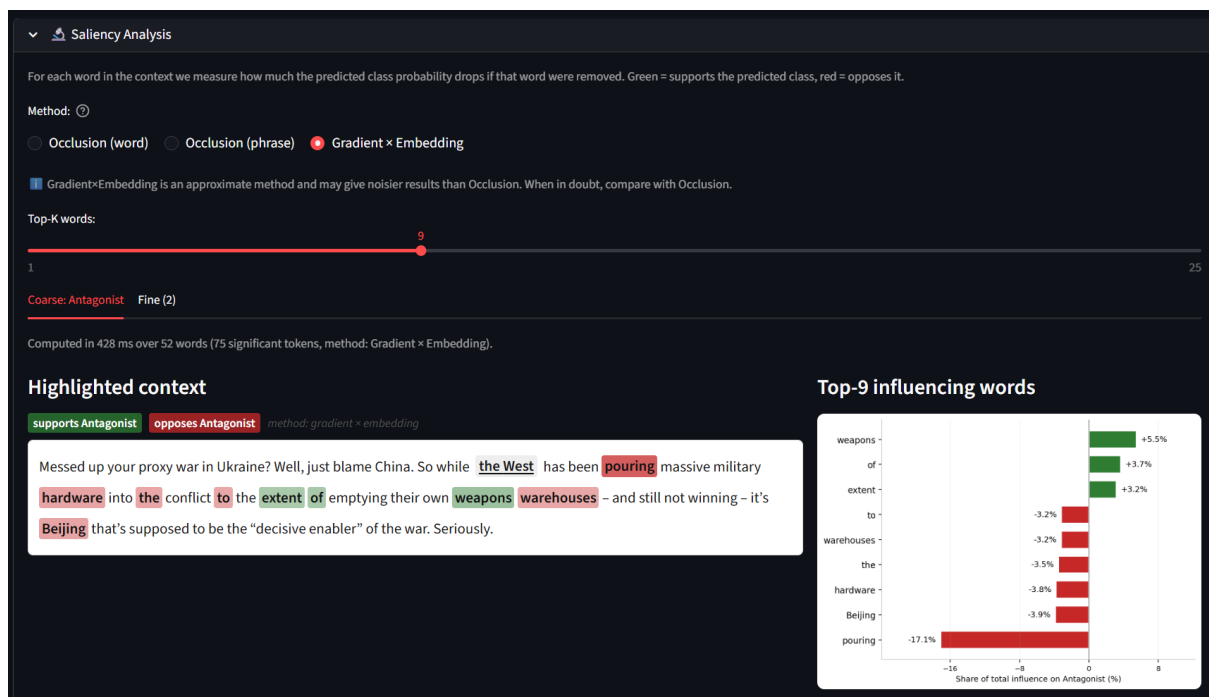
Фигура 7.4: Word Occlusion за ролята Foreign Adversary (фино ниво). Разпределението на приноса се измества към думи, свързани с военна намеса и конфликт, в сравнение с грубото ниво.

Phrase Occlusion. При оклузията по фрази, моделът идентифицира три свързани фрази с висок принос: “So while” (+4.2%), “has been pouring massive military” (+4.2%) и “of emptying their own weapons warehouses” (+4.0%), докато “and still not winning - it’s Beijing” (-2.6%) противодейства. Фразовата оклузия потвърждава наблюденията от оклузията на ниво дума и показва, че военната лексика действа съгласувано като смислова група, а не изолирано.



Фигура 7.5: Phrase Occlusion за ролята Antagonist. Фразата “has been pouring massive military” е идентифицирана като водещ положителен принос.

Gradient × Ввраждане. Методът дава по-различна картина: “pouring” (-17.1%) получава силно отрицателна стойност, докато при оклузията е положително. Това е пряка илюстрация на ограничението, описано в Секция 7.2.4 - линейната апроксимация и пристрастието към нормата на ввраждането могат да дадат различен знак от пертурбационните методи. Резултатите от двата класа методи следва да се разглеждат съвместно за по-надеждна интерпретация.



Фигура 7.6: Gradient × Ввраждане за ролята Antagonist. Резултатите се различават от оклузионните методи, което илюстрира линейната апроксимация на метода.

Глава 8

Заклучение

8.1 Обобщение на резултатите

В настоящата работа разработихме и оценихме система за йерархична класификация на ролите на именувани обекти в многоезични новинарски текстове. Системата е двустепенна каскада, базирана на XLM-RoBERTa-base, и включва:

- **Осредняване по обхват на обекта (Entity Span Pooling)** за извличане на представяне, фокусирано върху конкретния обект.
- **Класификация чрез семантично сходство** с опорни вектори, генерирани от имената на етикетите.
- **Класово балансирана кръстосана ентропия (CB-CE)** за компенсиране на класовия дисбаланс на грубо ниво.
- **Асиметрична загуба (ASL) с регуляризация на кардиналността** (целева стойност 1,5) за многоетикетната класификация на фино ниво.
- **Меко йерархично обуславяне** чрез обучаемата матрица на афинитет (3×22).
- **Относителен праг** с адаптивен ефективен праг за всеки пример.
- **Интерактивно приложение за демонстрация** (Глава 7), реализирано с Streamlit, което позволява класификация на произволен текст на петте езика на задачата.
- **Модул за анализ на приноса на думите** (Глава 7), предлагащ три метода за атрибуция - оклузия на ниво дума, оклузия на ниво фраза и Градиент $\times$ Вграждане - без повторно обучение или промяна на архитектурата.

Системата постига **81,68% претеглен F1** за основната роля (подобрене от 14,35 п.п. спрямо базовия модел) и **50,67% Sample-F1 (фино, end-to-end)** при **44,54% точно съвпадение (EMR)**. Спрямо базовия класификатор за фино ниво (38,86% Sample-F1, 11,75% EMR) подобренето е още по-изразено: +11,81 процентни пункта в Sample-F1 и +32,79 процентни пункта в EMR. За сравнение, водещите системи в SemEval-2025 Task 10 отчитат средно 0,475 EMR (DUTIR) и 0,421 EMR (PATeam) на скритото състезателно тестово множество, докато предложената система постига 0,4454 EMR на публичното dev множество. Сравнението е ориентировъчно поради различните множества, но показва, че малък енкодерен модел (278M параметъра) може да постигне резултати в обхвата на многократно по-големи декодерни системи.

Аблационният анализ (20 експеримента) показва приноса на всеки компонент и разкрива два ключови извода: (1) мекото обуславяне е критично (44,54% EMR срещу 0,00% при твърдо маскиране); (2) регуляризацията на кардиналността почти удвоява E2E F1 (50,66% срещу 25,97% без нея).

8.2 Ограничения

Предложената система има следните ограничения:

1. **Последователно обучение.** Двата класификатора се обучават каскадно, а не съвместно. Грешките от грубия класификатор не могат да бъдат коригирани чрез обратна връзка от финия.
2. **Фиксирани параметри на праговане.** Стойностите $\tau = 0,25$, $r = 0,7$ са фиксирани и не се оптимизират за конкретния модел или език.
3. **Единичен модел.** Не е приложен ансамблов подход, който би могъл да подобри устойчивостта на предсказанията.
4. **Разлика между перфектен вход и крайна оценка.** Финият класификатор постига 93,87% $\mu F1$ при изолирана оценка, но само 50,67% Sample-F1 (фино, end-to-end) - разлика от 43,20 п.п., което показва, че грешките от грубо ниво остават основен ограничаващ фактор.

8.3 Бъдещи насоки

Идентифицираме няколко перспективни направления за бъдещо развитие:

1. **Съвместно обучение** на двата класификатора с обща функция на загубата, което би позволило обратна връзка от финото към грубото ниво.

2. **По-големи модели.** Използване на XLM-RoBERTa-large (550M параметъра) или многоезични варианти на по-нови модели, което би подобрило както грубото, така и финото ниво.
3. **Подходи с големи езикови модели (LLM).** Работа с промптове или фино настройване на големи генеративни модели (например Llama, Mistral) за директно генериране на ролеви етикети - може да се изследва дали по-голям параметричен капацитет компенсира комплекта от ръчно проектирани компоненти (CB-CE, ASL, кардиналностна регуляризация).
4. **Разширена аугментация.** Използване на обратен превод (back-translation) или парафразиране за обогатяване на обучителното множество, особено за езици с малко данни (български, руски).
5. **Оптимизация на прага.** Автоматично настройване на параметрите на носителния праг чрез Байесова оптимизация или обучение на допълнителен класификатор за определяне на оптималния праг.
6. **Разширяване на анализа на приноса на думите.** Замяна на оклузионния метод с Integrated Gradients [23], което би дало теоретично по-обосновани атрибуции при сходно изчислително натоварване. Интересно направление е и сравнителен анализ между трите реализирани метода по корелация на атрибутите за едни и същи примери.

Използвана литература

- [1] Jakub Piskorski, Tarek Mahmoud, Nikolaos Nikolaidis, Ricardo Campos, Alípio Mário Jorge, Dimitar Dimitrov, Purificação Silvano, Roman Yangarber, Shivam Sharma, Tanmoy Chakraborty, Nuno Guimaraes, Elisa Sartori, Nicolas Stefanovitch, Zhuohan Xie, Preslav Nakov и Giovanni Da San Martino. "SemEval 2025 Task 10: Multilingual Characterization and Extraction of Narratives from Online News". B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, c. 2610—2643. URL: <https://aclanthology.org/2025.semeval-1.331/>.
- [2] Dimitar Dimitrov, Firoj Alam, Maram Hasanain, Abul Hasnat, Fabrizio Silvestri, Preslav Nakov и Giovanni Da San Martino. "SemEval-2024 Task 4: Multilingual Detection of Persuasion Techniques in Memes". B: *Proceedings of the 18th International Workshop on Semantic Evaluation (SemEval-2024)*. Mexico City, Mexico: Association for Computational Linguistics, 2024.
- [3] Tarek Mahmoud, Zhuohan Xie и Preslav Nakov. "BERTastic at SemEval-2025 Task 10: State-of-the-Art Accuracy in Coarse-Grained Entity Framing for Hindi News". B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, c. 386—396. URL: <https://aclanthology.org/2025.semeval-1.55/>.
- [4] Tengxiao Lv, Juntao Li, Chao Liu, Yiyang Kang, Ling Luo, Yuanyuan Sun и Hongfei Lin. "DUTIR at SemEval-2025 Task 10: A Large Language Model-based Approach for Entity Framing in Online News". B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, c. 174—179. URL: <https://aclanthology.org/2025.semeval-1.25/>.
- [5] Egil Rønningstad и Gaurav Negi. "LTG at SemEval-2025 Task 10: Optimizing Context for Classification of Narrative Roles". B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025. URL: <https://aclanthology.org/2025.semeval-1.61/>.

- [6] Adith Rajeev и Radhika Mamidi. "adithjrajeev at SemEval-2025 Task 10: Sequential Learning for Role Classification Using Entity-Centric News Summaries". B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, c. 241—246. URL: <https://aclanthology.org/2025.semeval-1.36/>.
- [7] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser и Illia Polosukhin. "Attention Is All You Need". B: *Advances in Neural Information Processing Systems 30 (NeurIPS)*. 2017.
- [8] Jacob Devlin, Ming-Wei Chang, Kenton Lee и Kristina Toutanova. "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding". B: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Minneapolis, Minnesota: Association for Computational Linguistics, 2019, c. 4171—4186.
- [9] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer и Veselin Stoyanov. "RoBERTa: A Robustly Optimized BERT Pretraining Approach". B: *arXiv preprint arXiv:1907.11692* (2019).
- [10] Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco Guzmán, Edouard Grave, Myle Ott, Luke Zettlemoyer и Veselin Stoyanov. "Unsupervised Cross-lingual Representation Learning at Scale". B: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*. Association for Computational Linguistics, 2020, c. 8440—8451.
- [11] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He и Piotr Dollár. "Focal Loss for Dense Object Detection". B: *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*. 2017, c. 2980—2988.
- [12] Yin Cui, Menglin Jia, Tsung-Yi Lin, Yang Song и Serge Belongie. "Class-Balanced Loss Based on Effective Number of Samples". B: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2019, c. 9268—9277.
- [13] Emanuel Ben-Baruch, Tal Ridnik, Nadav Zamir, Asaf Noy, Itamar Friedman, Matan Protter и Lihi Zelnik-Manor. "Asymmetric Loss For Multi-Label Classification". B: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, c. 82—91.

- [14] Livio Baldini Soares, Nicholas FitzGerald, Jeffrey Ling и Tom Kwiatkowski. "Matching the Blanks: Distributional Similarity Matters for Zero-Shot Entity Linking". B: *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL)*. Florence, Italy: Association for Computational Linguistics, 2019, с. 2896—2905.
- [15] Jake Snell, Kevin Swersky и Richard S. Zemel. "Prototypical Networks for Few-Shot Learning". B: *Advances in Neural Information Processing Systems 30 (NeurIPS)*. 2017, с. 4077—4087.
- [16] Chuan Guo, Geoff Pleiss, Yu Sun и Kilian Q. Weinberger. "On Calibration of Modern Neural Networks". B: *Proceedings of the 34th International Conference on Machine Learning (ICML)*. 2017, с. 1321—1330.
- [17] Ilya Loshchilov и Frank Hutter. "Decoupled Weight Decay Regularization". B: *International Conference on Learning Representations (ICLR)*. 2019.
- [18] Jônatas Wehrmann, Ricardo Cerri и Rodrigo Barros. "Hierarchical Multi-Label Classification Networks". B: *Proceedings of the 35th International Conference on Machine Learning (ICML)*. 2018, с. 5225—5234.
- [19] Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, Joe Davison, Sam Shleifer, Patrick von Platen, Clara Ma, Yacine Jernite, Julien Plu, Canwen Xu, Teven Le Scao, Sylvain Gugger, Mariama Drame, Quentin Lhoest и Alexander M. Rush. "Transformers: State-of-the-Art Natural Language Processing". B: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations (EMNLP)*. Online: Association for Computational Linguistics, 2020, с. 38—45.
- [20] Marco Tulio Ribeiro, Sameer Singh и Carlos Guestrin. "'Why Should I Trust You?': Explaining the Predictions of Any Classifier". B: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, с. 1135—1144.
- [21] Scott M. Lundberg и Su-In Lee. "A Unified Approach to Interpreting Model Predictions". B: *Advances in Neural Information Processing Systems 30 (NeurIPS)*. 2017.
- [22] Karen Simonyan, Andrea Vedaldi и Andrew Zisserman. "Deep Inside Convolutional Networks: Visualising Image Classification Models and Saliency Maps". B: *International Conference on Learning Representations (ICLR), Workshop Track*. 2014.
- [23] Mukund Sundararajan, Ankur Taly и Qiqi Yan. "Axiomatic Attribution for Deep Networks". B: *Proceedings of the 34th International Conference on Machine Learning (ICML)*. 2017, с. 3319—3328.

- [24] Daniel Smilkov, Nikhil Thorat, Been Kim, Fernanda Viégas и Martin Wattenberg. "SmoothGrad: removing noise by adding noise". B: *ICML Workshop on Visualization for Deep Learning*. 2017.
- [25] Sarthak Jain и Byron C. Wallace. "Attention is not Explanation". B: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. 2019, c. 3543—3556.
- [26] Samira Abnar и Willem Zuidema. "Quantifying Attention Flow in Transformers". B: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*. Association for Computational Linguistics, 2020, c. 4190—4197.
- [27] Sebastian Bach, Alexander Binder, Grégoire Montavon, Frederick Klauschen, Klaus-Robert Müller и Wojciech Samek. "On Pixel-Wise Explanations for Non-Linear Classifier Decisions by Layer-Wise Relevance Propagation". B: *PLOS ONE*. T. 10. 7. 2015.
- [28] Javier Ferrando, Gerard I. Gállego и Marta R. Costa-jussà. "Towards Opening the Black Box of Neural Machine Translation: Source and Target Interpretations of the Transformer". B: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 2022, c. 8756—8769.
- [29] Jiwei Li, Xinlei Chen, Eduard Hovy и Dan Jurafsky. "Visualizing and Understanding Neural Models in NLP". B: *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Association for Computational Linguistics, 2016, c. 681—691.