



Софийски университет „Св. Кл. Охридски“

Факултет по математика и информатика

Катедра „Софтуерни технологии“

ПРЕДДИПЛОМЕН ПРОЕКТ

на тема

Базови модели за разпознаване на семантични роли в новинарски статии

Дипломант: **Борислав Мартинов Минчев**

Факултетен номер: **5MI3400508**

Специалност: **Информатика**

Магистърска програма: **Извличане на информация и откриване на знания**

Научен ръководител:

**Проф. д-р Иван Койчев, катедра „Софтуерни технологии“,
ФМИ, СУ „Св. Климент Охридски“**

Консултант:

**докт. Димитър Димитров, катедра „Софтуерни технологии“,
ФМИ, СУ „Св. Климент Охридски“**

София, 2026 г.

Съдържание

1	Увод	3
2	Преглед на областта	5
2.1	Основни понятия	5
2.2	Обзор на съществуващи подходи и състезания	5
2.2.1	Йерархична класификация	6
2.2.2	Многоетикетна класификация	7
2.3	Многоезични предварително обучени модели	8
3	Описание на задачата и набора от данни	9
3.1	Същност и цели на задачата	9
3.2	Таксономия на ролите	9
3.3	Структура на данните и анализ	10
3.3.1	Анализ на разпределенията	11
3.3.2	Предизвикателства	15
4	Базови модели за двете нива на класификация	16
4.1	Подготовка и предобработка на данните	16
4.1.1	Гранулярност на текста	16
4.1.2	Маркиране на обекта	17
4.1.3	Токенизация и кодиране	17
4.1.4	Разделяне на данните	17
4.2	Архитектура на моделите	18
4.2.1	Споделен гръбнак	18
4.2.2	Класификатор на грубо ниво (3 класа)	19
4.2.3	Класификатор на фино ниво (22 етикета)	19
4.2.4	Хиперпараметри и обучение	20
4.3	Резултати и анализ	22
4.3.1	Обучителен процес	22
4.3.2	Резултати на грубия класификатор (3 класа)	22
4.3.3	Резултати на финия класификатор (22 етикета)	25

4.3.4	Йерархични метрики	28
4.3.5	Обобщение на резултатите и слабости	28
5	Анализ на интерпретируемостта на базовите модели	29
5.1	Мотивация и цели на анализа	29
5.2	Методи за оценка на приноса на думите	30
5.2.1	Оклузионен анализ	30
5.2.2	Градиент $\times$ Вграждане	31
5.3	Качествен анализ на примери	32
5.4	Изводи от анализа на интерпретируемостта	34
6	Заклучение и насоки за дипломната работа	35
	Използвана литература	38

Глава 1

Увод

Разпространението на дезинформация и пропаганда в онлайн новинарски медии е сериозно обществено предизвикателство. Автоматичното разпознаване на начина, по който именуваните обекти (лица, организации, държави) са представени в новинарските текстове - дали като протагонисти, антагонисти или невинни - е от ключово значение за медийния мониторинг, проверката на факти и анализа на наративни манипулации.

В контекста на споделената задача SemEval-2025 Task 10 [1] е предложена формална рамка за многоезична класификация на ролите на именувани обекти в новинарски текстове. Задачата обхваща пет езика (български, английски, хинди, португалски и руски), две тематични области (войната в Украйна и климатичните промени) и три подзадачи. Настоящата работа е посветена на **подзадача 1 (Entity Framing)**, която изисква за всяко споменаване на именуван обект в дадена статия да бъде определена една основна роля (грубо ниво) и една или повече детайлни роли (фино ниво) от предварително дефинирана таксономия с 22 етикета.

Настоящият преддипломен проект поставя основите за дипломна работа по тази задача. Конкретно, целите на проекта са:

- Формализиране на задачата за класификация на ролите на именувани обекти и преглед на съществуващите подходи.
- Задълбочен статистически анализ на многоезичния набор от данни.
- Разработка и оценка на **два независими базови модела**, базирани на XLM-RoBERTa [2]: (а) многокласов класификатор за основната роля (3 класа), и (б) многоетикетен класификатор за детайлните роли (22 етикета).
- Анализ на грешките и слабостите на базовите модели.
- Приложение на методи за анализ на приноса на думите върху базовите модели за интерпретация на класификациите и идентифициране на лексикалните сигнали за всяка роля.

Структурата на документа е следната. Глава 2 представя преглед на областта: основни понятия, съществуващи подходи и предварително обучени многоезични модели. Глава 3 описва задачата и набора от данни, включително статистически анализ и основни предизвикателства. Глава 4 представя двата базови модела - за грубо и фино ниво - с обща методология, експериментална настройка и резултати. Глава 5 представя анализ на интерпретируемостта на базовите модели чрез два метода за оценка на приноса на думите: оклузионен анализ и градиент $\times$ вграждане. Глава 6 обобщава изводите и очертава насоките за дипломната работа.

Глава 2

Преглед на областта

2.1 Основни понятия

Рамкиране на именувани обекти (Entity Framing) е задачата за автоматично определяне на наративната роля, която даден именуван обект изпълнява в текст - например дали дадено лице е представено като герой, злодей или жертва.

Йерархична класификация (Hierarchical Classification) се отнася до задачи, при които етикетите са организирани в дървовидна таксономия и предсказанията трябва да бъдат съобразени с нея. Подробен преглед на подходите следва в раздел 2.2.1.

Трансферно обучение (Transfer Learning) в обработката на естествен език е парадигма, при която модел първо се предварително обучава върху голям корпус от текст чрез задачи за самонаблюдение (self-supervised learning), а след това бива фина настроен (fine-tuning) върху конкретна задача с по-малко данни [3]. Този подход е в основата на съвременните езикови модели като BERT и XLM-RoBERTa.

Представяне на именувана същност чрез специални маркери (entity span pooling) е техника, при която в текста се вмъкват специални токени [ENTITY] и [/ENTITY] около споменаването на обекта. Моделът може след това да извлече представяне, специфично за обекта, чрез осредняване на скритите състояния между тези маркери.

2.2 Обзор на съществуващи подходи и състезания

SemEval-2025 Task 10 [1] е споделена задача, организирана в рамките на 19-ия семинар по семантична евалуация (SemEval-2025). Задачата се състои от три подзадачи: (1) Entity Framing - класификация на ролята на именувани обекти; (2) Narrative Classification - присвояване на наративни етикети на ниво документ; (3) Narrative Extraction - генериране на текстово обяснение за доминиращия наратив. В състеза-

нието са се регистрирали 310 екипа, от които 66 са подали официални резултати. Настоящата работа се фокусира изцяло върху подзадача 1.

Това е продължение на серията от споделени задачи за детекция на пропаганда, включително SemEval-2024 Task 4 [4] за многоезично разпознаване на техники за убеждаване в мемеа.

Сред системите, постигнали най-добри резултати в подзадача 1 (Entity Framing), се открояват:

- **BERTastic** [5] - съчетава фино настроен XLM-RoBERTa с промптиране на GPT-4o. Постига 78,48% точност за основната роля и 51,57% F1 за детайлните роли. Класира се на първо място за хинди.
- **DUTIR** [6] - използва рамка, комбинираща многоезичен превод с GLM-4-Plus, QLoRA фино настройване и ансамблова класификация. Постига първо място за английски, португалски и руски.
- **LTG** [7] - прилага евристики за избор на контекст около обекта в комбинация с XLM-RoBERTa. Постига конкурентни резултати спрямо по-големи генеративни модели.
- **adithjrajeev** [8] - използва последователно обучение с резюмета, центрирани около обекта.

Таблица 2.1: Сравнение на водещи системи в SemEval-2025 Task 10, подзадача 1.

Система	Базов модел	Осн. роля (%)	Fine F1 (%)
BERTastic	XLM-R + GPT-4o	78,48	51,57
DUTIR	GLM-4-Plus + QLoRA	—	—
LTG	XLM-RoBERTa	—	—
Нашият (baseline)	XLM-RoBERTa-base	67,72	38,86

Забележителна тенденция е, че подходите, базирани на големи езикови модели (LLM), доминират в общото класиране, но фино настроените по-малки модели (напр. XLM-RoBERTa) постигат конкурентни резултати при по-ниски изчислителни разходи.

2.2.1 Йерархична класификация

Йерархичната класификация на текст (Hierarchical Text Classification) е задача, при която етикетите са организирани в дървовидна таксономия с връзки „родител–дете“. За разлика от плоската класификация, при йерархичната предсказанията на

различните нива трябва да бъдат *съвместими* - например, ако обект е класифициран с детайлна роля *Guardian*, той трябва да принадлежи и към родителската категория *Protagonist*.

В литературата се разграничават три основни подхода:

- **Плосък подход** - игнорира йерархията и обучава един класификатор за всички етикети. Прост за реализация, но не гарантира съвместимост между нивата.
- **Локален подход** - обучава отделен класификатор за всяко ниво на йерархията. Предсказанието на горното ниво се предава като вход или ограничение на следващото. Два варианта на предаване са *твърдо маскиране* (hard masking), при което недопустимите етикети се зануляват, и *меко обуславяне* (soft conditioning), при което вероятностите от горното ниво модулират предсказанията на долното.
- **Глобален подход** - единен модел, отчитащ цялата йерархия чрез споделени представяния или рекурсивни механизми.

В настоящата работа се използва локален подход с два етапа: класификация на основната роля (грубо ниво), след което резултатът се предава на класификатора за детайлни роли (фино ниво). Този подход позволява всеки етап да бъде оптимизиран независимо, а йерархичните ограничения да бъдат наложени при прехода между нивата.

2.2.2 Многоетикетна класификация

При многоетикетната класификация всеки пример може да получи произволно подмножество от етикетите, което поставя специфични изисквания към метриките за оценка.

Метрики за оценка. Многоетикетната природа на задачата изисква специфични метрики. Основните метрики в SemEval-2025 Task 10 са:

- **Exact Match Ratio (EMR)** - официалната метрика за класиране; измерва дела на примерите, за които предсказаният набор от етикети съвпада *точно* с верния.
- **Micro-F1** - агрегира истински положителните, фалшиво положителните и фалшиво отрицателните над всички етикети и примери.
- **Точност на основната роля (Main Role Accuracy)** - точност на класификацията на грубо ниво (3 класа).

2.3 Многоезични предварително обучени модели

Transformer архитектурата [9], предложена от Vaswani et al., поставя основата на съвременната обработка на естествен език. Ключовата иновация е механизмът за самовнимание (self-attention), който позволява на модела да улавя зависимости между произволни позиции в поредицата с постоянна сложност.

BERT (Bidirectional Encoder Representations from Transformers) [3] адаптира кодиращата част на Transformer за предварително обучение чрез маскиране на езиков модел (MLM) и предсказване на следващо изречение (NSP). Двупосочната архитектура позволява на модела да улавя контекст и от двете страни на всеки токен, което води до значителни подобрения в широк кръг задачи.

RoBERTa [10] оптимизира стратегията за предварително обучение на BERT: премахва NSP задачата, увеличава размера на партидата и обема на данните, и въвежда динамично маскиране.

XLM-RoBERTa [2] разширява подхода на RoBERTa за 100 езика, като използва 2,5 TB данни от Common Crawl. Моделът постига значителни подобрения спрямо mBERT: +14,6% на XNLI, +13% F1 на MLQA и +2,4% F1 за NER. Той покрива всичките пет езика от задачата, което го прави естествен избор за нашата многоезична класификация.

В настоящата работа използваме `xlm-roberta-base` (278M параметъра, 12 Transformer слоя, скрита размерност 768).

Глава 3

Описание на задачата и набора от данни

3.1 Същност и цели на задачата

Подзадача 1 (Entity Framing) от SemEval-2025 Task 10 [1] се дефинира формално по следния начин: дадена е новинарска статия и списък от споменавания на именувани обекти в нея, всяко определено чрез идентификатор на документа, текстово споменаване и начална/крайна позиция. За всяко споменаване трябва да бъдат определени:

1. **Основна роля** (main role) - точно един от трите етикета: Protagonist, Antagonist, Innocent.
2. **Детайлни роли** (fine-grained roles) - една или повече от 22 етикета, организирани йерархично под трите основни роли.

Задачата е многоезична, като данните обхващат пет езика: български (BG), английски (EN), хинди (HI), португалски (PT) и руски (RU). Тематичните области са две: войната между Русия и Украйна (URW) и климатичните промени (CC).

Официалната метрика за класиране е **Exact Match Ratio (EMR)** за детайлните роли, допълнена от micro-F1 и точност на основната роля.

3.2 Таксономия на ролите

Таксономията се състои от три основни роли и 22 детайлни роли, разпределени неравномерно (таблица 3.1).

Таблица 3.1: Таксономия на ролите: 3 основни и 22 детайлни.


Основна роля	Детайлна роля	Описание (накратко)
Protagonist (6)	Guardian	Защитник, пазител
	Martyr	Мъченик за кауза
	Peacemaker	Миротворец
	Rebel	Бунтовник, борец за промяна
	Underdog	Аутсайдер в неравна борба
	Virtuous	Нравствен, етичен лидер
Antagonist (12)	Instigator	Подбудител на конфликт
	Conspirator	Участник в заговор
	Tyrant	Тиранин, деспот
	Foreign Adversary	Външен противник
	Traitor	Предател
	Spy	Шпионин
	Saboteur	Саботьор
	Corrupt	Корумпиран
	Incompetent	Некомпетентен
	Terrorist	Терорист
	Deceiver	Измамник
	Bigot	Фанатик, нетолерантен
Innocent (4)	Forgotten	Забравен от обществото
	Exploited	Експлоатиран
	Victim	Жертва
	Scapegoat	Изкупителна жертва

Забелязва се силна асиметрия: категория Antagonist съдържа 12 детайлни роли - два пъти повече от Protagonist и три пъти повече от Innocent.

3.3 Структура на данните и анализ


Данните са организирани в директории по език. За всеки език са предоставени: обучително множество с анотации (идентификатор, споменаване, позиция, основна роля, детайлни роли), валидационно множество без етикети и директория с оригиналните текстове на статиите. При предварителната обработка около споменаването на обекта се вмъкват маркери [ENTITY] и [/ENTITY].

3.3.1 Анализ на разпределенията




Фигура 3.1: Разпределение на основните роли по езици.

На фигура 3.1 е представено разпределението на трите основни роли по езици. Наблюдава се ясен дисбаланс: ролята Antagonist доминира във всички езици, следвана от Protagonist, докато Innocent е най-рядко срещаната категория. Този дисбаланс е по-изразен за хинди и португалски.




Фигура 3.2: Разпределение на броя детайлни етикети на обект.

Фигура 3.2 показва разпределението на броя детайлни етикети, присвоени на всяко споменаване на обект. Повечето обекти имат точно един етикет (приблизително 92%), а средната кардиналност в обучителното множество е около 1,1. Тази изразено разредена структура е от значение за проектирането на системата и мотивира както претеглянето на положителния клас в базовия модел, така и регуляризацията на кардиналността в дипломната работа.

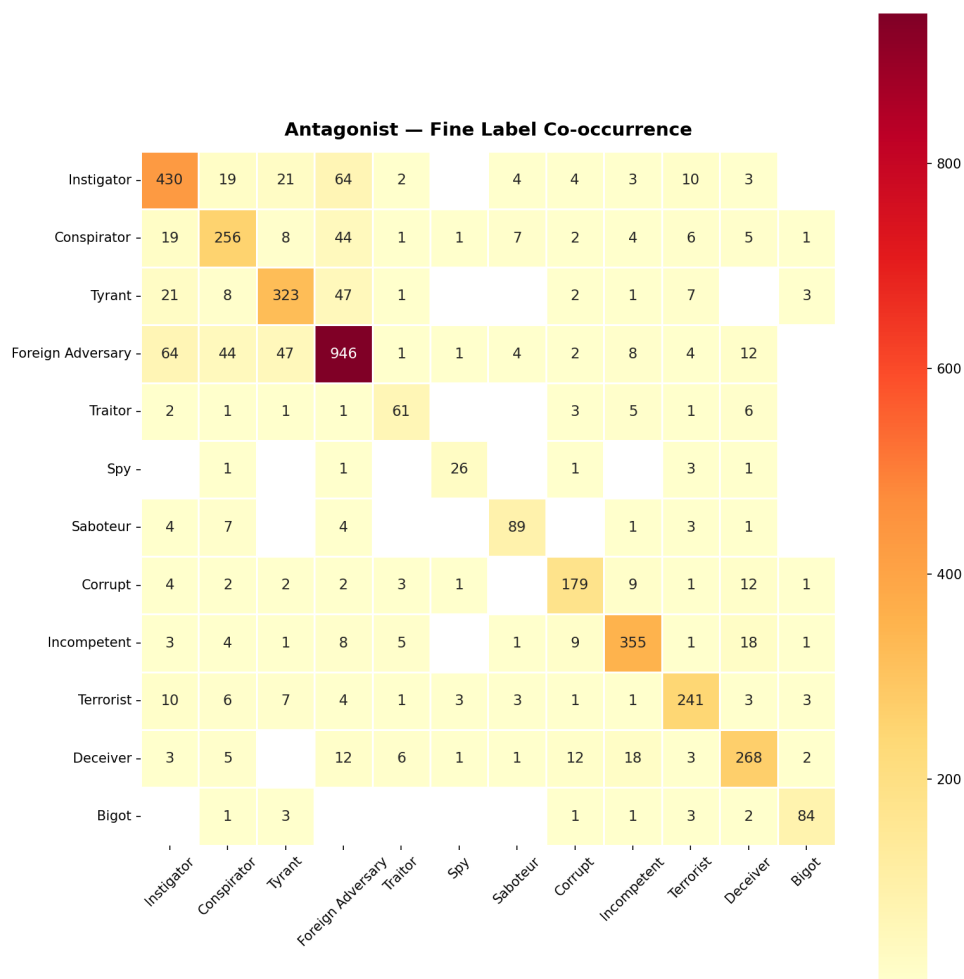


Фигура 3.3: Брой различни детайлни роли за многократно споменати именувани обекти в корпуса.


Фигура 3.3 показва броя различни детайлни роли за многократно споменаваните обекти в корпуса. По-голямата част запазват един и същ етикет - знак за последователно наративно рамкиране, - но малка група (типично политически фигури и държавни участници) получават различни роли в различни статии. Именно при тях е важно кои контекстуални сигнали определят класификацията при всяко споменаване - въпрос, по който анализът на приноса в глава 5 дава частичен отговор.



Фигура 3.4: Съвместно появяване на детайлните етикети в категория Protagonist.




Фигура 3.5: Съвместно появяване на детайлните етикети в категория Antagonist.




Фигура 3.6: Съвместно появяване на детайлните етикети в категория Innocent.

Матриците на съвместно появяване на детайлните етикети (фигури 3.4–3.6) показват, че съвместно срещащите се двойки са предимно в рамките на една и съща основна категория. При Protagonist (фигура 3.4) *Guardian* е най-честата роля (937 примера), като се комбинира най-често с *Virtuous* (116) и *Rebel* (61). При Antagonist (фигура 3.5) доминира *Foreign Adversary* (946), а най-честата двойка е *Instigator* + *Foreign Adversary* (64). При Innocent (фигура 3.6) категорията *Victim* е силно доминираща (1080), като често се комбинира с *Exploited* (41).



Фигура 3.7: Разпределение на дължината на текстовете по езици.

Фигура 3.7 представя разпределението на дължината на текстовете по езици. Наблюдава се значителна вариация - някои документи са много дълги и надхвърлят максималната дължина от 512 токена, използвана при токенизацията, което налага стратегии за отрязване (truncation).



Фигура 3.8: Разпределение по тематични области за езиците с налична информация.

Фигура 3.8 показва разпределението по тематични области за езиците, за които тази информация е налична. Трябва да се отбележи, че идентификаторите на документите за хинди и частично за португалски не съдържат маркери за домейн, поради което тези езици не са включени в диаграмата.

3.3.2 Предизвикателства

Анализът на данните разкрива няколко ключови предизвикателства:

1. **Класов дисбаланс.** Ролята Antagonist е значително по-застъпена от останалите, а Innocent е много рядка. Това налага използването на балансирани функции на загубата - например Class-Balanced Cross-Entropy [11].
2. **Разреденост на многоетикетното пространство.** При 22 възможни етикета и средна кардиналност от около 1,1, съотношението положителни/отрицателни за повечето класове е под 1:20. Стандартната функция на загубата (BCE) би довела до модел, който предсказва „нищо“ за повечето етикети.
3. **Многоезичност.** Петте езика имат различни типологични характеристики и писмени системи (латиница, кирилица, деванагари), което изисква многоезичен предварително обучен модел.
4. **Дълги документи.** Някои статии надхвърлят лимита от 512 токена, като обектът може да е споменат в различни части на текста.

Глава 4

Базови модели за двете нива на класификация

В тази глава са представени **два независими базови модела**: единият за класификация на основната роля, а другият за многоетикетна класификация на детайлните роли. Целта е да се установи начално ниво на производителност (baseline) за всяко от двете нива, спрямо което ще бъдат оценявани по-сложните архитектури в дипломната работа. Съзнателно са избрани най-простите решения за всеки компонент - стандартна класификационна глава, минимална предобработка и общи функции на загубата, - за да се изолира приносът на предварително обученения модел от този на архитектурните надстройки. Двата модела се обучават и оценяват независимо: йерархичните връзки между нивата (например че *Guardian* принадлежи на *Protagonist*) се въвеждат едва в дипломната работа чрез меко обуславяне.

И двата класификатора споделят обща архитектура (**xlm-roberta-base** с линейна глава върху [CLS] токена), стратегия за подготовка на данните и стратегия за селективно замразяване. Различията са в три точки: класификационната глава (3 срещу 22 изхода), функцията на загубата (Cross-Entropy срещу BCE) и стратегията за извеждане на предсказанието (argmax срещу прагуване).

4.1 Подготовка и предобработка на данните

4.1.1 Гранулярност на текста

Оригиналните новинарски статии варират значително по дължина - от няколко изречения до над 2000 думи (виж фигура 3.7). Тъй като максималната дължина на входа при токенизация е 256 токена, подаването на цял документ би довело до загуба на контекст след отрязване. Затова за всяко споменаване се работи само с абзаца, в който се намира обектът: това ограничава дължината на входа, запазва

най-информативния непосредствен контекст и избягва шума от несвързани абзаци. Позициите на споменаванията (start/end offsets) се преизчисляват спрямо началото на съответния абзац.

4.1.2 Маркиране на обекта

Около споменаването на обекта се вмъкват маркери [ENTITY] и [/ENTITY] чрез просто заместване на низ (string replace). За разлика от по-сложни подходи (например добавяне на специални токени към речника на токенизатора), тук маркерите се третираат като обикновен текст и се разделят на подтокени от SentencePiece алгоритъма на XLM-RoBERTa. Недостатъкът на този минимален подход е, че моделът не може да локализира точно границите на обекта - маркерите нямат специална семантика в речника. В дипломната работа те ще бъдат добавени като специални токени, което ще позволи прецизно осредняване по обхвата на обекта (entity span pooling).

4.1.3 Токенизация и кодиране

Маркираният текст се токенизира чрез стандартния XLM-RoBERTa токенизатор с максимална дължина 256 токена, отрязване (truncation) и допълване (padding) до фиксирана дължина. Основните роли се кодират като цели числа: Protagonist – 0, Antagonist – 1, Innocent – 2. Дължината 256 (вместо 512) е достатъчна на ниво абзац - под 5% от примерите я надхвърлят - и позволява по-голяма партия, което стабилизира градиентите.

4.1.4 Разделяне на данните

Организаторите предоставят обучително и валидационно множество, но не предоставят етикети за тестовото. Затова данните са разделени така:

- **Обучително множество:** 80% от оригиналното обучително множество (4 484 примера), получено чрез стратифицирано разделяне, запазващо пропорциите на основната роля.
- **Валидационно множество:** останалите 20% (1 122 примера), използвани за мониторинг на обучението и избор на най-добрата контролна точка (checkpoint).
- **Тестово множество:** оригиналното валидационно множество на организаторите (604 примера) - тъй като етикетите му са налични, то служи за крайна оценка.

Двата класификатора използват едно и също разделяне; разликата е само в целевото поле (основна роля срещу детайлни етикети). Разпределението по основни роли

в тестовото множество е Antagonist - 266 (44,0%), Protagonist - 191 (31,6%), Innocent - 147 (24,3%), а детайлните етикети са силно небалансирани (*Victim* - 119, *Guardian* - 85, *Foreign Adversary* - 81; *Martyr*, *Spy* и *Saboteur* - под 10).

4.2 Архитектура на моделите

И двата базови модела използват стандартната архитектура на HuggingFace `AutoModelForSequenceClassification` с линейна класификационна глава върху представянето на [CLS] токена. Гръбнакът (backbone) и стратегията за фино настройване са идентични; различават се само класификационната глава, размерността на изхода и функцията на загубата.

4.2.1 Споделен гръбнак

Предварително обучен модел. Използваме `xlm-roberta-base` [2] - многоезичен Transformer модел с 12 слоя, скрита размерност $d = 768$ и общо 278 милиона параметъра. Моделът е предварително обучен чрез задача за маскиран езиков модел (MLM) върху 2,5 TB текст от Common Crawl, покриващ 100 езика, включително всичките пет езика от задачата.

Селективно замразяване. За да се ограничи преобучаването при малък обем данни, замразяваме всички параметри на модела с изключение на:

- Слой 11 (последният Transformer блок) - 7,1M параметъра,
- Pooler слой - 590K параметъра,
- Класификационната глава (плътен слой 768×768 + изходна проекция) - 593K (грубо, 3 изхода) или 608K (фино, 22 изхода) параметъра.

Това дава общо приблизително 7,7M обучаеми параметъра от 278M (около 2,77%; стойността е практически еднаква за двата модела). Замразяването на слоеве 0–10 запазва общите лингвистични представяния, научени при предварителното обучение, докато слой 11 се адаптира към специфичната задача.

Представяне на входа. И двата класификатора получават като вход скритото състояние на токена [CLS] от последния Transformer слой:

$$\mathbf{h}_{[\text{CLS}]} = \text{XLM-R}(\text{tokenize}(\text{marked_text}))[0] \in \mathbb{R}^{768}. \quad (4.1)$$

Токенът [CLS] агрегира информация от целия вход чрез механизма за самовнимание, но не кодира експлицитно позицията на обекта - тази информация се подава имплицитно чрез текстовите маркери [ENTITY]/[/ENTITY].

4.2.2 Класификатор на грубо ниво (3 класа)

Класификатор C_{coarse} е стандартен многокласов класификатор за един от трите етикета (Protagonist, Antagonist, Innocent). Класификационната глава на XLMRobertaForSequencе се състои от два линейни слоя с активация $\tanh$ между тях:

$$\hat{\mathbf{y}}_{\text{coarse}} = \mathbf{W}_2 \tanh(\mathbf{W}_1 \mathbf{h}_{[\text{CLS}]} + \mathbf{b}_1) + \mathbf{b}_2, \quad (4.2)$$

където $\mathbf{W}_1 \in \mathbb{R}^{768 \times 768}$, $\mathbf{W}_2 \in \mathbb{R}^{3 \times 768}$ са обучаеми матрици, а $\hat{\mathbf{y}}_{\text{coarse}} \in \mathbb{R}^3$ е изходният вектор от логити. Крайните вероятности се получават чрез softmax: $p_i = \exp(\hat{y}_i) / \sum_j \exp(\hat{y}_j)$, а финалното предсказание е $\arg \max_i p_i$.

Функция на загубата. Използва се стандартна кръстосана ентропия (Cross-Entropy Loss) без претегляне по класове:

$$\mathcal{L}_{\text{CE}} = - \sum_{i=1}^3 y_i \log(p_i), \quad (4.3)$$

където y_i е one-hot индикатор на верния клас. Съзнателно се избира да не се използва балансирана загуба (например Class-Balanced CE [11] или Focal Loss [12]) - така грубото ниво остава чиста отправна точка без допълнителни корекции, а балансираните загуби са планирани за дипломната работа.

4.2.3 Класификатор на фино ниво (22 етикета)

Класификатор C_{fine} е многоетикетен класификатор: за всяко споменаване на обект може да върне произволно подмножество от 22-те детайлни етикета (включително празно). Класификационната глава има същата структура като при грубия модел, но с 22 изхода:

$$\hat{\mathbf{y}}_{\text{fine}} = \mathbf{W}'_2 \tanh(\mathbf{W}'_1 \mathbf{h}_{[\text{CLS}]} + \mathbf{b}'_1) + \mathbf{b}'_2 \in \mathbb{R}^{22}. \quad (4.4)$$

Изходните логити се преобразуват в индивидуални вероятности чрез сигмоидна функция $\sigma(\hat{y}_j) = 1/(1 + e^{-\hat{y}_j})$ (всеки етикет се третира като независим бинарен класификатор). Конфигурацията `problem_type="multi_label_classification"` на HuggingFace осигурява точно тази семантика.

Функция на загубата. Използва се бинарна кръстосана ентропия с логити (BCEWithLogitsLoss) с *претегляне на положителния клас* (`pos_weight`), което

компенсира силния класов дисбаланс при многоетикетна класификация с рядка средна кардиналност (около 1,08 в тестовото множество, 1,11 в обучителното):

$$\mathcal{L}_{\text{VCE}} = - \sum_{j=1}^{22} \left[w_j \cdot y_j \log \sigma(\hat{y}_j) + (1 - y_j) \log(1 - \sigma(\hat{y}_j)) \right], \quad (4.5)$$

където $y_j \in \{0, 1\}$ е индикатор за наличие на j -тия етикет, а $w_j = \min\left(\frac{N_{\text{neg},j}}{N_{\text{pos},j}}, 10\right)$ е тегло за положителния клас, изчислено от обучителното множество.

Без претегляне моделът колапсира до тривиалното решение „предсказвай нищо“, тъй като средното позитивно съотношение за повечето етикети е под 5%. Ограничаването на w_j до 10 (вместо суровото съотношение, което за най-редките етикети надвишава 100) предотвратява обратния провал, при който моделът значително надхвърля истинската кардиналност на предсказанията.

Извеждане на предсказание. Многоетикетното предсказание се получава чрез праг $\tau = 0,5$ върху индивидуалните вероятности: етикет j се присвоява, ако $\sigma(\hat{y}_j) \geq \tau$.

Резервна стратегия (argmax fallback). Ако нито един етикет не премине прага, се присвоява единствено етикетът с максимална вероятност. Тази стратегия отразява структурата на данните: всяко споменаване в анотациите има поне един детайлен етикет, така че празно предсказание никога не е правилно. Без нея класификаторът би жертвал около 5–10% от примерите още преди оценката.

4.2.4 Хиперпараметри и обучение

Хиперпараметрите за двата класификатора са обобщени в таблица 4.1. Споделените стойности (гръбнак, замразяване, оптимизатор, гранулярност) отразяват общата методологична рамка; различията (брой епохи, скорост на обучение, функция на загубата, метрика за избор на най-добрата контролна точка) отразяват различните характеристики на двете задачи.

Таблица 4.1: Хиперпараметри за обучение на двата базови класификатора.

Параметър	Грубо ниво	Фино ниво
Базов модел	xlm-roberta-base (278М параметъра)	
Обучаеми параметри	$\approx 7,7\text{M}$ ($\approx 2,77\%$)	
Замразени слоеве	Слоеви 0–10 (11 от 12)	
Макс. дължина на поредицата	256 токена	
Гранулярност на текста	Абзац	
Маркиране на обекта	[ENTITY] / [/ENTITY] (заместване на низ)	
Размер на партидата	8	
Тегловно затихване	0,01	
Оптимизатор	AdamW	
Брой класове / етикета	3 (един от три)	22 (произволно подмножество)
Брой епохи	5	10
Скорост на обучение	2×10^{-5}	3×10^{-5}
Функция на загубата	Cross-Entropy	BCE с pos_weight (срязан при 10)
Активация на изхода	Softmax	Sigmoid
Извеждане на предсказание	argmax	праг $\tau = 0,5$ + argmax fallback
Метрика за контролна точка	Micro-F1	Sample-F1

Различия в обучителните хиперпараметри. На финото ниво се използват повече епохи (10 срещу 5) и леко по-висока скорост на обучение (3×10^{-5} срещу 2×10^{-5}), защото многоетикетната задача с 22 рядко срещани етикета е по-трудна: повече итерации са нужни, за да научи моделът разделимост между редките класове.

Реализация. Обучението е реализирано чрез HuggingFace Transformers Trainer API. За многоетикетния модел е написан подклас WeightedBCETrainer, който замества метода compute_loss с nn.BCEWithLogitsLoss(pos_weight=...). Като най-добър модел се избира контролната точка с най-висок резултат на валидационното множество (Micro-F1 за грубия модел, Sample-F1 за финия).

Метрики за оценка. Двете задачи изискват различни метрики:


- **Грубо ниво:** точност (Accuracy), претеглена прецизност, претеглена пълнота (Recall) и претеглен F1, изчислени по стандартен начин за многокласова класификация.
- **Фино ниво:** Micro-F1, Macro-F1, Sample-F1 (средната F1, изчислена за всеки пример отделно върху множествата от истински и предсказани етикети) и Exact Match Ratio (EMR).

4.3 Резултати и анализ

В тази секция представяме резултатите на двата базови класификатора върху тестовото множество (604 примера) - последователно за грубото ниво, финото ниво и комбинираните йерархични метрики.

4.3.1 Обучителен процес


Фигура 4.1 показва кривите на обучителната и валидационната загуба за грубия класификатор. Обучителната загуба намалява устойчиво от 1,1 до 0,7 в рамките на 5 епохи. Валидационната загуба спада от 0,84 до 0,74, като конвергира след 3-тата епоха. Разликата между двете криви показва умерено преобучаване, но без драматично разминаване - знак, че селективното замразяване ефективно ограничава капацитета на модела. Аналогична динамика се наблюдава и при финия класификатор, при който валидационната Sample-F1 продължава да се подобрява до 7–8-та епоха, което потвърждава избора на 10 епохи за по-трудната многоетикетна задача.



Фигура 4.1: Криви на обучителната и валидационната загуба на грубия базов класификатор.


4.3.2 Резултати на грубия класификатор (3 класа)

Грубият класификатор постига **67,72% точност (Accuracy)** и **67,33% претеглен F1** върху тестовото множество, класифицирайки правилно 409 от 604 примера. Анализът по класове (фигура 4.2) разкрива три различни профила на грешки.



Фигура 4.2: Precision, Recall и F1 по класове за грубия модел.

- **Antagonist** показва висок Recall (75,6%), но умерен Precision (65,0%). Моделът е обучен в среда, в която Antagonist е мажоритарният клас (44% от тестовите примери), и развива класическо *отклонение към мажоритарния клас*, предсказвайки Antagonist за 309 примера при реални 266 (+16,2%).
- **Innocent** показва обратния модел: висок Precision (86,6%), но нисък Recall (48,3%). Когато моделът предсказва Innocent, той обикновено е прав, но намира едва 71 от 147 реални примера.
- **Protagonist** е балансиран, но с умерена производителност (F1=67,8%).



Фигура 4.3: Матрица на объркване за грубия класификатор (604 примера).

Матрицата на объркване (фигура 4.3) потвърждава двата доминиращи типа грешки: Innocent $\rightarrow$ Antagonist и Antagonist $\rightarrow$ Protagonist (по 57 примера, общо 58% от 195-те грешки). Особено показателна е асиметрията при Innocent - само 11 примера са погрешно класифицирани като Innocent, докато 76 реални Innocent са отнесени към други класове. Моделът е прекалено консервативен при присвояване на този етикет.

Таблица 4.2: Детайлни резултати на грубия класификатор по езици.

Език	n	Accuracy	WF1	$F1^{\text{Prot}}$	$F1^{\text{Antag}}$	$F1^{\text{Inn}}$
PT	116	81,9%	82,0%	0,831	0,655	0,893
BG	31	67,7%	61,5%	0,364	0,809	0,000
EN	91	71,4%	68,5%	0,200	0,829	0,000
HI	280	62,1%	60,5%	0,713	0,588	0,440
RU	86	62,8%	60,4%	0,560	0,709	0,167

Производителността по езици (таблица 4.2) показва значителна вариация: PT - 82,0% WF1, EN - 68,5%, BG - 61,5%, HI - 60,5%, RU - 60,4%. Особено забележителна е пълната неспособност на модела да разпознава Innocent примери за BG и EN ($F1=0,000$) - при тези езици 100% от Innocent примерите са погрешно класифицирани като Antagonist или Protagonist. Тази систематична грешка показва, че проблемът не е само в обема на данните, а и в лексикалното припокриване между Innocent и

Antagonist: жертвите на конфликт се споменават в същите текстове и контексти като извършителите.


4.3.3 Резултати на финия класификатор (22 етикета)

Резултатите на финия многоетикетен класификатор са представени в таблица 4.3. Тъй като той работи в значително по-разредено пространство (22 етикета при средна кардиналност от 1,08), всички абсолютни стойности са по-ниски, отколкото при грубия.

Таблица 4.3: Общи резултати на финия базов класификатор.

Метрика	Стойност
Micro-F1	35,64%
Macro-F1	22,41%
Sample-F1	38,86%
Exact Match Ratio (EMR)	11,75%
Средна предсказана кардиналност	2,70
Средна истинска кардиналност	1,08

Особено забележителна е разликата между средната предсказана кардиналност (2,70) и средната истинска кардиналност (1,08). Моделът систематично предсказва над два пъти повече етикета на пример, отколкото реално присъстват. Това е *очаквано* поведение за базовия модел: срязването на `pos_weight` при стойност 10 е компромис между научаването на редките класове и свръхпредсказването. Калибрирането на кардиналността остава основно предизвикателство, което в дипломната работа ще бъде адресирано чрез директна регуларизация на кардиналността и адаптивно праговане.




Фигура 4.4: F1 за всеки от 22-те детайлни етикета на финия класификатор, сортирани по support.

Производителност по етикети. Етикетите се разделят на три ясно различни групи:

- **Сравнително добре научени** ($F1 \geq 0,38$): водени от *Victim* (0,655), *Peacemaker* (0,477) и *Guardian* (0,454) - най-честите етикети или такива с еднозначен лексикален сигнал (*Terrorist*, 0,408).
- **Слабо научени** ($F1 \in [0,15, 0,38)$): деветте средночестотни етикета (*Incompetent*, *Tyrant*, *Instigator* и др.).
- **Напълно колапсирани** ($F1 = 0,000$): седемте най-редки етикета - *Martyr*, *Traitor*, *Spy*, *Saboteur*, *Bigot*, *Forgotten*, *Scapegoat* - всички с под 12 положителни примера в тестовото множество.


Седемте напълно колапсирани етикета представляват 31,8% от пространството на класовете и са основна причина Macro-F1 (22,41%) да изостава значително от Micro-F1 (35,64%). За тези класове базовият подход с BCE и фиксиран праг е принципно

недостатъчен - те изискват или специализирана функция на загубата (Asymmetric Loss [13], Focal Loss [12]), или семантично-базирано представяне, което да позволи трансфер на знания от родителската категория.



Фигура 4.5: Разпределение на броя истински и предсказани етикети на пример за финия класификатор.

Кардиналност на предсказанията. Истинското разпределение е силно концентрирано: над 92% от примерите имат точно един етикет, около 7% имат два, а само единични примери имат три или повече. Предсказаното разпределение е значително по-разпръснато: повечето примери получават 2–4 етикета, а в опашката се срещат предсказания с до 7 етикета.



Фигура 4.6: Sample-F1 на финия класификатор по езици.

Производителност по езици. Подреждането по езици е сходно с грубото ниво: PT е значително по-силен от останалите, а EN, BG и RU са най-слабите. Особено впечатляващ е скокът на EMR между PT (41,4%) и всички останали езици (под 7,2%):

на португалски моделът точно възпроизвежда множеството от детайлни етикети за над 4 от всеки 10 примера, а на английски - само за 1 от 91.

4.3.4 Йерархични метрики

Тъй като двата класификатора са обучени независимо, можем да ги комбинираме просто чрез обединяване на техните предсказания (без меко обуславяне). Йерархичните метрики, изчислени върху така комбинираните предсказания, са представени в таблица 4.4.

Таблица 4.4: Йерархични метрики на комбинирания базов модел (грубо $\oplus$ фино).

Метрика	Стойност
Coarse Accuracy	67,72%
Exact Match Ratio (EMR)	11,75%
Conditional Fine F1 (върху правилни груби)	48,77%
Брой верни груби предсказания	409 / 604

Условната Fine F1 (48,77%, върху 409-те примера с правилна груба роля) е с 9,9 процентни пункта над безусловната Sample-F1 (38,86%). Разликата е очаквана - грешка на грубо ниво обикновено проваля целия набор от детайлни етикети - и мотивира идеята за *меко обуславяне* в дипломната работа: разпределението от грубия класификатор може да служи като априорно за финия.

4.3.5 Обобщение на резултатите и слабости

Двата базови класификатора постигат разумни начални нива на производителност: 67,33% претеглен F1 на грубо ниво и 38,86% Sample-F1 на фино ниво. Анализът разкрива четири основни слабости: **отклонението към мажоритарния клас** на грубо ниво налага балансираните функции на загубата (Class-Balanced CE [11]); **коллапсът на седемте най-редки етикета** изисква специализирани многоетикетни загуби като Asymmetric Loss [13], която асиметрично потиска лесните отрицателни примери; **свръхпредсказването на кардиналност** мотивира директна регуларизация и адаптивно праговане; а **каскадните грешки между нивата** (условна Fine F1 с 9,9 пп над безусловната) насочват към меко йерархично обуславяне.

Силната езикова зависимост (от 21,6 пп между PT и RU на грубо ниво до близо 45 пп в Sample-F1 между PT и EN) показва, че производителността е обусловена от домейна и разпределението на класовете - което прави подходите, базирани на семантичното значение на етикетите, особено полезни за слабо представените езици и редки класове.

Глава 5

Анализ на интерпретируемостта на базовите модели

5.1 Мотивация и цели на анализа

Анализът на резултатите в глава 4 разкрива какво греша моделът, но не и защо. Матрицата на объркването показва, че 57 примера са погрешно класифицирани от Innocent, а 51 от Protagonist към Antagonist. Числата описват отклонението, но не разкриват кои думи в контекста го предизвикват - именно за тази цел служат методите за атрибуция на приноса.

При наративното рамкиране ролята на обекта се определя не от самоличността му, а от начина, по който е описан - лексикалните избори, синтактичната позиция (субект или обект на действие), съпровождащите глаголи. Затова е важно да се провери дали моделът е научил семантично обосновани сигнали, или се основава на повърхностни корелации с тематични думи от даден домейн.

В областта на обяснимия изкуствен интелект (Explainable AI) са разработени редица методи за атрибуция на приноса на входните характеристики - от базирани на смущения подходи като LIME [14] до унифицирани рамки като SHAP [15]. В настоящата глава прилагаме два метода, специално адаптирани за трансформерни езикови модели: оклузионен анализ и градиент $\times$ вграждане. И двата работят директно върху вече обучените базови класификатори, без допълнително обучение.

Анализът преследва две конкретни цели:

1. Да установи кои думи и фрази носят най-висок принос при класификацията на дадена роля - и дали тези думи са лингвистично правдоподобни.
2. Да обясни систематичните грешки, наблюдавани в глава 4, и да мотивира архитектурните подобрения, планирани за дипломната работа.

5.2 Методи за оценка на приноса на думите

5.2.1 Оклузионен анализ

Оклузионният анализ (occlusion saliency) е метод, базиран на смущения: важността на даден токен се измерва чрез промяната в предсказанието на модела, когато токентът е скрит. Методът не изисква достъп до вътрешни компоненти на модела - достатъчно е само да може да се извика пряк проход (forward pass).

Формално, за входна последователност $x = (x_1, \dots, x_T)$ и целеви клас c оклузионната значимост на позиция i се дефинира като:

$$\delta_i = f_c(x) - f_c(x^{(i \rightarrow [\text{MASK}])}), \quad i \in \mathcal{V}, \quad (5.1)$$

където $f_c(x)$ е логитът за клас c при оригиналния вход, $x^{(i \rightarrow [\text{MASK}])}$ е вариант на входа, при който позиция i е заместена с токена $[\text{MASK}]$, а $\mathcal{V}$ е множеството от допустими позиции (виж по-долу). Положителен δ_i означава, че скриването на думата намалява оценката за класа - тоест думата го *подкрепя*. Отрицателен δ_i означава, че думата *противодейства* на класа.

Защо логит, не вероятност. Изборът на суров логит вместо вероятност е съзнателен. При фините класификатори сигмоидната функция се насища около 1 при уверени предсказания, така че маскирането на дума би довело до почти нулева промяна в вероятността, въпреки че промяната в логита може да е значителна. Логитът е неограничен и остава чувствителен дори при висока увереност на модела.

Възможно разширение до фрази. Освен единичен токен може да се маскира и цяла фраза - група от съседни думи. Маскирането на фраза премахва по-голям съвместен контекст и дава по-силен и по-малко шумен сигнал, особено при кратки изречения. В настоящия анализ използваме единична оклузия, която е достатъчна за разглежданите примери.

Агрегация от подтокени към думи. XLM-RoBERTa използва алгоритъм SentencePiece, при който думите се разделят на подтокени. Значимостта на цяла дума се получава чрез сумиране на δ_i по всичките ѝ подтокени:

$$s_w = \sum_{i \in \text{tok}(w)} \delta_i, \quad (5.2)$$

където $\text{tok}(w)$ е множеството от подтокени на думата w .

Дял на влиянието. За интерпретация е удобно да изразим приноса на дума w като дял от общото абсолютно влияние:

$$\text{share}_w = \frac{s_w}{\sum_{w'} |s_{w'}|} \times 100\%. \quad (5.3)$$

Тази нормализация позволява да се каже, например, че дадена дума носи +12,3% от общото влияние в посока на подкрепа на класа.

Пропуснати позиции. Следните токени не се маскират: [CLS], [SEP], [PAD], маркерите [ENTITY] и [/ENTITY], и самият обхват на именувания обект между двата маркера. Маскирането на обхвата на обекта би унищожило смисъла на входа, тъй като задачата по дефиниция изисква обектът да присъства.

5.2.2 Градиент $\times$ Вграждане

Методът градиент $\times$ вграждане (Gradient $\times$ Embedding) е градиентен подход за атрибуция [16, 17]. За всеки токен на позиция i с вграждащ вектор $\mathbf{e}_i \in \mathbb{R}^H$ значимостта се дефинира като скалярно произведение на градиента на целевия логит спрямо вграждането и самото вграждане:

$$s_i^\nabla = (\nabla_{\mathbf{e}_i} f_c) \cdot \mathbf{e}_i = \sum_{k=1}^H \frac{\partial f_c}{\partial e_{ik}} \cdot e_{ik}. \quad (5.4)$$

Интуицията: $\nabla_{\mathbf{e}_i} f_c$ показва в каква посока малка промяна на вграждането би увеличила логита. Умножено по реалния вграждащ вектор $\mathbf{e}_i$, произведението дава знак и величина на приноса - със същата конвенция като при оклузионния анализ (положително - подкрепа, отрицателно - противодействие), което позволява директно сравнение на резултатите от двата метода.

Реализация. Методът се реализира чрез регистриране на прихващащ модул (hook) върху `word_embeddings` на XLM-RoBERTa. По време на прекия проход (forward pass) прихващащият модул съхранява изходния тензор на вгражданията и отбелязва нуждата от изчисляване на градиентите му. Обратното разпространение (backward pass) тръгва от целевия логит. Замразените тегла на модела не блокират потока на градиентите - нужен е градиентът на изходната активация, не на самите тегла.


Връзка с Интегрирани градиенти. Интегрираните градиенти [18] осредняват градиентите по права линия от нулево базово вграждане до реалното вграждане. Методът градиент $\times$ вграждане е еднократно приближение на тази интеграция - по-

бърз изчислително, при запазване на основния принцип на приписване на приноса чрез посоката на вграждането.

Резервна стратегия. Ако прихващаният модул не успее да прихване тензора (например при непредвидена архитектурна разлика), методът връща стойност `None` и автоматично се използва оклузионният анализ. Това гарантира стабилност при различни варианти на модела.


5.3 Качествен анализ на примери

В следващите три случая прилагаме двата метода върху конкретни примери от тестовото множество - по един за всяка основна роля, включващи както правилна, така и грешна класификация. За всеки пример фигурите показват дела на влиянието (%) на водещите думи върху грубото и финото ниво.




Фигура 5.1: Дял на влиянието на водещите думи за Случай 1 (обект *Russia*): грешна класификация Antagonist → Protagonist.

Случай 1: грешна класификация на Antagonist. Английски пример от домейна на войната в Русия и Украйна, в който обектът *Russia* има истинска роля Antagonist, но моделът го класифицира като Protagonist (с увереност 41%). Оклузионният анализ (фигура 5.1) разкрива защо: водещите думи са тематични и обстоятелствени - *civilian* (+8,2%), *pounded* (+7,1%), *Kharkiv* (+5,1%), *Russia* (+5,0%) - без нито един силно доминиращ сигнал. Разпределението е разпръснато, а самото име на обекта носи сравнително нисък дял. Липсата на ясен маркер обяснява защо моделът не разпознава антагонистичната роля.



Фигура 5.2: Дял на влиянието на водещите думи за Случай 2 (обект *Луганск*): правилна класификация Innocent.

Случай 2: правилна класификация на Innocent. Български пример, в който обектът *Луганск* е правилно разпознат като Innocent (44%). За разлика от Случай 1, тук един сигнал доминира силно: думата *удара* носи +17,9% от влиянието, следвана от *по* (+11,2%) и *МВнР* (+9,9%) (фигура 5.2). Концентрацията върху дума, описваща претърпяно действие (обектът е мишена на удар, а не извършител), е лингвистично правдоподобна за ролята на жертва.



Фигура 5.3: Сравнение на оклузионен анализ и градиент × вграждане за примера с *Russia*.

Случай 3: сравнение на двата метода. За примера с *Russia* прилагаме паралелно оклузионен анализ и градиент × вграждане (фигура 5.3). Двата метода се съгласуват слабо: само 1 от петте водещи думи съвпада между тях, а при първите десет - 5 от 10. Значите често се различават (например *pounded*: +7,1% при оклузия срещу -11,0% при градиента). Разминаването показва, че двата метода улавят различни аспекти - оклузията измерва маргиналният ефект от премахването на думата, докато градиентът измерва локалната чувствителност на логита спрямо посоката на вграждането. За този пример нито един метод не откроява стабилен сигнал, което е съгласувано с грешната класификация.

5.4 Изводи от анализа на интерпретируемостта

Анализът на двата метода върху примери от тестовото множество разкрива четири обобщаващи наблюдения.

Тематична, а не деятелна опора. При грешно класифицирания Antagonist (*Russia*) водещите сигнали са тематични и обстоятелствени думи (*civilian, Kharkiv, pounded*), а не думи, които ясно свързват обекта с активно вредоносно действие. Липсата на такъв концентриран сигнал обяснява защо моделът обърква Antagonist с Protagonist.

Концентриран сигнал при правилен Innocent. Обратно, правилно разпознатият Innocent (*Луганск*) се опира на един силно доминиращ сигнал (*удара*, +17,9%), описващ претърпяно действие. Когато контекстът съдържа ясен лексикален маркер за пасивна роля (обектът е мишена, а не извършител), моделът се справя добре - въпреки ниския общ Recall за Innocent (48,3%).

Езикова и доменна зависимост. Резултатите зависят силно от домейна и езика (например PT 82,0% WF1 срещу значително по-ниски стойности за останалите). Тематичните сигнали са надеждни в рамките на един домейн, но трудно се прехвърлят между домейни.

Разминаване между методите. Оклузионният и градиентният метод се съгласуват само частично (1 от петте водещи думи за разгледания пример). Това е очаквано, тъй като те измерват различни величини, и подчертава, че никой единичен метод за атрибуция не дава пълна картина [19].

Наблюденията насочват конкретно към архитектурните подобрения в дипломната работа: механизмът за осредняване по обхвата на обекта (*entity span pooling*) ще усили сигналите, свързващи обекта с конкретно действие, и ще намали влиянието на тематичните корелации. Анализът на приноса ще продължи да служи като диагностичен инструмент - за проверка дали архитектурните подобрения действително насочват модела към по-релевантни части на текста.

Глава 6

Заклучение и насоки за дипломната работа

В настоящия преддипломен проект бяха постигнати следните резултати:

1. **Формализиране на задачата.** Задачата за рамкиране на именувани обекти (Entity Framing) от SemEval-2025 Task 10 беше описана формално, включително таксономията от 3 основни и 22 детайлни роли, йерархичната структура и метриките за оценка.
2. **Анализ на данните.** Беше извършен задълбочен статистически анализ на многоезичния набор от данни (5 езика, 2 домейна), който разкри: (а) силен класов дисбаланс с доминираща категория Antagonist; (б) разреденост на многоетикетното пространство при средна кардиналност от около 1,1 в тестовото множество; (в) съвместно срещащите се двойки от детайлни етикети са почти изключително в рамките на една и съща основна категория, което валидира йерархичния подход.
3. **Два независими базови класификатора.** Бяха разработени и оценени два независими базови модела, базирани на `xlm-roberta-base` с обща архитектура (линейна глава върху [CLS] токена) и обща стратегия за селективно замразяване (около 2,77% обучаеми параметри). Грубият класификатор за основната роля (3 класа) постига 67,33% претеглен F1 и 67,72% точност. Финият многоетикетен класификатор за детайлните роли (22 етикета) постига 38,86% Sample-F1, 35,64% Micro-F1 и 11,75% EMR. При комбиниране на двата класификатора условната Fine F1 (само върху примерите с правилна груба роля) достига 48,77%.
4. **Задълбочен анализ на грешките.** Бяха идентифицирани четири основни слабости - отклонение към мажоритарния клас Antagonist, колапс на 7 от 22-те

редки етикета, свръхпредсказване на кардиналност (2,70 срещу 1,08) и силна езикова вариация - които пряко насочват архитектурните решения за дипломната работа.

5. **Анализ на интерпретируемостта.** Приложени бяха два метода за оценка на приноса на думите - оклузионен анализ и градиент $\times$ вграждане - върху конкретни примери. Анализът показва, че моделът се опира на тематична лексика вместо на сигнали за активната роля на обекта (което обяснява грешки като Antagonist $\rightarrow$ Protagonist), докато правилно разпознат Innocent почива на концентриран сигнал за претърпяно действие. Двата метода се съгласуват само частично, което подчертава нуждата от кръстосана проверка. Тези наблюдения мотивират по-прецизното локализиране на обекта в дипломната работа.

Ограничения

Двата базови класификатора са съзнателно опростени, за да установят долна граница на производителността. Основните ограничения - липса на балансиране на класовете, представяне само чрез [CLS] токена, независимо обучение на двете нива, маркиране чрез заместване на низ и фиксиран праг $\tau = 0,5$ - бяха разгледани в глава 4; всяко от тях се адресира от съответно подобрение, описано по-долу.

Насоки за дипломната работа

Анализът на слабостите мотивира следните подобрения, планирани за дипломната работа:

- **Entity span pooling** - представяне чрез осредняване на скритите състояния между маркерите [ENTITY] и [/ENTITY] (добавени като специални токени в речника), вместо [CLS] токена.
- **Семантично сходство като класификационна глава** (semantic similarity head) - косинусово подобие спрямо опорни представяния (anchor embeddings) на ролите, което позволява пренос на знания към редките етикети.
- **Балансирани функции на загубата** - Class-Balanced Cross-Entropy [11] за грубото ниво и Asymmetric Loss [13] за финото.
- **Меко йерархично обуславяне** (soft conditioning) - обучаемата матрица на сродство, която преобразува вероятностите от грубия класификатор в меко априорно разпределение за детайлните роли.

- **Регуляризация на кардиналността** - наказателна функция, ограничаваща очаквания брой предсказани етикети към наблюдаваното в обучителното множество разпределение.
- **Адаптивно праговане** - per-example праг вместо фиксираня глобален $\tau = 0,5$.

Настоящият преддипломен проект изгражда фундамента, върху който ще бъде изградена пълната йерархична класификационна система в дипломната работа. Интерпретируемостта остава активна нишка: анализът на приноса на думите ще се прилага и там за диагностика на по-сложните архитектурни компоненти, за да се провери дали те действително насочват модела към по-релевантни части на текста.

Използвана литература

- [1] Jakub Piskorski, Tarek Mahmoud, Nikolaos Nikolaidis, Ricardo Campos, Alípio Mário Jorge, Dimitar Dimitrov, Purificação Silvano, Roman Yangarber, Shivam Sharma, Tanmoy Chakraborty, Nuno Guimaraes, Elisa Sartori, Nicolas Stefanovitch, Zhuohan Xie, Preslav Nakov и Giovanni Da San Martino. ?SemEval 2025 Task 10: Multilingual Characterization and Extraction of Narratives from Online News? B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, с. 2610—2643. URL: <https://aclanthology.org/2025.semeval-1.331/>.
- [2] Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco Guzmán, Edouard Grave, Myle Ott, Luke Zettlemoyer и Veselin Stoyanov. ?Unsupervised Cross-lingual Representation Learning at Scale? B: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*. Association for Computational Linguistics, 2020, с. 8440—8451.
- [3] Jacob Devlin, Ming-Wei Chang, Kenton Lee и Kristina Toutanova. ?BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding? B: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Minneapolis, Minnesota: Association for Computational Linguistics, 2019, с. 4171—4186.
- [4] Dimitar Dimitrov, Firoj Alam, Maram Hasanain, Abul Hasnat, Fabrizio Silvestri, Preslav Nakov и Giovanni Da San Martino. ?SemEval-2024 Task 4: Multilingual Detection of Persuasion Techniques in Memes? B: *Proceedings of the 18th International Workshop on Semantic Evaluation (SemEval-2024)*. Mexico City, Mexico: Association for Computational Linguistics, 2024.
- [5] Tarek Mahmoud, Zhuohan Xie и Preslav Nakov. ?BERTastic at SemEval-2025 Task 10: State-of-the-Art Accuracy in Coarse-Grained Entity Framing for Hindi News? B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, с. 386—396. URL: <https://aclanthology.org/2025.semeval-1.55/>.

- [6] Tengxiao Lv, Juntao Li, Chao Liu, Yiyang Kang, Ling Luo, Yuanyuan Sun и Hongfei Lin. ?DUTIR at SemEval-2025 Task 10: A Large Language Model-based Approach for Entity Framing in Online News? B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, c. 174—179. URL: <https://aclanthology.org/2025.semeval-1.25/>.
- [7] Egil Rønningstad и Gaurav Negi. ?LTG at SemEval-2025 Task 10: Optimizing Context for Classification of Narrative Roles? B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025. URL: <https://aclanthology.org/2025.semeval-1.61/>.
- [8] Adith Rajeev и Radhika Mamidi. ?adithrajeev at SemEval-2025 Task 10: Sequential Learning for Role Classification Using Entity-Centric News Summaries? B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, c. 241—246. URL: <https://aclanthology.org/2025.semeval-1.36/>.
- [9] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser и Illia Polosukhin. ?Attention Is All You Need? B: *Advances in Neural Information Processing Systems 30 (NeurIPS)*. 2017.
- [10] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer и Veselin Stoyanov. ?RoBERTa: A Robustly Optimized BERT Pretraining Approach? B: *arXiv preprint arXiv:1907.11692* (2019).
- [11] Yin Cui, Menglin Jia, Tsung-Yi Lin, Yang Song и Serge Belongie. ?Class-Balanced Loss Based on Effective Number of Samples? B: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2019, c. 9268—9277.
- [12] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He и Piotr Dollár. ?Focal Loss for Dense Object Detection? B: *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*. 2017, c. 2980—2988.
- [13] Emanuel Ben-Baruch, Tal Ridnik, Nadav Zamir, Asaf Noy, Itamar Friedman, Matan Protter и Lihi Zelnik-Manor. ?Asymmetric Loss For Multi-Label Classification? B: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, c. 82—91.

- [14] Marco Tulio Ribeiro, Sameer Singh и Carlos Guestrin. "Why Should I Trust You?": Explaining the Predictions of Any Classifier? B: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, c. 1135—1144.
- [15] Scott M. Lundberg и Su-In Lee. "A Unified Approach to Interpreting Model Predictions? B: *Advances in Neural Information Processing Systems 30 (NeurIPS)*. 2017.
- [16] Karen Simonyan, Andrea Vedaldi и Andrew Zisserman. "Deep Inside Convolutional Networks: Visualising Image Classification Models and Saliency Maps? B: *International Conference on Learning Representations (ICLR), Workshop Track*. 2014.
- [17] Jiwei Li, Xinlei Chen, Eduard Hovy и Dan Jurafsky. "Visualizing and Understanding Neural Models in NLP? B: *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Association for Computational Linguistics, 2016, c. 681—691.
- [18] Mukund Sundararajan, Ankur Taly и Qiqi Yan. "Axiomatic Attribution for Deep Networks? B: *Proceedings of the 34th International Conference on Machine Learning (ICML)*. 2017, c. 3319—3328.
- [19] Sarthak Jain и Byron C. Wallace. "Attention is not Explanation? B: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. 2019, c. 3543—3556.