



Софийски университет „Св. Кл. Охридски”

Факултет по математика и информатика

Катедра „Софтуерни технологии”

ПРЕДДИПЛОМЕН ПРОЕКТ

на тема

Многоезична класификация на наративни роли в онлайн медии: базово ниво и интерпретируемост

Дипломант: Борислав Мартинов Минчев

Факултетен номер: 5M13400508

Специалност: Информатика

Магистърска програма: Извличане на информация и откриване на знания

Научен ръководител:

Проф. д-р Иван Койчев, катедра „Софтуерни технологии”,
ФМИ, СУ „Св. Климент Охридски”

Консултант:

докт. Димитър Димитров, катедра „Софтуерни технологии”,
ФМИ, СУ „Св. Климент Охридски”

София, 2026 г.

Съдържание

1	Увод	3
2	Преглед на областта	5
2.1	Основни понятия	5
2.2	Обзор на съществуващи подходи и състезания	6
2.2.1	Йерархична класификация	7
2.2.2	Многоетикетна класификация	7
2.3	Многоезични предварително обучени модели	8
3	Описание на задачата и набора от данни	9
3.1	Същност и цели на задачата	9
3.2	Таксономия на ролите	9
3.3	Структура на данните и статистически анализ	11
3.3.1	Статистически анализ на разпределенията	11
3.3.2	Предизвикателства	13
4	Базови модели за двете нива на класификация	17
4.1	Подготовка и предобработка на данните	18
4.1.1	Гранулярност на текста	18
4.1.2	Маркиране на обекта	18
4.1.3	Токенизация и кодиране	18
4.1.4	Разделяне на данните	19
4.2	Архитектура на моделите	19
4.2.1	Споделен гръбнак	19
4.2.2	Класификатор на грубо ниво (3 класа)	20
4.2.3	Класификатор на фино ниво (22 етикета)	21
4.2.4	Хиперпараметри и обучение	22
4.3	Резултати и анализ	23
4.3.1	Обучителен процес	24
4.3.2	Резултати на грубия класификатор (3 класа)	24
4.3.3	Резултати на финия класификатор (22 етикета)	27

4.3.4	Йерархични метрики	31
4.3.5	Обобщение на резултатите и слабости	32
5	Анализ на интерпретируемостта на базовите модели	33
5.1	Мотивация и цели на анализа	33
5.2	Методи за оценка на приноса на думите	34
5.2.1	Оклузионна салиентност	34
5.2.2	Градиент $\times$ Вложване	35
5.3	Качествен анализ на примери	36
5.4	Изводи от анализа на интерпретируемостта	37
6	Заклучение и насоки за дипломната работа	39
	Използвана литература	43

Глава 1

Увод

Разпространението на дезинформация и пропаганда в онлайн новинарски медии представлява едно от най-значимите предизвикателства на съвременното информационно общество. Автоматичното разпознаване на начина, по който именуваните обекти (лица, организации, държави) са представени в новинарските текстове — дали като протагонисти, антагонисти или невинни — е от ключово значение за медийния мониторинг, проверката на факти и анализа на наративни манипулации.

В контекста на споделената задача SemEval-2025 Task 10 [1] е предложена формална рамка за многоезична класификация на ролите на именувани обекти в новинарски текстове. Задачата обхваща пет езика (български, английски, хинди, португалски и руски), две тематични области (войната в Украйна и климатичните промени) и три подзадачи. Настоящата работа е посветена на **подзадача 1 (Entity Framing)**, която изисква за всяко споменаване на именуван обект в дадена статия да бъде определена една основна роля (грубо ниво) и една или повече детайлни роли (фино ниво) от предварително дефинирана таксономия с 22 етикета.

Настоящият преддипломен проект поставя основите за дипломна работа по тази задача. Конкретно, целите на проекта са:

- Формализиране на задачата за класификация на ролите на именувани обекти и преглед на съществуващите подходи.
- Задълбочен статистически анализ на многоезичния набор от данни, предоставен от организаторите на състезанието.
- Разработка и оценка на **два независими базови модела**, базирани на XLM-RoBERTa [2]: (а) многокласов класификатор за основната роля (3 класа), и (б) многоетикетен класификатор за детайлните роли (22 етикета). И двата използват стандартна линейна класификационна глава върху представянето на [CLS] токена.

- Анализ на грешките и слабостите на базовите модели, които мотивират по-сложните архитектурни решения в дипломната работа.
- Приложение на методи за анализ на приноса на думите (салиентност) върху базовите модели с цел интерпретация на получените класификации и идентифициране на лексикалните сигнали, специфични за всяка наративна роля.

Пълната двустепенна йерархична система — включваща entity span pooling, семантично сходство като класификационна глава, балансирани функции на загубата, фин класификатор с меко йерархично обуславяне и адаптивно праговане — ще бъде разработена в рамките на дипломната работа.

Структурата на документа е следната. Глава 2 представя преглед на областта: основни понятия, съществуващи подходи и предварително обучени многоезични модели. Глава 3 описва задачата и набора от данни, включително статистически анализ и основни предизвикателства. Глава 4 представя двата базови модела — за грубо и фино ниво — с обща методология, експериментална настройка и резултати. Глава 5 представя анализ на интерпретируемостта на базовите модели чрез два метода за оценка на приноса на думите: оклузионна салиентност и градиент $\times$ вложване. Глава 6 обобщава изводите и очертава насоките за дипломната работа.

Глава 2

Преглед на областта

2.1 Основни понятия

Рамкиране на именувани обекти (Entity Framing) е задачата за автоматично определяне на наративната роля, която даден именуван обект изпълнява в текст — например дали дадено лице е представено като герой, злодей или жертва. Тази задача е тясно свързана с анализа на медийни рамки (media framing) и детекцията на пропаганда.

Многоетикетна класификация (Multi-label Classification) е вид класификация, при която всеки пример може едновременно да бъде свързан с няколко етикета от множество от класове. За разлика от многокласовата класификация (multi-class), където точно един етикет се присвоява на всеки пример, при многоетикетната класификация броят на присвоените етикети е променлив. В контекста на нашата задача един обект може да бъде едновременно *Instigator* и *Deceiver*.

Йерархична класификация (Hierarchical Classification) се отнася до задачи, при които етикетите са организирани в дървовидна таксономия. Предсказанията трябва да бъдат съобразени с тази йерархия — например, ако обект е класифициран като *Guardian*, той трябва да принадлежи и към родителската категория *Protagonist*.

Трансферно обучение (Transfer Learning) в обработката на естествен език е парадигма, при която модел първо се предварително обучава върху голям корпус от текст чрез задачи за самонаблюдение (self-supervised learning), а след това се фина настройва (fine-tuning) върху конкретна задача с по-малко данни [3]. Този подход е в основата на съвременните езикови модели като BERT и XLM-RoBERTa.

Представяне на именувана същност чрез специални маркери е техника, при която в текста се вмъкват специални токени [ENTITY] и [/ENTITY] около споменаването на обекта. Моделът може след това да извлече представяне, специфично за обекта, чрез осредняване на скритите състояния между тези маркери (entity span pooling).

2.2 Обзор на съществуващи подходи и състезания

SemEval-2025 Task 10 [1] е споделена задача, организирана в рамките на 19-ия семинар по семантична евалуация (SemEval-2025). Задачата се състои от три подзадачи: (1) Entity Framing — класификация на ролята на именувани обекти; (2) Narrative Classification — присвояване на наративни етикети на ниво документ; (3) Narrative Extraction — генериране на текстово обяснение за доминиращия наратив. В състезанието са се регистрирали 310 екипа, от които 66 са подали официални резултати. Настоящата работа се фокусира изцяло върху подзадача 1.

Това е продължение на серията от споделени задачи за детекция на пропаганда, включително SemEval-2024 Task 4 [4] за многоезично разпознаване на техники за убеждаване в мемове.

Сред системите, постигнали най-добри резултати в подзадача 1 (Entity Framing), се открояват:

- **BERTastic** [5] — съчетава фино настроен XLM-RoBERTa с промптиране на GPT-4o. Постига 78,48% точност за основната роля и 51,57% F1 за детайлните роли. Класира се на първо място за хинди.
- **DUTIR** [6] — използва рамка, комбинираща многоезичен превод с GLM-4-Plus, QLoRA фино настройване и ансамблова класификация. Постига първо място за английски, португалски и руски.
- **LTG** [7] — прилага евристики за избор на контекст около обекта в комбинация с XLM-RoBERTa. Постига конкурентни резултати спрямо по-големи генеративни модели.
- **adithjrajeev** [8] — използва последователно обучение с резюмета, центрирани около обекта.

Таблица 2.1: Сравнение на водещи системи в SemEval-2025 Task 10, подзадача 1.

Система	Базов модел	Осн. роля (%)	Fine F1 (%)
BERTastic	XLM-R + GPT-4o	78,48	51,57
DUTIR	GLM-4-Plus + QLoRA	—	—
LTG	XLM-RoBERTa	—	—
Нашият (baseline)	XLM-RoBERTa-base	68,87	38,86

Забележителна тенденция е, че подходите, базирани на големи езикови модели (LLM), доминират в общото класиране, но фино настроените по-малки модели (напр. XLM-RoBERTa) постигат конкурентни резултати при по-ниски изчислителни разходи.

2.2.1 Йерархична класификация

Йерархичната класификация на текст (Hierarchical Text Classification) е задача, при която етикетите са организирани в дървовидна таксономия с връзки „родител–дете“. За разлика от плоската класификация, при йерархичната предсказанията на различните нива трябва да бъдат *съвместими* — например, ако обект е класифициран с детайлна роля *Guardian*, той трябва да принадлежи и към родителската категория *Protagonist*.

В литературата се разграничават три основни подхода:

- **Плосък подход** (flat) — игнорира йерархията и обучава един класификатор за всички етикети. Прост за реализация, но не гарантира съвместимост между нивата.
- **Локален подход** (local per-level) — обучава отделен класификатор за всяко ниво на йерархията. Предсказанието на горното ниво се предава като вход или ограничение на следващото. Два варианта на предаване са *твърдо маскиране* (hard masking), при което недопустимите етикети се зануляват, и *меко обуславяне* (soft conditioning), при което вероятностите от горното ниво модулират предсказанията на долното.
- **Глобален подход** (global) — единен модел, отчитащ цялата йерархия чрез споделени представяния или рекурсивни механизми.

В настоящата работа се използва локален подход с два етапа: класификация на основната роля (грубо ниво), след което резултатът се предава на класификатора за детайлни роли (фино ниво). Този подход позволява всеки етап да бъде оптимизиран независимо, а йерархичните ограничения да бъдат наложени при прехода между нивата.

2.2.2 Многоетикетна класификация

При многоетикетната класификация (Multi-label Classification) за всеки пример може да бъде присвоено произволно подмножество от множеството от етикети. Това е по-обща задача от многокласовата класификация, при която точно един етикет се присвоява на всеки пример.

Метрики за оценка. Многоетикетната природа на задачата изисква специфични метрики. Основните метрики в SemEval-2025 Task 10 са:

- **Exact Match Ratio (EMR)** — официалната метрика за класиране; измерва дела на примерите, за които предсказаният набор от етикети съвпада *точно* с верния.

- **Micro-F1** — агрегира истински положителните, фалшиво положителните и фалшиво отрицателните над всички етикети и примери.
- **Точност на основната роля (Main Role Accuracy)** — точност на класификацията на грубо ниво (3 класа).

Предизвикателство: дисбаланс на етикетите. При 22 възможни етикета и средна кардиналност от 1,1, съотношението положителни/отрицателни за повечето класове е под 1:20. Стандартната бинарна кръстосана ентропия (BCE) води до модел, който минимизира загубата, като предсказва „нищо“ за почти всички етикети. Това мотивира използването на специализирани функции на загубата: *Asymmetric Loss* [9] намалява приноса на лесните отрицателни примери чрез асиметрично претегляне; *Focal Loss* [10] адаптивно фокусира обучението върху трудно класифицируемите примери.

2.3 Многоезични предварително обучени модели

Архитектурата Transformer [11], предложена от Vaswani et al., поставя основата на съвременната обработка на естествен език. Ключовата иновация е механизмът за самовнимание (self-attention), който позволява на модела да улавя зависимости между произволни позиции в поредицата с постоянна сложност.

BERT (Bidirectional Encoder Representations from Transformers) [3] адаптира кодиращата част на Transformer за предварително обучение чрез маскиране на езиков модел (MLM) и предсказване на следващо изречение (NSP). Двупосочната архитектура позволява на модела да улавя контекст и от двете страни на всеки токен, което води до значителни подобрения в широк кръг задачи.

RoBERTa [12] оптимизира стратегията за предварително обучение на BERT: премахва NSP задачата, увеличава размера на партидата и обема на данните, и въвежда динамично маскиране. Авторите показват, че оригиналният BERT е бил значително недообучен при зададените хиперпараметри.

XLNet-RoBERTa [2] разширява подхода на RoBERTa за 100 езика, като използва 2,5 TB данни от Common Crawl. Моделът постига значителни подобрения спрямо mBERT: +14,6% на XNLI, +13% F1 на MLQA и +2,4% F1 за NER. Той покрива всичките пет езика от задачата (български, английски, хинди, португалски, руски), което го прави естествен избор за нашата многоезична класификация.

В настоящата работа използваме `xlm-roberta-base` (278M параметъра, 12 Transformer слоя, скрита размерност 768).

Глава 3

Описание на задачата и набора от данни

3.1 Същност и цели на задачата

Подзадача 1 (Entity Framing) от SemEval-2025 Task 10 [1] се дефинира формално по следния начин: дадена е новинарска статия и списък от споменавания на именувани обекти в нея, всяко определено чрез идентификатор на документа, текстово споменаване и начална/крайна позиция. За всяко споменаване трябва да бъдат определени:

1. **Основна роля** (main role) — точно един от трите етикета: Protagonist, Antagonist, Innocent.
2. **Детайлни роли** (fine-grained roles) — една или повече от 22 етикета, организирани йерархично под трите основни роли.

Задачата е многоезична, като данните обхващат пет езика: български (BG), английски (EN), хинди (HI), португалски (PT) и руски (RU). Тематичните области са две: войната между Русия и Украйна (URW) и климатичните промени (CC).

Официалната метрика за класиране е **Exact Match Ratio (EMR)** за детайлните роли, допълнена от micro-F1 и точност на основната роля.

3.2 Таксономия на ролите

Таксономията се състои от три основни роли и 22 детайлни роли, разпределени неравномерно (таблица 3.1).

Забелязва се силна асиметрия: категория Antagonist съдържа 12 детайлни роли — два пъти повече от Protagonist и три пъти повече от Innocent. Това отразява по-

Таблица 3.1: Таксономия на ролите: 3 основни и 22 детайлни.

Основна роля	Детайлна роля	Описание (накратко)
Protagonist (6)	Guardian	Защитник, пазител
	Martyr	Мъченик за кауза
	Peacemaker	Миротворец
	Rebel	Бунтовник, борец за промяна
	Underdog	Аутсайдер в неравна борба
	Virtuous	Нравствен, етичен лидер
Antagonist (12)	Instigator	Подбудител на конфликт
	Conspirator	Участник в заговор
	Tyrant	Тиранин, деспот
	Foreign Adversary	Външен противник
	Traitor	Предател
	Spy	Шпионин
	Saboteur	Саботьор
	Corrupt	Корумпиран
	Incompetent	Некомпетентен
	Terrorist	Терорист
	Deceiver	Измамник
	Bigot	Фанатик, нетолерантен
Innocent (4)	Forgotten	Забравен от обществото
	Exploited	Експлоатиран
	Victim	Жертва
	Scapegoat	Изкупителна жертва


богатото разнообразие от негативни наративни рамки в новинарските текстове и създава допълнително предизвикателство за класификацията.

3.3 Структура на данните и статистически анализ

Данните са организирани в директории по език. За всеки език са предоставени: обучително множество с анотации (идентификатор, споменаване, позиция, основна роля, детайлни роли), валидационно множество без етикети и директория с оригиналните текстове на статиите. Всяка анотация съдържа идентификатор на документа, текстово споменаване на обект, начална и крайна позиция в текста, основна роля (една от трите) и набор от детайлни роли (подмножество от 22-те). При предобработката около споменаването на обекта се вмъкват маркери [ENTITY] и [/ENTITY].

3.3.1 Статистически анализ на разпределенията


На фигура 3.1 е представено разпределението на трите основни роли по езици. Наблюдава се ясен дисбаланс: ролята Antagonist доминира във всички езици, следвана от Protagonist, докато Innocent е най-рядко срещаната категория. Този дисбаланс е по-изразен за хинди и португалски.



Фигура 3.1: Разпределение на основните роли по езици.


Фигура 3.2 показва разпределението на броя детайлни етикети, присвоени на всяко споменаване на обект. Повечето обекти имат точно един етикет (приблизително 92%), а средната кардиналност в обучителното множество е около 1,1. Тази изразена разредена структура е от значение за проектирането на системата и мотивира как-

то претеглянето на положителния клас в базовия модел, така и регуляризацията на кардиналността в дипломната работа.



Фигура 3.2: Разпределение на броя детайлни етикети на обект.


Фигура 3.3 показва броя различни детайлни роли, наблюдавани за именуваните обекти, появяващи се многократно в корпуса. По-голямата им част получават един и същ детайлен етикет при всяко споменаване — знак за последователно наративно рамкиране. Малка, но значима група обекти обаче получават различни роли в различни статии. Това явление е особено характерно за политически фигури и държавни участници, представяни в едни източници като протагонисти, а в други — като антагонисти. Именно при тези обекти с висока вариабилност на ролята е важно да се установи кои контекстуални сигнали определят класификацията при всяко конкретно споменаване — въпрос, на който анализът на приноса в глава 5 дава частичен отговор.



Фигура 3.3: Брой различни детайлни роли за многократно споменати именувани обекти в корпуса.

Матриците на съвместно появяване на детайлните етикети (фигури 3.4–3.6) показват, че съвместно срещащите се двойки са предимно в рамките на една и съща основна категория. При Protagonist (фигура 3.4) *Guardian* е най-честата роля (937 примера), като се комбинира най-често с *Virtuous* (116) и *Rebel* (61). При Antagonist

(фигура 3.5) доминира *Foreign Adversary* (946), а най-честата двойка е *Instigator* + *Foreign Adversary* (64). При Innocent (фигура 3.6) категорията *Victim* е силно доминираща (1080), като често се комбинира с *Exploited* (41). Междукатегорийните комбинации са редки, което подкрепя валидността на йерархичния подход.



Фигура 3.4: Съвместно появяване на детайлните етикети в категория Protagonist.


Фигура 3.7 представя разпределението на дължината на текстовете по езици. Наблюдава се значителна вариация — някои документи са много дълги и надхвърлят максималната дължина от 512 токена, използвана при токенизацията, което налага стратегии за отрязване (truncation).

Фигура 3.8 показва разпределението по тематични области за езиците, за които тази информация е налична. Трябва да се отбележи, че идентификаторите на документите за хинди и частично за португалски не съдържат маркери за домейн, поради което тези езици не са включени в диаграмата.


3.3.2 Предизвикателства

Анализът на данните разкрива няколко ключови предизвикателства:


1. **Класов дисбаланс.** Ролята Antagonist е значително по-застъпена от останалите, а Innocent е много рядка. Това налага използването на балансирани функции




Фигура 3.5: Съвместно появяване на детайлните етикети в категория Antagonist.



Фигура 3.6: Съвместно появяване на детайлните етикети в категория Innocent.



Фигура 3.7: Разпределение на дължината на текстовете по езици.



Фигура 3.8: Разпределение по тематични области за езиците с налична информация.

на загубата — например Class-Balanced Cross-Entropy [13].

2. **Разреденост на многоетикетното пространство.** При 22 възможни етикети и средна кардиналност от около 1,1, съотношението положителни/отрицателни за повечето класове е под 1:20. Стандартната функция на загубата (BCE) би довела до модел, който предсказва „нищо“ за повечето етикети.
3. **Многоезичност.** Петте езика имат различни типологични характеристики и писмени системи (латиница, кирилица, деванагари), което изисква многоезичен предварително обучен модел.
4. **Йерархични ограничения.** Детайлните етикети трябва да бъдат съобразени с основната категория. Грешки на грубо ниво неизбежно водят до каскадно разпространение на грешките.
5. **Дълги документи.** Някои статии надхвърлят лимита от 512 токена, като обектът може да е споменат в различни части на текста.
6. **Контекстна зависимост.** Ролята на обекта зависи от контекста, в който е споменат — една и съща личност може да бъде представена като протагонист в една статия и като антагонист в друга.

Глава 4

Базови модели за двете нива на класификация

В тази глава са представени **два независими базови модела**: единият за класификация на основната роля (3 класа), а другият за многоетикетна класификация на детайлните роли (22 етикета). Целта е да се установи начално ниво на производителност (baseline) за всяко от двете нива на йерархията, спрямо което ще бъдат оценявани по-сложните архитектури в дипломната работа. Съзнателно са избрани най-простите решения за всеки компонент на системата — стандартна класификационна глава, минимална предобработка и общи функции на загубата — за да се изолира приносът на самия предварително обучен модел от приноса на архитектурните надстройки.

И двата класификатора споделят една и съща обща архитектура (`xlm-roberta-base` с линейна глава върху `[CLS]` токена), една и съща стратегия за подготовка на данните и една и съща стратегия за селективно замразяване. Различията са локализирани в три точки: (1) класификационната глава (3 срещу 22 изхода), (2) функцията на загубата (Cross-Entropy срещу BCE) и (3) стратегията за извеждане на крайното предсказание (`argmax` срещу прагуване).

Двата модела са обучавани и оценявани *независимо* — няма обуславяне на детайлното ниво от грубото. Йерархичните връзки между нивата (например ограничението, че *Guardian* принадлежи на *Protagonist*) не се налагат експлицитно в базовите модели; те ще бъдат въведени едва в дипломната работа чрез меко обуславяне на класификационните глави.

4.1 Подготовка и предобработка на данните

4.1.1 Гранулярност на текста

Оригиналните новинарски статии варират значително по дължина — от няколко изречения до над 2000 думи (виж фигура 3.7). Тъй като максималната дължина на входа при токенизация е 256 токена, подаването на цял документ би довело до загуба на контекст след отрязване. Затова текстовете са разделени на абзаци (параграфи), като за всяко споменаване на обект е избран единствено абзацът, в който се намира оригиналният span. Този подход:

- ограничава дължината на входа до по-управляеми размери;
- запазва непосредствения контекст около обекта, който е най-информативен за определяне на ролята;
- избягва шум от несвързани абзаци в дълги статии.

След разделяне на абзаци оригиналните позиции на споменаванията (start/end offsets) се преизчисляват спрямо началото на съответния абзац.

4.1.2 Маркиране на обекта

Около споменаването на именувания обект в текста се вмъкват маркери [ENTITY] и [/ENTITY] чрез просто заместване на низ (string replace). За разлика от по-сложни подходи (напр. добавяне на специални токени към речника на токенизатора), тук маркерите се третират като обикновен текст и се разделят на подтокени от стандартния SentencePiece алгоритъм на XLM-RoBERTa.

Този избор е съзнателен — целта на базовия модел е да използва минимални модификации, за да се установи начално ниво. Недостатъкът е, че моделът не може да локализира точно границите на обекта, тъй като маркерите нямат специална семантика в речника на токенизатора. В дипломната работа ще бъдат добавени специални токени в речника, което ще позволи прецизно entity span pooling.

4.1.3 Токенизация и кодиране

Маркираният текст се токенизира чрез стандартния XLM-RoBERTa токенизатор с максимална дължина от 256 токена, отрязване (truncation) и допълване (padding) до фиксирана дължина. Основните роли се кодират като цели числа: Protagonist – 0, Antagonist – 1, Innocent – 2.

Изборът на максимална дължина от 256 токена (вместо 512) е мотивиран от два фактора: (1) тъй като работим на ниво абзац, а не на ниво документ, повечето

абзаци се побират в 256 токена; (2) по-късата дължина позволява по-голяма партия при обучение, което стабилизира градиентите. Анализ на данните показва, че при параграфна гранулярност по-малко от 5% от примерите надхвърлят 256 токена.

4.1.4 Разделяне на данните

Организаторите предоставят обучително и валидационно множество, но не предоставят етикети за тестовото. Затова данните са разделени така:

- **Обучително множество:** 80% от оригиналното обучително множество (4 484 примера), получено чрез стратифицирано разделяне, запазващо пропорциите на основната роля.
- **Валидационно множество:** останалите 20% (1 122 примера), използвани за мониторинг на обучението и избор на най-добрата контролна точка (checkpoint).
- **Тестово множество:** оригиналното валидационно множество на организаторите (604 примера) — тъй като етикетите му са налични, то служи за крайна оценка.

Едно и също разделяне на данните се използва и от двата класификатора — единствената разлика е, че класификаторът на грубо ниво вижда полето с основната роля (един от три етикета), докато класификаторът на фино ниво вижда пълния набор от детайлни етикети. Разпределението по основни роли в тестовото множество е: Antagonist — 266 примера (44,0%), Protagonist — 191 примера (31,6%), Innocent — 147 примера (24,3%). Разпределението на детайлните етикети е силно небалансирано (*Victim* — 119, *Guardian* — 85, *Foreign Adversary* — 81, докато *Martyr*, *Spy*, *Saboteur* са под 10 примера).

4.2 Архитектура на моделите

И двата базови модела използват стандартната архитектура на HuggingFace `AutoModelForSequenceClassification` с линейна класификационна глава върху представянето на [CLS] токена. Гръбнакът (backbone) и стратегията за фино настройване са идентични; различават се само класификационната глава, размерността на изхода и функцията на загубата.

4.2.1 Споделен гръбнак

Предварително обучен модел. Използваме `xlm-roberta-base` [2] — многоезичен Transformer модел с 12 слоя, скрита размерност $d = 768$ и общо 278 милиона

параметъра. Моделът е предварително обучен чрез задача за маскиран езиков модел (MLM) върху 2,5 TB текст от Common Crawl, покриващ 100 езика, включително всичките пет езика от задачата.

Селективно замразяване. За да се ограничи преобучаването при малък обем данни, замразяваме всички параметри на модела с изключение на:

- Слой 11 (последният Transformer блок) — 7,1M параметъра,
- Pooler слоя — 590K параметъра,
- Класификационната глава (плътен слой 768×768 + изходна проекция) — 593K (грубо, 3 изхода) или 608K (фино, 22 изхода) параметъра.

Това дава общо приблизително 7,68M обучаеми параметъра от 278M (около 2,76% — стойността е практически еднаква и за двата модела, защото изходната проекция на класификационната глава е минимална част от общия брой параметри). Замразяването на слоеве 0–10 запазва общите лингвистични представяния, научени при предварителното обучение, докато слой 11 се адаптира към специфичната задача. Този подход е аналогичен на техниката за извличане на признаци с фино настройване на последния слой (*feature extraction with fine-tuning of the last layer*), широко използвана при трансферно обучение [3].

Представяне на входа. И двата класификатора получават като вход скритото състояние на токена [CLS] от последния Transformer слой:

$$\mathbf{h}_{[\text{CLS}]} = \text{XLM-R}(\text{tokenize}(\text{marked_text})) [0] \in \mathbb{R}^{768}. \quad (4.1)$$

Токенът [CLS] агрегира информация от целия вход чрез механизма за самовнимание, но не кодира експлицитно позицията на обекта — тази информация се подава имплицитно чрез текстовите маркери [ENTITY]/[/ENTITY].

4.2.2 Класификатор на грубо ниво (3 класа)

Класификатор C_{coarse} е стандартен многокласов класификатор за един от трите етикета (Protagonist, Antagonist, Innocent). Класификационната глава на XLMRobertaForSequenc се състои от два линейни слоя с активация tanh между тях:

$$\hat{\mathbf{y}}_{\text{coarse}} = \mathbf{W}_2 \tanh(\mathbf{W}_1 \mathbf{h}_{[\text{CLS}]} + \mathbf{b}_1) + \mathbf{b}_2, \quad (4.2)$$

където $\mathbf{W}_1 \in \mathbb{R}^{768 \times 768}$, $\mathbf{W}_2 \in \mathbb{R}^{3 \times 768}$ са обучаеми матрици, а $\hat{\mathbf{y}}_{\text{coarse}} \in \mathbb{R}^3$ е изходният вектор от логити. Крайните вероятности се получават чрез softmax: $p_i = \exp(\hat{y}_i) / \sum_j \exp(\hat{y}_j)$, а финалното предсказание е $\arg \max_i p_i$.

Функция на загубата. Използва се стандартна кръстосана ентропия (Cross-Entropy Loss) без претегляне по класове:

$$\mathcal{L}_{\text{CE}} = - \sum_{i=1}^3 y_i \log(p_i), \quad (4.3)$$

където y_i е one-hot индикатор на верния клас. Съзнателно се избира да не се използва балансирана загуба (например Class-Balanced CE [13] или Focal Loss [10]), за да се изолира ефектът на самия модел без допълнителни корекции — балансираните загуби са планирани за дипломната работа.

4.2.3 Класификатор на фино ниво (22 етикета)

Класификатор C_{fine} е многоетикетен класификатор: за всяко споменаване на обект може да върне произволно подмножество от 22-те детайлни етикета (включително празно). Класификационната глава има същата структура като при грубия модел, но с 22 изхода:

$$\hat{\mathbf{y}}_{\text{fine}} = \mathbf{W}'_2 \tanh(\mathbf{W}'_1 \mathbf{h}_{[\text{CLS}]} + \mathbf{b}'_1) + \mathbf{b}'_2 \in \mathbb{R}^{22}. \quad (4.4)$$

Изходните логити се преобразуват в индивидуални вероятности чрез сигмоидна функция $\sigma(\hat{y}_j) = 1/(1 + e^{-\hat{y}_j})$ (всеки етикет се третира като независим бинарен класификатор). Конфигурацията `problem_type="multi_label_classification"` на HuggingFace осигурява точно тази семантика.

Функция на загубата. Използва се бинарна кръстосана ентропия с логити (BCEWithLogitsLoss) с *претегляне на положителния клас* (`pos_weight`), което компенсира силния класов дисбаланс при многоетикетна класификация с рядка средна кардиналност (около 1,08 в тестовото множество, 1,11 в обучителното):

$$\mathcal{L}_{\text{BCE}} = - \sum_{j=1}^{22} \left[w_j \cdot y_j \log \sigma(\hat{y}_j) + (1 - y_j) \log(1 - \sigma(\hat{y}_j)) \right], \quad (4.5)$$

където $y_j \in \{0, 1\}$ е индикатор за наличие на j -тия етикет, а $w_j = \min\left(\frac{N_{\text{neg},j}}{N_{\text{pos},j}}, 10\right)$ е тегло за положителния клас, изчислено от обучителното множество.

Без претегляне моделът колапсира до тривиалното решение „предсказвай нищо“, тъй като средното позитивно съотношение за повечето етикети е под 5%. Ограничаването на w_j до 10 (вместо суровото съотношение, което за най-редките етикети надвишава 100) предотвратява обратния провал, при който моделът значително надхвърля истинската кардиналност на предсказанията — при много високи тегла наблюдавахме средна предсказана кардиналност от около 7 етикета на пример при истинска средна стойност от около 1,1.

Извеждане на предсказание. Многоетикетното предсказание се получава чрез праг $\tau = 0,5$ върху индивидуалните вероятности: етикет j се присвоява, ако $\sigma(\hat{y}_j) \geq \tau$. Комбинацията от модерирано претегляне и стандартен праг калибрира средната предсказана кардиналност близо до истинската (около 2,7 при истинска 1,1).

Резервна стратегия (argmax fallback). Ако нито един етикет не премине прага, се присвоява единствено етикетът с максимална вероятност. Тази стратегия отразява структурата на данните: всяко споменаване в анотациите има поне един детайлен етикет, така че празно предсказание никога не е правилно. Без нея класификаторът би жертвал около 5–10% от примерите още преди оценката.

4.2.4 Хиперпараметри и обучение

Хиперпараметрите за двата класификатора са обобщени в таблица 4.1. Споделените стойности (гръбнак, замразяване, оптимизатор, гранулярност) отразяват общата методологична рамка; различията (брой епохи, скорост на обучение, функция на загубата, метрика за избор на най-добрата контролна точка) отразяват различните характеристики на двете задачи.

Таблица 4.1: Хиперпараметри за обучение на двата базови класификатора.

Параметър	Грубо ниво	Фино ниво
Базов модел	xlm-roberta-base (278М параметъра)	
Обучаеми параметри	$\approx 7,68\text{M}$ ($\approx 2,76\%$)	
Замразени слоеве	Слоеви 0–10 (11 от 12)	
Макс. дължина на поредицата	256 токена	
Гранулярност на текста	Абзац	
Маркиране на обекта	[ENTITY] / [/ENTITY] (заместване на низ)	
Размер на партидата	8	
Тегловно затихване	0,01	
Оптимизатор	AdamW	
Брой класове / етикета	3 (един от три)	22 (произволно подмножество)
Брой епохи	5	10
Скорост на обучение	2×10^{-5}	3×10^{-5}
Функция на загубата	Cross-Entropy	BCE с pos_weight (срязан при 10)
Активация на изхода	Softmax	Sigmoid
Извеждане на предсказание	argmax	праг $\tau = 0,5$ + argmax fallback
Метрика за контролна точка	Micro-F1	Sample-F1

Различия в обучителните хиперпараметри. На финото ниво се използват повече епохи (10 срещу 5) и леко по-висока скорост на обучение (3×10^{-5} срещу 2×10^{-5}), защото многоетикетната задача с 22 рядко срещани етикета е *строго по-трудна* от 3-класовата на грубото ниво. По-високата скорост и повече итерации позволяват на

модела да научи разделимост между редките етикети; при настройки идентични с грубия модел финият класификатор не успява да научи нищо за класове с под 50 положителни примера.

Реализация. Обучението е реализирано чрез HuggingFace Transformers Trainer API. За многоетикетния модел е написан подклас `WeightedBCETrainer`, който замества метода `compute_loss` с `nn.BCEWithLogitsLoss(pos_weight=...)`. Като най-добър модел се избира контролната точка с най-висок резултат на валидационното множество (Micro-F1 за грубия модел, Sample-F1 за финия). Всяко обучение отнема приблизително 20–40 минути на NVIDIA GPU.

Метрики за оценка. Двете задачи изискват различни метрики:

- **Грубо ниво:** точност (Accuracy), претеглена прецизност, претеглен recall и претеглен F1, изчислени по стандартен начин за многокласова класификация.
- **Фино ниво:** Micro-F1, Macro-F1, Sample-F1 (средната F1, изчислена за всеки пример отделно върху множествата от истински и предсказани етикети) и Exact Match Ratio (EMR) — делът на примерите, за които предсказаното множество съвпада точно с истинското. EMR е официалната метрика за класиране в SemEval-2025 Task 10.

Тъй като в дипломната работа двата класификатора ще бъдат интегрирани в обща йерархична система, оценяваме и три *йерархични* метрики, които комбинират предсказанията от двата независимо обучени базови модела:

- **Coarse Accuracy** — точност на грубото ниво (директно от грубия класификатор).
- **Exact Match Accuracy (EMR)** — точно съвпадение на множеството от детайлни етикети.
- **Conditional Fine F1** — Sample-F1 на фините етикети, изчислена само върху примерите, за които грубата роля е предсказана правилно. Тази метрика измерва качеството на финото предсказание при „идеално” грубо ниво и е директно сравнима с напредналата система, която използва меко обуславяне между нивата.


4.3 Резултати и анализ

В тази секция представяме резултатите на двата базови класификатора върху тестовото множество (604 примера). Първо разглеждаме обучителния процес и общите

метрики на грубия класификатор, след това на финия многоетикетен класификатор, и накрая йерархичните метрики, които комбинират предсказанията от двата независимо обучени модела.

4.3.1 Обучителен процес

Фигура 4.1 показва кривите на обучителната и валидационната загуба за грубия класификатор. Обучителната загуба намалява устойчиво от 1,1 до 0,7 в рамките на 5 епохи. Валидационната загуба спада от 0,84 до 0,74, като конвергира след 3-тата епоха. Разликата между двете криви показва умерено преобучаване, но без драматично разминаване — знак, че селективното замразяване ефективно ограничава капацитета на модела. Аналогична динамика се наблюдава и при финия класификатор, при който валидационната Sample-F1 продължава да се подобрява до 7–8-та епоха, което потвърждава избора на 10 епохи за по-трудната многоетикетна задача.



Фигура 4.1: Криви на обучителната и валидационната загуба на грубия базов класификатор.

4.3.2 Резултати на грубия класификатор (3 класа)

Резултатите на грубия класификатор върху тестовото множество са представени в таблица 4.2.


Таблица 4.2: Общи резултати на грубия базов класификатор.

Метрика	Стойност
Точност (Accuracy)	68,87%
Претеглен F1	68,59%

Моделът класифицира правилно 416 от 604 примера. Анализът по класове (таблица 4.3, фигура 4.2) разкрива три различни профила на грешки.

Таблица 4.3: Метрики по класове на грубия класификатор.

Клас	Support	Predicted	Precision	Recall	F1
Protagonist	191	201	0,667	0,702	0,684
Antagonist	266	311	0,659	0,771	0,711
Innocent	147	92	0,837	0,524	0,644




Фигура 4.2: Precision, Recall и F1 по класове за грубия модел.

- **Antagonist** показва висок Recall (77,1%), но умерен Precision (65,9%). Моделът е обучен в среда, в която Antagonist е мажоритарният клас (44% от тестовите примери), и развива систематично отклонение към тази категория, предсказвайки Antagonist за 311 примера при реални 266 (+16,9%).
- **Innocent** показва обратния модел: висок Precision (83,7%), но нисък Recall (52,4%). Когато моделът предсказва Innocent, той обикновено е прав, но намира едва 77 от 147 реални примера (−37,4% в броя на предсказанията).
- **Protagonist** е балансиран, но с умерена производителност (F1=68,4%).

Този модел на предсказване отразява класическо *отклонение към мажоритарния клас* — модел, обучен без балансиране на класовете, систематично предпочита по-честите категории за сметка на по-редките.

Матрицата на объркване (фигура 4.3) дава пълна картина на грешките. От 188 общи грешки, 53 (28,2%) са Protagonist → Antagonist, 53 (28,2%) са Innocent

→ Antagonist, 50 (26,6%) ca Antagonist → Protagonist, 17 (9,0%) ca Innocent → Protagonist, 11 (5,9%) ca Antagonist → Innocent и 4 (2,1%) ca Protagonist → Innocent. Грешките към/от Innocent са силно асиметрични: само 15 примера са *погрешно* класифицирани като Innocent (4+11), докато 70 примера са *погрешно* класифицирани от Innocent в други класове (17+53). Моделът е прекалено консервативен при присвояване на етикет Innocent.




Фигура 4.3: Матрица на объркване за грубия класификатор (604 примера).

Производителността по езици (таблица 4.4, фигура 4.4) показва значителна вариация: PT — 84,5% WF1, BG — 64,1%, EN — 67,8%, HI — 62,5%, RU — 60,4%. Особено забележителна е пълната неспособност на модела да разпознава Innocent примери за BG и EN (F1=0,000) — при тези езици 100% от Innocent примерите са погрешно класифицирани като Antagonist или Protagonist. Тази систематична грешка показва, че проблемът не е само в обема на данните, а и в лексикалното припокриване между Innocent и Antagonist: жертвите на конфликт се споменават в същите текстове и контексти като извършителите.

Таблица 4.4: Детайлни резултати на грубия класификатор по езици.

Език	n	Accuracy	WF1	F1 ^{Prot}	F1 ^{Antag}	F1 ^{Inn}
PT	116	84,5%	84,5%	0,844	0,704	0,912
BG	31	71,0%	64,1%	0,400	0,833	0,000
EN	91	70,3%	67,8%	0,190	0,821	0,000
HI	280	63,6%	62,5%	0,721	0,607	0,485
RU	86	62,8%	60,4%	0,560	0,709	0,167



Фигура 4.4: Претеглен F1 по езици за грубия класификатор.

4.3.3 Резултати на финия класификатор (22 етикета)

Резултатите на финия многоетикетен класификатор са представени в таблица 4.5. Тъй като финият класификатор работи в значително по-разредено пространство (22 етикета при средна кардиналност от 1,08), всички абсолютни стойности са пониски, отколкото при грубия класификатор.

Таблица 4.5: Общи резултати на финия базов класификатор.


Метрика	Стойност
Micro-F1	35,64%
Macro-F1	22,41%
Sample-F1	38,86%
Exact Match Ratio (EMR)	11,75%
Средна предсказана кардиналност	2,70
Средна истинска кардиналност	1,08

Моделът постига Sample-F1 от 38,86% и точно съвпадение на множеството от етикети за 11,75% от примерите (71 от 604). Разликата между Micro-F1 (35,64%) и Macro-F1 (22,41%) от около 13 процентни пункта показва силна неравномерност в производителността между отделните етикети — често срещани класове получават значително по-висок F1 от редки.

Особено забележителна е разликата между средната предсказана кардиналност (2,70) и средната истинска кардиналност (1,08). Моделът систематично предсказва над два пъти повече етикета на пример, отколкото реално присъстват. Това е *очаквано* поведение за базовия модел — алтернативата (без `pos_weight`) е BCE-колапс, при който моделът не предсказва нищо. Използваното срязване на `pos_weight` при стой-

ност 10 представлява компромис: достатъчно претегляне, за да научи редки класове, но не толкова силно, че да генерира 7+ етикета на пример. Калибрирането на кардиналността остава основно предизвикателство, което в дипломната работа ще бъде адресирано чрез директна регуларизация на кардиналността и адаптивно праговане.

Производителност по етикети. Фигура 4.5 представя F1 за всеки от 22-те етикета.



Фигура 4.5: F1 за всеки от 22-те детайлни етикета на финия класификатор, сортирани по support.


Етикетите се разделят на три ясно различими групи:

- **Сравнително добре научени** ($F1 \geq 0,38$): *Victim* (0,655 при support 119), *Peacemaker* (0,477 при 40), *Guardian* (0,454 при 85), *Terrorist* (0,408 при 19), *Foreign Adversary* (0,385 при 81), *Exploited* (0,385 при 20). Това са или най-честите етикети, или класове с относително еднозначен лексикален сигнал (*Terrorist*).

- **Слабо научени** ($F1 \in [0,15,0,38]$): *Incompetent* (0,328), *Underdog* (0,286), *Virtuous* (0,273), *Deceiver* (0,255), *Tyrant* (0,241), *Corrupt* (0,235), *Conspirator* (0,231), *Rebel* (0,168), *Instigator* (0,150).
- **Напълно колапсирани** ($F1 = 0,000$): *Martyr* (support 3), *Traitor* (7), *Spy* (6), *Saboteur* (7), *Bigot* (11), *Forgotten* (11), *Scapegoat* (7). Седем етикета не са научени изобщо — всички с под 12 положителни примера в тестовото множество.

Седемте напълно колапсирани етикета представляват 31,8% от пространството на класовете и са основна причина Macro-F1 (22,41%) да изостава значително от Micro-F1 (35,64%). За тези класове базовият подход с BCE и фиксиран праг е принципно недостатъчен — те изискват или специализирана функция на загубата (Asymmetric Loss [9], Focal Loss [10]), или семантично-базирано представяне, което да позволи трансфер на знания от родителската категория.

Кардиналност на предсказанията. Фигура 4.6 визуализира разпределението на броя истински и предсказани етикети.




Фигура 4.6: Разпределение на броя истински и предсказани етикети на пример за финия класификатор.

Истинското разпределение е силно концентрирано: над 92% от примерите имат точно един етикет, около 7% имат два, а само единични примери имат три или повече. Предсказаното разпределение е значително по-разпръснато: повечето примери получават 2–4 етикета, а в опашката се срещат предсказания с до 7 етикета. Това разминаване е директна последица от използването на `pos_weight` — претеглянето компенсира редкостта на положителните примери, но не отчита факта, че *целевото* разпределение е разредено.

Производителност по езици. Фигура 4.7 и таблица 4.6 представят финия Sample-F1 и EMR по езици.

Подреждането по езици е сходно с грубото ниво: PT е значително по-силен от останалите, а EN, BG и RU са най-слабите. Особено впечатляващ е скокът на EMR



Фигура 4.7: Sample-F1 на финия класификатор по езици.

Таблица 4.6: Резултати на финия класификатор по езици.

Език	n	Micro-F1	Macro-F1	Sample-F1	EMR
PT	116	0,591	0,226	0,661	41,4%
HI	280	0,345	0,187	0,360	7,1%
RU	86	0,347	0,177	0,345	1,2%
BG	31	0,269	0,148	0,252	3,2%
EN	91	0,224	0,103	0,216	1,1%


между РТ (41,4%) и всички останали езици (под 7,2%): на португалски моделът точно възпроизвежда множеството от детайлни етикети за над 4 от всеки 10 примера, а на английски — само за 1 от 91.

4.3.4 Йерархични метрики

Тъй като двата класификатора са обучени независимо, можем да ги комбинираме просто чрез обединяване на техните предсказания (без меко обуславяне). Йерархичните метрики, изчислени върху така комбинираните предсказания, са представени в таблица 4.7 и фигура 4.8.

Таблица 4.7: Йерархични метрики на комбинирания базов модел (грубо $\oplus$ фино).

Метрика	Стойност
Coarse Accuracy	68,87%
Exact Match Ratio (EMR)	11,75%
Conditional Fine F1 (върху правилни груби)	48,15%
Брой верни груби предсказания	416 / 604



Фигура 4.8: Обобщение на крайните метрики на комбинирания базов модел.

Условната Fine F1 (48,15%) е значително по-висока от безусловната Sample-F1 (38,86%), което е в съответствие с очакването, че финият класификатор се справя по-добре, когато грубата категория е правилна — грешка на грубо ниво обикновено води до пълно несъответствие на множеството от детайлни етикети, тъй като фините етикети рядко прескачат основната категория. Условната F1 е изчислена само върху примерите с правилна груба роля (416 примера), докато безусловната Sample-F1 се осреднява върху всички 604 примера; разликата отразява загубата от каскадните грешки на грубо ниво.

Разликата от 9,3 процентни пункта между условната и безусловната Sample-F1 директно мотивира идеята за *меко обуславяне* в дипломната работа: ако вероятностното разпределение от грубия класификатор може да се използва като информативно априорно разпределение върху финия, очакваме да компенсираме поне част от каскадните грешки.

4.3.5 Обобщение на резултатите и слабости

Двата базови класификатора постигат разумни начални нива на производителност: 68,59% претеглен F1 на грубо ниво и 38,86% Sample-F1 на фино ниво. Анализът разкрива четири основни слабости, които мотивират по-сложните подходи в дипломната работа:

1. **Отклонение към мажоритарния клас** (грубо ниво) — моделът предсказва Antagonist за 51,5% от примерите при реални 44,0%. Мотивира използването на балансиран функции на загубата (Class-Balanced CE [13]).
2. **Колапс на редки етикети** (фино ниво) — 7 от 22-те етикета имат F1=0. Мотивира специализирани многоетикетни функции на загубата като Asymmetric Loss [9], която асиметрично потиска лесните отрицателни примери.
3. **Свърхпредсказване на кардиналност** (фино ниво) — средно 2,70 предсказани етикета при истински 1,08. Мотивира директна регуларизация на кардиналността и адаптивно праговане.
4. **Каскадни грешки между нивата** — условната Fine F1 (48,15%) е с 9,3 процентни пункта по-висока от безусловната Sample-F1 (38,86%), което показва, че точността на грубото ниво е решаваща за финото. Мотивира меко йерархично обуславяне.

Освен тези четири слабости, силната зависимост на резултатите от езика (от 24,1 пп разлика между PT и RU на грубо ниво до близо 45 пп разлика в Sample-F1 на фино ниво между PT и EN) показва, че производителността е обусловена от тематичната област и разпределението на класовете. Това подсказва, че подходи, базирани на семантичното значение на самите етикети (например *semantic similarity head*), могат да бъдат особено полезни за по-слабо представени езици и редки класове.

Глава 5

Анализ на интерпретируемостта на базовите модели

5.1 Мотивация и цели на анализа

Анализът на резултатите в глава 4 разкрива какво греша моделът, но не и защо. Матрицата на объркването показва, че по 53 примера са погрешно класифицирани от Innocent и от Protagonist към Antagonist. Числата описват отклонението, но не разкриват кои думи в контекста го предизвикват — именно за тази цел служат методите за атрибуция на приноса.

За задача с наративно рамкиране (Entity Framing) интерпретируемостта е от особено значение. Ролята на именуван обект се определя не само от самата му самоличност, а от начина, по който е описан в конкретния текст — лексикалните избори на автора, синтактичната позиция на обекта (субект или обект на действие), съпровождащите глаголи и прилагателни. Модел, обучен да разпознава тези сигнали, трябва да може да бъде проверен: дали наученото е семантично обосновано, или се основава на повърхностни корелации като честото съвместно появяване с тематични думи от определен домейн?

В областта на обяснимия изкуствен интелект (Explainable AI) са разработени редица методи за атрибуция на приноса на входните характеристики — от базирани на смущения подходи като LIME [14] до унифицирани рамки като SHAP [15]. В настоящата глава прилагаме два метода, специално адаптирани за трансформерни езикови модели: оклузионна салиентност и градиент $\times$ вложване. И двата са реализирани в `src2/saliency.py` и работят директно върху вече обучените базови класификатори.

Анализът преследва две конкретни цели:

1. Да установи кои думи и фрази носят най-висок принос при класификацията на дадена роля — и дали тези думи са лингвистично правдоподобни.

2. Да обясни систематичните грешки, наблюдавани в глава 4, и да мотивира архитектурните подобрения, планирани за дипломната работа.

5.2 Методи за оценка на приноса на думите

5.2.1 Оклузионна салиентност

Оклузионната салиентност (occlusion saliency) е метод, базиран на смущения: важността на даден токен се измерва чрез промяната в предсказанието на модела, когато токенът е скрит. Методът не изисква достъп до вътрешни компоненти на модела — достатъчно е само да може да се извика пряк проход (forward pass).

Формално, за входна последователност $x = (x_1, \dots, x_T)$ и целеви клас c оклузионната салиентност на позиция i се дефинира като:

$$\delta_i = f_c(x) - f_c(x^{(i \rightarrow [\text{MASK}])}), \quad i \in \mathcal{V}, \quad (5.1)$$

където $f_c(x)$ е логитът за клас c при оригиналния вход, $x^{(i \rightarrow [\text{MASK}])}$ е вариант на входа, при който позиция i е заместена с токена $[\text{MASK}]$, а $\mathcal{V}$ е множеството от допустими позиции (виж по-долу). Положителен δ_i означава, че скриването на думата намалява оценката за класа — тоест думата го *подкрепя*. Отрицателен δ_i означава, че думата *противодейства* на класа.

Защо логит, не вероятност. Изборът на суров логит вместо вероятност е съзнателен. При фините класификатори сигмоидната функция се насища около 1 при уверени предсказания, така че маскирането на дума би довело до почти нулева промяна в вероятността, въпреки че промяната в логита може да е значителна. Логитът е неограничен и остава чувствителен дори при висока увереност на модела.

Разширение до фрази. Вместо маскиране на по един токен, може да се маскира цяла фраза — група от съседни думи. Маскирането на фраза премахва по-голям съвместен контекст и дава по-силен и по-малко шумен сигнал, особено при кратки изречения. Размерът на фразата се избира автоматично в зависимост от дължината на контекста: 1 дума за контексти под 6 думи, 2 думи за 7–15, 3 думи за 16–30 и 4 думи за по-дълги. Фразите никога не прекосяват граница на изречение.

Агрегация от подтокени към думи. XLM-RoBERTa използва алгоритъм SentencePiece, при който думите се разделят на подтокени. Салиентността на цяла

дума се получава чрез сумиране на δ_i по всичките ѝ подтокени:

$$s_w = \sum_{i \in \text{токени}(w)} \delta_i. \quad (5.2)$$

Дял на влиянието. За интерпретация е удобно да изразим приноса на дума w като дял от общото абсолютно влияние:

$$\text{дял}_w = \frac{s_w}{\sum_{w'} |s_{w'}|} \times 100\%. \quad (5.3)$$

Тази нормализация позволява да се каже, например, че дадена дума носи +12,3% от общото влияние в посока на подкрепа на класа.

Пропуснати позиции. Следните токени не се маскират: [CLS], [SEP], [PAD], маркерите [ENTITY] и [/ENTITY], и самият обхват на именувания обект между двата маркера. Маскирането на обхвата на обекта би унищожило смисъла на входа, тъй като задачата по дефиниция изисква обектът да присъства.

5.2.2 Градиент $\times$ Вложване

Методът градиент $\times$ вложване (Gradient $\times$ Embedding) е градиентен подход за атрибуция [16, 17]. За всеки токен на позиция i с вложващ вектор $\mathbf{e}_i \in \mathbb{R}^H$ салиентността се дефинира като скалярно произведение на градиента на целевия логит спрямо вложването и самото вложване:

$$s_i^\nabla = (\nabla_{\mathbf{e}_i} f_c) \cdot \mathbf{e}_i = \sum_{k=1}^H \frac{\partial f_c}{\partial e_{ik}} \cdot e_{ik}. \quad (5.4)$$

Интуицията: $\nabla_{\mathbf{e}_i} f_c$ показва в каква посока малка промяна на вложването би увеличила логита. Умножено по реалния вложващ вектор $\mathbf{e}_i$, произведението дава знак и величина — положително значение означава, че вложването на токена е ориентирано по посока, повишаваща оценката на класа (подкрепа), а отрицателно — обратното.

Реализация. Методът се реализира чрез регистриране на прихващащ модул (forward hook) върху `word_embeddings` на XLM-RoBERTa. При прякото преминаване хукът съхранява изходния тензор на вложванията и отбелязва нуждата от изчисляване на градиентите му. Обратното разпространение (backward pass) тръгва от целевия логит. Замразените тегла на модела не блокират потока на градиентите — нужен е градиентът на изходната активация, не на самите тегла.

Връзка с Интегрирани градиенти. Интегрираните градиенти [18] осредняват градиентите по права линия от нулево базово вложване до реалното вложване. Методът градиент $\times$ вложване е еднократно приближение на тази интеграция — по-бърз изчислително, при запазване на основния принцип на приписване на приноса чрез посоката на вложването.

Резервна стратегия. Ако хукът не успее да прихване тензора (например при непредвидена архитектурна разлика), методът връща стойност `None` и автоматично се използва оклузионната салиентност. Това гарантира стабилност при различни варианти на модела.

Обща знакова конвенция. И двата метода използват една и съща знакова конвенция: положително — подкрепа за целевия клас, отрицателно — противодействие. Това позволява директно сравнение на резултатите им.

5.3 Качествен анализ на примери

В следващите три случая прилагаме двата метода върху конкретни примери от тестовото множество. Разгледани са: правилна класификация, грешна класификация и директно сравнение на двата метода върху един и същ вход.

Случай 1: правилна класификация на Antagonist. Разглеждаме английски пример от домейна на Украинската война, при който обектът е правилно разпознат като Antagonist. Оклузионният анализ показва, че водещите думи по дял на влиянието са агентивни глаголи и именни фрази, описващи активна деструктивна роля: думи, свързани с обстрел, нападение и командни решения, носят положителни дялове от +15% до +10% от общото влияние. Неутрални обстоятелствени думи и предлози имат близък до нула принос. Тематични думи от военен домейн („army”, „forces”, „troops”), макар и присъстващи, носят по-нисък индивидуален дял — знак, че моделът не разчита единствено на тема, а разпознава и агентивни сигнали.

Резултатът е лингвистично правдоподобен: за класа Antagonist агентивните глаголи („attack”, „order”, „strike”) са по-директен сигнал от тематичните съществителни.

Случай 2: грешна класификация Innocent $\rightarrow$ Antagonist. Разглеждаме пример, при който реалната роля е Innocent, но моделът я предсказва като Antagonist. Оклузионният анализ разкрива причината: водещите сигнали са тематични думи от конфликтния домейн, общи за двата класа. Думи като „war”, „conflict”, „attack” присъстват в контекста и за обектите-жертви (Innocent), и за обектите-извършители

(Antagonist). Моделът не разполага с достатъчно ясен лексикален сигнал, разграничаващ пасивната позиция (жертва) от активната (агресор).

Сравнено с правилно класифицираните Antagonist примери, разпределението на салиентността тук е по-равномерно — без концентрация на сигнала върху малък брой думи. Моделът разчита на тематично припокриване с конфликтния домейн вместо на конкретни агентивни маркери, което обяснява ниския Recall за Innocent (52,4% в таблица 4.3).

Случай 3: сравнение на двата метода. За един и същ пример прилагаме паралелно оклузионна салиентност и градиент $\times$ вложване. За петте думи с най-висок абсолютен принос двата метода съвпадат напълно — еднакъв ред и знак. При думите от позиции 6–10 методите понякога разменят реда помежду си, но не си противоречат по знак.

Когато два принципно различни метода — един пертурбационен и един градиентен — посочват едни и същи думи като водещи, атрибуцията може да се счита за надеждна [19]. Разминаването в средната зона е очаквано: оклузионната салиентност улавя маргиналният ефект от отстраняването на всяка дума поотделно, докато градиентният метод измерва локалната чувствителност на логита спрямо посоката на вложването.

5.4 Изводи от анализа на интерпретируемостта

Анализът на двата метода върху примери от тестовото множество разкрива четири обобщаващи наблюдения.

Тематична зависимост. Думи от военния и политическия домейн са сред водещите сигнали за Antagonist. Тази зависимост обяснява частично езиковата вариация от глава 4 — при португалски данни лексиката е по-конкретна и резултатите са значително по-добри (84,5% WF1). Тематичните сигнали са надеждни в рамките на един домейн, но трудно се прехвърлят между домейни.

Агентивни сигнали при Antagonist. При правилните класификации на Antagonist водещите думи са предимно агентивни глаголи и техните граматически субекти — лексикален профил, съответстващ на таксономичното определение на ролята.

Размиване на сигнала при Innocent. При Innocent класификациите салиентността е разпръсната върху много думи с малки абсолютни стойности — без ясни концентрирани сигнали. Моделът не е успял да разграничи ролята на жертва от агентивните роли въз основа на наличния речник. Това обяснява ниския Recall (52,4%) и честите грешки Innocent $\rightarrow$ Antagonist.

Консистентност между методите. За думите с най-висок абсолютен принос

оклузионният и градиентният метод съвпадат по знак и ред. Разминаване се наблюдава предимно при думи с нисък принос — очаквано предвид разликите в начина на измерване. Тази консистентност потвърждава надеждността на основните атрибуции [20].

Наблюденията насочват конкретно към архитектурните подобрения в дипломната работа: механизмът за осредняване по обхвата на обекта (entity span pooling) ще позволи на модела да фокусира вниманието си върху непосредствения контекст около обекта, усилвайки агентивните сигнали и намалявайки влиянието на тематичните корелации. Анализът на приноса ще продължи да служи като диагностичен инструмент — за проверка дали архитектурните подобрения действително насочват модела към по-релевантни части на текста.

Глава 6

Заклучение и насоки за дипломната работа

В настоящия преддипломен проект бяха постигнати следните резултати:

1. **Формализиране на задачата.** Задачата за рамкиране на именувани обекти (Entity Framing) от SemEval-2025 Task 10 беше описана формално, включително таксономията от 3 основни и 22 детайлни роли, йерархичната структура и метриките за оценка.
2. **Анализ на данните.** Беше извършен задълбочен статистически анализ на многоезичния набор от данни (5 езика, 2 домейна), който разкри: (а) силен класов дисбаланс с доминираща категория Antagonist; (б) разреденост на многоетикетното пространство при средна кардиналност от около 1,1 в тестовото множество; (в) съвместно срещащите се двойки от детайлни етикети са почти изключително в рамките на една и съща основна категория, което валидира йерархичния подход.
3. **Два независими базови класификатора.** Бяха разработени и оценени два независими базови модела, базирани на `xlm-roberta-base` с обща архитектура (линейна глава върху [CLS] токена) и обща стратегия за селективно замразяване (около 2,76% обучаеми параметри). Грубият класификатор за основната роля (3 класа) постига 68,59% претеглен F1 и 68,87% точност. Финият многоетикетен класификатор за детайлните роли (22 етикета) постига 38,86% Sample-F1, 35,64% Micro-F1 и 11,75% EMR. При комбиниране на двата класификатора условната Fine F1 (само върху примерите с правилна груба роля) достига 48,15%.
4. **Задълбочен анализ на грешките.** Анализът разкри: (а) систематично отклонение към мажоритарния клас Antagonist в грубия класификатор (+45 излишни предсказания); (б) пълен колапс на 7 от 22-те фини етикета (всички с

под 12 положителни примера); (в) свръхпредсказване на кардиналност във финия модел (средно 2,70 при истинско 1,08); (г) значителна вариация по езици, особено на Innocent ниво (от 0,000 за BG/EN до 0,912 за PT). Тези конкретни слабости пряко насочват архитектурните решения за дипломната работа.

5. **Анализ на интерпретируемостта.** Приложени бяха два метода за оценка на приноса на думите — оклузионна салиентност и градиент $\times$ вложване — върху двата базови класификатора. Анализът разкри тематична зависимост при класификацията на Antagonist, агентивни сигнали при правилните класификации, размити и слаби сигнали при Innocent, и принципна консистентност между двата метода за водещите думи. Тези наблюдения мотивират по-прецизното локализиране на обекта в дипломната работа.

Ограничения

Двата базови класификатора са съзнателно опростени, за да установят долна граница на производителността. Основните ограничения са:

- **Липса на балансиране на класовете.** Стандартната функция на загубата с кръстосана ентропия (за грубо ниво) не компенсира дисбаланса между Antagonist (44%), Protagonist (32%) и Innocent (24%). За финото ниво се използва само `pos_weight` в BCE — елементарно претегляне, което предотвратява пълен колапс, но не калибрира кардиналността и не помага на най-редките класове.
- **Представяне чрез [CLS] токен.** Токенът [CLS] обобщава целия вход, но не кодира експлицитно позицията на обекта. При абзаци с множество споменати лица моделът не може да разграничи кое лице е целевото.
- **Независими класификатори.** Двата класификатора са обучени и приложени независимо. Това означава, че финият класификатор не може да използва информация от грубия (например че е невъзможно *Guardian* и *Tyrant* да се появят заедно), а грешките на грубо ниво каскадно засягат финото без коригиращ механизъм.
- **Маркиране чрез заместване на низ.** Простото заместване на текст не добавя специални токени в речника, поради което маркерите се разделят на подтокени и не могат да бъдат използвани за точно определяне на границите на обекта.
- **Фиксиран праг $\tau = 0,5$.** Изборът на единен глобален праг за всичките 22 фини етикета е удобен, но субоптимален: оптималният праг зависи от честотата и от увереността на модела за всеки клас поотделно.

Насоки за дипломната работа

Анализът на слабостите на базовите модели мотивира следните подобрения, планирани за дипломната работа:

- **Entity span pooling** — извличане на представяне чрез осредняване на скритите състояния между маркерите [ENTITY] и [/ENTITY], добавени като специални токени в речника. Това преодолява ограничението на [CLS] токена, като позволява на модела да фокусира вниманието си върху конкретния обект.
- **Семантично сходство като класификационна глава** (semantic similarity head) — замяна на линейната глава с подход, базиран на косинусово подобие спрямо опорни представяния (anchor embeddings) на ролите. Този подход използва семантичното значение на имената на етикетите и позволява пренос на знания между свързани класове, особено полезно за редки етикети.
- **Балансирани функции на загубата** — Class-Balanced Cross-Entropy [13] за грубото ниво и Asymmetric Loss [9] за многоетикетната класификация на фино ниво. ASL асиметрично потиска приноса на лесните отрицателни примери, което директно адресира колапса на 7-те най-редки етикета в базовия модел.
- **Меко йерархично обуславяне** (soft conditioning) — обучаемата матрица на сродство (affinity matrix), която преобразува вероятностите от грубия класификатор в меко априорно разпределение за детайлните роли. За разлика от твърдото маскиране, този подход позволява несигурността от грубото ниво да се разпространява в системата. Очакваният ефект е намаляване на разликата между условната Fine F1 (48,15%) и безусловната Sample-F1 (38,86%).
- **Регуларизация на кардиналността** — квадратична наказателна функция, ограничаваща очаквания брой предсказани етикети до целева стойност, базирана на наблюдаваното разпределение в обучителното множество. Това директно адресира свръхпредсказването от 2,70 на 1,08 етикета на пример в базовия модел.
- **Адаптивно праговане** — динамична стратегия за определяне на прага за многоетикетната класификация, базирана на съотношението на разликата (gap ratio) между най-високата вероятност и останалите. Това замества фиксирания глобален праг $\tau = 0,5$ с per-example решение.

Настоящият преддипломен проект изгражда фундамента — формалната рамка, разбирането на данните, базовото ниво на производителност за двете нива на йерархията и първоначалния анализ на интерпретируемостта — върху който ще бъде

изградена пълната йерархична класификационна система в дипломната работа. Интерпретируемостта остава активна нишка: анализът на приноса на думите ще се прилага и в дипломната работа за диагностика на по-сложните архитектурни компоненти (осредняване по обхвата на обекта, семантично сходство като класификационна глава), за да се провери дали те действително насочват модела към по-релевантни части на текста.

Използвана литература

- [1] Jakub Piskorski, Tarek Mahmoud, Nikolaos Nikolaidis, Ricardo Campos, Alípio Mário Jorge, Dimitar Dimitrov, Purificação Silvano, Roman Yangarber, Shivam Sharma, Tanmoy Chakraborty, Nuno Guimaraes, Elisa Sartori, Nicolas Stefanovitch, Zhuohan Xie, Preslav Nakov и Giovanni Da San Martino. ?SemEval 2025 Task 10: Multilingual Characterization and Extraction of Narratives from Online News? B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, с. 2610—2643. URL: <https://aclanthology.org/2025.semeval-1.331/>.
- [2] Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco Guzmán, Edouard Grave, Myle Ott, Luke Zettlemoyer и Veselin Stoyanov. ?Unsupervised Cross-lingual Representation Learning at Scale? B: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*. Association for Computational Linguistics, 2020, с. 8440—8451.
- [3] Jacob Devlin, Ming-Wei Chang, Kenton Lee и Kristina Toutanova. ?BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding? B: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Minneapolis, Minnesota: Association for Computational Linguistics, 2019, с. 4171—4186.
- [4] Dimitar Dimitrov, Firoj Alam, Maram Hasanain, Abul Hasnat, Fabrizio Silvestri, Preslav Nakov и Giovanni Da San Martino. ?SemEval-2024 Task 4: Multilingual Detection of Persuasion Techniques in Memes? B: *Proceedings of the 18th International Workshop on Semantic Evaluation (SemEval-2024)*. Mexico City, Mexico: Association for Computational Linguistics, 2024.
- [5] Tarek Mahmoud, Zhuohan Xie и Preslav Nakov. ?BERTastic at SemEval-2025 Task 10: State-of-the-Art Accuracy in Coarse-Grained Entity Framing for Hindi News? B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, с. 386—396. URL: <https://aclanthology.org/2025.semeval-1.55/>.

- [6] Tengxiao Lv, Juntao Li, Chao Liu, Yiyang Kang, Ling Luo, Yuanyuan Sun и Hongfei Lin. ?DUTIR at SemEval-2025 Task 10: A Large Language Model-based Approach for Entity Framing in Online News? B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, c. 174–179. URL: <https://aclanthology.org/2025.semeval-1.25/>.
- [7] Egil Rønningstad и Gaurav Negi. ?LTG at SemEval-2025 Task 10: Optimizing Context for Classification of Narrative Roles? B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025. URL: <https://aclanthology.org/2025.semeval-1.61/>.
- [8] Adith Rajeev и Radhika Mamidi. ?adithrajeev at SemEval-2025 Task 10: Sequential Learning for Role Classification Using Entity-Centric News Summaries? B: *Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025)*. Vienna, Austria: Association for Computational Linguistics, 2025, c. 241–246. URL: <https://aclanthology.org/2025.semeval-1.36/>.
- [9] Emanuel Ben-Baruch, Tal Ridnik, Nadav Zamir, Asaf Noy, Itamar Friedman, Matan Protter и Lihi Zelnik-Manor. ?Asymmetric Loss For Multi-Label Classification? B: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, c. 82–91.
- [10] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He и Piotr Dollár. ?Focal Loss for Dense Object Detection? B: *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*. 2017, c. 2980–2988.
- [11] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser и Illia Polosukhin. ?Attention Is All You Need? B: *Advances in Neural Information Processing Systems 30 (NeurIPS)*. 2017.
- [12] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer и Veselin Stoyanov. ?RoBERTa: A Robustly Optimized BERT Pretraining Approach? B: *arXiv preprint arXiv:1907.11692* (2019).
- [13] Yin Cui, Menglin Jia, Tsung-Yi Lin, Yang Song и Serge Belongie. ?Class-Balanced Loss Based on Effective Number of Samples? B: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2019, c. 9268–9277.

- [14] Marco Tulio Ribeiro, Sameer Singh и Carlos Guestrin. "Why Should I Trust You?": Explaining the Predictions of Any Classifier? B: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, c. 1135—1144.
- [15] Scott M. Lundberg и Su-In Lee. "A Unified Approach to Interpreting Model Predictions? B: *Advances in Neural Information Processing Systems 30 (NeurIPS)*. 2017.
- [16] Karen Simonyan, Andrea Vedaldi и Andrew Zisserman. "Deep Inside Convolutional Networks: Visualising Image Classification Models and Saliency Maps? B: *International Conference on Learning Representations (ICLR), Workshop Track*. 2014.
- [17] Jiwei Li, Xinlei Chen, Eduard Hovy и Dan Jurafsky. "Visualizing and Understanding Neural Models in NLP? B: *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Association for Computational Linguistics, 2016, c. 681—691.
- [18] Mukund Sundararajan, Ankur Taly и Qiqi Yan. "Axiomatic Attribution for Deep Networks? B: *Proceedings of the 34th International Conference on Machine Learning (ICML)*. 2017, c. 3319—3328.
- [19] Sarthak Jain и Byron C. Wallace. "Attention is not Explanation? B: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. 2019, c. 3543—3556.
- [20] Samira Abnar и Willem Zuidema. "Quantifying Attention Flow in Transformers? B: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*. Association for Computational Linguistics, 2020, c. 4190—4197.